UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO
FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA
ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS

Diseño e implementación de una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao

PRESENTADO POR
• Br. Edmil Jampier Saire Bustamante

DOCENTE
Msc. Raúl Huillca Huallparimachi

LUGAR Y AÑO
Cusco – Perú, 2026

Contenido

01 Problema de investigación
02 Justificación
03 Alcances y limitaciones
04 Objetivos
05 Hipótesis
06 Estado del arte
07 Marco teórico
08 Metodología

1. Problema de investigación – Contexto y evidencia

Recursos para Quechua Collao

Orcotoma et al. (2025) describen la creación de un corpus bilingüe a partir de materiales digitalizados. Duran y Silberztein (2026) presentan un recurso léxico verbal.

Estos recursos apoyan la investigación lingüística, pero no constituyen por sí solos un generador contextualizado.

El contexto debe evaluarse

Court y Elsner (2024) muestran que el efecto del contexto varía según el tipo de información en una tarea de traducción de quechua sureño al español.

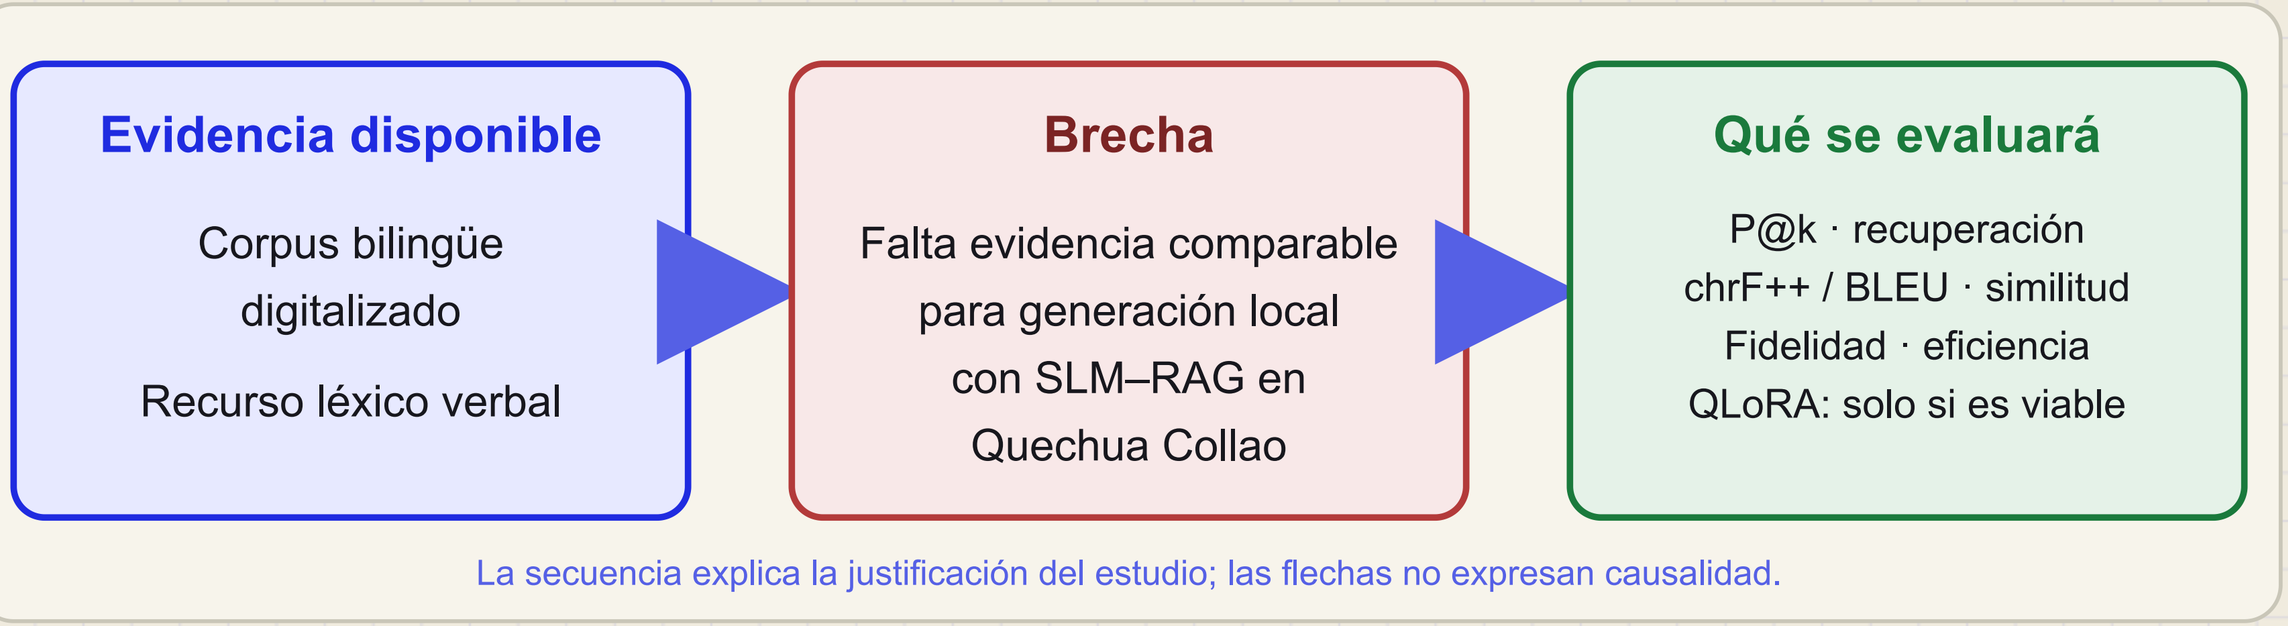
Ese resultado no anticipa el desempeño de generación en Quechua Collao.

Brecha por investigar

Falta evidencia experimental comparable sobre calidad de respuestas, fidelidad a fragmentos recuperados y eficiencia de SLM-RAG local para Quechua Collao.

QLoRA se evaluará si el ajuste y la inferencia con adaptador son viables.

1.2 Brecha de investigación



La secuencia explica la justificación del estudio; las flechas no expresan causalidad.

1.3 Formulación del problema

PROBLEMA GENERAL

¿Cómo se comporta una arquitectura SLM–RAG para la generación contextualizada en Quechua Collao dentro de un entorno computacional offline, y qué aporte adicional presenta QLoRA si el ajuste y la inferencia con adaptador son viables?

Problemas específicos

PE1 · Datos y recuperación. ¿Cómo estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación local?

PE2 · Núcleo técnico y adaptación. Si el ajuste y la inferencia con adaptador son viables, ¿qué diferencia produce QLoRA en la fidelidad al contexto de SLM–RAG bajo las mismas condiciones?

PE3 · Evaluación. ¿Qué diferencias de similitud, fidelidad contextual y eficiencia se observan entre SLM base, SLM–RAG y SLM–RAG–QLoRA, cuando esta última condición sea viable?

2. Justificación

Teórica

Los antecedentes cubren recursos para quechua, uso de contexto en traducción y sistemas offline en otros dominios.

Sus tareas y entornos difieren de la generación contextualizada en Quechua Collao. Hace falta evaluar esa combinación directamente.

Práctica

Se estudiará una arquitectura que pueda ejecutar inferencia sin conexión y consultar documentos trazables en Quechua Collao.

La utilidad, la calidad de las respuestas y su uso educativo son aspectos por evaluar; no se presuponen resultados ni efectos en estudiantes.

Metodológica

Se compararán el modelo base, SLM-RAG y SLM-RAG-QLoRA si esta última configuración es viable.

Se medirán recuperación, similitud de respuesta, fidelidad al contexto y eficiencia. Los ODS 9 y 10 son motivacionales; no se medirán impactos sociales.

3. Alcances y limitaciones

Alcances

DIMENSIÓN	DELIMITACIÓN
Lingüística	Fuentes y consultas identificadas como Quechua Collao o español; no se generalizarán resultados a otras variedades.
Tecnológica	SLM candidato, recuperación documental local e inferencia offline; QLoRA sujeto a viabilidad.
Evaluación	P@k, similitud con referencias, sustento contextual y recursos de cómputo.

Limitaciones previstas

- GPU disponible con 4 GB de VRAM; ajuste e inferencia con adaptador requieren pruebas.
- Cobertura, licencia y calidad OCR de las fuentes por inventariar.
- Las métricas de similitud no prueban por sí solas corrección semántica ni fluidez.
- El estudio no medirá aprendizaje ni impacto social.

4. Objetivos de la investigación

OBJETIVO GENERAL

Diseñar e implementar una arquitectura SLM–RAG para generar respuestas contextualizadas en Quechua Collao sin conexión y evaluar el aporte de QLoRA si el ajuste y la inferencia con adaptador son viables.



5. Hipótesis de investigación

HIPÓTESIS GENERAL

Si QLoRA resulta viable, SLM–RAG–QLoRA obtendrá mayor fidelidad al contexto y similitud con las respuestas de referencia que SLM–RAG. También se describirán sus diferencias frente al SLM base y su costo computacional.

HE1 · Recuperación

Con las consultas y etiquetas definidas, el índice semántico recuperará una mayor proporción de fragmentos pertinentes que la búsqueda léxica de referencia.

HE2 · QLoRA

Si el ajuste y la inferencia con el adaptador son viables, E3 tendrá mayor fidelidad al contexto que E2, manteniendo constantes modelo, fuentes, consultas y parámetros.

HE3 · Comparación

Si se ejecutan las tres condiciones, E3 tendrá mayor similitud con las referencias y mayor fidelidad al contexto que E1 y E2, según las métricas preestablecidas.

6. Estado del arte — Antecedentes relevantes

APORTES Y LÍMITES PARA ESTA PROPUESTA

ANTECEDENTE	APORTE Y LÍMITE
Orcotoma et al. (2025) y Duran y Silberztein (2026): recursos para quechua.	Corpus bilingüe y recurso léxico; no evalúan por sí mismos generación con RAG.
Court y Elsner (2024): contexto en traducción de quechua sureño.	El efecto depende del tipo de contexto; la tarea no es generación en Collao.
Hevia et al. (2025): tutoría offline con SLM y RAG.	Identifica riesgos ante fragmentos extensos o irrelevantes; evalúa biología en inglés.
Xu et al. (2024): modelos en dispositivos con recursos limitados.	Revisión de técnicas; no mide el hardware de este proyecto.
Dettmers et al. (2023): método QLoRA.	Describe ajuste eficiente en su entorno experimental; no prueba viabilidad en la GPU disponible aquí.

Estos antecedentes orientan el diseño y sus riesgos; sus resultados no se trasladan automáticamente a la tarea propuesta.

6.1 Decisiones de diseño sustentadas

CADA DECISIÓN SE SOMETERÁ A VERIFICACIÓN

① Condición offline

DELIMITACIÓN

La inferencia local sin conexión forma parte del alcance. La tesis no concluye que todos los servicios comerciales fallen en quechua.

② SLM base

REFERENCIA

Qwen2.5-3B-Instruct es el candidato inicial. Se comprobarán licencia, compatibilidad y consumo antes de fijar la configuración.

③ RAG local

A EVALUAR

El sistema recuperará documentos con procedencia y variedad identificadas. Se medirá la pertinencia; no se da por supuesta.

④ QLoRA condicionado

SUJETO A PRUEBA

Se intentará si son viables el ajuste y la inferencia con adaptador. Si no, se documentará el motivo y E3 no se reportará como evaluada.

⑤ Parámetros y métricas

A FIJAR EN PILOTO

Fragmentos de 250–400 tokens y recuperación de tres fragmentos son valores iniciales para el piloto. Se compararán P@k, similitud con referencias, fidelidad y eficiencia.

6.2 Brecha de investigación provisional

LA REVISIÓN ES PRELIMINAR; LA NOVEDAD DEBE VERIFICARSE

LÍNEA ESTUDIADA	ALCANCE OBSERVADO EN LOS ANTECEDENTES REVISADOS
Recursos lingüísticos para quechua	Corpus y recursos léxicos disponibles; no evalúan esta arquitectura generativa.
Contexto en tareas de quechua	Estudios de traducción; el efecto del contexto no es uniforme.
Tutoría offline con recuperación	Antecedente en otro dominio e idioma; limita la transferencia directa.
Inferencia local y eficiencia	Revisiones técnicas orientan opciones, pero no miden el equipo de esta tesis.
Adaptación QLoRA	El trabajo original no demuestra que ajuste e inferencia adaptada quepan en la GPU local de 4 GB.

Brecha por contrastar: la revisión preliminar no localizó evidencia comparable para SLM–RAG y QLoRA en generación contextualizada en Quechua Collao bajo operación offline. Esto no constituye todavía una afirmación definitiva de novedad.

7. Marco teórico — Conceptos de trabajo

1. Fuentes lingüísticas

Cada documento conservará procedencia, licencia, idioma y variedad. El material obtenido con OCR se revisará antes de indexarlo.

2. Modelo compacto local

Qwen2.5-3B-Instruct es el modelo candidato. Formato, cuantización y motor se fijarán tras comprobar compatibilidad y recursos.

3. Recuperación aumentada

RAG busca fragmentos en una base documental local y los aporta al contexto. La pertinencia se comparará con una búsqueda léxica.

4. Adaptación QLoRA

Ajuste de adaptadores sobre un modelo cuantizado. Se validarán entrenamiento, exportación y carga en inferencia.

5. Evaluación: recuperación, similitud con referencias, fidelidad a la evidencia y eficiencia. La similitud no equivale por sí sola a corrección semántica o fluidez.

7.1 Síntesis – Función de cada componente

COMPONENTE	CONDICIÓN	PAPEL EN EL ESTUDIO
SLM base	E1	Referencia local sin recuperación documental ni adaptador.
RAG local	E2; mismos documentos en E3	Aporta fragmentos al contexto; pertinencia y uso se medirán.
Adaptador QLoRA	E3, solo si es viable	Permite comparar E3 con E2 para estimar el aporte adicional de la adaptación.
Evaluación	Protocolo común	Mide P@k, similitud con referencias, sustento contextual y costo computacional.

E1 vs. E2 describe el cambio al añadir recuperación. **E2 vs. E3** compara la adaptación si el ajuste y la inferencia con adaptador son viables. **E1 vs. E3** refleja el efecto conjunto de los componentes.

8. Metodología – Enfoque, diseño y variables

TIPO
Aplicada y tecnológica

ENFOQUE
Cuantitativo

DISEÑO
Comparativo computacional
Medidas repetidas por consulta

Variable independiente – configuración del sistema

E1 · SLM base
Modelo local sin RAG ni adaptador.

E2 · SLM-RAG
El mismo modelo con recuperación documental local.

E3 · SLM-RAG-QLoRA
Misma configuración con adaptador, solo si entrenamiento e inferencia son viables.

VARIABLE DEPENDIENTE	INDICADORES	INSTRUMENTO / INTERPRETACIÓN
Recuperación	P@k con etiquetas de pertinencia	Comparar índice semántico y búsqueda léxica al mismo k.
Respuesta	chrF++ y BLEU	SacreBLEU frente a referencias; similitud, no medida completa de calidad lingüística.
Fidelidad	Afirmaciones respaldadas por fragmentos entregados	Revisión con rúbrica; evaluador automático exploratorio hasta validarlo para la variedad.
Eficiencia	Latencia, tokens/s, máximos de RAM/VRAM, errores	Telemetría y registros bajo un protocolo y equipo comunes.

Se controlarán modelo y tokenizador, documentos, consultas, índice, instrucciones, parámetros de generación, hardware y protocolo.

8.1 Procedimiento – DSR, muestra y gestión de datos

Investigación basada en diseño (DSR): diseñar, construir y evaluar el artefacto en tres fases.

Fase 1 · Datos

Inventariar fuentes.
Preparar corpus e índices.
Revisar OCR y P@k.

Fase 2 · Sistema

Integrar SLM–RAG offline.
Fijar versiones.
QLoRA si ajuste e inferencia adaptada son viables.

Fase 3 · Evaluación

Ejecutar condiciones viables.
Registrar respuestas y pasajes.
Medir y revisar errores.

Población, unidad y muestra

Población: consultas respondibles con fuentes autorizadas en español o Quechua Collao. **Unidad:** respuesta por consulta y condición. **Meta:** 100 consultas intencionales, sujeta al inventario y al piloto.

Datos y ética

Registrar licencia, idioma y variedad; contrastar texto sintético. Consultas fuera de QLoRA; mismas fuentes en E2/E3. Sin datos personales; consentimiento si hay revisores.

8.2 Métricas – Qué mide cada indicador

Recuperación

P@k con etiquetas de pertinencia. Comparar búsqueda semántica y léxica con el mismo k.

Similitud de respuesta

chrF++ y BLEU con referencias documentadas. No prueban por sí solos comprensión, corrección ni fluidez.

Fidelidad contextual

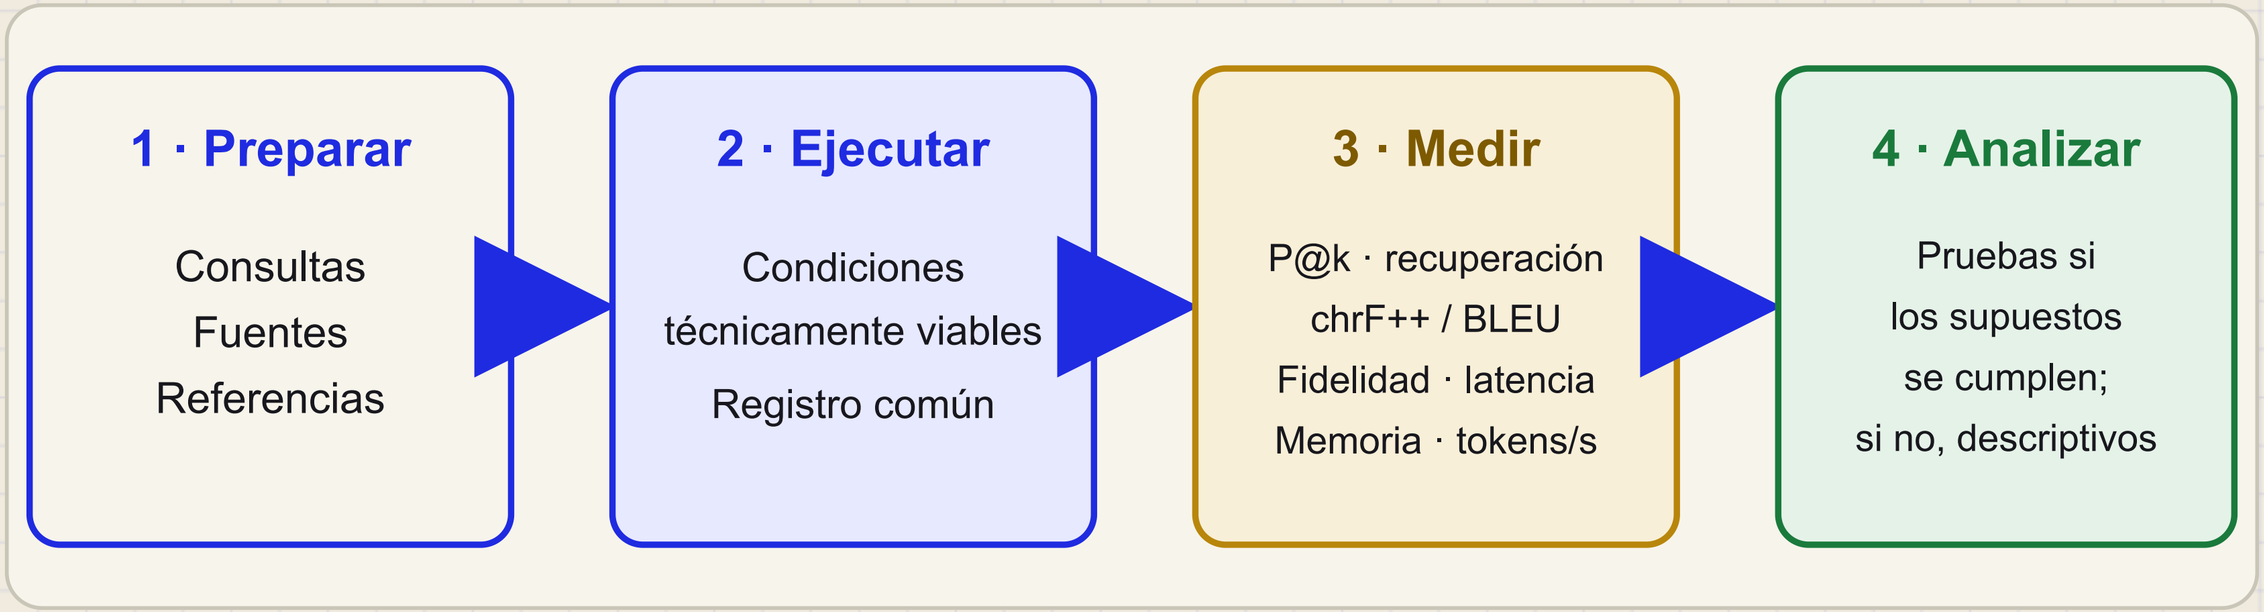
Afirmaciones respaldadas por fragmentos; revisión con rúbrica. RAGAS solo tras validar juez, idioma y variedad.

Eficiencia

Latencia, tokens/s, RAM/VRAM y errores bajo el mismo equipo y protocolo.

Una persona competente en Quechua Collao revisará las referencias; si no es posible, se reportará que las métricas comparan referencias no validadas.

8.3 Evaluación – Protocolo y análisis



Muestra

Meta de 100 consultas, sujeta al inventario y al piloto. Se mantienen consultas y documentos de evidencia comunes entre condiciones.

Análisis

Friedman y Wilcoxon con ajuste Holm, si los datos y supuestos lo permiten; si no, análisis descriptivo.

Cierre de la propuesta

Qué propone: evaluar una arquitectura SLM–RAG local para generar respuestas contextualizadas en Quechua Collao.

Cómo se evaluará: comparar recuperación, similitud con referencias, fidelidad al contexto y eficiencia; QLoRA se incluye solo si el ajuste y la inferencia con adaptador son viables.

Estado: el plan llega hasta Metodología. Los resultados aún requieren inventario, piloto, revisión lingüística y ejecución experimental.

Gracias · Preguntas