GUÍA DE ESTUDIO Y EXPOSICIÓN

Sustentación del plan de tesis sobre SLM-RAG y Quechua Collao

Guion explicado para las 19 diapositivas, conceptos clave y preguntas de comisión

PROPÓSITO	Preparar una exposición clara, coherente y fiel al estado actual del plan.
LÍMITE	Se presenta una propuesta hasta Metodología. Todavía no se reportan resultados experimentales.
PRESENTACIÓN	Usa el HTML para navegar; el PDF es una copia estática de las mismas láminas.

El objetivo no es memorizar párrafos. Es poder explicar la pregunta, el aporte esperado, el método y los límites con tus propias palabras.

1. La historia completa en menos de un minuto

Esta tesis estudia cómo generar respuestas contextualizadas en Quechua Collao con un modelo de lenguaje compacto que pueda operar localmente y consultar documentos trazables. Ya existen corpus bilingües y recursos léxicos, pero esos recursos no demuestran por sí solos el desempeño de una arquitectura de generación con recuperación. Se propone comparar un modelo base, el mismo modelo con RAG local y una versión con QLoRA solo si el ajuste y la inferencia adaptada son viables. La evaluación medirá recuperación, similitud con referencias, fidelidad al contexto y eficiencia computacional. Es un plan de investigación: sus hipótesis están por contrastar y todavía no hay resultados.

La cadena lógica que debes recordar

Recursos y antecedentes existentes -> brecha de evidencia -> problema y objetivos -> hipótesis -> componentes técnicos -> comparación controlada -> mediciones y análisis.

Cuatro límites que protegen la exposición

- QLoRA es condicional. Si no se puede ajustar y ejecutar el adaptador, E3 no se presenta como evaluada.

- La brecha y la novedad son provisionales hasta completar una revisión bibliográfica actualizada.

- Las métricas automáticas de similitud no demuestran por sí solas corrección, comprensión ni fluidez.

- El estudio no mide aprendizaje en estudiantes ni impacto social; evalúa un artefacto de software.

2. Guion para cada diapositiva

Usa el guion como base. Mira al público, señala el elemento visual relevante y adapta las frases al tiempo asignado por el docente.

Lámina 01. Apertura y título

Idea central: Presentar el tema como una propuesta de investigación, no como un sistema ya terminado.

Explicación sugerida: Saluda, indica tu nombre y presenta el título. Resume la idea en una frase: se estudiará una arquitectura local que combina un modelo de lenguaje compacto con recuperación de documentos para generar respuestas contextualizadas en Quechua Collao. Aclara desde el inicio que QLoRA es una condición que se probará si el hardware permite ajustar y ejecutar el adaptador.

Enlace con la siguiente: Transición: Para explicar por qué se propone este estudio, primero presentaré su recorrido.

Cuida: Evita explicar toda la arquitectura en la portada o decir que el sistema ya funciona.

Lámina 02. Ruta de la exposición

Idea central: Dar al público un mapa: problema, justificación, alcance, objetivos, hipótesis, antecedentes, conceptos y metodología.

Explicación sugerida: Explica que la secuencia va desde la necesidad de investigación hasta la forma de evaluarla. La presentación llega a Metodología. El cierre resume la propuesta y sus próximos pasos, no resultados.

Enlace con la siguiente: Transición: Empiezo por los recursos existentes y por lo que todavía no demuestran.

Cuida: El plan de factibilidad queda como esquema posterior; no desarrolles resultados, presupuesto ni cronograma como si fueran parte concluida.

Lámina 03. Contexto y evidencia

Idea central: Distinguir los recursos existentes para quechua de la arquitectura que la tesis propone evaluar.

Explicación sugerida: Orcotoma y colaboradores describen un corpus bilingüe digitalizado; Duran y Silberztein presentan un recurso léxico verbal. Son recursos útiles para investigación lingüística. Por separado, Court y Elsner estudian contexto en traducción de quechua sureño al español. Ninguno de esos antecedentes demuestra cómo responderá un SLM-RAG en Quechua Collao.

Enlace con la siguiente: Transición: Esa diferencia entre lo estudiado y lo que falta medir se resume en la brecha.

Cuida: No digas que no existen recursos para quechua ni que los sistemas comerciales fallan. El problema es la falta de evidencia comparable para esta combinación y tarea.

Lámina 04. Árbol del problema y brecha

Idea central: Leer el gráfico como una secuencia argumental, no como un diagrama causal.

Explicación sugerida: Señala de izquierda a derecha: hay corpus y recursos léxicos; la revisión preliminar no localizó una comparación equivalente de generación local con SLM-RAG en Quechua Collao; por eso la propuesta medirá recuperación, similitud, fidelidad y eficiencia. QLoRA depende de que el ajuste y la inferencia adaptada sean viables.

Enlace con la siguiente: Transición: Con esa brecha delimitada, formulo la pregunta que guiará el estudio.

Cuida: Las flechas organizan el argumento. No prueban que una condición cause otra ni que un factor ya haya producido un resultado.

Lámina 05. Problema general y problemas específicos

Idea central: Mostrar que la pregunta general se descompone en datos, adaptación y evaluación.

Explicación sugerida: El problema general pregunta cómo se comporta SLM-RAG offline y qué aporte adicional tendría QLoRA, si puede ejecutarse. PE1 aborda cómo preparar e indexar documentos. PE2 compara E2 con E3 para estudiar el aporte de QLoRA. PE3 compara las configuraciones en similitud, fidelidad y eficiencia.

Enlace con la siguiente: Transición: La importancia del problema se entiende desde tres razones complementarias.

Cuida: Al responder preguntas, no mezcles el efecto de RAG con el efecto de QLoRA: E2 frente a E3 es la comparación directa de adaptación.

Lámina 06. Justificación

Idea central: Explicar la pertinencia teórica, práctica y metodológica sin prometer impacto educativo.

Explicación sugerida: En lo teórico, los antecedentes cubren piezas distintas y no resuelven esta tarea. En lo práctico, interesa estudiar inferencia local y documentos trazables. En lo metodológico, se propone una comparación con mediciones separadas. Los ODS 9 y 10 sirven como motivación; esta investigación no medirá reducción de desigualdad ni mejora del aprendizaje.

Enlace con la siguiente: Transición: Para que la pregunta sea evaluable, ahora preciso qué incluye y qué queda fuera.

Cuida: No presentes el uso educativo como efecto probado ni afirmes que la tesis medirá resultados en estudiantes.

Lámina 07. Alcances y limitaciones

Idea central: Delimitar variedad, tecnología, métricas y límites del equipo.

Explicación sugerida: El estudio se centra en fuentes identificadas como Quechua Collao o español, generación textual y ejecución local. No generalizará a otras variedades. Entre las limitaciones previstas están la GPU de 4 GB, la cobertura y licencia de las fuentes, la calidad del OCR y que las métricas automáticas no prueban por sí solas corrección o fluidez. Tampoco se medirán aprendizaje ni impacto social.

Enlace con la siguiente: Transición: Dentro de esos límites, los objetivos ordenan el trabajo.

Cuida: QLoRA y el tamaño de muestra aún requieren pruebas y piloto. No los presentes como decisiones ya validadas.

Lámina 08. Objetivos y árbol de objetivos

Idea central: Vincular un objetivo general con tres pasos que se pueden evaluar.

Explicación sugerida: El objetivo general es diseñar e implementar SLM-RAG offline y estudiar el aporte de QLoRA si es viable. El árbol ordena los objetivos específicos: OE1 prepara fuentes e índices y mide recuperación; OE2 integra el sistema y prueba el adaptador; OE3 compara las condiciones ejecutables. Cada paso produce insumos para el siguiente.

Enlace con la siguiente: Transición: Los objetivos conducen a hipótesis que se contrastarán con datos.

Cuida: El gráfico muestra una secuencia de trabajo. No significa que los resultados de cada fase estén garantizados.

Lámina 09. Hipótesis

Idea central: Presentar expectativas comprobables como hipótesis, nunca como hallazgos.

Explicación sugerida: HE1 espera que la búsqueda semántica recupere más fragmentos pertinentes que la búsqueda léxica, según P@k. HE2 espera mayor fidelidad en E3 que en E2 si QLoRA es viable. HE3 plantea una comparación más amplia entre E1, E2 y E3. La hipótesis general también compara fidelidad y similitud de E3 con E2.

Enlace con la siguiente: Transición: Estas preguntas se apoyan en antecedentes que aportan métodos y también límites.

Cuida: Si una condición no se ejecuta, su hipótesis queda no evaluada; no se reemplaza con una estimación.

Lámina 10. Estado del arte

Idea central: Resumir qué aporta cada antecedente y por qué no basta para responder la pregunta de esta tesis.

Explicación sugerida: Los trabajos de Orcotoma y de Duran y Silberztein aportan recursos lingüísticos. Court y Elsner estudian traducción y el efecto variable del contexto. Hevia y colaboradores trabajan tutoría offline en biología en inglés. Xu revisa técnicas para dispositivos. Dettmers y colaboradores presentan QLoRA en otro entorno de hardware. Cada trabajo orienta una decisión, pero difiere en tarea, idioma o equipo.

Enlace con la siguiente: Transición: Por esas diferencias, las decisiones técnicas se plantean para verificación.

Cuida: No atribuyas a esos autores resultados sobre generación en Quechua Collao si sus estudios no evaluaron esa tarea.

Lámina 11. Decisiones de diseño

Idea central: Separar lo fijado como alcance de lo que se decidirá después del piloto.

Explicación sugerida: La operación offline forma parte del alcance. Qwen2.5-3B-Instruct es un candidato, pendiente de verificar licencia y consumo. El índice local se medirá, no se supone pertinente. QLoRA solo se integra si ajuste, exportación y carga funcionan. Los fragmentos de 250 a 400 tokens y tres pasajes recuperados son puntos de partida para el piloto, no parámetros definitivos.

Enlace con la siguiente: Transición: Por la misma razón, la brecha de investigación se mantiene provisional.

Cuida: No afirmes que el hardware ya ejecuta QLoRA ni que el tamaño de fragmento ya fue optimizado.

Lámina 12. Brecha provisional

Idea central: Explicar por qué la afirmación de novedad necesita una búsqueda más completa.

Explicación sugerida: La revisión preliminar cubre recursos lingüísticos, contexto en traducción, tutoría offline, eficiencia y QLoRA. No localizó evidencia comparable para la combinación propuesta. Eso delimita una brecha por verificar, pero no prueba que nadie haya investigado el tema. La revisión bibliográfica debe ampliarse y actualizarse antes de afirmar novedad definitiva.

Enlace con la siguiente: Transición: El marco teórico define los componentes que se combinarán y medirán.

Cuida: Si te preguntan si es la primera tesis o sistema, responde que todavía no se puede sostener esa afirmación.

Lámina 13. Conceptos teóricos

Idea central: Explicar el flujo funcional de los componentes y el papel de la calidad de datos.

Explicación sugerida: Las fuentes aportan el contenido documental y deben conservar licencia, idioma, variedad y procedencia. El SLM candidato genera texto. RAG busca pasajes locales y los incorpora al contexto de la consulta. QLoRA puede adaptar el modelo mediante un adaptador, si es técnicamente viable. La evaluación mide aspectos distintos porque recuperar un buen pasaje no garantiza una buena respuesta.

Enlace con la siguiente: Transición: La siguiente lámina compara las configuraciones para aislar esos efectos.

Cuida: RAG consulta documentos en cada solicitud; QLoRA modifica parámetros mediante ajuste. Son componentes diferentes y pueden evaluarse por separado.

Lámina 14. Configuraciones E1, E2 y E3

Idea central: Explicar qué comparación permite responder cada pregunta.

Explicación sugerida: E1 es el modelo base local. E2 añade recuperación documental. E3 añade QLoRA a E2, solo si se puede ejecutar. E1 frente a E2 describe el cambio asociado a RAG. E2 frente a E3 estima el aporte adicional de la adaptación. E1 frente a E3 refleja el efecto conjunto y no permite atribuir todo el cambio a QLoRA.

Enlace con la siguiente: Transición: Con las condiciones definidas, describo el diseño metodológico.

Cuida: Esta distinción es central: para hablar del aporte de QLoRA, compara E2 con E3 bajo las mismas condiciones.

Lámina 15. Enfoque, diseño y variables

Idea central: Defender el enfoque cuantitativo y las medidas repetidas por consulta.

Explicación sugerida: Es un estudio aplicado y tecnológico con experimento computacional comparativo. La variable independiente es la configuración del sistema. Las variables dependientes son recuperación, similitud, fidelidad y eficiencia. Las mismas consultas se ejecutan en las condiciones viables, manteniendo constantes documentos, modelo y parámetros que correspondan. Así cada consulta permite una comparación emparejada.

Enlace con la siguiente: Transición: El procedimiento de construcción y evaluación se organiza en tres fases DSR.

Cuida: Medidas repetidas significa que una misma consulta se compara entre condiciones; no significa que se repitan las personas.

Lámina 16. Procedimiento, muestra y gestión de datos

Idea central: Recorrer las fases, precisar qué significa 100 consultas y explicar resguardos.

Explicación sugerida: DSR organiza el trabajo en diseñar, construir y evaluar el artefacto. La fase 1 inventaría fuentes y prepara corpus e índices; la fase 2 integra SLM-RAG y verifica QLoRA; la fase 3 ejecuta y analiza. La meta de 100 consultas es intencional y provisional, sujeta al inventario y al piloto, no proviene todavía de un cálculo de potencia. Se registrarán licencias, variedad y procedencia, se separarán las consultas de evaluación del ajuste y no se incluirán datos personales.

Enlace con la siguiente: Transición: Para comparar las salidas se necesitan indicadores con significados distintos.

Cuida: No presentes 100 como tamaño estadísticamente justificado. Si hay revisores humanos, se requerirán las autorizaciones y consentimientos aplicables.

Lámina 17. Métricas

Idea central: Definir brevemente cada indicador y explicar qué no permite concluir.

Explicación sugerida: P@k mide qué proporción de los primeros k fragmentos es pertinente. BLEU y chrF++ miden similitud con respuestas de referencia. La fidelidad revisa si las afirmaciones están respaldadas por pasajes entregados. Latencia, tokens por segundo, RAM, VRAM y errores describen eficiencia. Las métricas automáticas no sustituyen la revisión lingüística; RAGAS será complementaria solo después de validar el evaluador para el idioma y la variedad.

Enlace con la siguiente: Transición: El protocolo fija cómo se recogerán y analizarán esos indicadores.

Cuida: Una puntuación alta de similitud no demuestra por sí sola que la respuesta sea correcta, fluida o fiel.

Lámina 18. Protocolo y análisis

Idea central: Explicar la comparación controlada y cuándo se usarán pruebas estadísticas.

Explicación sugerida: Se preparan consultas, fuentes y referencias; se ejecutan las configuraciones técnicamente viables bajo un registro común; se miden las cuatro dimensiones y se analizan. La meta sigue siendo 100 consultas tras inventario y piloto. Friedman sirve para tres condiciones relacionadas y Wilcoxon para pares, con ajuste Holm, si los datos y supuestos lo permiten. Si no, se presenta un análisis descriptivo y se explican las limitaciones.

Enlace con la siguiente: Transición: Con esto cierro resumiendo la propuesta y el trabajo pendiente.

Cuida: No prometas que las pruebas estadísticas se aplicarán a toda costa ni anuncies resultados que todavía no existen.

Lámina 19. Cierre y preguntas

Idea central: Cerrar con propuesta, método y estado real del plan.

Explicación sugerida: En síntesis, se propone evaluar una arquitectura local SLM-RAG para generación contextualizada en Quechua Collao. La comparación separa recuperación, similitud, fidelidad y eficiencia. QLoRA depende de la viabilidad técnica. El plan llega a metodología; faltan inventario, piloto, revisión lingüística y ejecución experimental. Agradece y abre el espacio de preguntas.

Enlace con la siguiente: Frase de cierre: La contribución esperada es evidencia reproducible sobre estas condiciones, no un resultado anticipado.

Cuida: Evita decir que el modelo ya mejoró respuestas, que QLoRA funcionó o que se demostró impacto educativo.

3. Cómo explicar los gráficos

Lámina 4, árbol del problema

Lee el gráfico de izquierda a derecha: evidencia disponible, brecha por investigar y dimensiones de evaluación. Explica que es una secuencia lógica del argumento. Las flechas no son relaciones de causa y efecto comprobadas.

Lámina 8, árbol de objetivos

Describe la progresión OE1, OE2 y OE3. Primero se preparan fuentes e índices; luego se integra el sistema y se prueba la viabilidad de QLoRA; finalmente se comparan las condiciones ejecutables.

Lámina 18, protocolo de evaluación

Sigue las cuatro etapas del diagrama: preparar consultas, fuentes y referencias; ejecutar configuraciones viables con el mismo registro; medir indicadores; analizar con pruebas estadísticas solo si los datos lo permiten.

Qué significa que el gráfico sea interactivo

El HTML permite avanzar y retroceder con botones, flechas del teclado, Page Up y Page Down. Los diagramas SVG del árbol y del protocolo son figuras estáticas. No los describas como gráficos de datos que reaccionan a filtros o clics.

4. Conceptos que debes poder definir

Término	Cómo explicarlo en voz alta
SLM	Modelo de lenguaje compacto que se considera para inferencia local. Ser pequeño no garantiza calidad suficiente para una tarea concreta.
RAG	Generación aumentada por recuperación. Busca pasajes en documentos externos y los aporta como contexto a la consulta del modelo.
QLoRA	Ajuste de adaptadores de bajo rango sobre un modelo base cuantizado. En el plan es una condición opcional, sujeta a prueba de hardware y compatibilidad.
Embedding	Vector que representa una consulta o un fragmento para ordenar documentos por similitud. La similitud vectorial no garantiza pertinencia semántica.
P@k	Proporción de los primeros k fragmentos recuperados que fueron etiquetados como pertinentes.
BLEU y chrF++	Métricas de similitud automática entre una respuesta y una referencia. No sustituyen la revisión de significado y fluidez.
Fidelidad contextual	Grado en que las afirmaciones de la respuesta se apoyan en los fragmentos entregados al modelo.
Inferencia offline	Generación que ocurre en el equipo local sin conexión a un servicio remoto durante la ejecución evaluada.
Medidas repetidas	La misma consulta se prueba en varias configuraciones y se comparan sus respuestas bajo condiciones controladas.
DSR	Investigación en ciencias del diseño: diseñar, construir y evaluar un artefacto para una necesidad delimitada.
VRAM y RAM	Memoria gráfica y memoria principal. Se registran junto con latencia, velocidad de generación y errores para describir el costo computacional.

5. Preguntas probables y respuestas defendibles

¿Cuál es el problema central?

Falta evidencia experimental comparable sobre la calidad, fidelidad al contexto y eficiencia de SLM-RAG local para generación en Quechua Collao. La revisión sigue siendo preliminar.

¿Qué aporta frente a los antecedentes?

Propone una comparación explícita para esta tarea, variedad y entorno local. La novedad todavía debe verificarse con una revisión bibliográfica más completa.

¿Por qué usar un modelo compacto?

El alcance considera ejecución local y restricciones de recursos. Qwen2.5-3B-Instruct es un candidato; se confirmarán licencia, compatibilidad y consumo.

¿Qué diferencia hay entre RAG y QLoRA?

RAG incorpora documentos relevantes a cada consulta. QLoRA adapta parámetros del modelo mediante un adaptador. La tesis separa ambos efectos en las comparaciones.

¿Cómo se aísla el aporte de QLoRA?

Se compara E2, SLM-RAG, contra E3, SLM-RAG-QLoRA, manteniendo modelo, fuentes, consultas y parámetros comunes. Si E3 no es viable, no se estima ese aporte.

¿Qué ocurre si QLoRA no puede ejecutarse?

Se registra el fallo y su motivo. E3 queda no evaluada; se pueden analizar E1 y E2 sin inventar resultados para E3.

¿Por qué se proponen 100 consultas?

Es una meta de planificación con selección intencional, sujeta al inventario de fuentes y al piloto. Todavía no procede de un cálculo de potencia estadística.

¿Cómo se valida la calidad en Quechua Collao?

Las referencias deben revisarse por una persona competente en la variedad. Si no se consigue, BLEU y chrF++ se reportan como similitud con referencias no validadas, no como prueba suficiente de calidad lingüística.

¿BLEU alto significa que la respuesta es correcta?

No. BLEU y chrF++ comparan texto con referencias. La corrección semántica, la fluidez y el respaldo documental necesitan revisión adicional.

¿Se probará que mejora el aprendizaje?

No. El diseño actual es un experimento computacional sobre un artefacto. No incluye una intervención ni mediciones con estudiantes.

¿Cómo se evita contaminar la evaluación?

Las consultas y respuestas de referencia de evaluación se reservan fuera del ajuste QLoRA. E2 y E3 usan los mismos documentos de evidencia y se registran coincidencias relevantes.

¿Qué análisis estadístico se aplicará?

Se prevén Friedman para tres condiciones relacionadas y Wilcoxon para comparaciones pareadas, con ajuste Holm, si los datos y supuestos lo permiten. Si no, el análisis será descriptivo.

¿Qué aporta la operación offline?

Permite evaluar generación local sin depender de una llamada remota durante la inferencia. No implica que se haya demostrado superioridad frente a todos los servicios en línea.

¿El estudio cubre todas las variedades quechuas?

No. Se limita a materiales identificados como Quechua Collao y no generaliza automáticamente a Chanka, otras variedades sureñas ni a todo el quechua.

¿Cuáles son los resultados?

Aún no hay resultados. La presentación expone un plan con hipótesis por contrastar después del inventario, piloto, validación lingüística y ejecución experimental.

6. Alineación que debes defender

Parte	Cómo encaja
Problema	No hay comparación experimental suficientemente delimitada para la combinación propuesta.
Objetivo	Diseñar e implementar SLM-RAG local y evaluar el aporte de QLoRA si es viable.
Hipótesis	Plantean diferencias esperadas en recuperación, fidelidad y similitud; todavía no se han probado.
Método	Experimento computacional repetido por consulta, con condiciones controladas y métricas separadas.
Límite	Si falla la viabilidad técnica o la validación de datos, se informa; no se disfraza como resultado.

7. Método breve para estudiar y ensayar

- Primera vuelta: cuenta la historia completa sin mirar las diapositivas. Debes poder decir problema, objetivo, solución propuesta, método y límites.

- Segunda vuelta: estudia las láminas 4, 8 y 18, que contienen los diagramas que conectan problema, objetivos y evaluación.

- Tercera vuelta: practica E1, E2 y E3, las cuatro dimensiones de evaluación y las condiciones de viabilidad de QLoRA.

- Ensayo individual: explica cada lámina con tus palabras y practica las preguntas de comisión. El docente asigna el orden al azar, así que prepara respuestas autónomas.

- Si no se sabe todavía algo, responde con precisión: 'Ese parámetro se fijará después del piloto' o 'esa hipótesis aún no se ha contrastado'.

- Usa la vista HTML para navegar con el teclado o botones. Lleva también el PDF como copia estática. Ajusta la duración al tiempo que asigne el docente.

Tarjeta para repasar justo antes de exponer

- Problema: falta evidencia comparable para esta arquitectura y tarea.

- Objetivo: diseñar e implementar SLM-RAG y evaluar QLoRA si es viable.

- Comparaciones: E1 vs. E2 mide el cambio al añadir RAG; E2 vs. E3 estudia QLoRA; E1 vs. E3 refleja el efecto conjunto.

- Métricas: recuperación, similitud, fidelidad y eficiencia responden preguntas distintas.

- Límite: es un plan hasta Metodología; resultados y novedad todavía requieren verificación.

Nota de fidelidad al proyecto: la brecha se presenta como provisional, los 100 casos como meta sujeta al piloto y QLoRA como opción condicionada. La guía no convierte hipótesis en resultados.