INTRODUCCIÓN DEL PLAN DE TESIS

Aplicación de los seis bloques

Plan de tesis: arquitectura SLM–RAG con QLoRA para Quechua Collao

Secuencia aplicada:
contexto → tecnología y método → vacío → problema → propuesta y justificación → organización

Tesista: Br. Edmil Jampier Saire Bustamante | **Cátedra:** Msc. Raúl Huillca Huallparimachi

UNSAAC – Facultad de Ingeniería Eléctrica, Electrónica, Informática y Mecánica | Cusco, 2026

Ruta del seminario aplicada al plan de tesis

01 Contexto
Campo, necesidad, dificultad y tema.
Fuente: 05–07

02 Tecnología y método
Métodos, fundamento, evidencia y límites.
Fuente: 08–10

03 Vacío
Síntesis, contraste, limitación y delimitación.
Fuente: 11–16

04 Problema específico
Objeto, condiciones, comparación y criterios.
Fuente: 17–21

05 Propuesta y valor
Objetivo, justificación y evaluación.
Fuente: 21–32

06 Organización
Estructura real del documento de tesis.
Fuente: 33–34

Cobertura de la fuente: 01–02 portada e índice; 03–04 arquitectura de seis bloques; 05–34 desarrollo y ejemplos; 35–36 síntesis y lista de control; 37 encabezado de referencias sin referencias legibles. Las 37 imágenes y su extracción permanecen en la carpeta del proyecto.

Seminario: diapositivas 03–04, 35–37

Bloque 1: del campo general al tema específico

A. Campo

El procesamiento del lenguaje natural permite analizar y generar textos mediante modelos computacionales.

B. Necesidad

La utilidad de estas herramientas depende también de corpus y recursos lingüísticos que representen la variedad estudiada.

C. Dificultad general

Los recursos disponibles y las condiciones de ejecución pueden limitar la generación contextualizada en lenguas con menos recursos digitales.

D. Delimitación

El plan se centra en generar respuestas contextualizadas en Quechua Collao dentro de un entorno offline.

Transición redactada: de la función del PLN y los recursos lingüísticos se pasa a la necesidad de evaluar generación contextualizada para Quechua Collao. Las afirmaciones sobre conectividad, cobertura digital o escasez deben apoyarse con fuentes del plan.

Bloque 2: tecnología, fundamento y evidencia

A–B. Métodos y función

- **SLM compacto:** produce la respuesta; el plan propone la familia Qwen2.5.
- **RAG local:** recupera fragmentos de la base documental para aportar contexto.
- **QLoRA:** adapta parámetros de manera eficiente; su aporte se debe medir.

Aplicación: integrar generación, recuperación local y adaptación para el dominio Quechua Collao.

C–D. Evidencia y límites

- Orcotoma et al. (2025) y Duran y Silberztein (2026) aportan recursos lingüísticos.
- Court y Elsner (2024) analizan contexto en traducción de quechua sureño al español.
- Hevia et al. (2025) evalúan RAG offline en otro dominio y reportan dificultades con contexto irrelevante o extenso.

Esas tareas y condiciones no demuestran el comportamiento del sistema propuesto para Quechua Collao.

Arquitectura a evaluar: SLM compacto + recuperación local (RAG) + adaptación (QLoRA)

Seminario: diapositivas 08–10

Bloque 3: construcción del vacío con evidencia

Antecedente revisado	Qué aporta	Qué deja abierto para este plan
Corpus y recursos para Quechua Collao	Mejoran la disponibilidad de datos y recursos léxicos.	No evalúan por sí solos generación contextualizada mediante SLM–RAG–QLoRA.
Recuperación contextual en traducción	Examina el uso del contexto en una tarea de traducción de quechua sureño.	No equivale a generación de respuestas en Quechua Collao bajo inferencia offline.
RAG offline con modelos pequeños	Muestra retos de contexto en una aplicación de otro dominio.	Sus resultados no se trasladan automáticamente a datos ni tareas de esta tesis.

Vacío provisional: falta determinar, con una revisión bibliográfica actualizada, cómo se comporta la combinación de modelo compacto, recuperación local y QLoRA al generar respuestas contextualizadas en Quechua Collao bajo restricciones offline. La novedad no se presenta como una afirmación universal.

Seminario: diapositivas 11–16

Bloque 4: delimitación del problema específico

Objeto
Arquitectura SLM–RAG con QLoRA

Contexto
Quechua Collao e inferencia offline

Comparadores
SLM base y RAG estándar

Criterios
Fidelidad, anclaje y costo

Pregunta de trabajo propuesta

¿De qué manera el diseño e implementación de una arquitectura SLM–RAG con QLoRA influye en la generación contextualizada en Quechua Collao frente al SLM base y al RAG estándar, bajo inferencia offline, considerando la fidelidad lingüística, el anclaje factual y el costo computacional?

La pregunta completa debe aparecer una sola vez en *Formulación del problema*. En la introducción se anticipa el problema sin duplicarla.

Seminario: diapositivas 17–21

Bloque 5: propuesta, objetivo y justificación

Propuesta aplicada

Diseñar e implementar una arquitectura compacta que combine SLM, recuperación documental local y adaptación QLoRA; evaluar su comportamiento frente al modelo base y al RAG estándar.

Objetivo general del plan, conservado

Diseñar e implementar una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao dentro de un entorno computacional offline.

Ciencia

Evidencia sobre recuperación y adaptación para Quechua Collao.

Método

Comparación reproducible entre configuraciones bajo condiciones definidas.

Tecnología

Capacidades y límites de ejecución local en el entorno planteado.

En la introducción se anticipan comparación y criterios; parámetros y procedimientos quedan en el capítulo metodológico.

Bloque 6: organización real de la tesis

I. Introducción
Problema, objetivos, justificación y alcance.

II. Marco teórico
Fundamentos y estado del arte.

III. Metodología
Diseño de la arquitectura y evaluación.

IV. Implementación
Desarrollo computacional del sistema.

V. Resultados
Resultados y evaluación experimental.

VI. Cierre
Conclusiones y trabajos futuros.

La secuencia se tomó de `partes/06cierre.tex`. El seminario ilustra cinco capítulos; para esta aplicación se conserva la estructura de seis capítulos del plan.

Seminario: diapositivas 33–34

La introducción integrada: la cadena argumental aplicada

1. Contexto

El PLN procesa y genera texto; su aplicación depende de recursos que representen Quechua Collao.

2. Tecnología y evidencia

El plan combina un modelo compacto, RAG local y QLoRA; los antecedentes estudian contextos diferentes.

3. Vacío provisional

Se evaluará la combinación para generación en Collao y en entorno offline; la revisión bibliográfica debe confirmar el vacío.

4. Problema

Se comparan SLM base, RAG estándar y configuración integrada según fidelidad, anclaje y costo.

5. Propuesta y valor

Se diseñará e implementará la arquitectura para generar texto contextualizado en Quechua Collao offline.

6. Organización

La tesis sigue seis capítulos: introducción, teoría, metodología, implementación, resultados y conclusiones.

Panel de revisión antes de integrar el borrador

Aplicación realizada

- ✓ Se recorren los seis bloques del seminario y se aplican al tema del plan.
- ✓ Se asigna trazabilidad a las diapositivas fuente 01–37.
- ✓ Se usa la estructura real de seis capítulos del plan.
- ✓ Los ejemplos QFT/CKKS se mantienen como ejemplos de clase, no como tema de tesis.
- ✓ El plan original permanece intacto; el fragmento se entrega aparte para revisión.

Pendiente de validar en el plan

- △ Confirmar el vacío con una búsqueda bibliográfica actualizada.
- △ Corregir o retirar `Chen2024`: su URL y su título local no corresponden.
- △ Sustentar con fuente la cifra de fertilidad de tokens cercana a $3.4\times$, o quitarla.
- △ Revisar coherencia entre pregunta, objetivo general, objetivos específicos y métricas.

El borrador es una propuesta de redacción, no una afirmación de resultados ni una modificación automática del plan.

Fuentes citadas en la aplicación

Orcotoma Mormontoy et al. (2025). *Towards the Creation of a Collao Quechua–Spanish Parallel Corpus Using Optical Character Recognition*. ACL Anthology

Duran y Silberztein (2026). *Semi-Automatic Construction of a Quechua–Spanish Dictionary*. ACL Anthology

Court y Elsner (2024). *Shortcomings of LLMs for Low-Resource Translation: Retrieval and Understanding Are Both the Problem*. ACL Anthology

Hevia et al. (2025). *Towards an Efficient, Customizable, and Accessible AI Tutor*. arXiv:2510.06255

Yang et al. (2024). *Qwen2.5 Technical Report*. arXiv:2412.15115

Dettmers et al. (2023). *QLoRA: Efficient Finetuning of Quantized Language Models*. arXiv:2305.14314

Xu et al. (2024). *On-Device Language Models: A Comprehensive Review*. arXiv:2409.00088

La diapositiva 37 del seminario solo muestra el encabezado de referencias. Estas fuentes proceden del borrador de aplicación y requieren revisión bibliográfica antes de incorporarse al documento final.

Seminario: diapositivas 37 y referencias del borrador