UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO

FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA

ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

Evaluación del efecto de QLoRA

en la calidad de respuestas breves

de un modelo de lenguaje compacto en quechua sureño

Acción y método Resultado evaluado Objeto y contexto

Curso:

Seminario de Investigación II

Docente:

Msc. Raúl Huillca Huallparimachi

Asesor/a de tesis:

Por designar

Para optar al Título Profesional de:

Ingeniero Informático y de Sistemas

Presentado por:

Br. Edmil Jampier Saire Bustamante

Cusco – Perú

2026

RESUMEN

La investigación evaluará el efecto de adaptar mediante QLoRA un modelo de lenguaje compacto para generar respuestas breves a preguntas cotidianas en quechua sureño, considerando las variedades chanka y collao. Se propone construir y validar un corpus con identificación de variedad y separación de ejemplos para entrenamiento, validación y prueba. El mismo modelo se evaluará antes y después de la adaptación con preguntas de prueba idénticas y parámetros de generación controlados. La calidad tendrá como indicador principal la aceptabilidad global, evaluada por hablantes competentes mediante una rúbrica que considere pertinencia, corrección lingüística y adecuación a la variedad. Las metas de tamaño del corpus y los parámetros de entrenamiento se tratarán como valores de diseño sujetos al piloto, a la disponibilidad de recursos lingüísticos y a la factibilidad computacional. El estudio es una propuesta; no presenta resultados ni presupone que QLoRA mejore el desempeño.

Palabras clave: Quechua sureño, Generación de respuestas, Modelos de lenguaje compactos, Adaptación de modelos, Evaluación humana.

ABSTRACT

This study will evaluate the effect of adapting a compact language model with QLoRA to generate brief answers to everyday questions in Southern Quechua, considering the Chanka and Collao varieties. It proposes to build and validate a corpus with variety labels and separate training, validation, and test examples. The same model will be evaluated before and after adaptation using identical test questions and controlled generation settings. Response quality will be assessed primarily through overall acceptability, rated by competent speakers using a rubric for relevance, linguistic correctness, and variety appropriateness. The proposed corpus size and training parameters will be treated as design targets subject to the pilot, availability of linguistic resources, and computational feasibility. This is a research proposal; it reports no results and does not assume that QLoRA will improve performance.

Keywords: Southern Quechua, Response generation, Compact language models, Model adaptation, Human evaluation.

ÍNDICE GENERAL

Resumen II

Abstract III

Índice general IV

Índice de tablas IX

Índice de figuras X

Índice de algoritmos XI

Lista de abreviaturas XII

Lista de símbolos XIII

Índice de ecuaciones XIV

Índice de apéndices (anexos) XV

Glosario de términos XVI

I. Introducción 1

1.1. Contexto y problema general 1

1.2. Tecnología o método 2

1.3. Vacío de investigación 2

1.4. Problema específico 3

1.4.1. Problema general 3

1.4.2. Problemas específicos 3

1.5. Propuesta, objetivo y justificación 3

1.5.1. Propuesta 3

1.5.2. Objetivo general 4
1.5.3. Objetivos específicos 4
1.5.4. Hipótesis 4
1.5.5. Justificación 4
1.5.6. Alcances y limitaciones 5
1.6. Organización de la tesis 6

II. Marco teórico y estado del arte **7**
2.1. Antecedentes relacionados con el quechua 7
2.1.1. Adaptación eficiente para traducción de lenguas indígenas 7
2.1.2. Datos sintéticos y traducción quechua–español 7
2.1.3. Construcción de recursos para quechua collao 7
2.1.4. Traducción para las variedades chanka y collao 8
2.1.5. Normalización y aumento de datos 8
2.1.6. Transformación morfosintáctica en quechua collao 8
2.2. Instrucciones y generación multilingüe 9
2.2.1. Datos nativos frente a datos traducidos 9
2.2.2. Limitaciones de utilizar traducción como intermediaria 9
2.2.3. Datos de instrucciones de bajos recursos 9
2.3. Antecedentes metodológicos 9
2.3.1. Adaptación eficiente 9
2.3.2. Evaluación humana de generación textual 10
2.4. Bases teóricas 10
2.4.1. Procesamiento del lenguaje natural 10
2.4.2. Arquitectura Transformer 10
2.4.3. Modelo de lenguaje compacto 11
2.4.4. Qwen2.5-0.5B-Instruct 11
2.4.5. Ajuste fino supervisado 11
2.4.6. QLoRA 12
2.4.7. Generación de respuestas breves 12

2.4.8. Quechua sureño 13
2.4.9. Calidad de respuesta 13
2.5. Síntesis del estado del arte y brecha de investigación 13

III. Metodología de la investigación **15**

3.1. Enfoque, tipo y diseño de investigación 15
3.1.1. Enfoque de investigación 15
3.1.2. Tipo de investigación 15
3.1.3. Alcance de investigación 15
3.1.4. Diseño de investigación 15
3.2. Variables y operacionalización 16
3.2.1. Variables de investigación 16
3.2.1.1. Variable independiente 16
3.2.1.2. Variable dependiente 16
3.2.1.3. Variables de control y estratificación 16
3.2.2. Operacionalización de variables 17
3.2.3. Criterio de aceptabilidad global 18
3.2.4. Matriz de consistencia 18
3.3. Unidades de análisis y selección de consultas 19
3.3.1. Unidad de análisis 19
3.3.2. Población y muestra 20
3.3.2.1. Población de referencia 20
3.3.2.2. Muestreo 20
3.3.2.3. Tamaño propuesto del corpus 20
3.4. Recursos lingüísticos y procedencia de datos 21
3.5. Construcción del corpus 21
3.5.1. Definición de dominios 21
3.5.2. Elaboración de ejemplos 22
3.5.3. Validación lingüística 22
3.5.4. Prevención de contaminación 23

3.5.5. Gestión de licencias 23
3.6. Modelo y entorno tecnológico 23
3.6.1. Modelo candidato 23
3.6.2. Evaluación preliminar de tokenización 23
3.6.3. Técnica de adaptación 24
3.7. Parámetros iniciales de entrenamiento 24
3.8. Condiciones de generación 25
3.9. Prueba piloto de factibilidad 26
3.9.1. Factibilidad lingüística 26
3.9.2. Factibilidad computacional 26
3.9.3. Factibilidad de evaluación 26
3.9.4. Criterios de continuidad 26
3.10. Instrumento y evaluación humana 27
3.11. Procedimiento de investigación 27
3.12. Plan de análisis de datos 30
3.13. Gestión de datos y consideraciones éticas 31

IV. Estudio de factibilidad **32**
4.1. Enfoque adoptado 32
4.2. Factibilidad técnica 32
4.2.1. Hardware e inferencia local 32
4.2.2. Estrategia de datos 32
4.2.3. Herramientas y software 32
4.3. Factibilidad económica 32
4.4. Factibilidad operativa 32
4.5. Viabilidad y sostenibilidad 32

Referencias **33**

A. Matriz de consistencia **36**

B. Ficha técnica de registro experimental **37**

C. Rúbrica de evaluación de respuestas **38**

D. Plantilla de registro del corpus **39**

ÍNDICE DE TABLAS

1. Operacionalización de las variables 17
2. Matriz de consistencia de la investigación 19
3. Distribución propuesta de pares de pregunta y respuesta 20
4. Recursos lingüísticos que se auditarán antes de su uso 21
5. Configuración inicial propuesta para el piloto de QLoRA 25
6. Condiciones controladas de generación 25
7. Matriz de consistencia de la investigación 36
8. Ficha vacía para registrar una corrida experimental 37
9. Rúbrica propuesta para evaluar respuestas breves en quechua sureño 38
10. Campos propuestos para documentar los pares de pregunta y respuesta 39

ÍNDICE DE FIGURAS

1. Flujo metodológico propuesto para comparar las respuestas del modelo original y del adaptado. 29

ÍNDICE DE ALGORITMOS

1. Comparación pareada de respuestas en el conjunto de prueba 29

LISTA DE ABREVIATURAS

Abreviatura	Significado
GPU	*Graphics Processing Unit*; unidad de procesamiento gráfico.
LoRA	*Low-Rank Adaptation*; adaptación de bajo rango.
NF4	*4-bit NormalFloat*; formato de cuantización de cuatro bits utilizado en la configuración piloto propuesta.
PLN	Procesamiento del lenguaje natural.
QLoRA	*Quantized Low-Rank Adaptation*; adaptación de bajo rango sobre un modelo base cuantizado.

LISTA DE SÍMBOLOS

Símbolo	Definición
Q, K, V	Representaciones de consulta, clave y valor en el mecanismo de atención.
d_k	Dimensión de las representaciones de clave; factor de escala en la autoatención.
W_0	Matriz de pesos preentrenada que permanece congelada durante la adaptación LoRA.
ΔW	Actualización de los pesos representada mediante matrices de bajo rango.
A, B	Matrices entrenables que parametrizan la actualización de bajo rango.
r	Rango de las matrices A y B.
α	Factor de escala de la actualización LoRA.
c	Condición evaluada: modelo original o modelo adaptado mediante QLoRA.
N_c	Número de preguntas de prueba evaluadas en la condición c para una variedad.
$n_{\text{aceptables},c}$	Número de respuestas aceptables en la condición c.
$\widehat{p}_c$	Proporción estimada de respuestas aceptables en la condición c.
$\widehat{\Delta p}$	Diferencia entre las proporciones de respuestas aceptables del modelo QLoRA y del modelo original.
q_i	Pregunta de prueba identificada con el índice i.
$y_{i,A}$, $y_{i,B}$	Respuestas a la pregunta q_i del modelo original y del modelo QLoRA, respectivamente.
H_0, H_1	Hipótesis nula y alternativa de la comparación principal.

ÍNDICE DE ECUACIONES

Número	Descripción	Ecuación	Página
Autoatención	Atención de producto escalar escalado en la arquitectura Transformer	(1)	11
LoRA	Descomposición de bajo rango de la actualización de pesos	(2)	12
Aceptabilidad	Proporción de respuestas aceptables por condición	(3)	18
Efecto	Diferencia pareada entre proporciones de aceptabilidad	(4)	18

ÍNDICE DE APÉNDICES (ANEXOS)

Anexo	Contenido	Página
A	Matriz de consistencia alineada con problemas, objetivos, hipótesis y método	36
B	Ficha vacía para registrar condiciones y salidas de cada corrida	37
C	Rúbrica para valorar las respuestas breves en quechua sureño	38
D	Plantilla de registro del corpus y de sus particiones	39

GLOSARIO DE TÉRMINOS

Aceptabilidad global: Clasificación binaria de una respuesta derivada de los umbrales definidos para pertinencia, corrección lingüística y adecuación a la variedad.

Adaptación eficiente: Ajuste de un modelo que reduce los parámetros entrenables o los recursos requeridos; en este estudio se operacionaliza mediante QLoRA.

Corpus de preguntas y respuestas: Conjunto documentado de preguntas y respuestas con etiquetas lingüísticas, temáticas, de procedencia y de partición.

Evaluación ciega: Procedimiento en que quienes califican no conocen si cada respuesta proviene del modelo original o del adaptado.

Grupo semántico: Conjunto de preguntas equivalentes o estrechamente relacionadas que debe conservarse en una sola partición para reducir contaminación.

Modelo de lenguaje compacto: Modelo definido operacionalmente para esta propuesta como uno con menos de mil millones de parámetros.

QLoRA: Técnica de adaptación que combina cuantización del modelo base con adaptadores entrenables de bajo rango.

Tokenizador: Componente que convierte el texto en unidades discretas procesables por el modelo; sus fragmentaciones se revisarán para ambas variedades.

Variedad lingüística: Forma lingüística identificada y delimitada en los datos; esta propuesta distingue quechua chanka y quechua collao.

CAPÍTULO I INTRODUCCIÓN

1.1 Contexto y problema general

El procesamiento del lenguaje natural ha avanzado mediante modelos de lenguaje basados en la arquitectura Transformer. Sin embargo, las lenguas con menor presencia en los recursos digitales afrontan limitaciones en la cantidad, diversidad, procedencia y calidad de los datos disponibles. El quechua constituye un caso relevante: aunque existen investigaciones sobre su procesamiento computacional, una parte importante de los trabajos recientes se ha concentrado en la traducción automática entre quechua y español.

Garcia Gilabert et al. (2024) estudiaron el uso de adaptadores LoRA en sistemas de traducción para lenguas indígenas. Asillo Congora et al. (2025) investigaron la ampliación de datos paralelos mediante ejemplos sintéticos para traducción quechua–español, y Quispe Callañaupa et al. (2026) abordaron el ajuste de NLLB-200 para traducir entre español y las variedades quechua chanka y collao. Estos trabajos aportan evidencia sobre el procesamiento del quechua, pero la traducción transforma un texto entre lenguas, mientras que la generación de respuestas debe interpretar una pregunta y producir una contestación pertinente. Por ello, los resultados de traducción no demuestran por sí mismos la calidad de respuestas generadas directamente en quechua.

También se han estudiado otras tareas. Pocco y Oncevay (2026) analizaron transformaciones morfosintácticas controladas en quechua collao. En el ámbito multilingüe, Chen et al. (2024) y Liu et al. (2025) examinaron diferencias entre datos de instrucciones originados en una lengua y datos obtenidos mediante traducción. Estos antecedentes muestran que el procesamiento computacional del quechua abarca tareas diversas, cuyos resultados no son intercambiables.

El estudio se delimita al quechua sureño y distingue las variedades chanka o ayacuchana y collao o cusqueña. La escritura se contrastará con el *Manual de escritura quechua sureño* del Ministerio de Educación (2021); la aceptabilidad de las respuestas también requerirá la valoración de hablantes competentes. Recursos como AmericasNLP y materiales de quechua de

Puno pueden apoyar la revisión lingüística, pero no se asumirán como un corpus validado y equilibrado de preguntas y respuestas para las dos variedades estudiadas.

1.2 Tecnología o método

La investigación propone estudiar un único modelo de lenguaje compacto. Qwen2.5-0.5B-Instruct es el candidato inicial (Qwen Team, 2024). Para adaptar el modelo se plantea utilizar QLoRA, técnica que combina la cuantización del modelo base con adaptadores de bajo rango (Dettmers et al., 2023). Su uso dependerá de una prueba de factibilidad computacional; la técnica no garantiza por sí sola respuestas adecuadas en las variedades examinadas.

La comparación considerará el mismo modelo en dos condiciones: original y adaptado mediante QLoRA. Ambas condiciones recibirán las mismas preguntas de prueba y parámetros de generación. La calidad se valorará principalmente mediante la aceptabilidad global, junto con pertinencia, corrección lingüística y adecuación a la variedad, usando una rúbrica aplicada por evaluadores competentes.

1.3 Vacío de investigación

Los antecedentes revisados tratan traducción automática, preparación de corpus y transformaciones textuales, pero no responden directamente a la pregunta delimitada en este plan. La brecha que orienta el estudio es establecer qué efecto produce adaptar mediante QLoRA un único modelo compacto sobre la aceptabilidad de respuestas breves a preguntas cotidianas en quechua sureño, a partir de un corpus validado y con evaluación diferenciada para chanka y collao.

Esta brecha es provisional y se apoya en los antecedentes identificados hasta ahora. No se afirma que no existan estudios similares, ni se presenta como novedosa la generación de texto en quechua o la técnica QLoRA. La investigación se concentrará en preguntas cotidianas de un solo turno, de complejidad limitada y evaluables sin consultar información externa.

1.4 Problema específico

El problema central consiste en determinar si la adaptación mediante QLoRA produce una diferencia medible en la calidad de las respuestas del modelo y establecer los límites de esa diferencia para las variedades chanka y collao.

1.4.1 Problema general

¿Qué efecto tiene adaptar mediante QLoRA un modelo de lenguaje compacto sobre la calidad de sus respuestas breves a preguntas cotidianas en quechua sureño?

1.4.2 Problemas específicos

1. ¿Cómo construir y validar un conjunto de preguntas y respuestas cotidianas que permita evaluar las variedades chanka y collao sin confundir datos de traducción con datos de generación de respuestas?

2. ¿Cómo adaptar un único modelo de lenguaje compacto mediante QLoRA para la generación de respuestas breves en quechua sureño, considerando las restricciones computacionales disponibles?

3. ¿Qué diferencias se observan en la aceptabilidad, pertinencia, corrección lingüística y adecuación a la variedad de las respuestas del modelo antes y después de la adaptación?

1.5 Propuesta, objetivo y justificación

1.5.1 Propuesta

Se propone construir y validar un corpus de preguntas y respuestas cotidianas por variedad, comprobar la factibilidad computacional y, solo si resulta viable, adaptar mediante QLoRA el modelo candidato. Después se compararán las respuestas del mismo modelo antes y después del ajuste, con las mismas preguntas de prueba y una evaluación humana. El estudio busca aportar evidencia experimental reproducible; no anticipa que QLoRA mejorará las respuestas.

1.5.2 Objetivo general

Evaluar el efecto de adaptar mediante QLoRA un modelo de lenguaje compacto sobre la calidad de sus respuestas breves a preguntas cotidianas en quechua sureño.

1.5.3 Objetivos específicos

1. Construir y validar un corpus de preguntas y respuestas breves de uso cotidiano en quechua sureño, con identificación de las variedades chanka y collao y separación de datos para entrenamiento, validación y prueba.

2. Evaluar la factibilidad computacional y, si resulta viable, adaptar un único modelo de lenguaje compacto mediante QLoRA y documentar su configuración.

3. Comparar, mediante evaluación humana y análisis estadístico pareado, la calidad de las respuestas generadas por el mismo modelo antes y después de su adaptación, presentando resultados generales y diferenciados por variedad.

1.5.4 Hipótesis

H1: Existe una diferencia en la proporción de respuestas aceptables a preguntas cotidianas en quechua sureño entre un modelo de lenguaje compacto original y el mismo modelo adaptado mediante QLoRA.

H0: No existe diferencia en la proporción de respuestas aceptables entre el modelo original y el mismo modelo adaptado mediante QLoRA.

Se utilizará un contraste bilateral, puesto que la adaptación podría mejorar, empeorar o no modificar el desempeño. La dirección y magnitud de la diferencia se determinarán a partir de los datos.

1.5.5 Justificación

Científica. La investigación abordará una tarea de generación textual distinta de la traducción automática: producir respuestas breves a preguntas formuladas directamente en quechua sureño. Su aporte será evidencia experimental sobre el efecto de adaptar mediante QLoRA un modelo

compacto en una tarea y un ámbito lingüístico definidos. No se afirmará que QLoRA sea una técnica nueva ni que no existan estudios previos sobre generación de lenguaje en quechua. La comparación reproducible entre el mismo modelo antes y después de su adaptación se acompañará de un protocolo de evaluación lingüística.

Metodológica. Se establecerá un procedimiento que contemple procedencia de datos, identificación de variedades, separación de particiones, control de contaminación, evaluación ciega, acuerdo entre evaluadores y análisis estadístico. Este procedimiento permitirá interpretar los resultados con mayor rigor que una demostración funcional del modelo.

Tecnológica. Se estudiará la utilización de un modelo compacto y una técnica de ajuste fino eficiente en un escenario de recursos computacionales limitados. Se registrarán las condiciones de entrenamiento e inferencia, sin asumir que QLoRA garantiza compatibilidad con cualquier GPU.

Lingüística y social. El trabajo buscará contribuir a la documentación y evaluación de tecnologías relacionadas con el quechua sureño. La participación de hablantes competentes permitirá reconocer diferencias entre las variedades estudiadas y evitar que la evaluación dependa exclusivamente de indicadores automáticos. Los resultados no se presentarán como sustitutos del conocimiento de los hablantes ni como una herramienta lingüística validada para cualquier situación comunicativa.

1.5.6 Alcances y limitaciones

Temática. La tarea consistirá en responder preguntas cotidianas de un solo turno mediante textos breves. Se priorizarán preguntas sobre situaciones sociales, actividades habituales, alimentos, familia y otros contextos sencillos que puedan ser evaluados por hablantes competentes. Se excluirán consultas médicas, jurídicas y financieras; preguntas de actualidad; información personal desconocida; y solicitudes que requieran búsquedas externas. Las preguntas deberán contener información suficiente para producir una respuesta razonable o pertenecer a situaciones comunicativas de conocimiento cotidiano. No se evaluará al modelo por inventar datos personales que no conoce.

Lingüística. Se estudiarán el quechua chanka o ayacuchano, identificado habitualmente con

quy, y el quechua collao o cusqueño, identificado habitualmente con quz. Los ejemplos deberán estar etiquetados y validados para la variedad correspondiente. Los datos de quechua de Puno (qxp) no se incorporarán automáticamente como equivalentes a los de chanka o collao. Las conclusiones se limitarán a las variedades, los temas y las condiciones efectivamente estudiados.

Tecnológica. Se empleará un único modelo compacto, cuyo candidato inicial será Qwen2.5-0.5B-Instruct, y una única técnica de adaptación, QLoRA, siempre que supere la prueba de factibilidad. No se implementarán RAG, bases vectoriales, recuperación de documentos, reconocimiento de voz ni comparación entre arquitecturas.

Experimental. Se compararán dos condiciones del mismo modelo: (A) modelo original y (B) modelo adaptado mediante QLoRA. Ambas utilizarán las mismas preguntas de prueba, instrucciones equivalentes y parámetros de generación. La interpretación se limitará a este modelo, el corpus validado, las variedades y el protocolo efectivamente evaluados.

1.6 Organización de la tesis

El capítulo I presenta la introducción, el problema, la propuesta, los objetivos, la hipótesis y la justificación. El capítulo II desarrolla los antecedentes, el marco teórico y la brecha de investigación. El capítulo III describe la metodología propuesta, incluidas las variables, la operacionalización y los procedimientos de evaluación. El capítulo IV conserva únicamente el esquema del estudio de factibilidad para una etapa posterior. El plan incluye además las referencias y los apéndices; no presenta resultados experimentales.

CAPÍTULO II MARCO TEÓRICO Y ESTADO DEL ARTE

2.1 Antecedentes relacionados con el quechua

2.1.1 Adaptación eficiente para traducción de lenguas indígenas

Garcia Gilabert et al. (2024), en *BSC Submission to the AmericasNLP 2024 Shared Task*, presentaron sistemas de traducción del español al quechua y al guaraní mediante adaptadores LoRA. Sus resultados mostraron que era posible obtener un rendimiento competitivo sin ajustar todos los parámetros.

Este antecedente demuestra la aplicabilidad de la adaptación eficiente en tareas relacionadas con lenguas indígenas. Sin embargo, no evalúa respuestas monolingües a preguntas cotidianas.

2.1.2 Datos sintéticos y traducción quechua–español

Asillo Congora et al. (2025), en *UCSP Submission to the AmericasNLP 2025 Shared Task*, estudiaron la ampliación de datos paralelos mediante ejemplos sintéticos y el ajuste de mT5 para traducción entre quechua y español.

Su trabajo evidencia la importancia de la cantidad y preparación de datos. No obstante, las oraciones paralelas utilizadas para traducción no deben tratarse directamente como pares de preguntas y respuestas.

2.1.3 Construcción de recursos para quechua collao

Orcotoma Mormontoy et al. (2025), en *Towards the Creation of a Collao Quechua–Spanish Parallel Corpus Using Optical Character Recognition*, presentaron una metodología para digitalizar y preparar recursos paralelos.

El trabajo muestra la relevancia de construir recursos lingüísticos y verificar su integridad. Su posible utilización en esta investigación dependerá de la disponibilidad y autorización de los datos.

2.1.4 Traducción para las variedades chanka y collao

Quispe Callañaupa et al. (2026), en *Optimization of Voice Translation Systems for Indigenous Languages: Retraining the NLLB-200 Model for the Quechua–Spanish Pair*, estudiaron el reajuste de NLLB-200 utilizando 22 891 pares paralelos depurados.

Este antecedente resulta importante por su tratamiento de chanka y collao y por considerar hardware de consumo. Sin embargo, su tarea fue la traducción, no la generación de respuestas monolingües.

2.1.5 Normalización y aumento de datos

Dhawan et al. (2026), en *Improving Indigenous Language Machine Translation with Synthetic Data and Language-Specific Preprocessing*, estudiaron la ampliación sintética de corpus y el preprocesamiento específico para lenguas indígenas, incluido el quechua.

Este trabajo impide considerar la normalización ortográfica convencional como una contribución novedosa por sí misma. En la presente investigación, el control ortográfico será una medida de calidad de datos, no el aporte central.

2.1.6 Transformación morfosintáctica en quechua collao

Pocco y Oncevay (2026), en *On the Robustness of Morphosyntactic Transformation with Large Language Models: The Case of Quechua Collao*, evaluaron modelos de lenguaje en una tarea de transformación morfosintáctica controlada.

Los resultados muestran que el comportamiento de los modelos depende de la complejidad lingüística y de las condiciones de entrada.

El trabajo demuestra que ya existen estudios de generación o transformación textual relacionados con quechua. Por ello, la presente tesis no reclamará como novedad el simple hecho de generar texto en esa lengua.

2.2 Instrucciones y generación multilingüe

2.2.1 Datos nativos frente a datos traducidos

Chen et al. (2024), en *Is It Good Data for Multilingual Instruction Tuning or Just Bad Multilingual Evaluation for Large Language Models?*, analizaron diferencias entre datos de instrucciones nativos y traducidos.

Sus resultados indican que la procedencia de los datos puede influir en la evaluación de generación multilingüe.

En esta investigación, los ejemplos deberán validarse en quechua y no se considerará suficiente traducir automáticamente preguntas y respuestas desde el español.

2.2.2 Limitaciones de utilizar traducción como intermediaria

Liu et al. (2025), en *Is Translation All You Need? A Study on Solving Multilingual Tasks with Large Language Models*, estudiaron estrategias para resolver tareas multilingües.

Sus resultados muestran que traducir hacia una lengua dominante no siempre es la mejor estrategia para todas las tareas.

Este antecedente respalda el interés de evaluar preguntas y respuestas directamente en quechua.

2.2.3 Datos de instrucciones de bajos recursos

Köksal et al. (2025), en *MURI: High-Quality Instruction Tuning Datasets for Low-Resource Languages via Reverse Instructions*, propusieron un procedimiento para obtener pares de instrucción y respuesta a partir de textos disponibles en lenguas de pocos recursos.

El trabajo aporta antecedentes para la construcción de datos de instrucciones, aunque no sustituye la necesidad de validar un corpus específico de quechua sureño.

2.3 Antecedentes metodológicos

2.3.1 Adaptación eficiente

Hu et al. (2022) propusieron LoRA, que permite entrenar matrices de bajo rango manteniendo congelados los parámetros principales de un modelo.

Dettmers et al. (2023) presentaron QLoRA, que combina cuantización y adaptación de bajo rango para disminuir los requerimientos de memoria durante el ajuste fino.

Estas técnicas constituyen herramientas metodológicas ya establecidas. La investigación no intentará demostrar que QLoRA es mejor que otros métodos, puesto que no comparará técnicas de adaptación.

2.3.2 Evaluación humana de generación textual

van der Lee et al. (2019) revisaron las prácticas de evaluación humana de textos generados y recomendaron definir criterios claros, documentar a los evaluadores y reportar adecuadamente los procedimientos.

Amidei et al. (2019) analizaron el uso de escalas de valoración en tareas de generación de lenguaje.

Estos trabajos sustentan la necesidad de una rúbrica previamente validada, evaluación ciega y análisis del acuerdo entre evaluadores.

2.4 Bases teóricas

2.4.1 Procesamiento del lenguaje natural

El procesamiento del lenguaje natural (PLN) estudia métodos computacionales para analizar, interpretar y generar lenguaje humano.

En esta investigación se abordará la generación de respuestas textuales breves, no la traducción automática.

2.4.2 Arquitectura Transformer

La arquitectura Transformer, presentada por Vaswani et al. (2017), utiliza mecanismos de atención para representar relaciones entre elementos de una secuencia.

Los modelos de lenguaje autorregresivos basados en esta arquitectura generan texto mediante la predicción sucesiva de tokens.

En la autoatención, las representaciones de consulta (Q), clave (K) y valor (V)

determinan cómo se pondera la información de la secuencia. La operación se expresa como:

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)V. \quad (1)$$

En esta expresión, d_k es la dimensión de las claves y el factor de escala evita que los productos internos crezcan con la dimensión.

2.4.3 Modelo de lenguaje compacto

Para esta investigación, se considerará compacto un modelo con menos de mil millones de parámetros.

Esta definición es operacional y se utilizará únicamente para delimitar el estudio.

El tamaño reducido puede favorecer su utilización en hardware limitado, pero no garantiza competencia en una lengua de pocos recursos.

2.4.4 Qwen2.5-0.5B-Instruct

Qwen2.5-0.5B-Instruct es un modelo autorregresivo ajustado para seguir instrucciones, con aproximadamente 490 millones de parámetros (Qwen Team, 2024).

Se utilizará como candidato inicial por su tamaño, disponibilidad pública y licencia Apache 2.0.

Su documentación no demuestra específicamente un rendimiento adecuado en quechua sureño. Por tanto, será necesaria una prueba preliminar de tokenización, generación y compatibilidad técnica.

2.4.5 Ajuste fino supervisado

El ajuste fino supervisado consiste en adaptar un modelo mediante ejemplos que contienen entradas y salidas esperadas.

En este estudio, las entradas serán preguntas cotidianas y las salidas serán respuestas breves validadas en quechua sureño.

Durante el entrenamiento se procurará que la función de pérdida se aplique principalmente a los tokens de la respuesta, evitando utilizar las instrucciones como objetivo de

predicción.

2.4.6 QLoRA

QLoRA es una técnica de adaptación eficiente que permite entrenar adaptadores de bajo rango sobre un modelo base cuantizado (Dettmers et al., 2023). Sea W_0 la matriz de pesos preentrenada y congelada durante el ajuste; la actualización se parametriza como:

La cuantización reduce el espacio necesario para almacenar determinados pesos, mientras que los adaptadores concentran los parámetros entrenables.

Su aplicación estará condicionada a la compatibilidad del hardware y del software disponible.

En LoRA, la actualización de una matriz de pesos congelada se representa mediante dos matrices entrenables de rango reducido:

$$\Delta W = \frac{\alpha}{r} BA, \tag{2}$$

donde r es el rango y α es el factor de escala. La ecuación describe la parametrización de LoRA; no implica que el ajuste vaya a mejorar la calidad de las respuestas.

2.4.7 Generación de respuestas breves

La generación de respuestas breves consiste en producir una contestación concisa que atienda una pregunta.

Para este estudio, una respuesta deberá:

- Estar formulada en quechua.
- Corresponder a la variedad solicitada.
- Atender directamente la intención de la pregunta.
- Evitar información no solicitada o inventada.
- Mantener una extensión preferente de una o dos oraciones.

La longitud se controlará también mediante un límite técnico de tokens, pero no se equipararán automáticamente los tokens con palabras u oraciones.

2.4.8 Quechua sureño

El estudio comprenderá las variedades chanka y collao.

Se utilizará el *Manual de escritura quechua sureño* del Ministerio de Educación como referencia de escritura, complementado con la revisión de hablantes competentes.

Las decisiones sobre variantes aceptables se documentarán antes de la evaluación.

2.4.9 Calidad de respuesta

La calidad de respuesta será un constructo evaluado mediante tres dimensiones:

Pertinencia: correspondencia entre la pregunta y la contestación.

Corrección lingüística: aceptabilidad y comprensibilidad de la formulación.

Adecuación a la variedad: correspondencia con la variedad lingüística solicitada.

Se establecerá un criterio binario de aceptabilidad global a partir de estas dimensiones.

2.5 Síntesis del estado del arte y brecha de investigación

La revisión presentada identifica cuatro líneas de investigación relacionadas:

1. Traducción automática quechua–español.
2. Construcción y preparación de recursos lingüísticos.
3. Adaptación eficiente de modelos.
4. Evaluación multilingüe y generación textual.

Los antecedentes demuestran que estas líneas cuentan con investigaciones previas. Por ello, no se planteará como novedad la utilización de QLoRA, la construcción de un modelo de traducción ni la generación de texto en quechua considerada de manera general.

La brecha específica de este estudio se formula de la siguiente manera:

Falta establecer, para las condiciones delimitadas de esta investigación, qué efecto produce adaptar mediante QLoRA un único modelo compacto sobre la aceptabilidad de respuestas breves a preguntas cotidianas en quechua sureño, utilizando un corpus validado y una evaluación humana diferenciada para las variedades chanka y collao.

Esta brecha es una hipótesis de trabajo fundamentada en los antecedentes examinados, no una declaración de inexistencia absoluta de estudios similares.

La contribución esperada será un resultado experimental reproducible, acompañado de un conjunto de evaluación documentado y un análisis de las limitaciones del modelo.

CAPÍTULO III METODOLOGÍA DE LA INVESTIGACIÓN

3.1 Enfoque, tipo y diseño de investigación

3.1.1 Enfoque de investigación

La investigación tendrá un enfoque cuantitativo.

Se compararán resultados medibles de un sistema computacional y se utilizarán valoraciones humanas estructuradas para establecer indicadores de calidad.

La revisión lingüística será necesaria para obtener mediciones válidas, pero no convertirá automáticamente la investigación en un estudio de enfoque mixto.

3.1.2 Tipo de investigación

La investigación será aplicada, porque utilizará métodos existentes de aprendizaje automático para estudiar una tarea concreta de procesamiento del quechua sureño.

3.1.3 Alcance de investigación

El alcance será comparativo y evaluativo, con una interpretación causal limitada a la intervención realizada sobre el modelo estudiado.

No se pretende generalizar el resultado a todos los modelos compactos ni demostrar que QLoRA supera a otras técnicas de ajuste fino.

3.1.4 Diseño de investigación

Se utilizará un **diseño experimental computacional de comparación pareada**, con un único modelo base y dos condiciones.

La condición A corresponderá al modelo original.

La condición B corresponderá al mismo modelo después del ajuste supervisado mediante QLoRA.

Las mismas preguntas de prueba serán utilizadas en ambas condiciones.

No se aplicará aleatorización de participantes a grupos de tratamiento, puesto que las

unidades experimentales son entradas lingüísticas procesadas por un sistema computacional.

La aleatorización se utilizará para ocultar el origen de las respuestas durante su evaluación humana.

El estudio estimará el efecto de la adaptación sobre este modelo y corpus específicos. Una sola ejecución de entrenamiento no permitirá estimar completamente la variabilidad asociada a diferentes semillas de entrenamiento.

3.2 Variables y operacionalización

3.2.1 Variables de investigación

3.2.1.1 Variable independiente

Condición de adaptación del modelo.

Se trata de una variable categórica con dos niveles:

- A: modelo original.
- B: mismo modelo adaptado mediante QLoRA.

3.2.1.2 Variable dependiente

Calidad de las respuestas breves a preguntas cotidianas en quechua sureño.

Se medirá mediante pertinencia, corrección lingüística y adecuación a la variedad.

El indicador principal será la aceptabilidad global de la respuesta.

3.2.1.3 Variables de control y estratificación

Se controlarán:

- Identidad y versión del modelo base.
- Conjunto de preguntas de prueba.
- Plantilla de instrucciones.
- Configuración de generación.
- Límite máximo de tokens de salida.
- Entorno de inferencia.

- Criterios de evaluación.

Se registrarán como factores de estratificación:

- Variedad lingüística.
- Dominio temático.
- Tipo de pregunta.
- Longitud de entrada.

3.2.2 Operacionalización de variables

La Tabla 1 relaciona cada variable con sus dimensiones, indicadores, escala de medición y fuente prevista.

Tabla 1
Operacionalización de las variables

Variable	Dimensión	Indicador	Escala	Fuente
Condición de adaptación	Estado del modelo	Modelo original o el mismo modelo adaptado mediante QLoRA	Nominal	Configuración experimental
Calidad de respuesta	Pertinencia	Puntuación de la rúbrica: 0, 1 o 2	Ordinal	Evaluación humana
Calidad de respuesta	Corrección lingüística	Puntuación de la rúbrica: 0, 1 o 2	Ordinal	Evaluación humana
Calidad de respuesta	Adecuación a la variedad	Puntuación de la rúbrica: 0, 1 o 2	Ordinal	Evaluación humana
Calidad de respuesta	Aceptabilidad global	Aceptable o no aceptable según regla predefinida	Nominal dicotómica	Rúbrica adjudicada
Desempeño técnico complementario	Memoria	Pico de memoria de GPU durante entrenamiento e inferencia	Razón	Registro técnico
Desempeño técnico complementario	Latencia	Segundos por respuesta	Razón	Registro técnico
Desempeño técnico complementario	Entrenamiento	Duración y número de parámetros entrenables	Razón	Registro técnico

Nota. Las medidas técnicas serán descriptivas y no constituirán una segunda variable dependiente principal.

3.2.3 Criterio de aceptabilidad global

Cada dimensión recibirá una puntuación de 0 a 2.

Una respuesta será clasificada como aceptable si cumple simultáneamente:

- Pertinencia: 2 puntos.
- Corrección lingüística: al menos 1 punto.
- Adecuación a la variedad: al menos 1 punto.

Una respuesta que no conteste la pregunta no será aceptable, aunque su formulación sea lingüísticamente correcta.

Este criterio deberá ser aprobado durante la validación de la rúbrica, antes de la evaluación final.

Para cada condición c y variedad, la proporción de respuestas aceptables se calculará como:

$$\widehat{p}_c = \frac{n_{\text{aceptables},c}}{N_c}, \tag{3}$$

donde $n_{\text{aceptables},c}$ es el número de respuestas clasificadas como aceptables y N_c es el número de preguntas de prueba de esa variedad evaluadas en la condición c.

La diferencia pareada de interés entre las dos condiciones se expresará como:

$$\widehat{\Delta p} = \widehat{p}_{\text{QLoRA}} - \widehat{p}_{\text{original}}. \tag{4}$$

El signo y la magnitud se estimarán con los datos; no se presupone una mejora.

3.2.4 Matriz de consistencia

La Tabla 2 muestra la correspondencia entre los problemas, los objetivos, las hipótesis y el método propuesto.

Tabla 2
Matriz de consistencia de la investigación

Problema	Objetivo	Variable o resultado	Procedimiento
¿Qué efecto tiene adaptar mediante QLoRA un modelo de lenguaje compacto sobre la calidad de sus respuestas breves a preguntas cotidianas en quechua sureño?	Evaluar el efecto de adaptar mediante QLoRA un modelo de lenguaje compacto sobre la calidad de sus respuestas breves a preguntas cotidianas en quechua sureño.	Condición de adaptación; calidad de respuestas y aceptabilidad global.	Comparación pareada con las mismas preguntas; evaluación humana ciega y análisis por variedad.
¿Cómo construir y validar un conjunto de preguntas y respuestas cotidianas que permita evaluar las variedades chanka y collao sin confundir datos de traducción con datos de generación de respuestas?	Construir y validar un corpus de preguntas y respuestas breves de uso cotidiano en quechua sureño, con identificación de las variedades chanka y collao y separación de datos para entrenamiento, validación y prueba.	Calidad y composición del corpus	Auditoría de fuentes, revisión lingüística y partición por grupos semánticos.
¿Cómo adaptar un único modelo de lenguaje compacto mediante QLoRA para la generación de respuestas breves en quechua sureño, considerando las restricciones computacionales disponibles?	Evaluar la factibilidad computacional y, si resulta viable, adaptar un único modelo de lenguaje compacto mediante QLoRA y documentar su configuración.	Condición de adaptación	Piloto, ajuste supervisado y registro de configuración si el entrenamiento es viable.
¿Qué diferencias se observan en la aceptabilidad, pertinencia, corrección lingüística y adecuación a la variedad de las respuestas del modelo antes y después de la adaptación?	Comparar, mediante evaluación humana y análisis estadístico pareado, la calidad de las respuestas generadas por el mismo modelo antes y después de su adaptación, presentando resultados generales y diferenciados por variedad.	Aceptabilidad y dimensiones de calidad	Generación controlada, evaluación ciega con rúbrica y análisis estadístico pareado.

3.3 Unidades de análisis y selección de consultas

3.3.1 Unidad de análisis

La unidad principal de análisis será una pregunta de prueba y el par de respuestas producido para ella:

- Respuesta del modelo original.
- Respuesta del modelo adaptado.

Las puntuaciones emitidas por distintos evaluadores para una misma respuesta no serán tratadas como unidades independientes.

3.3.2 Población y muestra

3.3.2.1 Población de referencia

La población conceptual estará formada por preguntas cotidianas de un solo turno, formuladas en quechua chanka o collao, cuya respuesta pueda expresarse brevemente y evaluarse sin recurrir a información externa.

No existe un listado exhaustivo de esta población.

3.3.2.2 Muestreo

Se empleará un muestreo intencional, estratificado por variedad y dominio temático.

Las conclusiones tendrán alcance limitado a la muestra y a las condiciones lingüísticas estudiadas.

3.3.2.3 Tamaño propuesto del corpus

Se plantea una meta inicial de **680 pares de pregunta y respuesta validados**. La Tabla 3 presenta su distribución propuesta por partición y variedad.

Tabla 3
Distribución propuesta de pares de pregunta y respuesta

Partición	Chanka	Collao	Total
Piloto	20	20	40
Entrenamiento	200	200	400
Validación	40	40	80
Prueba final	80	80	160
Total	**340**	**340**	**680**

Nota. Son metas de diseño; el piloto y la estimación de precisión o potencia determinarán el tamaño final. Las preguntas piloto se mantendrán separadas de las particiones de entrenamiento, validación y prueba.

Estas cantidades son metas de diseño y no representan datos que ya se hayan obtenido.

La cantidad definitiva de preguntas de prueba deberá justificarse mediante una estimación de precisión o potencia estadística, utilizando información del piloto y una diferencia mínima de interés definida antes de la evaluación final.

Las 160 preguntas propuestas no garantizan por sí solas potencia suficiente para detectar efectos pequeños.

Si el cálculo indica que se requiere una muestra mayor, deberá ampliarse la evaluación o declararse el carácter exploratorio del contraste.

3.4 Recursos lingüísticos y procedencia de datos

La Tabla 4 resume las fuentes que se auditarán, su posible función y las restricciones que deben comprobarse antes de utilizarlas.

Tabla 4

Recursos lingüísticos que se auditarán antes de su uso

Recurso	Tipo de datos	Utilización prevista	Limitación
AmericasNLP 2025 (Asillo Congora et al., 2025)	Textos paralelos quechua–español	Apoyo lingüístico y revisión de vocabulario	No es un corpus de preguntas y respuestas.
Manual de escritura quechua sureño (Ministerio de Educación, 2021)	Material normativo	Criterios de escritura	No constituye un conjunto de entrenamiento.
Corpus Collao–español (Orcotoma Mormontoy et al., 2025)	Corpus paralelo preparado mediante OCR	Posible apoyo lingüístico	Disponibilidad, licencia e idoneidad por comprobar.
Ejemplos elaborados y revisados para el estudio	Preguntas y respuestas monolingües	Entrenamiento, validación y evaluación	Deben crearse y validarse; todavía no son datos obtenidos.

Nota. No se tratarán automáticamente pares de traducción como ejemplos de generación de respuestas. Las fuentes se incorporarán solo después de verificar procedencia, variedad, licencia y compatibilidad con los objetivos.

El corpus definitivo estará compuesto por ejemplos con procedencia documentada y validación lingüística.

No se incorporarán automáticamente pares de traducción ni transcripciones de voz como si fueran ejemplos listos de entrenamiento para generación de respuestas.

3.5 Construcción del corpus

3.5.1 Definición de dominios

Se establecerán inicialmente cinco dominios:

1. Saludos y relaciones sociales.
2. Actividades cotidianas.

3. Familia y convivencia.
4. Alimentos y actividades domésticas.
5. Situaciones comunes de la comunidad.

Se excluirán preguntas cuya respuesta dependa de información privada, de hechos actuales o de conocimientos especializados.

3.5.2 Elaboración de ejemplos

Cada ejemplo contendrá:

- Identificador.
- Pregunta.
- Respuesta validada.
- Variedad lingüística.
- Dominio.
- Intención comunicativa.
- Fuente.
- Autor o responsable de revisión.
- Estado de validación.
- Grupo semántico.
- Partición del corpus.

Las preguntas deberán presentar diversidad de estructuras y situaciones, evitando que el corpus se reduzca a repeticiones de una misma plantilla.

3.5.3 Validación lingüística

Los ejemplos serán revisados por hablantes competentes en la variedad correspondiente.

La revisión verificará:

- Comprensibilidad.
- Pertinencia de la respuesta.
- Corrección lingüística.

- Adecuación a la variedad.
- Ausencia de ambigüedad no controlada.

Se documentarán las correcciones y exclusiones.

3.5.4 Prevención de contaminación

La separación entre entrenamiento, validación y prueba se realizará por grupos semánticos.

Preguntas equivalentes, paráfrasis cercanas o versiones de una misma pregunta en distintas variedades no podrán distribuirse entre entrenamiento y prueba.

Se utilizarán procedimientos de detección de duplicados y revisión manual.

Las preguntas de prueba no se emplearán para seleccionar hiperparámetros ni modificar la rúbrica.

3.5.5 Gestión de licencias

Antes de utilizar cada recurso se documentará su licencia, procedencia, restricciones de redistribución y posibles datos personales.

Los ejemplos elaborados por participantes se utilizarán con autorización expresa.

Los materiales que no permitan redistribución no se publicarán como parte del corpus abierto.

3.6 Modelo y entorno tecnológico

3.6.1 Modelo candidato

Se utilizará inicialmente Qwen2.5-0.5B-Instruct, con aproximadamente 490 millones de parámetros (Qwen Team, 2024).

Se registrará la revisión exacta del modelo descargado para garantizar reproducibilidad.

3.6.2 Evaluación preliminar de tokenización

Antes del ajuste fino se estudiará el comportamiento del tokenizador sobre ejemplos de ambas variedades.

Se registrarán:

- Número de tokens por pregunta.
- Número de tokens por respuesta.
- Relación entre longitud textual y longitud tokenizada.
- Presencia de fragmentaciones excesivas.
- Errores de codificación o representación.

Esta evaluación no demostrará comprensión lingüística, pero permitirá identificar dificultades técnicas relevantes.

3.6.3 Técnica de adaptación

Se empleará QLoRA como única técnica de ajuste fino (Dettmers et al., 2023).

El entrenamiento será supervisado, utilizando preguntas como entradas y respuestas validadas como salidas.

Se aplicará la plantilla de conversación correspondiente al modelo seleccionado.

La función de pérdida se calculará sobre los tokens de la respuesta, según las capacidades de la implementación utilizada.

3.7 Parámetros iniciales de entrenamiento

La Tabla 5 reúne los valores de configuración inicial propuestos para el piloto; no constituyen resultados experimentales.

Tabla 5
Configuración inicial propuesta para el piloto de QLoRA

Parámetro	Valor inicial propuesto
Modelo	Qwen2.5-0.5B-Instruct
Cuantización y tipo	4 bits; NF4
Rango LoRA (r) y escala (α)	8 y 16
Dropout	0,05
Módulos iniciales	Proyecciones de atención `q_proj` y `v_proj`
Micro-lote y acumulación de gradientes	1 y 8
Longitud máxima de secuencia	256 tokens
Épocas máximas	3
Tasa de aprendizaje inicial	2×10^{-4}
Semilla	Fijada y registrada
Selección del modelo final	Pérdida y evaluación en validación

Nota. Los valores son puntos de partida, no resultados confirmados. Se ajustarán durante el piloto y se documentarán antes de evaluar el conjunto de prueba.

Se utilizarán técnicas de ahorro de memoria compatibles con el hardware, como *gradient checkpointing* y optimizadores de menor consumo, cuando estén disponibles.

Los valores definitivos deberán quedar registrados después del piloto.

No se utilizará el conjunto de prueba para modificar esta configuración.

3.8 Condiciones de generación

Para evitar que las diferencias se deban a configuraciones distintas, la Tabla 6 recoge los parámetros que se mantendrán iguales en ambas condiciones.

Tabla 6
Condiciones controladas de generación

Parámetro	Configuración propuesta
Plantilla de instrucciones	Idéntica en ambas condiciones
Preguntas de prueba	Las mismas para el modelo original y el adaptado
Decodificación y muestreo	Decodificación determinista; muestreo desactivado
Máximo de tokens nuevos	64
Historial conversacional	Ninguno
Recuperación documental	No se utilizará
Ejemplos dentro del prompt de prueba	Ninguno

La instrucción indicará la variedad solicitada y pedirá una respuesta breve en quechua.

Se utilizará la misma estructura de instrucción en ambas condiciones.

Se conservarán las respuestas originales, incluidas aquellas que contengan errores, texto en español o ausencia de respuesta.

3.9 Prueba piloto de factibilidad

Antes del experimento definitivo se realizará un piloto con 40 preguntas, 20 por variedad.

Se comprobarán tres aspectos.

3.9.1 Factibilidad lingüística

Se verificará que las preguntas puedan ser interpretadas y evaluadas de manera consistente por hablantes competentes.

3.9.2 Factibilidad computacional

Se comprobará que el modelo pueda cargarse, generar respuestas y ejecutar un ciclo breve de entrenamiento.

Se registrará el consumo máximo de memoria.

No se asumirá que una GPU de 4 GB es suficiente sin medición.

3.9.3 Factibilidad de evaluación

Se aplicará la rúbrica preliminar y se analizarán desacuerdos entre evaluadores.

La rúbrica podrá modificarse después del piloto, pero deberá quedar congelada antes de la evaluación definitiva.

3.9.4 Criterios de continuidad

La ejecución definitiva requerirá:

- Corpus suficiente y validado para las dos variedades.
- Disponibilidad de evaluadores competentes.
- Ausencia de contaminación entre particiones.

- Entrenamiento técnicamente ejecutable.
- Rúbrica comprensible y aplicable.
- Procedimiento de evaluación aprobado antes de generar los resultados finales.

Si alguna condición no se cumple, se revisará la factibilidad y se ajustará el protocolo antes de usar la prueba final. Sin una adaptación ejecutable y una evaluación válida, no se afirmará ni se contrastará inferencialmente un efecto de QLoRA.

3.10 Instrumento y evaluación humana

Se utilizará una rúbrica analítica con tres dimensiones: pertinencia, corrección lingüística y adecuación a la variedad. Cada dimensión se puntuará en una escala ordinal de 0 a 2, con descriptores conductuales para distinguir una respuesta insuficiente, parcialmente adecuada y adecuada. La regla para clasificar la aceptabilidad global se presenta en la Sección 3.2.3.

Se propone que dos evaluadores competentes en cada variedad califiquen las respuestas de manera independiente. Antes de la evaluación final, revisarán la rúbrica con ejemplos del piloto y recibirán instrucciones comunes. La procedencia de cada salida (modelo original o adaptado) se ocultará; las respuestas se presentarán en orden aleatorio y separadas, conservando un identificador que permita reconstruir cada par durante el análisis. La pertinencia de criterios, la formación de evaluadores y la presentación ciega se documentarán (Amidei et al., 2019; van der Lee et al., 2019).

Se conservarán las puntuaciones independientes. Los desacuerdos se resolverán mediante adjudicación documentada por una tercera persona competente; la puntuación adjudicada se usará para el resultado principal y las puntuaciones iniciales se usarán para estimar concordancia. La disponibilidad de evaluadores y la claridad de la rúbrica deberán confirmarse en el piloto.

3.11 Procedimiento de investigación

El procedimiento se ejecutará en este orden:

1. Auditar las fuentes lingüísticas y registrar procedencia, licencia, restricciones de uso y variedad antes de incorporar cualquier material.

2. Elaborar y revisar los pares de pregunta y respuesta; etiquetar variedad, dominio y grupo semántico, y separar los conjuntos evitando que paráfrasis o preguntas equivalentes queden en particiones diferentes.

3. Mantener el piloto separado. Aplicarlo para comprobar factibilidad lingüística, técnica y de evaluación; ajustar y congelar la rúbrica y los parámetros antes de usar el conjunto de prueba.

4. Entrenar el modelo candidato mediante QLoRA solo con la partición de entrenamiento. Utilizar validación para seleccionar la configuración final y registrar versiones, semilla, parámetros, duración y memoria.

5. Congelar el modelo, las instrucciones, la decodificación y los criterios. Para cada pregunta de prueba, generar una respuesta del modelo original y otra del modelo adaptado bajo las mismas condiciones.

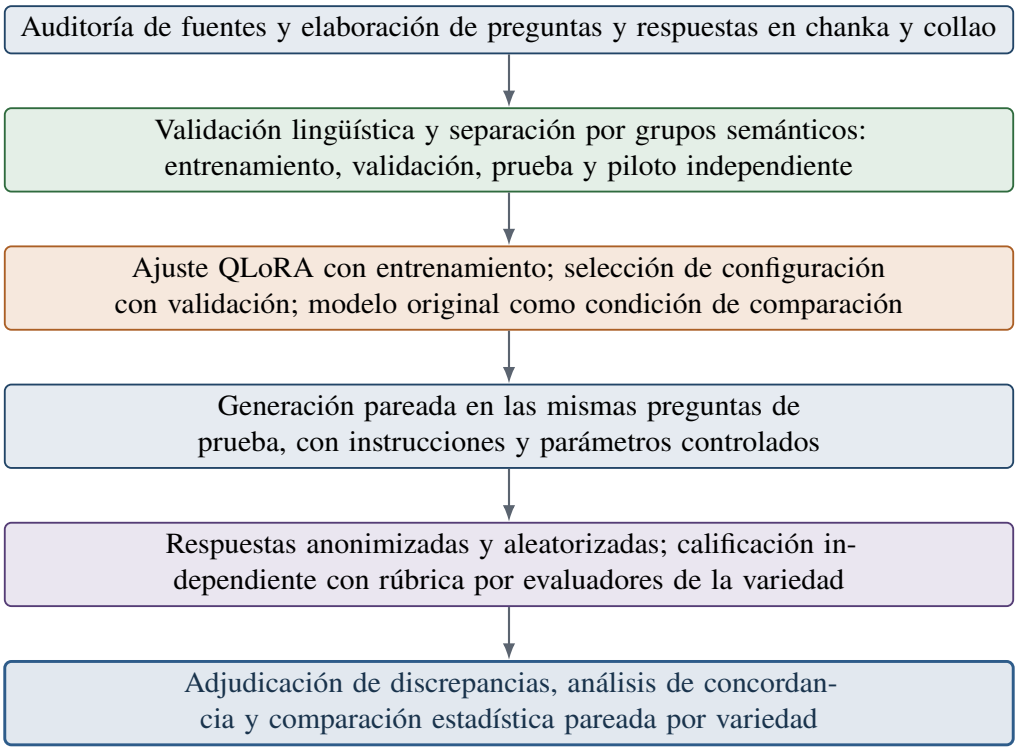
6. Asignar identificadores neutrales, ocultar la condición, aleatorizar el orden de evaluación y recopilar las puntuaciones independientes de los evaluadores.

7. Resolver desacuerdos según el procedimiento definido, estimar concordancia y analizar los resultados pareados en conjunto y por variedad.

La secuencia prevista se resume en la Figura 1 y se formaliza en el Algoritmo 1.

Figura 1

Flujo metodológico propuesto para comparar las respuestas del modelo original y del adaptado.



Nota. Elaboración propia.

1. Congelar las versiones del modelo, las instrucciones, la decodificación y la rúbrica utilizando únicamente el piloto y la validación.
2. Para cada pregunta de prueba q_i, generar $y_{i,A}$ con el modelo original y $y_{i,B}$ con el modelo QLoRA.
3. Guardar ambos resultados con identificadores neutrales y presentar cada respuesta en orden aleatorio a los evaluadores de su variedad.
4. Registrar las puntuaciones independientes de pertinencia, corrección lingüística y adecuación a la variedad.
5. Adjudicar los desacuerdos y asignar la etiqueta de aceptabilidad con la regla definida antes de la evaluación final.
6. Comparar los resultados A y B por pregunta; estimar el efecto global y los resultados separados para chanka y collao.

Algoritmo 1

Comparación pareada de respuestas en el conjunto de prueba

3.12 Plan de análisis de datos

El análisis principal utilizará la etiqueta adjudicada de aceptabilidad para cada respuesta. Se calcularán las proporciones de respuestas aceptables en la condición original y en la condición QLoRA, globalmente y por variedad, junto con la diferencia absoluta entre condiciones y su intervalo de confianza del 95 %.

Como las dos respuestas corresponden a la misma pregunta, el contraste principal será pareado. Para el resultado dicotómico se propone la prueba bilateral de McNemar; si el número de pares discordantes es bajo, se utilizará su versión exacta (McNemar, 1947). Para las puntuaciones ordinales adjudicadas de cada dimensión se presentarán distribuciones y se aplicará, como análisis secundario exploratorio, la prueba de rangos con signo de Wilcoxon por pares (Wilcoxon, 1945); se interpretará con cautela por el carácter ordinal de la escala y sus posibles empates. Los análisis por variedad se informarán por separado; si se realizan varios contrastes secundarios, se controlará el error por comparaciones múltiples con el procedimiento de Holm (Holm, 1979).

Se utilizará un nivel de significación bilateral de $\alpha = 0{,}05$ para el contraste principal. Las medidas técnicas —duración del entrenamiento, número de parámetros entrenables, latencia y memoria máxima— se resumirán de forma descriptiva y no se usarán para afirmar una mejora de calidad.

La concordancia entre evaluadores se estimará con kappa ponderado para las dimensiones ordinales y kappa de Cohen para la clasificación dicotómica, antes de adjudicar discrepancias (Cohen, 1960, 1968). Se reportarán los desacuerdos y el procedimiento de resolución; las puntuaciones de varios evaluadores no se tratarán como observaciones independientes.

La meta de 160 preguntas de prueba es provisional. El tamaño definitivo se justificará mediante precisión o potencia con información del piloto y una diferencia mínima de interés establecida antes del análisis final. Si no se alcanza precisión suficiente, los resultados se presentarán como exploratorios y se evitarán conclusiones de ausencia de efecto basadas únicamente en un valor de significación. Las métricas automáticas de similitud no sustituirán la evaluación humana ni serán el resultado principal.

3.13 Gestión de datos y consideraciones éticas

Se mantendrá un registro de las fuentes, licencias, transformaciones, exclusiones, particiones, versiones del modelo y decisiones de análisis. Los archivos de evaluación conservarán identificadores seudónimos y las puntuaciones originales, además de las decisiones de adjudicación. Se establecerán copias de seguridad y acceso restringido a los datos de evaluación.

No se recopilarán datos personales sensibles mediante las preguntas. Si se invita a hablantes o evaluadores a participar, se explicarán el propósito, el uso de sus aportes y las condiciones de almacenamiento, y se solicitará su consentimiento. Antes de iniciar esa participación se confirmará si corresponde revisión o autorización ética institucional. Solo se redistribuirán recursos cuya licencia lo permita; las fuentes restringidas se citarán y describirán sin publicar sus contenidos protegidos.

CAPÍTULO IV ESTUDIO DE FACTIBILIDAD

4.1 Enfoque adoptado

4.2 Factibilidad técnica

4.2.1 Hardware e inferencia local

4.2.2 Estrategia de datos

4.2.3 Herramientas y software

4.3 Factibilidad económica

4.4 Factibilidad operativa

4.5 Viabilidad y sostenibilidad

REFERENCIAS

Amidei, J., Piwek, P., & Willis, A. (2019). The Use of Rating and Likert Scales in Natural Language Generation Human Evaluation Tasks: A Review and Some Recommendations. *Proceedings of the 12th International Conference on Natural Language Generation*, 397-402. https://doi.org/10.18653/v1/W19-8648

Asillo Congora, J., Santisteban, J., & Lazo Vasquez, R. (2025). UCSP Submission to the AmericasNLP 2025 Shared Task. *Proceedings of the Fifth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, 84-91. https://doi.org/10.18653/v1/2025.americasnlp-1.9

Chen, P., Yu, S., Guo, Z., & Haddow, B. (2024). Is It Good Data for Multilingual Instruction Tuning or Just Bad Multilingual Evaluation for Large Language Models? *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, 9706-9726. https://doi.org/10.18653/v1/2024.emnlp-main.542

Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. *Educational and Psychological Measurement*, *20*(1), 37-46. https://doi.org/10.1177/001316446002000104

Cohen, J. (1968). Weighted Kappa: Nominal Scale Agreement Provision for Scaled Disagreement or Partial Credit. *Psychological Bulletin*, *70*(4), 213-220. https://doi.org/10.1037/h0026256

Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. *Advances in Neural Information Processing Systems*, *36*, 10088-10115. https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract-Conference.html

Dhawan, A., Driggers-Ellis, C., Grant, C., & Wang, D. Z. (2026). Improving Indigenous Language Machine Translation with Synthetic Data and Language-Specific Preprocessing. *Proceedings for the Ninth Workshop on Technologies for Machine*

Translation of Low Resource Languages (LoResMT 2026), 119-126. https://doi.org/10.18653/v1/2026.loresmt-1.10

Garcia Gilabert, J., Sant, A., Escolano, C., De Luca Fornaciari, F., Mash, A., & Melero, M. (2024). BSC Submission to the AmericasNLP 2024 Shared Task. *Proceedings of the 4th Workshop on Natural Language Processing for Indigenous Languages of the Americas (AmericasNLP 2024)*, 143-149. https://doi.org/10.18653/v1/2024.americasnlp-1.17

Holm, S. (1979). A Simple Sequentially Rejective Multiple Test Procedure. *Scandinavian Journal of Statistics*, *6*(2), 65-70. https://www.jstor.org/stable/4615733

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-Rank Adaptation of Large Language Models. *International Conference on Learning Representations*. https://openreview.net/forum?id=nZeVKeeFYf9

Köksal, A., Thaler, M., Imani, A., Üstün, A., Korhonen, A., & Schütze, H. (2025). MURI: High-Quality Instruction Tuning Datasets for Low-Resource Languages via Reverse Instructions. *Transactions of the Association for Computational Linguistics*, *13*, 1032-1055. https://doi.org/10.1162/tacl.a.18

Liu, C., Zhang, W., Zhao, Y., Luu, A. T., & Bing, L. (2025). Is Translation All You Need? A Study on Solving Multilingual Tasks with Large Language Models. *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies*, 9594-9614. https://doi.org/10.18653/v1/2025.naacl-long.485

McNemar, Q. (1947). Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages. *Psychometrika*, *12*(2), 153-157. https://doi.org/10.1007/BF02295996

Ministerio de Educación. (2021). *Urin Qichwa Qillqay Yachana Mayt'u: Manual de escritura quechua sureño*. Dirección General de Educación Básica Alternativa, Intercultural Bilingüe y de Servicios Educativos en el Ámbito Rural. https://repositorio.minedu.gob.pe/handle/20.500.12799/7190

Orcotoma Mormontoy, G. C., Leon Nuñez, L., & Espetia Huamanga, H. (2025). Towards the creation of a Collao Quechua–Spanish parallel corpus using optical character

recognition. *Proceedings of the Workshop on Beyond English: Natural Language Processing for All Languages in an Era of Large Language Models*, 1-6. https://aclanthology.org/2025.globalnlp-1.1/

Pocco, P., & Oncevay, A. (2026). On the Robustness of Morphosyntactic Transformation with Large Language Models: The Case of Quechua Collao. *Proceedings of the Sixth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, 128-146. https://doi.org/10.18653/v1/2026.americasnlp-6.12

Quispe Callañaupa, M. D., Toledo Bernal, M. E., Torres Bautista, R. N., & Pumaccahua Huallpa, P. M. (2026). Optimization of Voice Translation Systems for Indigenous Languages: Retraining the NLLB-200 Model for the Quechua–Spanish Pair. *Proceedings of the 23rd International Conference on Spoken Language Translation (IWSLT 2026)*, 316-317. https://doi.org/10.18653/v1/2026.iwslt-1.35

Qwen Team. (2024). *Qwen2.5-0.5B-Instruct* [Model card]. https://huggingface.co/Qwen/Qwen2.5-0.5B-Instruct

van der Lee, C., Gatt, A., van Miltenburg, E., Wubben, S., & Krahmer, E. (2019). Best Practices for the Human Evaluation of Automatically Generated Text. *Proceedings of the 12th International Conference on Natural Language Generation*, 355-368. https://doi.org/10.18653/v1/W19-8643

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, *30*, 5998-6008. https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html

Wilcoxon, F. (1945). Individual Comparisons by Ranking Methods. *Biometrics Bulletin*, *1*(6), 80-83. https://doi.org/10.2307/3001968

APÉNDICE A MATRIZ DE CONSISTENCIA

La Tabla 7 integra el problema, los objetivos, la hipótesis, el indicador principal y el método previsto para comprobar su correspondencia.

Tabla 7

Matriz de consistencia de la investigación

Componente	Problema	Objetivo	Hipótesis, indicador y método
General	¿Qué efecto tiene adaptar mediante QLoRA un modelo de lenguaje compacto sobre la calidad de sus respuestas breves a preguntas cotidianas en quechua sureño?	Evaluar el efecto de adaptar mediante QLoRA un modelo de lenguaje compacto sobre la calidad de sus respuestas breves a preguntas cotidianas en quechua sureño.	H_1: existe diferencia en la proporción de respuestas aceptables; H_0: no existe diferencia. Indicador principal: aceptabilidad adjudicada. Comparación pareada con las mismas preguntas.
Específico 1	¿Cómo construir y validar un conjunto de preguntas y respuestas cotidianas que permita evaluar las variedades chanka y collao sin confundir datos de traducción con datos de generación de respuestas?	Construir y validar un corpus de preguntas y respuestas breves de uso cotidiano en quechua sureño, con identificación de las variedades chanka y collao y separación de datos para entrenamiento, validación y prueba.	Método: auditoría de fuentes, revisión lingüística y separación por grupos semánticos. Producto previsto: corpus documentado y particiones.
Específico 2	¿Cómo adaptar un único modelo de lenguaje compacto mediante QLoRA para la generación de respuestas breves en quechua sureño, considerando las restricciones computacionales disponibles?	Evaluar la factibilidad computacional y, si resulta viable, adaptar un único modelo de lenguaje compacto mediante QLoRA y documentar su configuración.	Método: prueba piloto y ajuste supervisado con QLoRA solo si el entrenamiento es viable. Producto previsto: registro del piloto y configuración.
Específico 3	¿Qué diferencias se observan en la aceptabilidad, pertinencia, corrección lingüística y adecuación a la variedad de las respuestas del modelo antes y después de la adaptación?	Comparar, mediante evaluación humana y análisis estadístico pareado, la calidad de las respuestas generadas por el mismo modelo antes y después de su adaptación, presentando resultados generales y diferenciados por variedad.	Indicador principal: aceptabilidad; dimensiones secundarias: pertinencia, corrección lingüística y adecuación a la variedad. Método: evaluación ciega y análisis pareado.

Nota. QLoRA, el tamaño del corpus, el equipo de evaluación y los parámetros son propuestas sujetas al piloto y a la disponibilidad comprobada. No se reportan datos ni resultados experimentales en esta matriz.

APÉNDICE B FICHA TÉCNICA DE REGISTRO EXPERIMENTAL

La Tabla 8 ofrece campos en blanco para documentar cada corrida, sus condiciones, las respuestas generadas y las observaciones técnicas.

Tabla 8
Ficha vacía para registrar una corrida experimental

Campo	**Registro al ejecutar**
Identificador de corrida	
Fecha y responsable	
Condición	Modelo original / modelo QLoRA
Modelo y revisión exacta	
Variedad y pregunta de prueba	Chanka / collao; identificador de pregunta: _____
Instrucción y parámetros de generación	
Versión del adaptador y parámetros de entrenamiento	Completar solo en la condición adaptada
Respuesta generada	
Latencia y memoria máxima	Registrar valores observados y unidad
Puntuaciones por criterio y evaluador seudónimo	Pertinencia / corrección / variedad; conservar cada valoración
Adjudicación y observaciones	Registrar discrepancias, decisión y cualquier error técnico

Nota. Formato en blanco. No contiene mediciones, salidas ni resultados previamente obtenidos.

APÉNDICE C RÚBRICA DE EVALUACIÓN DE RESPUESTAS

La Tabla 9 presenta los descriptores propuestos para las tres dimensiones de calidad y la regla preliminar de aceptabilidad, que se validará durante el piloto.

Tabla 9

Rúbrica propuesta para evaluar respuestas breves en quechua sureño

Dimensión	0: insuficiente	1: parcialmente adecuada	2: adecuada
Pertinencia	No responde a la pregunta o altera su intención.	Responde solo una parte o añade información que dificulta identificar la contestación.	Responde de forma directa a la intención de la pregunta.
Corrección lingüística	La formulación impide comprender la respuesta en la variedad indicada.	El sentido general se comprende, aunque requiere correcciones lingüísticas.	La respuesta es comprensible y lingüísticamente aceptable según el criterio acordado con hablantes.
Adecuación a la variedad	La respuesta no corresponde a la variedad solicitada o contiene formas que alteran su interpretación.	La variedad puede identificarse, pero hay mezcla o formas que requieren revisión.	La respuesta es adecuada para la variedad solicitada, admitiendo variantes documentadas.

Nota. Se clasifica como aceptable una respuesta con pertinencia = 2, corrección lingüística ≥ 1 y adecuación a la variedad ≥ 1. Una respuesta que no contesta la pregunta no es aceptable. La rúbrica se validará durante el piloto y se congelará antes de la evaluación final.

APÉNDICE D PLANTILLA DE REGISTRO DEL CORPUS

La Tabla 10 reúne los campos necesarios para identificar cada ejemplo, documentar su procedencia y registrar su variedad, revisión y partición.

Tabla 10
Campos propuestos para documentar los pares de pregunta y respuesta

Campo	Valor por completar	Uso en el estudio
Identificador		Seguimiento sin usar nombres personales.
Pregunta		Entrada idéntica para las dos condiciones de prueba.
Respuesta de referencia		Orienta la validación del ejemplo; no reemplaza la evaluación humana del modelo.
Variedad	Chanka / collao	Estratificación, asignación de evaluadores y presentación de resultados.
Dominio e intención		Descripción temática y comunicativa.
Fuente, licencia y procedencia		Auditoría de permisos y trazabilidad.
Revisión lingüística		Responsable seudónimo, estado y observaciones de validación.
Grupo semántico y partición	Entrenamiento / validación / prueba / piloto	Evita que paráfrasis o preguntas equivalentes se distribuyan entre conjuntos.

Nota. Plantilla vacía. Los ejemplos se incorporarán solo después de validar su variedad, respuesta, procedencia y permiso de uso.