UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO

FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA

ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

Diseño e implementación de una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao

Curso:

Seminario de Investigación II

Docente:

Msc. Raúl Huillca Huallparimachi

Asesor/a de tesis:

Por designar

Para optar al Título Profesional de:

Ingeniero Informático y de Sistemas

Presentado por:

Br. Edmil Jampier Saire Bustamante

Cusco – Perú

2026

RESUMEN

La propuesta aborda el diseño y evaluación de un asistente de generación contextualizada en Quechua Collao que pueda ejecutarse sin conexión a Internet. Se plantea una arquitectura que integra un modelo de lenguaje compacto, recuperación local de documentos y adaptación mediante QLoRA, condicionada a su viabilidad técnica. El estudio comparará el modelo base, la configuración con recuperación y la configuración integrada, bajo condiciones de ejecución documentadas. Se medirán la similitud de las respuestas con referencias documentadas, la pertinencia de los fragmentos recuperados, el respaldo de las respuestas en la evidencia y el costo computacional en el hardware disponible. La preparación de los datos considerará la identificación de la variedad lingüística y la trazabilidad de las fuentes. El trabajo es una propuesta: los resultados se obtendrán durante la ejecución experimental y no se anticipan en este documento.

Palabras clave: modelos de lenguaje compactos, generación aumentada por recuperación, Quechua Collao, QLoRA, inferencia local.

ABSTRACT

This research proposal addresses the design and evaluation of a contextualized generation assistant for Quechua Collao that can run without an Internet connection. It proposes an architecture combining a small language model, local document retrieval, and QLoRA adaptation, subject to technical feasibility. The study will compare the base model, the retrieval-augmented configuration, and the integrated configuration under documented execution conditions. It will measure response similarity against documented references, the relevance of retrieved passages, answer support in the evidence, and computational cost on the available hardware. Data preparation will account for language-variety identification and source traceability. This document presents a proposal; experimental results will be obtained during the study and are not anticipated here.

Keywords: small language models, retrieval-augmented generation, Quechua Collao, QLoRA, local inference.

ÍNDICE GENERAL

Resumen II

Abstract III

Índice general IV

Índice de figuras VIII

Índice de tablas IX

Índice de algoritmos X

Lista de abreviaturas XI

Lista de símbolos XII

Índice de ecuaciones XIII

Índice de anexos XIV

Glosario de términos XV

Introducción XVII

I. Generalidades 1

1.1. Planteamiento del problema 1

1.1.1. Descripción del problema 1

1.1.2. Identificación del problema 2

1.1.3. Formulación del problema 2

1.2. Objetivos de la investigación 3

1.2.1. Objetivo general 3

1.2.2. Objetivos específicos 3

1.3. Hipótesis de la investigación 4
1.3.1. Hipótesis general 4
1.3.2. Hipótesis específicas 4
1.4. Justificación de la investigación 5
1.5. Alcances y limitaciones 6
1.5.1. Alcances 6
1.5.2. Limitaciones 7
1.6. Matriz de consistencia metodológica 7

II. Marco teórico y estado del arte **9**
2.1. Estado del arte 9
2.1.1. Recursos lingüísticos para quechua 9
2.1.2. Uso de contexto en tareas de quechua 9
2.1.3. Modelos compactos, RAG y operación local 10
2.1.4. Adaptación eficiente de modelos 10
2.1.5. Síntesis y brecha de investigación 10
2.2. Fundamentos teóricos 11
2.2.1. Modelos compactos e inferencia local 11
2.2.2. Generación aumentada por recuperación 12
2.2.3. Adaptación de bajo rango y QLoRA 13
2.2.4. Recursos digitales y variación del Quechua Collao 13
2.2.5. Evaluación de generación y recuperación 14
2.3. Definición de términos básicos 15

III. Metodología de la investigación **16**
3.1. Enfoque, tipo y diseño de investigación 16
3.1.1. Enfoque de investigación 16
3.1.2. Tipo de investigación 16
3.1.3. Diseño de investigación 16
3.2. Variables y operacionalización 17

3.2.1. Identificación de variables 17
3.2.2. Matriz de operacionalización de variables 17
3.3. Unidades de análisis y selección de consultas 18
3.3.1. Unidad de análisis 18
3.3.2. Población y muestra 19
3.3.3. Preparación del corpus y prevención de contaminación 19
3.4. Técnicas e instrumentos de recolección 20
3.5. Procedimiento metodológico 20
3.6. Protocolo de evaluación 21
3.6.1. Métricas de calidad lingüística 22
3.6.2. Métricas de recuperación y fidelidad 22
3.6.3. Métricas de eficiencia 22
3.7. Métodos de análisis de datos 23
3.8. Aspectos éticos y de gestión de datos 23

IV. Estudio de factibilidad **24**

4.1. Enfoque adoptado 24
4.2. Factibilidad técnica 24
4.2.1. Hardware e inferencia local 24
4.2.2. Estrategia de datos 24
4.2.3. Herramientas y software 24
4.3. Factibilidad económica 24
4.4. Factibilidad operativa 24
4.5. Viabilidad y sostenibilidad 24

Referencias **25**

Anexos **27**

Anexo 1: Matriz de consistencia lógica 27
Anexo 2: Ficha técnica de registro experimental 28
Anexo 3: Rúbrica de revisión lingüística y factual 29

Anexo 4: Plantilla del banco de consultas de evaluación 30

ÍNDICE DE FIGURAS

1. Problema central, factores por examinar y dimensiones por evaluar 2
2. Objetivo general y secuencia de los objetivos específicos 4

ÍNDICE DE TABLAS

1. Matriz de consistencia metodológica del proyecto de tesis 8

2. Síntesis comparativa de antecedentes relevantes 11

3. Matriz de operacionalización de variables 18

4. Matriz de consistencia lógica de la investigación 27

5. Ficha para registrar una corrida experimental 28

6. Rúbrica para revisar respuestas generadas en Quechua Collao 29

7. Estructura prevista para documentar consultas de evaluación 30

ÍNDICE DE ALGORITMOS

1. Flujo de inferencia propuesto para SLM–RAG con adaptación QLoRA 14

LISTA DE ABREVIATURAS

Abreviatura / Sigla	Significado y Descripción Técnica
AMLQ	Academia Mayor de la Lengua Quechua (Cusco, Perú).
BLEU	*Bilingual Evaluation Understudy* (métrica de concordancia de n-gramas léxicos).
chrF++	*Character n-gram F-score with word n-grams*, métrica de similitud léxica a nivel de caracteres y palabras.
CPU	*Central Processing Unit* (unidad central de procesamiento).
DSR	*Design Science Research* (marco metodológico de investigación en ciencias del diseño).
FAISS	*Facebook AI Similarity Search* (biblioteca de búsqueda vectorial densa eficiente).
GPU	*Graphics Processing Unit* (unidad de procesamiento gráfico acelerado).
HE	Hipótesis Específica (HE1, HE2, HE3).
HG	Hipótesis General de la investigación.
LLM	*Large Language Model* (modelo de lenguaje de gran escala).
LoRA	*Low-Rank Adaptation* (técnica de adaptación mediante descomposición de bajo rango).
ODS	Objetivos de Desarrollo Sostenible de las Naciones Unidas (ODS 9 y ODS 10).
OE	Objetivo Específico (OE1, OE2, OE3).
OG	Objetivo General de la investigación.
P@k	*Precision at k*: proporción de fragmentos pertinentes entre los primeros k recuperados.
PE	Problema Específico (PE1, PE2, PE3).
PG	Problema General de la investigación.
PLN	Procesamiento de Lenguaje Natural (equivalente a NLP en inglés).
QLoRA	*Quantized Low-Rank Adaptation* (adaptación de bajo rango sobre un modelo base cuantizado; su viabilidad se comprobará en el entorno).
RAG	*Retrieval-Augmented Generation* (generación aumentada por recuperación).
RAGAS	*Retrieval Augmented Generation Assessment*; marco de métricas para evaluación de sistemas RAG, cuya aplicabilidad al Quechua Collao deberá comprobarse.
RAM	*Random Access Memory* (memoria principal del sistema).
SLM	*Small Language Model* (modelo de lenguaje compacto; en este estudio, candidato de hasta 3B parámetros).
TPS	*Tokens Per Second* (rendimiento de generación de tokens por segundo).
VRAM	*Video Random Access Memory* (memoria gráfica de video dedicada).

LISTA DE SÍMBOLOS

Símbolo / Notación	Definición y Rol Computacional
W_0	Matriz de pesos preentrenada del SLM; se congelará durante el ajuste ($W_0 \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$).
ΔW	Matriz de actualización adaptativa acumulada sobre los pesos del modelo ($\Delta W \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$).
A	Matriz de proyección de bajo rango inicializada de forma aleatoria ($A \in \mathbb{R}^{r \times d_{\text{in}}}$).
B	Matriz de proyección de bajo rango inicializada en ceros ($B \in \mathbb{R}^{d_{\text{out}} \times r}$).
r	Rango de las matrices de bajo rango, que se fijará durante el diseño experimental ($r \ll \text{mín}(d_{\text{out}}, d_{\text{in}})$).
α	Factor de escala de la actualización LoRA, cuyo valor se especificará en la configuración experimental.
x	Vector de activación de entrada a la capa Transformer (tokens de consulta + contexto RAG).
h	Vector de activación adaptado de salida: $h = W_0 x + \frac{\alpha}{r}(B \cdot A)x$.
Q, K, V	Matrices de Consulta (*Query*), Clave (*Key*) y Valor (*Value*) en las capas de autoatención.
W_q, W_k, W_v, W_o	Matrices de proyección lineal de los cabezales de atención objetivo del ajuste fino QLoRA.
d_k	Dimensión de escalamiento de los vectores de clave en el producto escalar de autoatención.
$\mathbf{e}_q$	Vector de incrustación denso (*embedding*) de la consulta formulada por el usuario.
$\mathbf{e}_d$	Vector de incrustación denso del fragmento documental indexado en la base de conocimiento.
q	Consulta de entrada al sistema de recuperación.
d	Fragmento documental candidato para una consulta.
$\text{sim}(q, d)$	Similitud del coseno normalizada entre los vectores de consulta y fragmento documental.
$\mathcal{D}$	Colección curada de fragmentos documentales bilingües indexados en la base vectorial local.
C_k	Conjunto de los k fragmentos documentales de mayor afinidad semántica recuperados.
$P@k$	Proporción de fragmentos pertinentes en el conjunto de los primeros k resultados recuperados.

ÍNDICE DE ECUACIONES

Ecuación	Descripción Matemática y Teórica	Página
Ecuación (1)	Métrica de similitud del coseno para recuperación densa de fragmentos documentales	12
Ecuación (2)	Precisión entre los primeros k fragmentos recuperados (P@k)	12
Ecuación (3)	Descomposición de bajo rango para adaptación eficiente de pesos (LoRA / QLoRA)	13
Ecuación (4)	Proyecciones lineales de consulta (Q), clave (K) y valor (V) en capas Transformer	13
Ecuación (5)	Mecanismo de autoatención con producto escalar escalado (*Scaled Dot-Product Attention*)	13
Ecuación (6)	Proyección lineal de salida multicabezal del bloque de atención Transformer	13

ÍNDICE DE ANEXOS

Identificador	Título y Contenido del Anexo	Página
Anexo 1	Matriz de consistencia lógica de la investigación	27
Anexo 2	Ficha técnica para registro de corridas experimentales	28
Anexo 3	Rúbrica de revisión lingüística y factual	29
Anexo 4	Banco de consultas patrón de evaluación	30

GLOSARIO DE TÉRMINOS

Aglutinación: Proceso morfológico en el que una palabra puede incorporar varios sufijos, cada uno con una función gramatical o discursiva.

Alucinación: Respuesta generada que contiene afirmaciones no sustentadas por la información disponible o por las fuentes consultadas.

Cuantización: Representación de los pesos de un modelo con menor precisión numérica para reducir el espacio requerido en memoria; su efecto sobre calidad y velocidad debe medirse.

Design Science Research (DSR): Enfoque de investigación que diseña, construye y evalúa un artefacto para atender un problema delimitado.

Embedding: Representación vectorial de una consulta o fragmento documental usada para calcular similitud.

Fidelidad al contexto: Grado en que las afirmaciones de una respuesta se sustentan en el contexto recuperado, según una métrica o protocolo definido.

Generación aumentada por recuperación (RAG): Arquitectura que recupera documentos externos y los incorpora como contexto para una respuesta generada.

Inferencia local: Ejecución del modelo en el equipo del usuario sin enviar la consulta a un servicio remoto durante la generación.

NormalFloat de 4 bits (NF4): Formato de cuantización de 4 bits descrito como parte del método QLoRA.

QLoRA: Método que combina un modelo base cuantizado y adaptadores entrenables de bajo rango; su viabilidad depende del modelo, la configuración y el hardware.

Quechua Collao: Variedad quechua delimitada como objeto de este estudio; los datos deberán conservar esta etiqueta y su procedencia.

Small Language Model (SLM): Modelo de lenguaje compacto; para esta propuesta se considera como candidato uno de hasta tres mil millones de parámetros.

INTRODUCCIÓN

El procesamiento del lenguaje natural (PLN) permite analizar y generar textos mediante modelos computacionales, pero su aplicación depende también de contar con recursos que representen la variedad estudiada. Para Quechua Collao se han desarrollado corpus paralelos y recursos léxicos que aportan una base para la investigación, aunque no constituyen por sí mismos un sistema de generación contextualizada (Duran & Silberztein, 2026; Orcotoma Mormontoy et al., 2025). A partir de estos recursos, el plan propone estudiar un modelo de lenguaje compacto (SLM) con generación aumentada por recuperación (RAG), que incorpora documentos locales como contexto para producir respuestas sin conexión.

La utilidad de esta arquitectura depende de la pertinencia de los documentos recuperados y del uso que el modelo haga de ellos. También se examinará el aporte de QLoRA, únicamente si el ajuste y la inferencia con el adaptador resultan viables (Dettmers et al., 2023). Los antecedentes disponibles abordan partes distintas de este problema: los estudios sobre contexto en quechua se centran en traducción al español (Court & Elsner, 2024), mientras que las evaluaciones de RAG offline corresponden a otros dominios (Hevia et al., 2025). Por tanto, sus resultados orientan el estudio, pero no permiten anticipar el desempeño de la generación contextualizada en Quechua Collao.

En esta revisión preliminar, el vacío se plantea como la falta de evidencia experimental comparable sobre SLM–RAG local para generar respuestas en Quechua Collao y sobre el aporte adicional de QLoRA cuando pueda ejecutarse. Esta delimitación es provisional y deberá contrastarse con una búsqueda bibliográfica actualizada. El problema y la pregunta general se desarrollan en el apartado de formulación del problema.

Para abordar ese problema, el objetivo es diseñar e implementar una arquitectura SLM–RAG para la generación contextualizada en Quechua Collao dentro de un entorno computacional offline, y evaluar el aporte adicional de QLoRA si el ajuste y la inferencia con adaptador son viables. Se busca aportar evidencia sobre la interacción entre recuperación documental y adaptación, sin presuponer la viabilidad de QLoRA ni la superioridad de una configuración.

La evaluación comparará el modelo base, SLM–RAG y, si resulta viable, SLM–RAG–QLoRA,

utilizando consultas y fuentes trazables. Se examinarán la recuperación de información pertinente, la similitud y el sustento de las respuestas, y la eficiencia computacional. Este resumen anticipa el enfoque comparativo; los indicadores, las condiciones y los procedimientos se especifican en la metodología.

El plan comprende cinco capítulos: generalidades; marco teórico y estado del arte; metodología; estructura del estudio de factibilidad; y aspectos administrativos. Este avance desarrolla el contenido hasta metodología, conserva el capítulo de factibilidad como esquema y deja los aspectos administrativos para una revisión posterior. Después se presentan las referencias y los anexos.

CAPÍTULO I GENERALIDADES

1.1. Planteamiento del problema

1.1.1. Descripción del problema

El desarrollo de herramientas computacionales para lenguas con menos recursos digitales enfrenta limitaciones de datos, representación y evaluación. Para el quechua, los trabajos disponibles documentan tanto la creación de corpus como la formalización de recursos léxicos, y también muestran que la variedad y el tipo de información lingüística afectan las tareas de traducción automática (Court & Elsner, 2024; Duran & Silberztein, 2026; Orcotoma Mormontoy et al., 2025). Estos antecedentes no permiten atribuir una única causa ni una magnitud uniforme a las dificultades de procesamiento del Quechua Collao.

Los modelos que dependen de servicios remotos no pueden atender solicitudes cuando el dispositivo carece de conexión. La ejecución local evita esa dependencia durante la inferencia, pero obliga a trabajar dentro de los límites de memoria y procesamiento disponibles; las técnicas de cuantización pueden reducir el tamaño del modelo a costa de compromisos que deben medirse en el equipo objetivo (Xu et al., 2024).

La generación aumentada por recuperación (RAG) incorpora fragmentos de documentos al contexto de entrada para que la respuesta pueda apoyarse en información externa. Su desempeño depende de la recuperación y de la capacidad del modelo para usar el contexto. En una evaluación de tutoría educativa, un modelo pequeño tuvo dificultades con contextos extensos o irrelevantes; ese resultado evidencia un riesgo de diseño, no una conclusión directa sobre Quechua Collao (Hevia et al., 2025).

El ajuste de bajo rango sobre modelos cuantizados ofrece una alternativa al entrenamiento completo, pero sus necesidades de hardware dependen del tamaño del modelo y de la configuración. El trabajo original de QLoRA informa resultados en equipos con recursos considerablemente mayores que la GPU local de 4 GB considerada en este proyecto, por lo que no se asumirá que el ajuste será viable antes de probarlo (Dettmers et al., 2023). El problema de

investigación consiste, por tanto, en determinar cómo se comporta una arquitectura compacta que combine recuperación local y adaptación bajo las restricciones reales del entorno.

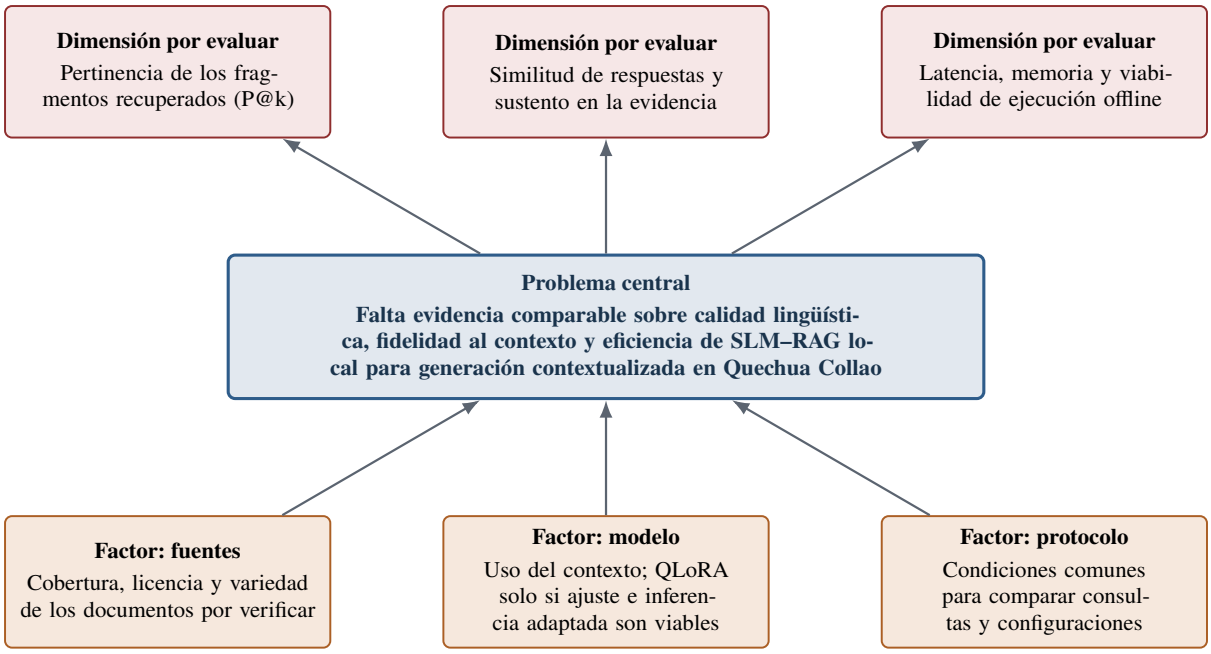
1.1.2. Identificación del problema

El problema central es la falta de evidencia experimental comparable sobre la calidad lingüística, la fidelidad al contexto recuperado y la eficiencia computacional de una arquitectura local SLM–RAG para Quechua Collao. Se evaluará el aporte adicional de QLoRA solo si el ajuste y la inferencia con el adaptador son viables en el entorno disponible.

La Figura 1 organiza los factores del estudio y las dimensiones cuyo comportamiento aún debe evaluarse. Las conexiones expresan relaciones por contrastar, no causas ni efectos ya demostrados.

Figura 1

Problema central, factores por examinar y dimensiones por evaluar



1.1.3. Formulación del problema

Problema general. ¿Cómo se comporta una arquitectura SLM–RAG para la generación contextualizada en Quechua Collao dentro de un entorno computacional offline, y qué aporte adicional presenta QLoRA si el ajuste y la inferencia con adaptador son viables?

Problemas específicos.

- **PE1 (Datos y Recuperación):** ¿Cómo estructurar e indexar semánticamente una base de conocimiento documental bilingüe para optimizar la recuperación local en Quechua Collao?
- **PE2 (Núcleo Técnico y Adaptación):** Si el ajuste y la inferencia con adaptador son viables, ¿qué diferencia produce QLoRA en la fidelidad al contexto de una configuración SLM–RAG bajo las mismas condiciones locales?
- **PE3 (Evaluación Computacional):** ¿Qué diferencias de similitud de respuesta, fidelidad al contexto y eficiencia computacional se observan entre SLM base, SLM–RAG y SLM–RAG–QLoRA, cuando esta última condición sea viable?

1.2. Objetivos de la investigación

1.2.1. Objetivo general

Diseñar e implementar una arquitectura SLM–RAG para la generación contextualizada en Quechua Collao dentro de un entorno computacional offline, y evaluar el aporte adicional de QLoRA si el ajuste y la inferencia con adaptador son viables.

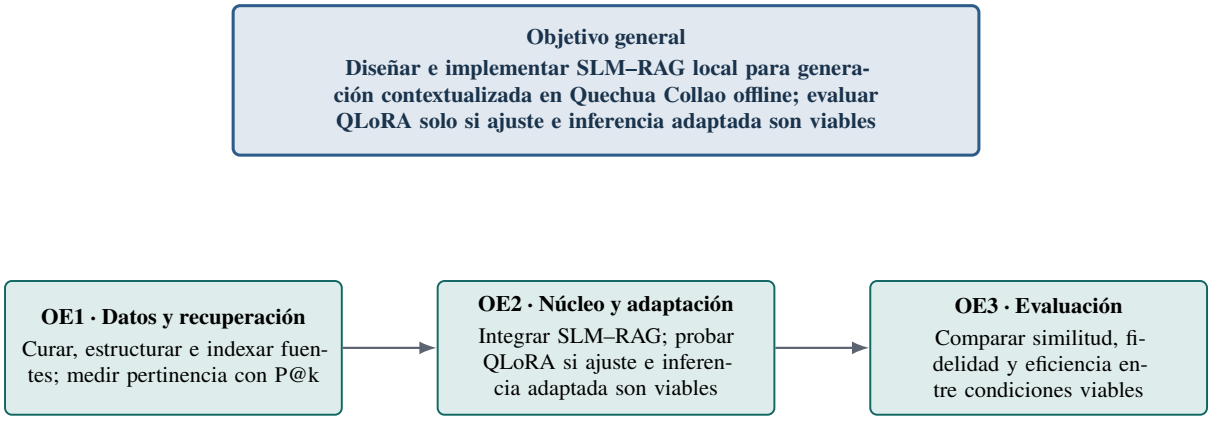
1.2.2. Objetivos específicos

- **OE1 (Datos y Recuperación):** Curar, estructurar e indexar semánticamente una base de conocimiento documental bilingüe para optimizar la recuperación local en Quechua Collao.
- **OE2 (Núcleo Técnico y Adaptación):** Implementar e integrar adaptadores QLoRA en la configuración SLM–RAG y comparar su fidelidad al contexto con la configuración SLM–RAG sin adaptación, si el ajuste y la inferencia con el adaptador son viables en el entorno local.

- **OE3 (Evaluación Computacional):** Comparar SLM base, SLM–RAG y SLM–RAG–QLoRA, cuando esta última condición sea viable, mediante indicadores de similitud de respuesta, fidelidad al contexto y eficiencia computacional.

La Figura 2 presenta el objetivo general y la secuencia de trabajo de los objetivos específicos: preparar los datos y la recuperación, integrar el núcleo técnico y evaluar las condiciones viables. Los ODS 9 y 10 se mantienen como contexto motivacional en la justificación; el estudio no los incorpora como fines ni mide sus impactos.

Figura 2
Objetivo general y secuencia de los objetivos específicos



1.3. Hipótesis de la investigación

1.3.1. Hipótesis general

En las condiciones de prueba definidas, si QLoRA resulta viable, la configuración SLM–RAG–QLoRA obtendrá mayor fidelidad al contexto y similitud con las respuestas de referencia que SLM–RAG; la evaluación también describirá sus diferencias frente al SLM base y su costo computacional.

1.3.2. Hipótesis específicas

- **HE1 (Datos y recuperación):** Con las consultas y etiquetas de relevancia definidas, la indexación semántica local recuperará una mayor proporción de fragmentos pertinentes

que la búsqueda léxica de referencia.

- **HE2 (Núcleo técnico y adaptación):** Si el ajuste QLoRA y la inferencia con el adaptador son viables, SLM–RAG–QLoRA obtendrá mayor fidelidad al contexto que SLM–RAG, manteniendo constantes el modelo base, las fuentes, las consultas y los parámetros de generación.
- **HE3 (Evaluación computacional):** Si las tres configuraciones pueden ejecutarse, SLM–RAG–QLoRA obtendrá mayor similitud con las respuestas de referencia y mayor fidelidad al contexto que SLM base y SLM–RAG, según las métricas preestablecidas.

1.4. Justificación de la investigación

La investigación se justifica por la necesidad de estudiar alternativas de generación que puedan ejecutarse sin conexión y apoyarse en documentos trazables en Quechua Collao. La propuesta se organiza desde cuatro perspectivas de ingeniería:

- **Justificación teórica:** Examina la relación entre recuperación documental, modelos compactos y adaptación de bajo rango en una tarea de generación para Quechua Collao. Los antecedentes sobre traducción de quechua muestran que el tipo de contexto puede influir de manera distinta en el resultado, por lo que la propuesta requiere una evaluación específica (Court & Elsner, 2024).
- **Justificación práctica:** El prototipo se diseñará para funcionar localmente y sin conexión durante la inferencia. Su utilidad y calidad deberán medirse; el plan no presupone que las respuestas serán siempre precisas ni que todos los componentes podrán ejecutarse en la GPU local de 4 GB.
- **Justificación metodológica:** Propone pruebas computacionales comparativas para medir el comportamiento del modelo base, la recuperación local y la adaptación QLoRA mediante indicadores de calidad y eficiencia.
- **Justificación tecnológica y social:** El posible aporte se relaciona con el acceso a tecnologías locales y con la disponibilidad de recursos lingüísticos. El vínculo con los ODS 9

y 10 se plantea como motivación, no como un impacto social que el experimento vaya a medir (United Nations General Assembly, 2015):

- **ODS 9 — Industria, innovación e infraestructura:** Se vincula con la exploración de una arquitectura de procesamiento local y eficiente.
- **ODS 10 — Reducción de las desigualdades:** Se vincula con la investigación de herramientas digitales para una lengua originaria; el proyecto no medirá reducción de brechas sociales.

1.5. Alcances y limitaciones

1.5.1. Alcances

El presente estudio abarca el diseño, implementación y evaluación experimental de una arquitectura SLM–RAG con QLoRA para inferencia local offline en Quechua Collao:

- **Alcance tecnológico:** Comprende la selección de un SLM abierto de la familia Qwen2.5 como candidato, la evaluación de cuantización e inferencia local y la integración con recuperación documental local. QLoRA se probará como componente condicionado a la viabilidad de memoria; la cuantización, el formato y el motor final se fijarán y documentarán antes de la comparación (Dettmers et al., 2023; Qwen Team, 2024).
- **Alcance lingüístico:** Se delimita a materiales identificados como Quechua Collao. Cada fuente y consulta conservará una etiqueta de idioma y variedad; no se extrapolarán resultados a otras variedades quechuas.
- **Alcance experimental y métrico:** La evaluación comparará similitud de respuesta mediante chrF++ (métrica de n-gramas de caracteres y palabras) y BLEU (*Bilingual Evaluation Understudy*), con SacreBLEU como implementación; también medirá recuperación y fidelidad al contexto mediante indicadores definidos y eficiencia local mediante latencia, tokens por segundo y consumo de RAM/VRAM (Popović, 2017; Post, 2018).

- **Alcance disciplinar:** Se ubica estrictamente dentro de la Ciencia de la Computación, la Inteligencia Artificial y la Ingeniería de Sistemas, en las subáreas de Procesamiento de Lenguaje Natural y Sistemas Distribuidos/Edge Computing.

1.5.2. Limitaciones

Se reconocen las siguientes limitaciones del estudio:

- **Disponibilidad y cobertura de datos:** Los recursos quechuas existentes no garantizan cobertura suficiente de todas las consultas o registros del Quechua Collao; la selección, licencia y trazabilidad del corpus limitarán el alcance de la evaluación (Duran & Silberztein, 2026; Orcotoma Mormontoy et al., 2025).

- **Variación lingüística y tokenización:** Los resultados no se generalizarán a otras variedades quechuas. La segmentación de subpalabras y sus efectos sobre memoria y calidad se medirán en el modelo elegido, sin asumir una razón fija frente al español.

- **Capacidad de hardware local:** La GPU disponible cuenta con 4 GB de VRAM. El ajuste QLoRA de un modelo compacto puede no ser viable en ese dispositivo; se informará cualquier reducción de alcance, uso de CPU u otra condición computacional, sin presentar las alternativas como equivalentes.

- **Modalidad textual:** El sistema procesa y genera exclusivamente texto digital; el procesamiento de habla (reconocimiento y síntesis de voz) queda fuera de la delimitación del presente proyecto.

1.6. Matriz de consistencia metodológica

La Tabla 1 resume la correspondencia entre los problemas, objetivos, hipótesis, variables e instrumentos propuestos.

Tabla 1

Matriz de consistencia metodológica del proyecto de tesis

Problema	Objetivo	Hipótesis	Variable(s)	Instrumento / Métrica
Nivel General				
¿Cómo se comporta una arquitectura SLM–RAG para la generación contextualizada en Quechua Collao dentro de un entorno computacional sin conexión, y qué aporte adicional presenta QLoRA si el ajuste y la inferencia con adaptador son viables?	Diseñar e implementar una arquitectura SLM–RAG para la generación contextualizada en Quechua Collao dentro de un entorno computacional sin conexión, y evaluar el aporte adicional de QLoRA si el ajuste y la inferencia con adaptador son viables.	Si QLoRA resulta viable, SLM–RAG–QLoRA obtendrá mayor fidelidad al contexto y similitud con las respuestas de referencia que SLM–RAG; también se describirá su diferencia frente al SLM base y su costo computacional.	**VI:** Configuración del sistema. **VD:** Calidad lingüística, fidelidad y eficiencia.	Consultas repetidas por configuración; métricas lingüísticas, de RAG y de rendimiento.
Nivel Específico (Fases Metodológicas de Ingeniería)				
PE1 (Datos y Recuperación): ¿Cómo estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación local en Quechua Collao?	**OE1:** Curar, estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación local en Quechua Collao.	**HE1:** La indexación semántica local recuperará una mayor proporción de fragmentos pertinentes que la búsqueda léxica de referencia, según las etiquetas definidas.	Precisión de recuperación (P@k) y trazabilidad de fuentes.	Índice local, consultas con documentos pertinentes identificados y registro de fragmentos recuperados.
PE2 (Núcleo y Adaptación): Si el ajuste y la inferencia con adaptador son viables, ¿qué diferencia produce QLoRA en la fidelidad al contexto de SLM–RAG bajo las mismas condiciones locales?	**OE2:** Implementar e integrar adaptadores QLoRA en SLM–RAG y comparar su fidelidad al contexto con SLM–RAG sin adaptación, si el ajuste y la inferencia con adaptador son viables.	**HE2:** Si el ajuste QLoRA y la inferencia con el adaptador son viables, SLM–RAG–QLoRA tendrá mayor fidelidad al contexto que SLM–RAG, manteniendo constantes modelo, fuentes, consultas y parámetros.	Fidelidad al contexto; latencia; tokens por segundo; RAM y VRAM.	Comparación pareada por consulta; ficha experimental y telemetría del mismo equipo.
PE3 (Evaluación Computacional): ¿Qué diferencias de similitud de respuesta, fidelidad al contexto y eficiencia se observan entre SLM, SLM–RAG y SLM–RAG–QLoRA, cuando esta última condición sea viable?	**OE3:** Comparar SLM base, SLM–RAG y SLM–RAG–QLoRA, cuando esta última condición sea viable, mediante indicadores de similitud de respuesta, fidelidad al contexto y eficiencia computacional.	**HE3:** Si las tres configuraciones pueden ejecutarse, SLM–RAG–QLoRA obtendrá mayor similitud con las respuestas de referencia y mayor fidelidad que SLM y SLM–RAG.	chrF++; BLEU; P@k; fidelidad al contexto; latencia y memoria.	Scripts documentados, revisión lingüística y factual, SacreBLEU y análisis de medidas repetidas.

CAPÍTULO II MARCO TEÓRICO Y ESTADO DEL ARTE

2.1. Estado del arte

La revisión reúne antecedentes directamente relacionados con los recursos lingüísticos para quechua, el uso de contexto en tareas de lenguaje, la inferencia local y la adaptación eficiente de modelos. Los estudios no son equivalentes en lengua, tarea ni entorno; por ello, sus resultados se usan para delimitar decisiones de diseño y preguntas de evaluación, no como prueba anticipada del desempeño del sistema propuesto.

2.1.1. Recursos lingüísticos para quechua

Orcotoma Mormontoy et al. (2025) describen un procedimiento para construir un corpus paralelo de Quechua Collao y español mediante la digitalización y el reconocimiento óptico de textos bilingües producidos en el ámbito de la Academia Mayor de la Lengua Quechua. El trabajo aporta una ruta para obtener recursos a partir de materiales impresos y documenta etapas de captura, etiquetado, preprocesamiento y reconocimiento. Su objetivo es formar un recurso para investigación lingüística y PLN; no evalúa un sistema de generación con recuperación documental.

Duran y Silberztein (2026) presentan un diccionario quechua–español de verbos con gramáticas morfosintácticas para representar flexión y derivación. El recurso descrito parte de 1 444 verbos quechuas y permite generar más de 2 777 000 formas verbales, además de establecer correspondencias con un diccionario verbal en español. Este antecedente puede orientar la normalización y consulta léxica, aunque un recurso verbal no sustituye un corpus educativo ni cubre por sí mismo todas las variantes de uso.

2.1.2. Uso de contexto en tareas de quechua

Court y Elsner (2024) estudian la traducción de quechua sureño al español con modelos de lenguaje y comparan distintos tipos de contexto recuperado. Sus experimentos indican que

las traducciones de morfemas pueden ayudar en ciertas condiciones, mientras que la información gramatical o ejemplos de corpus no mejoran de forma uniforme los resultados. La investigación es relevante porque muestra que añadir contexto no garantiza una respuesta mejor; sin embargo, su tarea es traducción hacia el español y sus conclusiones no se trasladan automáticamente a la generación en Quechua Collao.

2.1.3. Modelos compactos, RAG y operación local

En un sistema de tutoría educativa, Hevia et al. (2025) proponen combinar un modelo pequeño con recuperación de documentos y ejecución offline. Su estudio señala dificultades cuando el modelo recibe fragmentos extensos o irrelevantes. El dominio evaluado es material de biología en inglés, de modo que el antecedente identifica un riesgo para el diseño de RAG, pero no establece el comportamiento de un modelo en una lengua originaria.

La revisión de Xu et al. (2024) organiza técnicas para ejecutar modelos de lenguaje en dispositivos con recursos limitados, entre ellas cuantización, poda y destilación. Al tratarse de una revisión en arXiv, sirve como panorama técnico y no como una medición de latencia o memoria del equipo de este proyecto. La propuesta utilizará esas restricciones como variables de evaluación y reportará los valores medidos en el entorno real.

2.1.4. Adaptación eficiente de modelos

Dettmers et al. (2023) presentan QLoRA, que propaga gradientes a través de un modelo preentrenado cuantizado de 4 bits hacia adaptadores de bajo rango. El artículo muestra que este enfoque reduce el uso de memoria en sus experimentos, realizados con hardware de mayor capacidad que la GPU local de 4 GB considerada aquí. Por ello, QLoRA se incluye como condición que se intentará evaluar, sujeta a una prueba de viabilidad y sin dar por garantizado su entrenamiento en el equipo disponible.

2.1.5. Síntesis y brecha de investigación

Los antecedentes muestran avances complementarios: se han documentado recursos digitales y léxicos para quechua, se han estudiado los efectos de distintos tipos de contexto en traduc-

ción y se han propuesto sistemas offline con modelos pequeños en otros dominios. La revisión realizada para este plan todavía es preliminar y no permite sostener una afirmación definitiva de novedad. La pregunta que queda por evaluar es cómo se comporta, en Quechua Collao y bajo restricciones locales, la combinación de modelo compacto, recuperación documental y adaptación QLoRA, comparada con configuraciones de referencia.

Tabla 2
Síntesis comparativa de antecedentes relevantes

Estudio	Objeto	Hallazgo o aporte descrito	Límite para esta propuesta
Orcotoma Mormontoy et al. (2025)	Corpus Quechua Collao–español	Procedimiento de digitalización y OCR de textos bilingües	No evalúa generación ni RAG.
Duran & Silberztein (2026)	Diccionario verbal quechua–español	Recurso léxico con reglas de flexión y derivación	Se concentra en verbos; no es una base educativa general.
Court & Elsner (2024)	Traducción de quechua sureño al español	El efecto del contexto varía según su tipo y pertinencia	La tarea y la dirección lingüística difieren de la generación propuesta.
Hevia et al. (2025)	Tutoría con SLM y RAG offline	Identifica dificultades ante contexto extenso o irrelevante	Se estudia biología en inglés, no Quechua Collao.
Xu et al. (2024)	Modelos en dispositivos	Revisa técnicas de eficiencia y despliegue local	Es una revisión; no mide el hardware de este proyecto.
Dettmers et al. (2023)	Ajuste QLoRA	Describe ajuste eficiente sobre modelos cuantizados	Sus experimentos no demuestran viabilidad en una GPU de 4 GB.

Nota. Síntesis parafraseada de las fuentes citadas; las diferencias de tarea, lengua y hardware limitan la comparación directa.

2.2. Fundamentos teóricos

2.2.1. Modelos compactos e inferencia local

Los modelos de lenguaje estiman distribuciones de probabilidad sobre secuencias de tokens y generan texto de manera autorregresiva. Los modelos compactos reducen el número de parámetros respecto de modelos de mayor tamaño, lo que puede facilitar su ejecución local; esa

reducción no garantiza por sí sola calidad suficiente para una tarea o lengua determinada. La revisión de modelos en dispositivos describe cuantización y otras técnicas de compresión como herramientas para ajustarse a límites de memoria, con compromisos que deben observarse durante la evaluación (Xu et al., 2024).

Como línea base, el proyecto considera Qwen2.5-3B-Instruct, sujeto a la verificación de disponibilidad, licencia y compatibilidad con el entorno de inferencia local (Qwen Team, 2024). Se registrarán la revisión exacta y el formato utilizado; la familia y el tamaño del modelo no se tratarán como garantía de desempeño en Quechua Collao.

2.2.2. Generación aumentada por recuperación

La generación aumentada por recuperación combina un modelo generativo con una memoria documental externa. En una configuración densa, una consulta y cada fragmento se representan como vectores; la recuperación ordena los fragmentos según una función de similitud y entrega los más pertinentes al modelo generativo (Lewis et al., 2020). La similitud del coseno se expresa como:

$$\mathrm{sim}(q,d) = \frac{\mathbf{e}_q \cdot \mathbf{e}_d}{\|\mathbf{e}_q\| \, \|\mathbf{e}_d\|}. \tag{1}$$

La fórmula describe un criterio de ordenamiento, no una garantía de que el fragmento recuperado sea pertinente ni de que el modelo lo utilice correctamente. Por ello, la propuesta medirá por separado la recuperación documental y la calidad de las respuestas. El tamaño de los fragmentos, el modelo de embeddings, el índice y el número de resultados recuperados se mantendrán documentados como parámetros del experimento.

La precisión en los primeros k resultados se calculará como la proporción de fragmentos recuperados que fueron etiquetados como pertinentes para la consulta:

$$P@k = \frac{|\{d \in C_k : d \text{ es pertinente}\}|}{k}. \tag{2}$$

Esta métrica requiere etiquetar la pertinencia de los fragmentos para cada consulta antes de la evaluación.

2.2.3. Adaptación de bajo rango y QLoRA

La adaptación de bajo rango representa una actualización de pesos mediante dos matrices de rango reducido. En la formulación utilizada en este plan:

$$W = W_0 + \Delta W = W_0 + \frac{\alpha}{r}(BA), \tag{3}$$

donde W_0 son los pesos preentrenados, A y B son matrices entrenables, r es el rango y α es un factor de escala. Esta parametrización corresponde a LoRA (Hu et al., 2022). QLoRA conserva el modelo base cuantizado y adapta matrices de bajo rango; los beneficios de memoria comunicados en el artículo original deben interpretarse en las condiciones de hardware y entrenamiento evaluadas por sus autores (Dettmers et al., 2023).

En las capas de autoatención, las representaciones de entrada se proyectan en consultas, claves y valores:

$$Q = XW_q, \qquad K = XW_k, \qquad V = XW_v. \tag{4}$$

La operación de atención escalada se define como:

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V. \tag{5}$$

La salida de la proyección del bloque se representa como:

$$\text{Output} = \text{Attention}(Q,K,V)W_o. \tag{6}$$

Estas expresiones formalizan componentes de la arquitectura Transformer (Vaswani et al., 2017); no implican que adaptar todas las matrices sea la única estrategia. La ubicación de los adaptadores será un parámetro que deberá fijarse en la implementación.

2.2.4. Recursos digitales y variación del Quechua Collao

El Quechua Collao requiere que la preparación de datos conserve la identidad de la variedad y la procedencia de cada texto. Los antecedentes disponibles describen corpus obtenidos de ma-

teriales bilingües y recursos léxicos con reglas morfológicas, pero no sustituyen la validación de las fuentes que se incorporen al índice documental (Duran & Silberztein, 2026; Orcotoma Mormontoy et al., 2025). En tareas de traducción, además, se han observado diferencias según el tipo de contexto proporcionado, lo que respalda la necesidad de medir el comportamiento lingüístico para la tarea concreta y no inferirlo a partir de otra dirección de traducción (Court & Elsner, 2024).

2.2.5. Evaluación de generación y recuperación

La evaluación considerará dimensiones distintas: similitud de texto con referencias, recuperación de evidencia, correspondencia de las respuestas con el contexto y costo de ejecución. chrF++ combina n-gramas de caracteres y palabras (Popović, 2017); SacreBLEU facilita la comparación reproducible de puntajes BLEU cuando se registran sus parámetros (Post, 2018). Para recuperación aumentada, RAGAS propone métricas automatizadas como fidelidad y relevancia, que en este proyecto se usarán como indicadores complementarios y solo tras comprobar su aplicabilidad a Quechua Collao (Es et al., 2024). La latencia, el uso de RAM/VRAM y los tokens generados por segundo se obtendrán mediante medición instrumentada en el entorno descrito en el capítulo metodológico.

Entrada: Consulta q, colección documental indexada $\mathcal{D}$, modelo base W_0, adaptadores QLoRA opcionales $\{A_l, B_l\}$ y cantidad de fragmentos k.
Salida: Respuesta y en el idioma solicitado, acompañada de los fragmentos recuperados para su trazabilidad.

---

1. Codificar la consulta y obtener su representación vectorial $\mathbf{e}_q$.
2. Calcular similitudes con los fragmentos documentales y recuperar los k candidatos mejor posicionados.
3. Construir el contexto con instrucciones, fragmentos recuperados y consulta.
4. Generar una respuesta con el modelo base; activar la configuración adaptada solo si el ajuste y la inferencia con el adaptador son viables.
5. Registrar la respuesta, los fragmentos, la latencia y el consumo de memoria para la evaluación.

Algoritmo 1
Flujo de inferencia propuesto para SLM–RAG con adaptación QLoRA

2.3. Definición de términos básicos

Adaptador de bajo rango: Parámetros entrenables que representan una actualización de pesos mediante matrices de rango reducido.

Corpus paralelo: Colección de textos alineados entre dos lenguas o variedades, con correspondencia documentada entre sus segmentos.

Embedding: Representación vectorial de una consulta o fragmento, utilizada para calcular similitud y ordenar candidatos de recuperación.

Fidelidad al contexto: Grado en que las afirmaciones de una respuesta se sostienen en la evidencia recuperada; se tratará como indicador y se interpretará junto con sus limitaciones.

Inferencia local: Generación ejecutada en el dispositivo o equipo del usuario sin enviar la consulta a un servicio remoto durante la ejecución.

Quechua Collao: Variedad quechua delimitada por el estudio. Los datos y resultados del proyecto no se generalizarán automáticamente a otras variedades.

QLoRA: Método de ajuste eficiente que combina pesos base cuantizados con adaptadores de bajo rango entrenables (Dettmers et al., 2023).

Cuantización: Representación de pesos del modelo con menor precisión numérica para reducir su tamaño en memoria, con posibles cambios en el rendimiento.

RAG: Arquitectura que recupera documentos externos y los incorpora como contexto de entrada para la generación (Lewis et al., 2020).

SLM: Modelo de lenguaje compacto seleccionado considerando el tamaño, la licencia, la calidad esperada y los recursos del dispositivo.

CAPÍTULO III METODOLOGÍA DE LA INVESTIGACIÓN

3.1. Enfoque, tipo y diseño de investigación

3.1.1. Enfoque de investigación

El estudio tendrá un enfoque cuantitativo: comparará configuraciones de software mediante indicadores numéricos de recuperación, calidad de respuesta y eficiencia computacional. La unidad de evaluación será la respuesta producida para una consulta bajo una configuración determinada. No se medirán efectos educativos en estudiantes ni impactos sociales.

3.1.2. Tipo de investigación

La investigación será aplicada y tecnológica porque diseñará, implementará y evaluará un artefacto de software para una necesidad delimitada. El proceso seguirá las actividades de diseño, construcción y evaluación de artefactos de la investigación en ciencias del diseño (DSR, de *Design Science Research*) (Hevner et al., 2004).

3.1.3. Diseño de investigación

Se realizará un experimento computacional comparativo con medidas repetidas por consulta. Las condiciones de generación serán: (a) SLM base; (b) el mismo SLM con recuperación documental local (SLM–RAG); y (c) SLM–RAG con adaptadores QLoRA, únicamente si el entrenamiento y la inferencia adaptada son viables. Para la hipótesis de recuperación se contrastará, por separado, el índice semántico con una búsqueda léxica de referencia. En cada comparación se mantendrán constantes las consultas, los documentos disponibles, el hardware y los parámetros pertinentes. La comparación directa para estimar el aporte de QLoRA será SLM–RAG frente a SLM–RAG–QLoRA; la comparación con SLM base describirá el efecto conjunto de recuperación y adaptación.

3.2. Variables y operacionalización

3.2.1. Identificación de variables

- **Variable independiente:** configuración del sistema: SLM base, SLM–RAG o SLM–RAG–QLoRA, cuando esta última pueda ejecutarse.
- **Variables dependientes:** recuperación de fragmentos pertinentes, similitud de las respuestas con referencias validadas, fidelidad al contexto y eficiencia computacional.
- **Condiciones de control:** versión del modelo y del tokenizador, cuantización, colección documental, consultas, índice, plantilla de instrucciones, parámetros de generación, equipo y protocolo de medición. Los valores concretos se registrarán antes de la comparación.

3.2.2. Matriz de operacionalización de variables

La Tabla 3 describe los indicadores y el procedimiento previsto para obtenerlos. Las métricas automáticas de similitud se interpretarán como aproximaciones respecto de una referencia, no como una medida completa de corrección o fluidez.

Tabla 3
Matriz de operacionalización de variables

Variable	Operacionalización	Indicadores	Escala e instrumento
Configuración (independiente)	Condición aplicada a cada consulta: SLM, SLM–RAG o SLM–RAG–QLoRA, si es viable.	Identificador de configuración; modelo, índice y fragmentos usados.	Categórica; configuración versionada y ficha del Anexo 2.
Recuperación	Pertinencia de los primeros k fragmentos para cada consulta.	Precisión en los primeros k resultados (P@k), índice semántico frente a búsqueda léxica.	Numérica; banco de consultas, etiquetas de relevancia y registro del recuperador.
Respuesta y fidelidad	Comparación de cada salida con una respuesta de referencia y con la evidencia entregada al modelo.	chrF++; BLEU; fidelidad y recuperación de contexto, si se valida el evaluador automático.	Numérica; SacreBLEU, implementación documentada de las métricas RAG y revisión con la rúbrica del Anexo 3.
Eficiencia	Costo de ejecución por consulta y configuración en el mismo equipo.	Latencia; tokens generados por segundo; máximos de RAM y VRAM; errores de ejecución.	Numérica; temporizador, telemetría del sistema y ficha del Anexo 2.

Nota. Se registrarán las versiones de herramientas, los parámetros, las reglas de normalización y los valores de k. Las métricas RAG que dependan de un modelo evaluador solo se usarán de forma confirmatoria si se verifica su capacidad para evaluar respuestas en Quechua Collao.

3.3. Unidades de análisis y selección de consultas

3.3.1. Unidad de análisis

Para la evaluación de respuestas, la unidad de análisis será el par formado por una consulta y la respuesta generada bajo una configuración, junto con los fragmentos recuperados y el registro de ejecución. Para la comparación de recuperadores, la unidad será la consulta con sus etiquetas de pertinencia. Cada consulta se mantendrá emparejada entre las condiciones que se comparen.

3.3.2. Población y muestra

La población conceptual comprende consultas textuales que puedan responderse con fuentes autorizadas identificadas como Quechua Collao o español. La factibilidad propone un banco intencional de 100 consultas patrón; se conserva como meta de planificación, sujeta al inventario de fuentes y a un piloto. No proviene aún de un cálculo de potencia estadística. Se incluirán consultas con respuesta sustentable en una fuente rastreable y se excluirán las que requieran información ausente o ambigua en el corpus. Si se ejecuta QLoRA, las consultas de evaluación y sus respuestas de referencia se reservarán fuera de los ejemplos de ajuste; el tratamiento de documentos indexados y coincidencias con ejemplos de entrenamiento seguirá el procedimiento de la subsección siguiente.

3.3.3. Preparación del corpus y prevención de contaminación

Se inventariarán las fuentes propuestas en el estudio de factibilidad —corpus bilingües, recursos léxicos y textos abiertos— y se registrarán su procedencia, licencia, idioma y variedad. Los materiales obtenidos mediante reconocimiento óptico de caracteres (OCR) se revisarán antes de indexarlos; se conservarán los datos de procedencia y las correcciones aplicadas. Los documentos se limpiarán y segmentarán. La fuente del proyecto propone fragmentos de 250–400 tokens y recuperar tres fragmentos por consulta; ambos valores se tratarán como puntos de partida para el piloto, no como parámetros ya validados, y se fijarán antes de la evaluación comparativa.

La propuesta fuente también contempla pares de pregunta y respuesta generados con asistencia de modelos de lenguaje. Si se emplean, se identificarán como datos sintéticos y no se considerarán referencias correctas por el hecho de haber sido generados. Se contrastarán con fuentes trazables y se someterán a revisión lingüística competente antes de servir como ejemplos de ajuste o referencias de evaluación. Las consultas de evaluación y sus respuestas de referencia se mantendrán fuera del ajuste QLoRA. En cambio, los documentos con la evidencia necesaria para responderlas permanecerán disponibles en la base de conocimiento de las condiciones RAG, con el mismo contenido para SLM–RAG y SLM–RAG–QLoRA; se

registrarán coincidencias textuales relevantes entre datos de ajuste y documentos indexados. Así se evita excluir del índice la evidencia que el sistema debe recuperar.

3.4. Técnicas e instrumentos de recolección

La técnica principal será la ejecución controlada del prototipo con captura automatizada de consultas, respuestas, fragmentos recuperados, latencia, consumo de memoria y errores. Los instrumentos serán el inventario de fuentes, el banco de consultas del Anexo 4, la ficha de ejecución del Anexo 2, los scripts versionados de métricas y la rúbrica de revisión lingüística y factual del Anexo 3.

Antes de calcular métricas con referencias, se documentará para cada consulta su idioma y variedad, fuente, respuesta de referencia y evidencia pertinente. Una persona competente en Quechua Collao deberá revisar las referencias destinadas a medir similitud lingüística. Si esa revisión no se consigue, chrF++ y BLEU se informarán como similitud automática con referencias no validadas, y no como prueba suficiente de calidad lingüística. Una métrica automática de fidelidad que requiera un modelo juez se considerará exploratoria hasta comprobar, en un piloto documentado, que el juez puede evaluar el idioma y la variedad del estudio.

3.5. Procedimiento metodológico

El procedimiento conserva las tres fases y la correspondencia con los objetivos específicos de la presentación de objetivos:

1. **Fase 1 — Datos y recuperación (OE1):** inventariar las fuentes y sus licencias; etiquetar idioma, variedad y procedencia; revisar y depurar los documentos; pilotear la segmentación y el número de fragmentos recuperados; crear el índice semántico y una búsqueda léxica de referencia; y preparar consultas con sus fuentes y fragmentos pertinentes identificados.

2. **Fase 2 — Núcleo técnico y adaptación (OE2):** comprobar la inferencia local de Qwen2.5-3B-Instruct y del recuperador; fijar y registrar las versiones, el formato de

cuantización, las instrucciones y los parámetros de generación; integrar SLM y RAG; y realizar una prueba técnica preliminar de ajuste, exportación, carga e inferencia con QLoRA para determinar si puede ejecutarse la condición E3. Esta comprobación forma parte del procedimiento metodológico; el análisis global de factibilidad técnica, económica y operativa, así como de viabilidad y sostenibilidad, se desarrollará por separado en el capítulo IV. La fuente propone Q4_K_M/GGUF con `llama.cpp` para inferencia y contempla `bitsandbytes`/PEFT para el ajuste; son etapas y formatos distintos, y se verificará que la exportación y carga del adaptador sean compatibles. En este equipo se prevé evaluar WSL2 con Ubuntu para `bitsandbytes`. Si el ajuste o la inferencia adaptada fallan o no son reproducibles, se registrará el motivo y no se ejecutará la condición integrada.

3. **Fase 3 — Evaluación y análisis (OE3):** ejecutar el mismo banco bajo cada condición viable; registrar entradas, salidas, fragmentos y telemetría; calcular las métricas definidas; inspeccionar errores con criterios comunes; y conservar los scripts, parámetros y registros suficientes para repetir el procedimiento.

3.6. Protocolo de evaluación

Antes de la corrida comparativa se cerrará un protocolo que identifique el modelo y su revisión, cuantización de inferencia y de ajuste, tokenizador, motor de inferencia, modelo de embeddings, segmentación documental, valor de k, plantilla de instrucciones y parámetros de decodificación. Se ejecutará la evaluación sin conexión y con los mismos recursos de hardware. Se registrarán el sistema operativo y las versiones de software. Las consultas de evaluación no se usarán para seleccionar parámetros ni ajustar QLoRA. El número de repeticiones para mediciones de rendimiento se fijará tras el piloto y se aplicará igual a todas las condiciones; las respuestas utilizadas para métricas de texto se generarán con parámetros de decodificación constantes.

3.6.1. Métricas de calidad lingüística

Se calcularán chrF++ y BLEU mediante SacreBLEU, comparando las salidas con referencias documentadas y, cuando sea posible, revisadas por una persona competente en la variedad. Se conservarán la versión de SacreBLEU, su firma de configuración, la tokenización, la normalización, el idioma de salida y la cantidad de consultas (Popović, 2017; Post, 2018). Estas métricas cuantifican similitud con referencias y no se interpretarán por sí solas como comprensión, corrección semántica o fluidez.

3.6.2. Métricas de recuperación y fidelidad

Se calculará la precisión en los primeros k resultados (P@k) usando etiquetas de pertinencia definidas antes de evaluar y el mismo k para la búsqueda léxica y semántica. Para las respuestas se registrará si sus afirmaciones están respaldadas por los fragmentos proporcionados. Las métricas de RAGAS seleccionadas podrán complementar esa revisión solo si la versión y el modelo evaluador se identifican y el piloto confirma su uso pertinente con Quechua Collao; de lo contrario, sus puntuaciones no se presentarán como evidencia confirmatoria (Es et al., 2024).

3.6.3. Métricas de eficiencia

Por consulta y condición se medirán latencia, tokens generados por segundo y máximos de memoria principal (RAM) y memoria gráfica (VRAM). Se informarán medidas descriptivas, dispersión, fallos y datos faltantes. Cuando la instrumentación lo permita, se separarán los tiempos de recuperación, preparación del contexto e inferencia. Las mediciones de rendimiento seguirán el mismo procedimiento de calentamiento y repetición en cada condición, definido y registrado antes de la comparación.

3.7. Métodos de análisis de datos

Se calcularán estadísticos descriptivos por configuración y métrica. Para HE1 se comparará P@k del recuperador semántico con la búsqueda léxica sobre las mismas consultas. Para HE2, si QLoRA es viable, la comparación principal será SLM–RAG frente a SLM–RAG–QLoRA, manteniendo los demás parámetros. Para HE3 se describirán y, si los datos emparejados y los supuestos lo permiten, se contrastarán las tres configuraciones. Friedman se usará para tres condiciones relacionadas y Wilcoxon de rangos con signo para comparaciones pareadas; las comparaciones múltiples se ajustarán mediante Holm. Se comprobará que la escala y los datos disponibles permitan aplicar estas pruebas; si no, el análisis será descriptivo y se informará la limitación. Se fijará $\alpha = 0{,}05$ antes del análisis y se informarán tamaños de efecto, intervalos de confianza cuando sean estimables, datos faltantes y ajustes por comparaciones múltiples. Si QLoRA no es viable, HE2 y las comparaciones de HE3 que la involucren se declararán no evaluadas; no se inferirá superioridad de una condición que no se ejecutó.

3.8. Aspectos éticos y de gestión de datos

Se incorporarán documentos con procedencia y condiciones de uso verificables, se citarán las fuentes y no se redistribuirán contenidos protegidos sin autorización. Las consultas y bitácoras no incluirán datos personales. Los datos generados artificialmente se identificarán y separarán de los textos fuente. Se conservarán las etiquetas de Quechua Collao y no se mezclarán variedades sin identificación explícita. Si la validación lingüística requiere participación de personas, se obtendrán las autorizaciones y el consentimiento informado que correspondan antes de recoger sus evaluaciones.

CAPÍTULO IV ESTUDIO DE FACTIBILIDAD

4.1. Enfoque adoptado

4.2. Factibilidad técnica

4.2.1. Hardware e inferencia local

4.2.2. Estrategia de datos

4.2.3. Herramientas y software

4.3. Factibilidad económica

4.4. Factibilidad operativa

4.5. Viabilidad y sostenibilidad

REFERENCIAS

Court, S., & Elsner, M. (2024). Shortcomings of LLMs for low-resource translation: Retrieval and understanding are both the problem. *Proceedings of the Ninth Conference on Machine Translation*, 1332-1354. https://doi.org/10.18653/v1/2024.wmt-1.125

Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. *Advances in Neural Information Processing Systems*, *36*, 10088-10115. https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract-Conference.html

Duran, M., & Silberztein, M. (2026). Semi-automatic construction of a Quechua-Spanish dictionary. *Proceedings for the Ninth Workshop on Technologies for Machine Translation of Low Resource Languages (LoResMT 2026)*, 111-118. https://doi.org/10.18653/v1/2026.loresmt-1.9

Es, S., James, J., Espinosa Anke, L., & Schockaert, S. (2024). RAGAs: Automated evaluation of retrieval augmented generation. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, 150-158. https://doi.org/10.18653/v1/2024.eacl-demo.16

Hevia, J. S., Arredondo, F., & Kumar, V. (2025). Towards an efficient, customizable, and accessible AI tutor. *Proceedings of the Innovation and Responsibility in AI-Supported Education Workshop*, *273*, 250-254. https://proceedings.mlr.press/v273/hevia25a.html

Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, *28*(1), 75-105. https://doi.org/10.2307/25148625

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-Rank Adaptation of Large Language Models. *International Conference on Learning Representations*. https://openreview.net/forum?id=nZeVKeeFYf9

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rockt.[a]schel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Proces-*

sing Systems, *33*, 9459-9474. https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html

Orcotoma Mormontoy, G. C., Leon Nuñez, L., & Espetia Huamanga, H. (2025). Towards the creation of a Collao Quechua–Spanish parallel corpus using optical character recognition. *Proceedings of the Workshop on Beyond English: Natural Language Processing for All Languages in an Era of Large Language Models*, 1-6. https://doi.org/10.26615/978-954-452-105-9-001

Popović, M. (2017). chrF++: Words Helping Character N-Grams. *Proceedings of the Second Conference on Machine Translation*, 612-618. https://doi.org/10.18653/v1/W17-4770

Post, M. (2018). A call for clarity in reporting BLEU scores. *Proceedings of the Third Conference on Machine Translation: Research Papers*, 186-191. https://doi.org/10.18653/v1/W18-6319

Qwen Team. (2024). Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*. https://doi.org/10.48550/arXiv.2412.15115

United Nations General Assembly. (2015, 21 de octubre). *Transforming Our World: The 2030 Agenda for Sustainable Development* (Resolution A/RES/70/1). United Nations. https://sdgs.un.org/2030agenda

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, *30*, 5998-6008. https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html

Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., & Ling, Z. (2024). On-device language models: A comprehensive review. *arXiv preprint arXiv:2409.00088*. https://doi.org/10.48550/arXiv.2409.00088

ANEXOS

Anexo 1: Matriz de consistencia lógica

Tabla 4

Matriz de consistencia lógica de la investigación

Problemas	Objetivos	Hipótesis	Variables e indicadores	Método
Problema general: ¿Cómo se comporta una arquitectura SLM–RAG para la generación contextualizada en Quechua Collao dentro de un entorno computacional sin conexión, y qué aporte adicional presenta QLoRA si el ajuste y la inferencia con adaptador son viables?	**Objetivo general:** Diseñar e implementar una arquitectura SLM–RAG para la generación contextualizada en Quechua Collao y evaluar el aporte adicional de QLoRA si el ajuste y la inferencia con adaptador son viables.	**Hipótesis general:** Si QLoRA es viable, SLM–RAG–QLoRA obtendrá mayor fidelidad al contexto y similitud con referencias que SLM–RAG; también se describirán sus diferencias frente al SLM base y su costo computacional.	**VI:** configuración del sistema. **VD:** similitud con referencias, fidelidad y eficiencia.	Enfoque cuantitativo; investigación aplicada y tecnológica; experimento computacional comparativo con consultas repetidas.
Problema específico 1: ¿Cómo estructurar e indexar una base documental bilingüe para recuperar información pertinente en Quechua Collao?	**Objetivo específico 1:** Curar, estructurar e indexar documentos bilingües para recuperación local.	**Hipótesis específica 1:** La indexación semántica recuperará una mayor proporción de fragmentos pertinentes que la búsqueda léxica de referencia, según las consultas y etiquetas definidas.	Precisión de recuperación (P@k), cobertura de fuentes y trazabilidad documental.	Corpus con etiquetas de idioma y variedad; índice local y consultas con evidencia relevante identificada.
Problema específico 2: Si el ajuste y la inferencia con adaptador son viables, ¿qué diferencia produce QLoRA en la fidelidad al contexto de SLM–RAG bajo las mismas condiciones locales?	**Objetivo específico 2:** Integrar QLoRA en SLM–RAG y comparar su fidelidad al contexto con SLM–RAG sin adaptación, si el ajuste y la inferencia con adaptador son viables.	**Hipótesis específica 2:** Si el ajuste QLoRA y la inferencia con el adaptador son viables, SLM–RAG–QLoRA tendrá mayor fidelidad al contexto que SLM–RAG, manteniendo constantes las demás condiciones.	Fidelidad al contexto; latencia; tokens por segundo; RAM y VRAM.	Registro de configuración y telemetría; prueba de viabilidad previa al experimento completo.
Problema específico 3: ¿Qué diferencias de similitud de respuesta, fidelidad al contexto y eficiencia se observan entre SLM, SLM–RAG y SLM–RAG–QLoRA, cuando esta última condición sea viable?	**Objetivo específico 3:** Comparar SLM base, SLM–RAG y SLM–RAG–QLoRA, cuando esta última condición sea viable, mediante indicadores de similitud de respuesta, fidelidad al contexto y eficiencia computacional.	**Hipótesis específica 3:** Si las tres configuraciones pueden ejecutarse, SLM–RAG–QLoRA obtendrá mayor similitud con las respuestas de referencia y mayor fidelidad que SLM y SLM–RAG.	chrF++; BLEU; P@k; fidelidad al contexto; latencia y memoria.	Banco provisional de consultas; comparaciones pareadas y prueba global si se evalúan tres condiciones.

Nota. El tamaño de 100 consultas y la evaluación de QLoRA son provisionales. Se confirmarán después de validar el corpus y la viabilidad del hardware.

Anexo 2: Ficha técnica de registro experimental

Tabla 5
Ficha para registrar una corrida experimental

Campo	**Registro durante la ejecución**
Identificador	Completar al ejecutar
Configuración	SLM base / SLM–RAG / SLM–RAG–QLoRA, según viabilidad
Dispositivo y entorno	Modelo del equipo, sistema operativo y versiones
Modelo y cuantización	Nombre, versión y formato realmente utilizados
Consulta y variedad	Consulta evaluada, idioma y variedad identificados
Fragmentos recuperados	Identificadores de fuente y fragmentos entregados al modelo
Latencia y rendimiento	Medición en milisegundos y tokens por segundo
Consumo de memoria	Pico de RAM y VRAM medidos
Salida y métricas	Respuesta generada y puntuaciones calculadas
Observaciones	Errores, interrupciones y notas del evaluador

Anexo 3: Rúbrica de revisión lingüística y factual

Tabla 6
Rúbrica para revisar respuestas generadas en Quechua Collao

Criterio	Insuficiente (1)	Parcial (2–3)	Adecuado (4–5)
Comprensión de la consulta	No responde a la pregunta o altera su sentido.	Responde parcialmente o añade contenido no solicitado.	Responde al propósito de la consulta de forma directa.
Corrección lingüística	Errores que impiden comprender el sentido en la variedad indicada.	El sentido general se entiende, aunque requiere correcciones.	Redacción comprensible y consistente con Quechua Collao.
Fidelidad a la fuente	Incluye afirmaciones que contradicen o no aparecen en la evidencia.	La mayoría de afirmaciones se sustenta, con omisiones o dudas.	Las afirmaciones evaluables se sustentan en la fuente proporcionada.
Variedad y vocabulario	Mezcla variedades o usa vocabulario que cambia el significado.	Mantiene parcialmente la variedad, con usos que requieren revisión.	Conserva la variedad y el vocabulario pertinentes a la consulta.

Nota. La ficha será aplicada por una persona competente en Quechua Collao, con criterios acordados antes de evaluar. Si participan evaluadores, se registrará el procedimiento de revisión y resolución de discrepancias. La rúbrica complementa, pero no sustituye, las métricas automáticas.

Anexo 4: Plantilla del banco de consultas de evaluación

Tabla 7

Estructura prevista para documentar consultas de evaluación

ID	Tema e idioma / variedad	Consulta	Fuente, referencia y pasajes pertinentes
Q01	Pendiente de selección; por identificar	Completar tras curar las fuentes	Registrar documento, respuesta verificable e identificadores de evidencia
Q02	Pendiente de selección; por identificar	Completar tras curar las fuentes	Registrar documento, respuesta verificable e identificadores de evidencia
Q03	Pendiente de selección; por identificar	Completar tras curar las fuentes	Registrar documento, respuesta verificable e identificadores de evidencia

Nota. Plantilla del instrumento; no representa consultas ni resultados ya validados. Se registrarán los fragmentos considerados pertinentes para contrastar la recuperación. El banco previsto se completará después de verificar las fuentes y la cobertura lingüística.