UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO

FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA

ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

Diseño e implementación de una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao

---

Curso:

Seminario de Investigación II

Docente:

Msc. Raúl Huillca Huallparimachi

Asesor/a de tesis:

Por designar

Para optar al Título Profesional de:

Ingeniero Informático y de Sistemas

Presentado por:

Br. Edmil Jampier Saire Bustamante

Cusco – Perú

2026

RESUMEN

La propuesta aborda el diseño y evaluación de un asistente de generación contextualizada en Quechua Collao que pueda ejecutarse sin conexión a Internet. Se plantea una arquitectura que integra un modelo de lenguaje compacto, recuperación local de documentos y adaptación mediante QLoRA. El estudio comparará el modelo base, la configuración con recuperación y la configuración integrada, bajo condiciones de ejecución documentadas. Se medirán la calidad lingüística de las respuestas, su correspondencia con la evidencia recuperada y el costo computacional en el hardware disponible. La preparación de los datos considerará la identificación de la variedad lingüística y la trazabilidad de las fuentes. El trabajo es una propuesta: los resultados se obtendrán durante la ejecución experimental y no se anticipan en este documento.

Palabras clave: modelos de lenguaje compactos, generación aumentada por recuperación, Quechua Collao, QLoRA, inferencia local.

ABSTRACT

This research proposal addresses the design and evaluation of a contextualized generation assistant for Quechua Collao that can run without an Internet connection. It proposes an architecture combining a small language model, local document retrieval, and QLoRA adaptation. The study will compare the base model, the retrieval-augmented configuration, and the integrated configuration under documented execution conditions. It will measure linguistic quality, the correspondence between answers and retrieved evidence, and computational cost on the available hardware. Data preparation will account for language-variety identification and source traceability. This document presents a proposal; experimental results will be obtained during the study and are not anticipated here.

Keywords: small language models, retrieval-augmented generation, Quechua Collao, QLoRA, local inference.

ÍNDICE GENERAL

Resumen II

Abstract III

Índice general IV

Índice de figuras VIII

Índice de tablas IX

Índice de algoritmos X

Lista de abreviaturas XI

Lista de símbolos XII

Índice de ecuaciones XIII

Índice de anexos XIV

Glosario de términos XV

Introducción XVII

I. Generalidades 1

1.1. Planteamiento del problema 1

1.1.1. Descripción del problema 1

1.1.2. Identificación del problema 2

1.1.3. Formulación del problema 2

1.2. Objetivos de la investigación 3

1.2.1. Objetivo general 3

1.2.2. Objetivos específicos 3

1.3. Hipótesis de la investigación 4
1.3.1. Hipótesis general 4
1.3.2. Hipótesis específicas 4
1.4. Justificación de la investigación 5
1.5. Alcances y limitaciones 6
1.5.1. Alcances 6
1.5.2. Limitaciones 7
1.6. Matriz de consistencia metodológica 7

II. Marco teórico y estado del arte **9**
2.1. Estado del arte 9
2.1.1. Recursos lingüísticos para quechua 9
2.1.2. Uso de contexto en tareas de quechua 9
2.1.3. Modelos compactos, RAG y operación local 10
2.1.4. Adaptación eficiente de modelos 10
2.1.5. Síntesis y brecha de investigación 10
2.2. Fundamentos teóricos 11
2.2.1. Modelos compactos e inferencia local 11
2.2.2. Generación aumentada por recuperación 12
2.2.3. Adaptación de bajo rango y QLoRA 13
2.2.4. Recursos digitales y variación del Quechua Collao 13
2.2.5. Evaluación de generación y recuperación 14
2.3. Definición de términos básicos 15

III. Metodología de la investigación **16**
3.1. Enfoque, tipo y diseño de investigación 16
3.1.1. Enfoque de investigación 16
3.1.2. Tipo de investigación 16
3.1.3. Diseño de investigación 16
3.2. Variables y operacionalización 17

3.2.1. Identificación de variables 17
3.2.2. Matriz de operacionalización de variables 17
3.3. Unidades de análisis y selección de consultas 18
3.3.1. Unidad de análisis 18
3.3.2. Población y muestra 18
3.4. Técnicas e instrumentos de recolección 18
3.5. Procedimiento metodológico 19
3.6. Protocolo de evaluación 19
3.6.1. Métricas de calidad lingüística 19
3.6.2. Métricas de recuperación y fidelidad 20
3.6.3. Métricas de eficiencia 20
3.7. Métodos de análisis de datos 20
3.8. Aspectos éticos y de gestión de datos 20

IV. Estudio de factibilidad **22**
4.1. Enfoque adoptado 22
4.2. Factibilidad técnica 22
4.2.1. Hardware e inferencia local 22
4.2.2. Estrategia de datos 23
4.2.3. Herramientas y software 23
4.3. Factibilidad económica 23
4.4. Factibilidad operativa 24
4.5. Viabilidad y sostenibilidad 24

V. Aspectos administrativos **25**
5.1. Cronograma de actividades 25
5.2. Presupuesto y financiamiento 25
5.3. Equipo de investigación 26

Referencias **27**

Anexos **29**

Anexo 1: Matriz de consistencia lógica 29

Anexo 2: Ficha técnica de registro experimental 30

Anexo 3: Rúbrica complementaria de pertinencia pedagógica 31

Anexo 4: Plantilla del banco de consultas de evaluación 32

ÍNDICE DE FIGURAS

1. Árbol de problemas: causas tecnológicas y efectos computacionales 2
2. Árbol de objetivos: medios de investigación y fines previstos 4

ÍNDICE DE TABLAS

1. Matriz de consistencia metodológica del proyecto de tesis 8

2. Síntesis comparativa de antecedentes relevantes 11

3. Matriz de operacionalización de variables 17

4. Comparación de alternativas de arquitectura 22

5. Cronograma de actividades de la investigación 25

6. Presupuesto analítico de la investigación 26

7. Equipo de investigación 26

8. Matriz de consistencia lógica de la investigación 29

9. Ficha para registrar una corrida experimental 30

10. Rúbrica complementaria para valorar respuestas del prototipo 31

11. Estructura prevista para documentar consultas de evaluación 32

ÍNDICE DE ALGORITMOS

1. Flujo de inferencia propuesto para SLM–RAG con adaptación QLoRA 14

LISTA DE ABREVIATURAS

Abreviatura / Sigla	Significado y Descripción Técnica
AMLQ	Academia Mayor de la Lengua Quechua (Cusco, Perú).
BLEU	*Bilingual Evaluation Understudy* (métrica de concordancia de n-gramas léxicos).
chrF++	*Character n-gram F-score with word n-grams*, métrica de similitud léxica a nivel de caracteres y palabras.
CPU	*Central Processing Unit* (unidad central de procesamiento).
DSR	*Design Science Research* (marco metodológico de investigación en ciencias del diseño).
FAISS	*Facebook AI Similarity Search* (biblioteca de búsqueda vectorial densa eficiente).
GPU	*Graphics Processing Unit* (unidad de procesamiento gráfico acelerado).
HE	Hipótesis Específica (HE1, HE2, HE3).
HG	Hipótesis General de la investigación.
LLM	*Large Language Model* (modelo de lenguaje de gran escala).
LoRA	*Low-Rank Adaptation* (técnica de adaptación mediante descomposición de bajo rango).
ODS	Objetivos de Desarrollo Sostenible de las Naciones Unidas (ODS 9 y ODS 10).
OE	Objetivo Específico (OE1, OE2, OE3).
OG	Objetivo General de la investigación.
P@k	*Precision at k*: proporción de fragmentos pertinentes entre los primeros k recuperados.
PE	Problema Específico (PE1, PE2, PE3).
PG	Problema General de la investigación.
PLN	Procesamiento de Lenguaje Natural (equivalente a NLP en inglés).
QLoRA	*Quantized Low-Rank Adaptation* (adaptadores de bajo rango sobre pesos base en 4 bits).
RAG	*Retrieval-Augmented Generation* (generación aumentada por recuperación).
RAGAS	*Retrieval Augmented Generation Assessment*, marco de métricas para evaluación de sistemas RAG.
RAM	*Random Access Memory* (memoria principal del sistema).
SLM	*Small Language Model* (modelo de lenguaje compacto; en este estudio, candidato de hasta 3B parámetros).
TPS	*Tokens Per Second* (rendimiento de generación de tokens por segundo).
VRAM	*Video Random Access Memory* (memoria gráfica de video dedicada).

LISTA DE SÍMBOLOS

Símbolo / Notación	Definición y Rol Computacional
W_0	Matriz de pesos preentrenada original del SLM congelada en 4 bits ($W_0 \in \mathbb{R}^{d\times k}$).
ΔW	Matriz de actualización adaptativa acumulada sobre los pesos del modelo ($\Delta W \in \mathbb{R}^{d\times k}$).
A	Matriz de proyección de bajo rango inicializada de forma gaussiana ($A \in \mathbb{R}^{r\times k}$).
B	Matriz de proyección de bajo rango inicializada en ceros ($B \in \mathbb{R}^{d\times r}$).
r	Rango de las matrices de bajo rango, que se fijará durante el diseño experimental ($r \ll \text{mín}(d,k)$).
α	Factor de escala de la actualización LoRA, cuyo valor se especificará en la configuración experimental.
x	Vector de activación de entrada a la capa Transformer (tokens de consulta + contexto RAG).
h	Vector de activación adaptado de salida: $h = W_0x + \frac{\alpha}{r}(B \cdot A)x$.
Q, K, V	Matrices de Consulta (*Query*), Clave (*Key*) y Valor (*Value*) en las capas de autoatención.
W_q, W_k, W_v, W_o	Matrices de proyección lineal de los cabezales de atención objetivo del ajuste fino QLoRA.
d_k	Dimensión de escalamiento de los vectores de clave en el producto escalar de autoatención.
$\mathbf{e}_q$	Vector de incrustación denso (*embedding*) de la consulta formulada por el usuario.
$\mathbf{e}_d$	Vector de incrustación denso del fragmento documental indexado en la base de conocimiento.
q	Consulta de entrada al sistema de recuperación.
d	Fragmento documental candidato para una consulta.
$\text{sim}(q, d)$	Similitud del coseno normalizada entre los vectores de consulta y fragmento documental.
$\mathcal{D}$	Colección curada de fragmentos documentales bilingües indexados en la base vectorial local.
C_k	Conjunto de los k fragmentos documentales de mayor afinidad semántica recuperados.
$P@k$	Proporción de fragmentos pertinentes en el conjunto de los primeros k resultados recuperados.

ÍNDICE DE ECUACIONES

Ecuación	Descripción Matemática y Teórica	Página
Ecuación (1)	Métrica de similitud del coseno para recuperación densa de fragmentos documentales	12
Ecuación (2)	Precisión entre los primeros k fragmentos recuperados (P@k)	12
Ecuación (3)	Descomposición de bajo rango para adaptación eficiente de pesos (LoRA / QLoRA)	13
Ecuación (4)	Proyecciones lineales de consulta (Q), clave (K) y valor (V) en capas Transformer	13
Ecuación (5)	Mecanismo de autoatención con producto escalar escalado (*Scaled Dot-Product Attention*)	13
Ecuación (6)	Proyección lineal de salida multicabezal del bloque de atención Transformer	13

ÍNDICE DE ANEXOS

Identificador	Título y Contenido del Anexo	Página
Anexo 1	Matriz de consistencia lógica de la investigación	29
Anexo 2	Ficha técnica para registro de corridas experimentales	30
Anexo 3	Rúbrica de evaluación de pertinencia pedagógica	31
Anexo 4	Banco de consultas patrón de evaluación	32

GLOSARIO DE TÉRMINOS

Aglutinación: Proceso morfológico en el que una palabra puede incorporar varios sufijos, cada uno con una función gramatical o discursiva.

Alucinación: Respuesta generada que contiene afirmaciones no sustentadas por la información disponible o por las fuentes consultadas.

Cuantización: Representación de los pesos de un modelo con menor precisión numérica para reducir el espacio requerido en memoria; su efecto sobre calidad y velocidad debe medirse.

Design Science Research (DSR): Enfoque de investigación que diseña, construye y evalúa un artefacto para atender un problema delimitado.

Embedding: Representación vectorial de una consulta o fragmento documental usada para calcular similitud.

Fidelidad al contexto: Grado en que las afirmaciones de una respuesta se sustentan en el contexto recuperado, según una métrica o protocolo definido.

Generación aumentada por recuperación (RAG): Arquitectura que recupera documentos externos y los incorpora como contexto para una respuesta generada.

Inferencia local: Ejecución del modelo en el equipo del usuario sin enviar la consulta a un servicio remoto durante la generación.

NormalFloat de 4 bits (NF4): Formato de cuantización de 4 bits descrito como parte del método QLoRA.

QLoRA: Método que combina un modelo base cuantizado y adaptadores entrenables de bajo rango; su viabilidad depende del modelo, la configuración y el hardware.

Quechua Collao: Variedad quechua delimitada como objeto de este estudio; los datos deberán conservar esta etiqueta y su procedencia.

Small Language Model (SLM): Modelo de lenguaje compacto; para esta propuesta se considera como candidato uno de hasta tres mil millones de parámetros.

INTRODUCCIÓN

El procesamiento de lenguaje natural depende de la disponibilidad de datos y recursos lingüísticos adecuados. En Quechua Collao, los trabajos disponibles incluyen corpus paralelo y recursos léxicos que aportan materiales para el análisis computacional, aunque no constituyen por sí mismos un asistente de generación local basado en recuperación documental (Duran & Silberztein, 2026; Orcotoma Mormontoy et al., 2025).

La investigación reciente también muestra que el uso de contexto en lenguas de bajos recursos depende de la pertinencia y del tipo de información suministrada. En tareas de traducción de quechua sureño al español, Court y Elsner (2024) observaron resultados distintos según la información contextual recuperada; el estudio no evalúa generación en Quechua Collao. En un dominio educativo diferente, Hevia et al. (2025) analizaron un sistema de tutoría con un modelo pequeño y RAG offline, y señalaron dificultades cuando se incorporan contextos extensos o irrelevantes. Estos resultados orientan el diseño de la evaluación, pero no permiten anticipar el rendimiento de la arquitectura propuesta.

La ejecución local puede reducir la dependencia de servicios remotos, aunque debe ajustarse a los límites de memoria y cómputo del dispositivo. Las revisiones sobre modelos en dispositivos describen la cuantización y otras técnicas de compresión como opciones para reducir recursos, junto con compromisos de rendimiento que deben medirse (Xu et al., 2024). La familia Qwen2.5 ofrece modelos de pesos abiertos en varios tamaños; el proyecto considera como candidato un modelo compacto de esa familia, cuya elección final dependerá de las pruebas de compatibilidad y memoria (Qwen Team, 2024).

QLoRA adapta un modelo cuantizado mediante matrices de bajo rango y reduce el costo de ajuste respecto del entrenamiento completo en las condiciones evaluadas por sus autores (Dettmers et al., 2023). Sin embargo, ese antecedente no demuestra que el ajuste de un modelo de tres mil millones de parámetros sea viable en la GPU local de 4 GB disponible para este proyecto. Por ello, la factibilidad del ajuste se tratará como una condición experimental y, si los recursos no bastan, se documentará el alcance de la alternativa evaluada.

La revisión preliminar identifica estudios sobre recursos quechuas, uso de contexto para tra-

ducción y sistemas de tutoría offline, pero todavía no permite afirmar de manera concluyente que no existan trabajos comparables. La brecha de investigación se formula provisionalmente como la falta de evidencia reunida en este proyecto sobre el comportamiento de una arquitectura que combine un modelo compacto, recuperación documental local y adaptación QLoRA para generar respuestas contextualizadas en Quechua Collao sin conexión.

En consecuencia, la investigación pregunta de qué manera el diseño e implementación de una arquitectura SLM–RAG con QLoRA influye en la generación contextualizada en Quechua Collao dentro de un entorno computacional offline. El plan presenta el problema, los objetivos y las hipótesis; después desarrolla el estado del arte y el marco teórico, la metodología, la factibilidad y los aspectos administrativos. Los resultados, la discusión y las conclusiones corresponderán al informe final una vez realizadas las pruebas.

CAPÍTULO I GENERALIDADES

1.1. Planteamiento del problema

1.1.1. Descripción del problema

El desarrollo de herramientas computacionales para lenguas con menos recursos digitales enfrenta limitaciones de datos, representación y evaluación. Para el quechua, los trabajos disponibles documentan tanto la creación de corpus como la formalización de recursos léxicos, y también muestran que la variedad y el tipo de información lingüística afectan las tareas de traducción automática (Court & Elsner, 2024; Duran & Silberztein, 2026; Orcotoma Mormontoy et al., 2025). Estos antecedentes no permiten atribuir una única causa ni una magnitud uniforme a las dificultades de procesamiento del Quechua Collao.

Los modelos que dependen de servicios remotos no pueden atender solicitudes cuando el dispositivo carece de conexión. La ejecución local evita esa dependencia durante la inferencia, pero obliga a trabajar dentro de los límites de memoria y procesamiento disponibles; las técnicas de cuantización pueden reducir el tamaño del modelo a costa de compromisos que deben medirse en el equipo objetivo (Xu et al., 2024).

La generación aumentada por recuperación (RAG) incorpora fragmentos de documentos al contexto de entrada para que la respuesta pueda apoyarse en información externa. Su desempeño depende de la recuperación y de la capacidad del modelo para usar el contexto. En una evaluación de tutoría educativa, un modelo pequeño tuvo dificultades con contextos extensos o irrelevantes; ese resultado evidencia un riesgo de diseño, no una conclusión directa sobre Quechua Collao (Hevia et al., 2025).

El ajuste de bajo rango sobre modelos cuantizados ofrece una alternativa al entrenamiento completo, pero sus necesidades de hardware dependen del tamaño del modelo y de la configuración. El trabajo original de QLoRA informa resultados en equipos con recursos considerablemente mayores que la GPU local de 4 GB considerada en este proyecto, por lo que no se asumirá que el ajuste será viable antes de probarlo (Dettmers et al., 2023). El problema de

investigación consiste, por tanto, en determinar cómo se comporta una arquitectura compacta que combine recuperación local y adaptación bajo las restricciones reales del entorno.

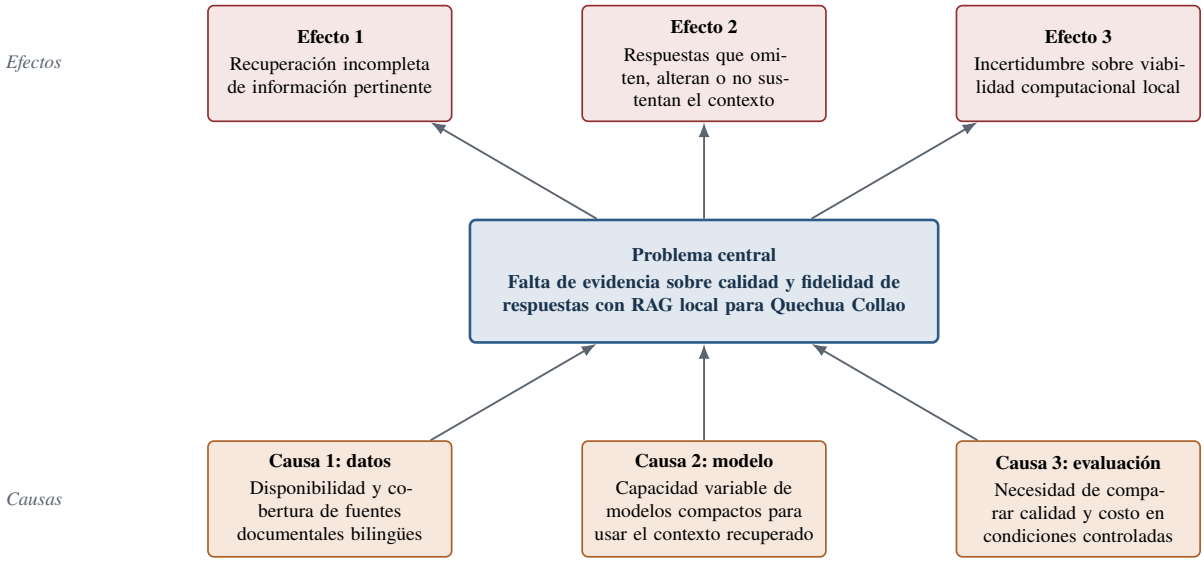
1.1.2. Identificación del problema

El problema central es la falta de evidencia experimental sobre la calidad lingüística, la fidelidad al contexto recuperado y el costo computacional de un sistema local de generación en Quechua Collao que combine un modelo compacto y RAG, con adaptación QLoRA evaluada de manera condicionada a la memoria disponible.

La Figura 1 sintetiza, mediante un árbol de problemas, las causas identificadas y los efectos derivados del problema central.

Figura 1

Árbol de problemas: causas tecnológicas y efectos computacionales



1.1.3. Formulación del problema

Problema general. ¿De qué manera el diseño e implementación de una arquitectura SLM–RAG con QLoRA influye en la generación contextualizada en Quechua Collao dentro de un entorno computacional offline?

Problemas específicos.

- **PE1 (Datos y Recuperación):** ¿Cómo estructurar e indexar semánticamente una base de conocimiento documental bilingüe para optimizar la recuperación local en Quechua Collao?
- **PE2 (Núcleo Técnico y Adaptación):** ¿De qué manera los adaptadores QLoRA en un SLM cuantizado optimizan la utilización del contexto recuperado bajo restricciones de hardware local?
- **PE3 (Evaluación Computacional):** ¿Qué nivel de fidelidad léxica, consistencia factual y eficiencia computacional alcanza la arquitectura integrada frente al modelo base y a la recuperación estándar?

1.2. Objetivos de la investigación

1.2.1. Objetivo general

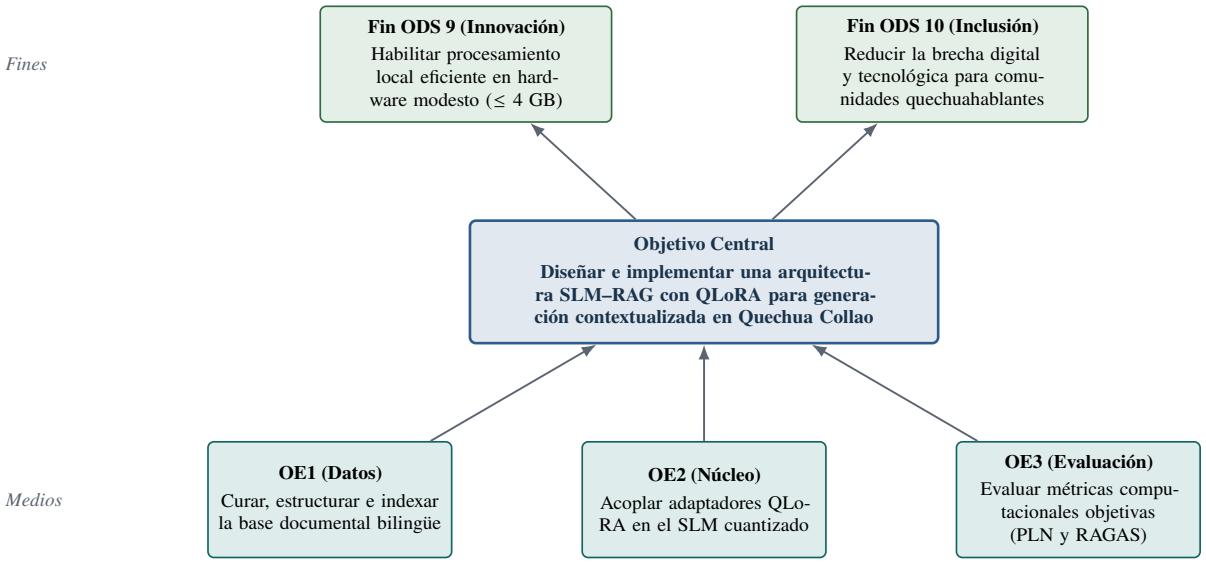
Diseñar e implementar una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao dentro de un entorno computacional offline.

1.2.2. Objetivos específicos

- **OE1 (Datos y Recuperación):** Curar, estructurar e indexar semánticamente una base de conocimiento documental bilingüe para optimizar la recuperación local en Quechua Collao.
- **OE2 (Núcleo Técnico y Adaptación):** Implementar y acoplar adaptadores QLoRA en el SLM cuantizado para maximizar la asimilación del contexto RAG en inferencia offline.
- **OE3 (Evaluación Computacional):** Evaluar computacionalmente el rendimiento técnico, la fidelidad lingüística y el anclaje factual de la arquitectura frente al SLM base y al RAG estándar mediante métricas objetivas de PLN y RAG.

La Figura 2 presenta el árbol de objetivos, organizado en correspondencia directa con el árbol de problemas: los objetivos específicos actúan como hitos cronológicos de ingeniería para lograr el objetivo central, alineado con los Objetivos de Desarrollo Sostenible (ODS).

Figura 2
Árbol de objetivos: medios de investigación y fines previstos



1.3. Hipótesis de la investigación

1.3.1. Hipótesis general

En las condiciones de prueba definidas, la configuración SLM–RAG con QLoRA obtendrá mejores valores de fidelidad al contexto recuperado y calidad lingüística que las configuraciones de referencia, sin exceder los recursos computacionales disponibles.

1.3.2. Hipótesis específicas

- **HE1 (Datos y recuperación):** Con las consultas y etiquetas de relevancia definidas, la indexación semántica local recuperará una mayor proporción de fragmentos pertinentes que la búsqueda léxica de referencia.
- **HE2 (Núcleo técnico y adaptación):** Si el ajuste QLoRA resulta ejecutable en el entorno previsto, la configuración adaptada mostrará mayor utilización de la evidencia

recuperada que el SLM base, manteniendo constantes los documentos, las consultas y los parámetros de generación.

- **HE3 (Evaluación computacional):** La configuración integrada obtendrá mejores puntuaciones de calidad lingüística y fidelidad factual que el SLM base y la configuración SLM–RAG sin adaptación, de acuerdo con las métricas y el análisis estadístico establecidos.

1.4. Justificación de la investigación

La investigación se justifica por la necesidad de estudiar alternativas de generación que puedan ejecutarse sin conexión y apoyarse en documentos trazables en Quechua Collao. La propuesta se organiza desde cuatro perspectivas de ingeniería:

- **Justificación teórica:** Examina la relación entre recuperación documental, modelos compactos y adaptación de bajo rango en una tarea de generación para Quechua Collao. Los antecedentes sobre traducción de quechua muestran que el tipo de contexto puede influir de manera distinta en el resultado, por lo que la propuesta requiere una evaluación específica (Court & Elsner, 2024).

- **Justificación práctica:** El prototipo se diseñará para funcionar localmente y sin conexión durante la inferencia. Su utilidad y calidad deberán medirse; el plan no presupone que las respuestas serán siempre precisas ni que todos los componentes podrán ejecutarse en la GPU local de 4 GB.

- **Justificación metodológica:** Propone pruebas computacionales comparativas para medir el comportamiento del modelo base, la recuperación local y la adaptación QLoRA mediante indicadores de calidad y eficiencia.

- **Justificación tecnológica y social:** El posible aporte se relaciona con el acceso a tecnologías locales y con la disponibilidad de recursos lingüísticos. Esta relación se plantea como motivación, no como un impacto social que el experimento vaya a medir:

- **ODS 9 — Industria, innovación e infraestructura:** Se vincula con la exploración de una arquitectura de procesamiento local y eficiente.
- **ODS 10 — Reducción de las desigualdades:** Se vincula con la investigación de herramientas digitales para una lengua originaria; el proyecto no medirá reducción de brechas sociales.

1.5. Alcances y limitaciones

1.5.1. Alcances

El presente estudio abarca el diseño, implementación y evaluación experimental de una arquitectura SLM–RAG con QLoRA para inferencia local offline en Quechua Collao:

- **Alcance tecnológico:** Comprende la selección de un SLM abierto de la familia Qwen2.5 como candidato, la evaluación de cuantización e inferencia local y la integración con recuperación documental local. QLoRA se probará como componente condicionado a la viabilidad de memoria; la cuantización, el formato y el motor final se fijarán y documentarán antes de la comparación (Dettmers et al., 2023; Qwen Team, 2024).
- **Alcance lingüístico:** Se delimita a materiales identificados como Quechua Collao. Cada fuente y consulta conservará una etiqueta de idioma y variedad; no se extrapolarán resultados a otras variedades quechuas.
- **Alcance experimental y métrico:** La evaluación comparará calidad lingüística (chrF++ y SacreBLEU), recuperación y fidelidad al contexto (métricas RAG seleccionadas) y eficiencia local (latencia, tokens por segundo y consumo de RAM/VRAM).
- **Alcance disciplinar:** Se ubica estrictamente dentro de la Ciencia de la Computación, la Inteligencia Artificial y la Ingeniería de Sistemas, en las subáreas de Procesamiento de Lenguaje Natural y Sistemas Distribuidos/Edge Computing.

1.5.2. Limitaciones

Se reconocen las siguientes limitaciones del estudio:

- **Disponibilidad y cobertura de datos:** Los recursos quechuas existentes no garantizan cobertura suficiente de todas las consultas o registros del Quechua Collao; la selección, licencia y trazabilidad del corpus limitarán el alcance de la evaluación (Duran & Silberztein, 2026; Orcotoma Mormontoy et al., 2025).
- **Variación lingüística y tokenización:** Los resultados no se generalizarán a otras variedades quechuas. La segmentación de subpalabras y sus efectos sobre memoria y calidad se medirán en el modelo elegido, sin asumir una razón fija frente al español.
- **Capacidad de hardware local:** La GPU disponible cuenta con 4 GB de VRAM. El ajuste QLoRA de un modelo compacto puede no ser viable en ese dispositivo; se informará cualquier reducción de alcance, uso de CPU u otra condición computacional, sin presentar las alternativas como equivalentes.
- **Modalidad textual:** El sistema procesa y genera exclusivamente texto digital; el procesamiento de habla (reconocimiento y síntesis de voz) queda fuera de la delimitación del presente proyecto.

1.6. Matriz de consistencia metodológica

La Tabla 1 resume la correspondencia entre los problemas, objetivos, hipótesis, variables e instrumentos propuestos.

Tabla 1

Matriz de consistencia metodológica del proyecto de tesis

Problema	Objetivo	Hipótesis	Variable(s)	Instrumento / Métrica
Nivel General				
¿De qué manera el diseño e implementación de una arquitectura SLM–RAG con QLoRA influye en la generación contextualizada en Quechua Collao en un entorno offline?	Diseñar e implementar una arquitectura SLM–RAG con QLoRA para generación contextualizada en Quechua Collao en un entorno offline.	En las condiciones de prueba definidas, SLM–RAG con QLoRA obtendrá mejores valores de fidelidad y calidad lingüística que las configuraciones de referencia, sin exceder los recursos disponibles.	**VI:** Configuración del sistema. **VD:** Calidad lingüística, fidelidad y eficiencia.	Consultas repetidas por configuración; métricas lingüísticas, de RAG y de rendimiento.
Nivel Específico (Fases Metodológicas de Ingeniería)				
PE1 (Datos y Recuperación): ¿Cómo estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación local en Quechua Collao?	**OE1:** Curar, estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación local en Quechua Collao.	**HE1:** La indexación semántica local recuperará una mayor proporción de fragmentos pertinentes que la búsqueda léxica de referencia, según las etiquetas definidas.	Precisión de recuperación (P@k) y trazabilidad de fuentes.	Índice local, consultas con documentos pertinentes identificados y registro de fragmentos recuperados.
PE2 (Núcleo y Adaptación): ¿De qué manera los adaptadores QLoRA del SLM cuantizado optimizan la utilización de contexto bajo restricciones offline?	**OE2:** Implementar y acoplar adaptadores QLoRA en el SLM cuantizado para maximizar la utilización del contexto RAG en inferencia offline.	**HE2:** Si el ajuste QLoRA es ejecutable, la configuración adaptada mostrará mayor uso de evidencia que el SLM base, manteniendo constantes los demás parámetros.	Uso de evidencia, latencia, tokens por segundo, RAM y VRAM.	Bitácora de ejecución y telemetría en el mismo equipo de pruebas.
PE3 (Evaluación Computacional): ¿Qué nivel de fidelidad léxica, consistencia factual y eficiencia alcanza la arquitectura frente al modelo base y RAG estándar?	**OE3:** Evaluar computacionalmente el rendimiento, fidelidad lingüística y anclaje factual frente al SLM base y RAG estándar.	**HE3:** La configuración integrada obtendrá mejores puntuaciones que SLM y SLM–RAG en las métricas seleccionadas, si puede evaluarse QLoRA.	Fidelidad lingüística (chrF++, BLEU) y anclaje RAG (*faithfulness*, *context recall*).	Scripts de evaluación, SacreBLEU, métricas RAG seleccionadas y análisis de medidas repetidas.

CAPÍTULO II MARCO TEÓRICO Y ESTADO DEL ARTE

2.1. Estado del arte

La revisión reúne antecedentes directamente relacionados con los recursos lingüísticos para quechua, el uso de contexto en tareas de lenguaje, la inferencia local y la adaptación eficiente de modelos. Los estudios no son equivalentes en lengua, tarea ni entorno; por ello, sus resultados se usan para delimitar decisiones de diseño y preguntas de evaluación, no como prueba anticipada del desempeño del sistema propuesto.

2.1.1. Recursos lingüísticos para quechua

Orcotoma Mormontoy et al. (2025) describen un procedimiento para construir un corpus paralelo de Quechua Collao y español mediante la digitalización y el reconocimiento óptico de textos bilingües producidos en el ámbito de la Academia Mayor de la Lengua Quechua. El trabajo aporta una ruta para obtener recursos a partir de materiales impresos y documenta etapas de captura, etiquetado, preprocesamiento y reconocimiento. Su objetivo es formar un recurso para investigación lingüística y PLN; no evalúa un sistema de generación con recuperación documental.

Duran y Silberztein (2026) presentan un diccionario quechua–español de verbos con gramáticas morfosintácticas para representar flexión y derivación. El recurso descrito parte de 1 444 verbos quechuas y permite generar más de 2 777 000 formas verbales, además de establecer correspondencias con un diccionario verbal en español. Este antecedente puede orientar la normalización y consulta léxica, aunque un recurso verbal no sustituye un corpus educativo ni cubre por sí mismo todas las variantes de uso.

2.1.2. Uso de contexto en tareas de quechua

Court y Elsner (2024) estudian la traducción de quechua sureño al español con modelos de lenguaje y comparan distintos tipos de contexto recuperado. Sus experimentos indican que

las traducciones de morfemas pueden ayudar en ciertas condiciones, mientras que la información gramatical o ejemplos de corpus no mejoran de forma uniforme los resultados. La investigación es relevante porque muestra que añadir contexto no garantiza una respuesta mejor; sin embargo, su tarea es traducción hacia el español y sus conclusiones no se trasladan automáticamente a la generación en Quechua Collao.

2.1.3. Modelos compactos, RAG y operación local

En un sistema de tutoría educativa, Hevia et al. (2025) proponen combinar un modelo pequeño con recuperación de documentos y ejecución offline. Su estudio señala dificultades cuando el modelo recibe fragmentos extensos o irrelevantes. El dominio evaluado es material de biología en inglés, de modo que el antecedente identifica un riesgo para el diseño de RAG, pero no establece el comportamiento de un modelo en una lengua originaria.

La revisión de Xu et al. (2024) organiza técnicas para ejecutar modelos de lenguaje en dispositivos con recursos limitados, entre ellas cuantización, poda y destilación. Al tratarse de una revisión en arXiv, sirve como panorama técnico y no como una medición de latencia o memoria del equipo de este proyecto. La propuesta utilizará esas restricciones como variables de evaluación y reportará los valores medidos en el entorno real.

2.1.4. Adaptación eficiente de modelos

Dettmers et al. (2023) presentan QLoRA, que propaga gradientes a través de un modelo preentrenado cuantizado de 4 bits hacia adaptadores de bajo rango. El artículo muestra que este enfoque reduce el uso de memoria en sus experimentos, realizados con hardware de mayor capacidad que la GPU local de 4 GB considerada aquí. Por ello, QLoRA se incluye como condición que se intentará evaluar, sujeta a una prueba de viabilidad y sin dar por garantizado su entrenamiento en el equipo disponible.

2.1.5. Síntesis y brecha de investigación

Los antecedentes muestran avances complementarios: se han documentado recursos digitales y léxicos para quechua, se han estudiado los efectos de distintos tipos de contexto en traduc-

ción y se han propuesto sistemas offline con modelos pequeños en otros dominios. La revisión realizada para este plan todavía es preliminar y no permite sostener una afirmación definitiva de novedad. La pregunta que queda por evaluar es cómo se comporta, en Quechua Collao y bajo restricciones locales, la combinación de modelo compacto, recuperación documental y adaptación QLoRA, comparada con configuraciones de referencia.

Tabla 2
Síntesis comparativa de antecedentes relevantes

Estudio	Objeto	Hallazgo o aporte descrito	Límite para esta propuesta
Orcotoma Mormontoy et al. (2025)	Corpus Quechua Collao–español	Procedimiento de digitalización y OCR de textos bilingües	No evalúa generación ni RAG.
Duran & Silberztein (2026)	Diccionario verbal quechua–español	Recurso léxico con reglas de flexión y derivación	Se concentra en verbos; no es una base educativa general.
Court & Elsner (2024)	Traducción de quechua sureño al español	El efecto del contexto varía según su tipo y pertinencia	La tarea y la dirección lingüística difieren de la generación propuesta.
Hevia et al. (2025)	Tutoría con SLM y RAG offline	Identifica dificultades ante contexto extenso o irrelevante	Se estudia biología en inglés, no Quechua Collao.
Xu et al. (2024)	Modelos en dispositivos	Revisa técnicas de eficiencia y despliegue local	Es una revisión; no mide el hardware de este proyecto.
Dettmers et al. (2023)	Ajuste QLoRA	Describe ajuste eficiente sobre modelos cuantizados	Sus experimentos no demuestran viabilidad en una GPU de 4 GB.

Nota. Síntesis parafraseada de las fuentes citadas; las diferencias de tarea, lengua y hardware limitan la comparación directa.

2.2. Fundamentos teóricos

2.2.1. Modelos compactos e inferencia local

Los modelos de lenguaje estiman distribuciones de probabilidad sobre secuencias de tokens y generan texto de manera autorregresiva. Los modelos compactos reducen el número de parámetros respecto de modelos de mayor tamaño, lo que puede facilitar su ejecución local; esa

reducción no garantiza por sí sola calidad suficiente para una tarea o lengua determinada. La revisión de modelos en dispositivos describe cuantización y otras técnicas de compresión como herramientas para ajustarse a límites de memoria, con compromisos que deben observarse durante la evaluación (Xu et al., 2024).

Como candidato inicial, el proyecto considera un modelo de la familia Qwen2.5 de hasta tres mil millones de parámetros, sujeto a la disponibilidad del modelo, su licencia y pruebas de compatibilidad con el entorno de inferencia local (Qwen Team, 2024). La selección definitiva se registrará antes del experimento; no se tratará la familia o el tamaño como garantía de desempeño en Quechua Collao.

2.2.2. Generación aumentada por recuperación

La generación aumentada por recuperación combina un modelo generativo con una memoria documental externa. En una configuración densa, una consulta y cada fragmento se representan como vectores; la recuperación ordena los fragmentos según una función de similitud y entrega los más pertinentes al modelo generativo (Lewis et al., 2020). La similitud del coseno se expresa como:

$$\mathrm{sim}(q,d) = \frac{\mathbf{e}_q \cdot \mathbf{e}_d}{\|\mathbf{e}_q\| \, \|\mathbf{e}_d\|}. \tag{1}$$

La fórmula describe un criterio de ordenamiento, no una garantía de que el fragmento recuperado sea pertinente ni de que el modelo lo utilice correctamente. Por ello, la propuesta medirá por separado la recuperación documental y la calidad de las respuestas. El tamaño de los fragmentos, el modelo de embeddings, el índice y el número de resultados recuperados se mantendrán documentados como parámetros del experimento.

La precisión en los primeros k resultados se calculará como la proporción de fragmentos recuperados que fueron etiquetados como pertinentes para la consulta:

$$P@k = \frac{|\{d \in C_k : d \text{ es pertinente}\}|}{k}. \tag{2}$$

Esta métrica requiere etiquetar la pertinencia de los fragmentos para cada consulta antes de la evaluación.

2.2.3. Adaptación de bajo rango y QLoRA

La adaptación de bajo rango representa una actualización de pesos mediante dos matrices de rango reducido. En la formulación utilizada en este plan:

$$W = W_0 + \Delta W = W_0 + \frac{\alpha}{r}(BA), \tag{3}$$

donde W_0 son los pesos preentrenados, A y B son matrices entrenables, r es el rango y α es un factor de escala. QLoRA conserva el modelo base cuantizado y adapta matrices de bajo rango; los beneficios de memoria comunicados en el artículo original deben interpretarse en las condiciones de hardware y entrenamiento evaluadas por sus autores (Dettmers et al., 2023).

En las capas de autoatención, las representaciones de entrada se proyectan en consultas, claves y valores:

$$Q = XW_q, \qquad K = XW_k, \qquad V = XW_v. \tag{4}$$

La operación de atención escalada se define como:

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V. \tag{5}$$

La salida de la proyección del bloque se representa como:

$$\text{Output} = \text{Attention}(Q,K,V)W_o. \tag{6}$$

Estas expresiones formalizan componentes de la arquitectura Transformer; no implican que adaptar todas las matrices sea la única estrategia. La ubicación de los adaptadores será un parámetro que deberá fijarse en la implementación.

2.2.4. Recursos digitales y variación del Quechua Collao

El Quechua Collao requiere que la preparación de datos conserve la identidad de la variedad y la procedencia de cada texto. Los antecedentes disponibles describen corpus obtenidos de ma-

teriales bilingües y recursos léxicos con reglas morfológicas, pero no sustituyen la validación de las fuentes que se incorporen al índice documental (Duran & Silberztein, 2026; Orcotoma Mormontoy et al., 2025). En tareas de traducción, además, se han observado diferencias según el tipo de contexto proporcionado, lo que respalda la necesidad de medir el comportamiento lingüístico para la tarea concreta y no inferirlo a partir de otra dirección de traducción (Court & Elsner, 2024).

2.2.5. Evaluación de generación y recuperación

La evaluación considerará dimensiones distintas: calidad de texto, recuperación de evidencia, correspondencia de las respuestas con el contexto y costo de ejecución. SacreBLEU facilita la comparación reproducible de puntajes BLEU cuando se registran sus parámetros (Post, 2018). Para recuperación aumentada, RAGAS propone métricas automatizadas como fidelidad y relevancia, que en este proyecto se usarán como indicadores complementarios y no como sustituto de la revisión de errores específicos (Es et al., 2024). La latencia, el uso de RAM/VRAM y los tokens generados por segundo se obtendrán mediante medición instrumentada en el entorno descrito en el capítulo metodológico.

Entrada: Consulta q, colección documental indexada $\mathcal{D}$, modelo base W_0, adaptadores QLoRA opcionales $\{A_l, B_l\}$ y cantidad de fragmentos k.
Salida: Respuesta y en el idioma solicitado, acompañada de los fragmentos recuperados para su trazabilidad.

---

1. Codificar la consulta y obtener su representación vectorial $\mathbf{e}_q$.
2. Calcular similitudes con los fragmentos documentales y recuperar los k candidatos mejor posicionados.
3. Construir el contexto con instrucciones, fragmentos recuperados y consulta.
4. Generar una respuesta con el modelo base; activar la configuración adaptada solo si el ajuste fue viable.
5. Registrar la respuesta, los fragmentos, la latencia y el consumo de memoria para la evaluación.

Algoritmo 1
Flujo de inferencia propuesto para SLM–RAG con adaptación QLoRA

2.3. Definición de términos básicos

Adaptador de bajo rango: Parámetros entrenables que representan una actualización de pesos mediante matrices de rango reducido.

Corpus paralelo: Colección de textos alineados entre dos lenguas o variedades, con correspondencia documentada entre sus segmentos.

Embedding: Representación vectorial de una consulta o fragmento, utilizada para calcular similitud y ordenar candidatos de recuperación.

Fidelidad al contexto: Grado en que las afirmaciones de una respuesta se sostienen en la evidencia recuperada; se tratará como indicador y se interpretará junto con sus limitaciones.

Inferencia local: Generación ejecutada en el dispositivo o equipo del usuario sin enviar la consulta a un servicio remoto durante la ejecución.

Quechua Collao: Variedad quechua delimitada por el estudio. Los datos y resultados del proyecto no se generalizarán automáticamente a otras variedades.

QLoRA: Método de ajuste eficiente que combina pesos base cuantizados con adaptadores de bajo rango entrenables (Dettmers et al., 2023).

Cuantización: Representación de pesos del modelo con menor precisión numérica para reducir su tamaño en memoria, con posibles cambios en el rendimiento.

RAG: Arquitectura que recupera documentos externos y los incorpora como contexto de entrada para la generación (Lewis et al., 2020).

SLM: Modelo de lenguaje compacto seleccionado considerando el tamaño, la licencia, la calidad esperada y los recursos del dispositivo.

CAPÍTULO III METODOLOGÍA DE LA INVESTIGACIÓN

3.1. Enfoque, tipo y diseño de investigación

3.1.1. Enfoque de investigación

El estudio tendrá un enfoque cuantitativo porque comparará configuraciones computacionales mediante indicadores numéricos de calidad y eficiencia. Las unidades de evaluación serán consultas y respuestas registradas por el sistema; no se medirán efectos educativos sobre estudiantes en esta etapa.

3.1.2. Tipo de investigación

La investigación será aplicada y tecnológica: diseñará un artefacto de software para atender una necesidad definida y documentará su evaluación. El trabajo seguirá un proceso de diseño, construcción y evaluación de artefactos propio de la investigación en ciencias del diseño (Hevner et al., 2004).

3.1.3. Diseño de investigación

Se propone un experimento computacional comparativo con medidas repetidas: cada consulta del banco de evaluación se procesará, en lo posible, bajo las mismas condiciones en tres configuraciones: (a) SLM base; (b) SLM con RAG local; y (c) SLM con RAG y QLoRA, si el ajuste y la inferencia adaptada son viables. Para contrastar la recuperación semántica de la HE1, se comparará además con una búsqueda léxica de referencia sobre los mismos documentos y consultas, con el mismo valor de k y etiquetas de pertinencia. Se mantendrán constantes el hardware, el conjunto de consultas, los documentos, la plantilla de instrucciones y los parámetros de generación. Las diferencias observadas se interpretarán como resultados del experimento y no se anticipan en este plan.

3.2. Variables y operacionalización

3.2.1. Identificación de variables

- **Variable independiente:** configuración del sistema (SLM base, SLM–RAG o SLM–RAG–QLoRA).
- **Variables dependientes:** calidad lingüística de la respuesta, fidelidad a la evidencia recuperada y eficiencia computacional.
- **Condiciones de control:** versión y cuantización del modelo, consultas, documentos, índice, instrucciones, parámetros de decodificación, hardware y procedimiento de medición.

3.2.2. Matriz de operacionalización de variables

La Tabla 3 define los indicadores que se registrarán y las herramientas previstas para calcularlos.

Tabla 3
Matriz de operacionalización de variables

Variable	Operacionalización	Indicadores	Escala e instrumento
Configuración (independiente)	Condición del sistema usada para cada consulta: SLM, SLM–RAG o SLM–RAG–QLoRA si es viable.	Tipo de configuración; documentos y fragmentos recuperados.	Categórica; configuración, índice y bitácora de ejecución.
Calidad y fidelidad (dependientes)	Comparación entre la salida y referencias lingüísticas y documentales definidas para cada consulta.	chrF++; SacreBLEU; P@k; fidelidad y relevancia del contexto según métricas RAG seleccionadas.	Numérica; scripts reproducibles y, si se habilita, implementación local de RAGAS (Es et al., 2024; Post, 2018).
Eficiencia (dependiente)	Medición del costo de ejecutar cada condición en el mismo equipo.	Latencia por respuesta; tokens por segundo; RAM y VRAM máximas.	Numérica; temporizador, registro del proceso y telemetría del sistema.

Nota. Los nombres y versiones de las herramientas, parámetros de evaluación y reglas de preprocesamiento se registrarán antes de ejecutar la comparación.

3.3. Unidades de análisis y selección de consultas

3.3.1. Unidad de análisis

La unidad de análisis será la respuesta generada para una consulta en una configuración determinada, junto con los fragmentos recuperados y sus registros de ejecución. La unidad de observación para las métricas de rendimiento será cada corrida individual.

3.3.2. Población y muestra

La población conceptual comprende consultas textuales que puedan responderse con el corpus bilingüe seleccionado para Quechua Collao y español. Como no existe en este plan un marco muestral exhaustivo, se propone construir una muestra intencional de 100 consultas patrón, distribuida por temas y por idioma según la cobertura real de las fuentes. Este tamaño es provisional: se revisará después de verificar la disponibilidad, licencia y calidad de documentos y referencias. Las mismas consultas se reutilizarán en las configuraciones comparadas.

3.4. Técnicas e instrumentos de recolección

La técnica principal será la ejecución controlada del prototipo con captura automatizada de entradas, salidas, fragmentos recuperados, tiempo de respuesta y consumo de memoria. Los instrumentos serán el banco de consultas, la ficha de registro experimental del Anexo 2, los scripts de cálculo de métricas y los registros del entorno de ejecución. La matriz de consistencia y la ficha técnica se conservarán como anexos del plan.

La validez de contenido del banco dependerá de que cada consulta tenga fuente rastreable, respuesta de referencia y variedad lingüística identificada. Se verificará esa trazabilidad antes de puntuar resultados. Las traducciones o respuestas generadas sintéticamente se identificarán como tales y no se presentarán como producción nativa validada. Si se requiere valoración humana de lengua o pertinencia pedagógica, deberá definirse un protocolo específico y obtenerse la autorización correspondiente antes de recoger esas evaluaciones.

3.5. Procedimiento metodológico

El trabajo se organizará en seis fases relacionadas con el ciclo de diseño, construcción y evaluación de artefactos (Hevner et al., 2004):

1. **Diagnóstico y requisitos:** delimitar consultas, usuarios previstos, restricciones offline, criterios de éxito y fuentes autorizadas.

2. **Curaduría de datos:** inventariar documentos, registrar idioma y variedad, normalizar los archivos y conservar la procedencia y licencia.

3. **Diseño y prototipo:** especificar el flujo de recuperación, la representación de documentos, las interfaces y el protocolo de registro.

4. **Implementación:** integrar modelo, índice local y generación; evaluar primero la inferencia y recuperación base. Intentar QLoRA solo si el entorno permite hacerlo de forma reproducible.

5. **Evaluación:** ejecutar las consultas bajo cada condición viable, registrar errores, métricas y consumo de recursos, y conservar las configuraciones.

6. **Análisis y documentación:** contrastar las condiciones, reportar limitaciones y documentar el artefacto y el procedimiento sin anticipar conclusiones.

3.6. Protocolo de evaluación

3.6.1. Métricas de calidad lingüística

Se calcularán chrF++ y BLEU mediante SacreBLEU sobre salidas y referencias normalizadas con el mismo procedimiento. Se registrarán versión, firma de configuración, tokenización, idioma de referencia y número de consultas; BLEU no se interpretará como medida única de calidad (Post, 2018).

3.6.2. Métricas de recuperación y fidelidad

Se calculará P@k a partir de las etiquetas de pertinencia asignadas a los fragmentos recuperados para cada consulta. Además, se evaluará si las afirmaciones de la respuesta se sostienen en el contexto mediante métricas de RAGAS compatibles con una configuración reproducible; cuando una métrica requiera un modelo evaluador, se documentará su identidad y ejecución local. Las puntuaciones automatizadas se tratarán como indicadores y se complementarán con inspección de errores, pues no sustituyen una validación lingüística especializada (Es et al., 2024).

3.6.3. Métricas de eficiencia

Por consulta y condición se registrarán latencia, tokens generados por segundo y memoria máxima de RAM y VRAM. Se informarán mediana, rango intercuartílico y valores faltantes o fallos. Las mediciones se repetirán con el mismo protocolo y se separarán los tiempos de recuperación, preprocesamiento e inferencia cuando la instrumentación lo permita.

3.7. Métodos de análisis de datos

Primero se calcularán estadísticos descriptivos por configuración e indicador, junto con intervalos de incertidumbre cuando la distribución y el diseño permitan interpretarlos. Para comparar las tres configuraciones sobre las mismas consultas se propone la prueba de Friedman; las comparaciones pareadas posteriores podrán usar Wilcoxon con corrección por comparaciones múltiples. Si QLoRA no fuera viable, esa condición se reportará como no evaluada y no se afirmará su superioridad. El nivel de significación se fijará en $\alpha = 0{,}05$ antes del análisis, y se reportarán tamaño de efecto y datos faltantes además del valor p.

3.8. Aspectos éticos y de gestión de datos

Se utilizarán documentos con procedencia y condiciones de uso verificables; las fuentes se citarán y no se redistribuirán contenidos protegidos sin autorización. Se evitará almacenar

datos personales en consultas y registros. Los datos generados artificialmente se marcarán y separarán de los materiales originales. El diseño respetará la identificación de Quechua Collao y no mezclará variedades sin etiquetas explícitas. Cualquier prueba con personas, datos sensibles o evaluación por especialistas requerirá autorización y un procedimiento informado antes de realizarse.

CAPÍTULO IV ESTUDIO DE FACTIBILIDAD

4.1. Enfoque adoptado

Se propone una arquitectura local por fases: primero se comprobarán inferencia del modelo y recuperación documental; después se incorporará QLoRA únicamente si el ajuste resulta compatible con el entorno. Esta decisión permite medir el aporte de cada componente y reducir el riesgo de atribuir a la adaptación un efecto que provenga del modelo, los datos o la recuperación.
La Tabla 4 resume las opciones consideradas.

Tabla 4
Comparación de alternativas de arquitectura

Alternativa	Ventaja prevista	Riesgo o límite	Ajuste al objetivo	Decisión
Modelo remoto en la nube	Puede usar modelos de mayor tamaño sin alojar los pesos en el equipo local.	Depende de Internet y transmite consultas a un servicio externo.	Bajo	No es condición principal.
SLM local sin RAG	Permite medir una línea base completamente local.	El conocimiento depende de los parámetros del modelo.	Parcial	Línea base de comparación.
SLM con RAG local y QLoRA condicionado	Permite comparar recuperación y adaptación en el mismo entorno local.	La recuperación puede aportar fragmentos irrelevantes y QLoRA puede exceder la memoria disponible.	Alto	Alternativa propuesta, sujeta a pruebas de viabilidad.

Nota. La decisión se basa en la delimitación offline del proyecto; no implica que la alternativa seleccionada ya haya sido validada.

4.2. Factibilidad técnica

4.2.1. Hardware e inferencia local

El entorno disponible incluye una GPU NVIDIA GTX 1050 Ti con 4 GB de VRAM. Se priorizarán pruebas acotadas de inferencia local, recuperación y evaluación. El modelo candidato

Qwen2.5-3B cuantizado podría superar la memoria disponible según la configuración; por ello se medirán RAM, VRAM y latencia antes de fijar el modelo definitivo. El ajuste QLoRA se tratará como experimental y de riesgo alto en este hardware; se iniciará con una prueba mínima y se detendrá o reducirá si no es reproducible. Para flujos que dependan de ‘bitsandbytes‘, el entorno previsto es WSL2/Linux.

4.2.2. Estrategia de datos

Se identificarán documentos bilingües y recursos léxicos pertinentes, incluyendo las fuentes descritas por Orcotoma Mormontoy et al. (2025) y Duran y Silberztein (2026). Antes de incorporarlos al sistema se comprobarán acceso, licencia, formato, variedad lingüística y posibilidad de redistribución. Los fragmentos conservarán identificadores de fuente, idioma y variedad. El plan no presupone que el material publicado esté disponible en un formato directamente indexable.

4.2.3. Herramientas y software

Se evaluarán herramientas de código abierto para inferencia local, almacenamiento vectorial, adaptación de bajo rango y cálculo de métricas, entre ellas `llama.cpp`, FAISS o `sqlite-vec`, bibliotecas de adaptación y scripts propios. La selección final dependerá de compatibilidad con el sistema, versión, licencia y resultados de pruebas iniciales. Para evaluación RAG se usará una configuración local trazable cuando las métricas seleccionadas requieran un modelo evaluador.

4.3. Factibilidad económica

La propuesta prioriza software libre y el equipo de cómputo ya disponible. No se dispone todavía de cotizaciones verificadas para almacenamiento, impresión, conectividad o validación lingüística; esos rubros se consignarán como pendientes de estimación en el presupuesto administrativo. No se fija un costo total ni se declara costo cero mientras falten esas cotizaciones.

4.4. Factibilidad operativa

El prototipo se probará mediante ejecuciones controladas y registro reproducible, inicialmente por el tesista. Su operación sin conexión se considerará demostrada únicamente si el flujo completo puede ejecutarse sin solicitar servicios externos durante la consulta. Las pruebas no equivalen a un despliegue institucional ni a una validación con estudiantes.

4.5. Viabilidad y sostenibilidad

La viabilidad dependerá de que el modelo, el índice documental y las herramientas seleccionadas funcionen dentro de los recursos medidos. Si el ajuste QLoRA no puede realizarse en el entorno local, se conservarán la comparación SLM y SLM–RAG y se reportará esa limitación. La sostenibilidad del recurso requiere mantener procedencia, licencias y etiquetas dialectales, así como documentar las condiciones para actualizar el corpus sin mezclar variedades de quechua.

CAPÍTULO V ASPECTOS ADMINISTRATIVOS

5.1. Cronograma de actividades

La Tabla 5 detalla la programación temporal de las actividades de la investigación.

Tabla 5
Cronograma de actividades de la investigación

Actividades / Fases del Proyecto	M1	M2	M3	M4	M5	M6
Fase 1: Preparación y Marco Ético						
Revisión de literatura y estado del arte	X					
Levantamiento de requerimientos	X	X				
Permisos institucionales y validación ética	X					
Fase 2: Diseño de la Solución						
Diseño de la arquitectura del sistema		X				
Selección y configuración del modelo base		X				
Fase 3: Recursos y Corpus Bilingüe						
Curaduría y normalización del corpus		X	X			
Construcción del banco de consultas patrón			X			
Fase 4: Implementación del Prototipo						
Cuantización e integración RAG local			X	X		
Adaptación del modelo (condicionada)				X		
Desarrollo de la interfaz de interacción				X		
Fase 5: Evaluación Experimental						
Ejecución de experimentos y captura de métricas				X	X	
Análisis estadístico de resultados					X	
Revisión lingüística especializada, si se aprueba el protocolo					X	
Fase 6: Documentación y Tesis						
Redacción del informe final de tesis					X	X
Revisión con asesor y preparación de sustentación						X

Nota. Planificación relativa a seis meses desde la aprobación del plan; las fechas calendario se consignarán cuando se establezca el inicio del proyecto.

5.2. Presupuesto y financiamiento

La Tabla 6 resume el presupuesto analítico de la investigación.

Tabla 6
Presupuesto analítico de la investigación

Rubro	Descripción / Concepto	Cantidad	Monto (S/.)
1. Bienes y Equipos			
Equipo de cómputo / prueba	Equipo disponible para las pruebas locales	1 equipo	Aporte en especie
Almacenamiento y respaldo	Espacio de almacenamiento y respaldo de datos	Por definir	Por cotizar
Material bibliográfico	Fuentes de acceso abierto y materiales que requieran adquisición	Por definir	Por cotizar
2. Servicios			
Servicios de cómputo / servidor	Procesamiento adicional, si las pruebas QLoRA lo requieren	Por definir	Por cotizar
Servicio de conectividad	Conectividad eventual para obtener fuentes y dependencias	Por definir	Por cotizar
Materiales e impresiones	Impresión y encuadernación requeridas por la escuela	Por definir	Por cotizar
3. Recursos Humanos			
Validación lingüística	Revisión especializada, si se incorpora al protocolo	Por definir	Por cotizar
Total General			**Por estimar**

Nota. La fuente y distribución del financiamiento están pendientes de confirmación; el equipo disponible se registra como aporte en especie.

5.3. Equipo de investigación

La Tabla 7 presenta los integrantes del equipo de investigación y sus funciones.

Tabla 7
Equipo de investigación

Integrante	Rol	Funciones Principales
Edmil Jampier Saire Bustamante	Tesista	Diseño, implementación, registro de pruebas y redacción del plan.
Por designar	Asesor/a	Orientación y revisión del proyecto, una vez formalizada la designación.

Nota. La asesoría y las funciones se actualizarán cuando se formalice la designación correspondiente.

REFERENCIAS

Court, S., & Elsner, M. (2024). Shortcomings of LLMs for low-resource translation: Retrieval and understanding are both the problem. *Proceedings of the Ninth Conference on Machine Translation*, 1332-1354. https://doi.org/10.18653/v1/2024.wmt-1.125

Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. *Advances in Neural Information Processing Systems*, *36*, 10088-10115. https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract-Conference.html

Duran, M., & Silberztein, M. (2026). Semi-automatic construction of a Quechua-Spanish dictionary. *Proceedings for the Ninth Workshop on Technologies for Machine Translation of Low Resource Languages (LoResMT 2026)*, 111-118. https://doi.org/10.18653/v1/2026.loresmt-1.9

Es, S., James, J., Espinosa Anke, L., & Schockaert, S. (2024). RAGAs: Automated evaluation of retrieval augmented generation. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, 150-158. https://doi.org/10.18653/v1/2024.eacl-demo.16

Hevia, J. S., Arredondo, F., & Kumar, V. (2025). Towards an efficient, customizable, and accessible AI tutor. *Proceedings of the Innovation and Responsibility in AI-Supported Education Workshop*, *273*, 250-254. https://proceedings.mlr.press/v273/hevia25a.html

Hevner, A. R., March, S. T., Park, J., & Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, *28*(1), 75-105. https://doi.org/10.2307/25148625

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rockt.[a]schel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, *33*, 9459-9474. https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html

Orcotoma Mormontoy, G. C., Leon Nuñez, L., & Espetia Huamanga, H. (2025). Towards the creation of a Collao Quechua–Spanish parallel corpus using optical character

recognition. *Proceedings of the Workshop on Beyond English: Natural Language Processing for All Languages in an Era of Large Language Models*, 1-6. https://doi.org/10.26615/978-954-452-105-9-001

Post, M. (2018). A call for clarity in reporting BLEU scores. *Proceedings of the Third Conference on Machine Translation: Research Papers*, 186-191. https://doi.org/10.18653/v1/W18-6319

Qwen Team. (2024). Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*. https://doi.org/10.48550/arXiv.2412.15115

Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., & Ling, Z. (2024). On-device language models: A comprehensive review. *arXiv preprint arXiv:2409.00088*. https://doi.org/10.48550/arXiv.2409.00088

ANEXOS

Anexo 1: Matriz de consistencia lógica

Tabla 8

Matriz de consistencia lógica de la investigación

Problemas	Objetivos	Hipótesis	Variables e indicadores	Método
Problema general: ¿De qué manera el diseño e implementación de una arquitectura SLM–RAG con QLoRA influye en la generación contextualizada en Quechua Collao en un entorno offline?	**Objetivo general:** Diseñar e implementar una arquitectura SLM–RAG con QLoRA para generación contextualizada en Quechua Collao en un entorno offline.	**Hipótesis general:** En las condiciones de prueba definidas, SLM–RAG con QLoRA obtendrá mejores valores de fidelidad y calidad lingüística que las configuraciones de referencia, sin exceder los recursos disponibles.	**VI:** configuración del sistema. **VD:** calidad lingüística, fidelidad y eficiencia.	Enfoque cuantitativo; investigación aplicada y tecnológica; experimento computacional comparativo con consultas repetidas.
Problema específico 1: ¿Cómo estructurar e indexar una base documental bilingüe para recuperar información pertinente en Quechua Collao?	**Objetivo específico 1:** Curar, estructurar e indexar documentos bilingües para recuperación local.	**Hipótesis específica 1:** La indexación semántica recuperará una mayor proporción de fragmentos pertinentes que la búsqueda léxica de referencia, según las consultas y etiquetas definidas.	Precisión de recuperación (P@k), cobertura de fuentes y trazabilidad documental.	Corpus con etiquetas de idioma y variedad; índice local y consultas con evidencia relevante identificada.
Problema específico 2: ¿De qué manera los adaptadores QLoRA afectan el uso del contexto bajo restricciones locales?	**Objetivo específico 2:** Implementar y acoplar QLoRA si el ajuste es viable en el entorno definido.	**Hipótesis específica 2:** Si el ajuste QLoRA resulta ejecutable, la configuración adaptada mostrará mayor uso de la evidencia que el SLM base, manteniendo constantes las demás condiciones.	Utilización de contexto; latencia; tokens por segundo; RAM y VRAM.	Registro de configuración y telemetría; prueba de viabilidad previa al experimento completo.
Problema específico 3: ¿Qué calidad lingüística, fidelidad y eficiencia alcanza el sistema frente a sus líneas base?	**Objetivo específico 3:** Comparar las configuraciones mediante métricas lingüísticas, de RAG y de eficiencia.	**Hipótesis específica 3:** La configuración integrada obtendrá mejores puntuaciones que SLM y SLM–RAG en las métricas seleccionadas, si la condición QLoRA puede evaluarse.	chrF++; SacreBLEU; fidelidad y relevancia RAG; latencia y memoria.	Banco previsto de 100 consultas; Friedman y comparaciones pareadas si se cumplen los supuestos y hay tres condiciones evaluables.

Nota. El tamaño de 100 consultas y la evaluación de QLoRA son provisionales. Se confirmarán después de validar el corpus y la viabilidad del hardware.

Anexo 2: Ficha técnica de registro experimental

Tabla 9
Ficha para registrar una corrida experimental

Campo	**Registro durante la ejecución**
Identificador	Completar al ejecutar
Configuración	SLM base / SLM–RAG / SLM–RAG–QLoRA, según viabilidad
Dispositivo y entorno	Modelo del equipo, sistema operativo y versiones
Modelo y cuantización	Nombre, versión y formato realmente utilizados
Consulta y variedad	Consulta evaluada, idioma y variedad identificados
Fragmentos recuperados	Identificadores de fuente y fragmentos entregados al modelo
Latencia y rendimiento	Medición en milisegundos y tokens por segundo
Consumo de memoria	Pico de RAM y VRAM medidos
Salida y métricas	Respuesta generada y puntuaciones calculadas
Observaciones	Errores, interrupciones y notas del evaluador

Anexo 3: Rúbrica complementaria de pertinencia pedagógica

Tabla 10
Rúbrica complementaria para valorar respuestas del prototipo

Criterio	**Insuficiente (1)**	**Parcial (2–3)**	**Adecuado (4–5)**
Pertinencia curricular	No responde al propósito de la consulta.	Responde parcialmente o incluye contenido accesorio.	Responde al propósito y se apoya en la fuente indicada.
Corrección lingüística	Errores que alteran el sentido o la variedad.	El sentido general se entiende, con errores que requieren corrección.	Redacción comprensible y variedad identificada por la persona evaluadora.
Andamiaje pedagógico	No explica ni organiza la respuesta.	Presenta alguna explicación, pero deja pasos o conceptos sin aclarar.	Explica de forma ordenada y adecuada al tipo de consulta.
Adecuación cultural	Contiene expresiones estereotipadas o inadecuadas.	Es neutral, aunque requiere contextualización.	Es respetuosa y coherente con el contexto documentado.
Claridad	Respuesta incoherente o difícil de seguir.	Comprensible con ambigüedades o repetición.	Clara, organizada y concisa.

Nota. Instrumento complementario; solo se aplicará si se aprueba un protocolo con evaluadores competentes. No sustituye las métricas computacionales principales.

Anexo 4: Plantilla del banco de consultas de evaluación

Tabla 11

Estructura prevista para documentar consultas de evaluación

ID	Tema	Idioma / variedad	Consulta validada	Fuente y respuesta de referencia
Q01	Pendiente de selección	Por identificar	Completar tras curar las fuentes	Registrar documento y respuesta verificable
Q02	Pendiente de selección	Por identificar	Completar tras curar las fuentes	Registrar documento y respuesta verificable
Q03	Pendiente de selección	Por identificar	Completar tras curar las fuentes	Registrar documento y respuesta verificable

Nota. Plantilla del instrumento; no representa consultas ni resultados ya validados. El banco previsto se completará después de verificar las fuentes y la cobertura lingüística.