

UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO
FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y
MECÁNICA
ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

Small Language Model bilingüe español-Quechua Collao para asistencia educativa
offline en entornos rurales de Educación Intercultural Bilingüe del sur andino
peruano

Curso:

Seminario de Investigación I

Para optar al Título Profesional de:

Ingeniero Informático y de Sistemas

Presentado por:

Br. Edmil Jampier Saire Bustamante

Br. Haider Alex Carpio Hermoza

Asesora:

Dra. Gabriela Zuñiga Rojas

Cusco – Perú
2026

Resumen

La presente propuesta de plan de tesis aborda el diseño, implementación y evaluación de un Small Language Model bilingüe español-Quechua Collao para asistencia educativa offline en contextos rurales de Educación Intercultural Bilingüe del sur andino peruano. El problema se ubica en la convergencia de tres factores: la brecha de conectividad que afecta a más del 79 % de los hogares rurales sin acceso a internet, la limitada disponibilidad de recursos tecnológicos adaptados a lenguas indígenas de bajos recursos y la necesidad de apoyo pedagógico contextualizado para estudiantes que interactúan en español, Quechua Collao o formas mixtas de comunicación. La investigación plantea un asistente educativo que no funcione como traductor aislado, sino como un sistema capaz de detectar el idioma predominante de la consulta, recuperar contenidos curriculares y glosarios locales mediante generación aumentada por recuperación, y producir respuestas pedagógicas pertinentes en el idioma requerido. El estudio se delimita exclusivamente a la variedad Quechua Collao, de acuerdo con la ubicación geográfica del estudio, la disponibilidad de corpus paralelos validados y la presencia de rasgos fonológicos diferenciadores como consonantes oclusivas glotizadas y aspiradas. Se espera que la propuesta contribuya teórica, práctica y metodológicamente al integrar procesamiento de lenguaje natural para lenguas indígenas, modelos compactos desplegados en dispositivos locales mediante técnicas de cuantización y criterios pedagógicos propios de la Educación Intercultural Bilingüe.

Palabras clave: Small Language Model, Quechua Collao, Educación Intercultural Bilingüe, asistencia educativa, inferencia offline, RAG.

Índice general

Resumen	II
Índice general	III
Índice de figuras	V
Índice de Tablas	VI
1. Justificación	1
2. Problema de Investigación	1
2.1. Descripción del problema	1
2.2. Identificación del problema	3
2.3. Formulación del problema	3
3. Alcances y limitaciones	3
3.1. Alcances	3
3.2. Limitaciones	4
4. Objetivos	5
4.1. Objetivo General	5
4.2. Objetivos Específicos	5
4.3. Alineación con los Objetivos de Desarrollo Sostenible	5
Estado del Arte	7
5. Estado del Arte	7
5.1. Procesamiento de Lenguaje Natural y Traducción Automática para Quechua Collao	7
5.2. Small Language Models y Despliegue Offline	7
5.3. Generación Aumentada por Recuperación (RAG) y Tecnología Educativa con IA	8
5.4. Política Educativa y Educación Intercultural Bilingüe en el Perú	8
5.5. Síntesis crítica y vacíos de investigación	8
6. Antecedentes	9
7. Marco Teórico	12
7.1. Educación Intercultural Bilingüe (EIB)	12
7.2. Quechua Collao	12
7.3. Small Language Models	13
7.4. Generación Aumentada por Recuperación (RAG)	13
7.5. Detección automática de idioma	13
7.6. Evaluación de sistemas educativos con IA	14
8. Metodología	14
8.1. Enfoque	14
8.2. Alcance	14
8.3. Diseño	14
8.4. Metodología de desarrollo	14
8.5. Población y muestra	15
9. Importancia del estudio	15
9.1. Resultados esperados	15

9.2.	Contribuciones	16
9.3.	Impacto social	16
10.	Cronograma de actividades	16
11.	Presupuesto	17
	Bibliografía	19
	Anexos	20

Índice de figuras

Índice de Tablas

1.	Cronograma de actividades por fases y meses	17
2.	Presupuesto estimado del proyecto	18

1. Justificación

La investigación se justifica porque la Educación Intercultural Bilingüe (EIB) en zonas rurales del sur andino peruano requiere soluciones tecnológicas que respondan simultáneamente a condiciones lingüísticas, pedagógicas y de conectividad. Según datos del INEI, al primer trimestre de 2025 solo el 20,5 % de los hogares del área rural cuenta con acceso a internet, frente al promedio nacional que supera el 58 %. Esta brecha se profundiza en los departamentos del sur andino, como Cusco, Apurímac, Ayacucho, Puno y Huancavelica. En estos mismos territorios, el sistema EIB atiende a más de 1,2 millones de estudiantes en aproximadamente 26 400 instituciones educativas (Ministerio de Educación del Perú, 2018), lo que evidencia una población escolar extensa que carece de herramientas tecnológicas adaptadas a su realidad lingüística y territorial. El proyecto se justifica desde tres perspectivas principales:

- **Justificación Teórica:** El estudio aporta a un campo todavía fragmentado. Mientras existen investigaciones sobre traducción automática neural para quechua (Sulla Torres et al., 2024; Orcotoma Mormontoy et al., 2025) y se sabe que los Grandes Modelos de Lenguaje presentan deficiencias sistemáticas en lenguas de bajos recursos (Court and Elsner, 2024), estas líneas no se han integrado con un enfoque educativo bilingüe. La investigación propone articular avances en inferencia local de modelos pequeños (Xu et al., 2024) con detección de idioma y generación aumentada por recuperación (RAG).
- **Justificación Práctica:** El proyecto propone una alternativa directa para apoyar a docentes y estudiantes en entornos de baja conectividad sin necesidad de reemplazar al docente. Su propósito es ofrecer apoyo localizado para responder consultas, explicar conceptos y recuperar información curricular manteniendo el Quechua Collao como lengua válida de aprendizaje. Estudios recientes, como la arquitectura Arapai (Walusimbi et al., 2026), confirman que el despliegue de chatbots offline con modelos pequeños es viable para entornos con limitaciones de infraestructura similares al sur andino peruano.
- **Justificación Metodológica:** La propuesta permite organizar un proceso de diseño y evaluación que combina herramientas de procesamiento de lenguaje natural con criterios pedagógicos. La integración de sistemas RAG (Li et al., 2025) y modelos de tutoría inteligente (Hevia et al., 2025; Levonian et al., 2025) permite evaluar el sistema no solo por métricas lingüísticas algorítmicas (como BLEU o chrF++), sino también por criterios de utilidad educativa, pertinencia cultural, y estabilidad *offline* en hardware de bajo costo.

La viabilidad del estudio se sostiene en la disponibilidad creciente de modelos compactos y herramientas de inferencia local que pueden ejecutarse mediante técnicas de cuantización (Xu et al., 2024).

2. Problema de Investigación

2.1. Descripción del problema

El desarrollo reciente de la inteligencia artificial generativa ha ampliado las posibilidades de crear asistentes educativos capaces de responder preguntas, explicar contenidos y apoyar procesos de aprendizaje. No obstante, gran parte de estas soluciones dependen de servicios en la nube, conectividad estable y modelos entrenados principalmente con lenguas de alta

disponibilidad de datos. Esta dependencia genera una brecha adicional para comunidades rurales donde solo dos de cada diez hogares acceden a internet y donde los estudiantes no siempre interactúan únicamente en español.

En el contexto peruano, la EIB responde a la necesidad de garantizar procesos educativos pertinentes para estudiantes de pueblos originarios. En el caso del quechua, la situación requiere una delimitación lingüística cuidadosa, porque no se trata de una lengua homogénea. El presente estudio se enfoca exclusivamente en la variedad Quechua Collao, hablada principalmente en Cusco, Puno, Arequipa y Moquegua. Esta variedad posee particularidades fonológicas relevantes, como la presencia de consonantes oclusivas glotizadas y aspiradas. Estas características deben considerarse al diseñar recursos tecnológicos para evitar producir respuestas lingüísticamente inadecuadas o invisibilizar los rasgos dialectales de esta región.

La literatura técnica muestra avances específicos en este campo. Sulla Torres et al. (2024) desarrollaron un modelo de traducción automática neural optimizado con BERT para la dirección quechua-español, reportando un BLEU de 20,13 y destacando las dificultades de la morfología aglutinante del quechua para los modelos estándar. Orcotoma Mormontoy et al. (2025) contribuyeron con la creación de un corpus paralelo Quechua Collao-español usando OCR sobre diccionarios publicados por la Academia Mayor de la Lengua Quechua, sentando precedentes para la recopilación de datos en esta variedad específica. Duran and Silberstein (2026) propusieron un método semi-automático de construcción de diccionarios quechua-español utilizando formalismos lingüísticos y transductores de estados finitos, ampliando los recursos léxicos disponibles. Sin embargo, estos trabajos se concentran principalmente en subtarefas lingüísticas y no necesariamente en la construcción de un asistente educativo offline alineado con materiales curriculares y necesidades docentes.

Del mismo modo, los estudios sobre modelos pequeños y despliegue en dispositivos de borde demuestran viabilidad técnica. Xu et al. (2024) documentan las principales técnicas de compresión, cuantización y optimización de inferencia que permiten ejecutar modelos generativos en hardware limitado. Walusimbi et al. (2026) proponen Arapai, una arquitectura de chatbot educativo offline-first diseñada para entornos de baja conectividad, validando que modelos cuantizados a 4 bits pueden funcionar en dispositivos locales con latencia aceptable. Court and Elsner (2024) evidencian que los LLM presentan deficiencias tanto de recuperación como de comprensión en lenguas de bajos recursos, lo que refuerza la necesidad de módulos RAG especializados y ajuste fino con datos específicos de la lengua objetivo. No obstante, estos estudios no resuelven por sí solos la pertinencia lingüística y pedagógica en contextos EIB.

El problema se agrava cuando los estudiantes formulan consultas en español, Quechua Collao o mezclas bilingües, fenómeno documentado en aulas EIB del sur andino como alternancia de códigos o translenguaje. En estos casos, un sistema educativo debe identificar el idioma predominante, reconocer posibles segmentos alternados, decidir el idioma de respuesta y recuperar materiales adecuados al contexto, considerando que la identificación lingüística en lenguas indígenas de bajos recursos presenta dificultades particulares. Si el sistema falla en esta etapa, puede responder en una lengua no pertinente, perder información cultural o generar explicaciones desconectadas del currículo local. Por ello, el reto no es únicamente técnico, sino también pedagógico y lingüístico.

En consecuencia, existe una brecha de investigación y desarrollo: no se identifica una solución integrada de asistente educativo bilingüe español-Quechua Collao que funcione offline, use modelos pequeños de lenguaje, incorpore detección automática del idioma y recupere contenido curricular local para apoyar procesos de aprendizaje en zonas rurales de EIB. Esta brecha justifica el diseño de una propuesta que articule las capas lingüística, pedagógica y tecnológica en un único artefacto evaluable.

2.2. Identificación del problema

El problema central de la investigación es la ausencia de un asistente educativo bilingüe español-Quechua Collao, ejecutable sin conexión a internet, que integre detección automática del idioma, recuperación local de contenidos curriculares y generación de respuestas pedagógicas pertinentes para estudiantes y docentes de contextos rurales de Educación Intercultural Bilingüe del sur andino peruano.

2.3. Formulación del problema

Problema general.

¿Cómo diseñar un asistente educativo bilingüe español-Quechua Collao basado en un Small Language Model que funcione offline en dispositivos de bajo o mediano costo para apoyar procesos de aprendizaje en contextos rurales de Educación Intercultural Bilingüe del sur andino peruano?

Sub problemas.

- ¿Cómo delimitar los recursos lingüísticos y pedagógicos necesarios para que el asistente trabaje con español y Quechua Collao, respetando sus particularidades morfológicas y fonológicas?
- ¿Cómo incorporar detección automática del idioma para manejar consultas en español, Quechua Collao o entradas mixtas español-quechua?
- ¿Cómo organizar un módulo RAG local que recupere currículo, glosarios y materiales EIB para mejorar la pertinencia de las respuestas?
- ¿Cómo evaluar la calidad lingüística, utilidad educativa, adecuación cultural y rendimiento offline del asistente propuesto?

3. Alcances y limitaciones

3.1. Alcances

El presente estudio abarca el diseño, implementación y evaluación de un asistente educativo bilingüe español-Quechua Collao basado en un Small Language Model. La investigación se centra en la asistencia textual para estudiantes y docentes de contextos rurales de EIB, considerando entradas en español, Quechua Collao o mezcla bilingüe. La salida esperada será una respuesta pedagógica en el idioma predominante del usuario o en modo bilingüe cuando el contexto educativo lo requiera. Se definen los siguientes alcances específicos:

- **Alcance lingüístico:** Se delimita de forma exclusiva al Quechua Collao (variante de Cusco), de acuerdo con la ubicación geográfica del estudio y la disponibilidad de corpus paralelos como los construidos por Orcotoma Mormontoy et al. (2025). Esta variedad presenta rasgos fonológicos diferenciadores (consonantes oclusivas glotizadas y aspiradas) que deben reflejarse cuidadosamente. Esta delimitación evita prometer cobertura de otras variedades dialectales, permitiendo construir un prototipo culturalmente pertinente.

- **Alcance tecnológico:** Comprende una arquitectura offline compuesta por detección automática del idioma, enrutamiento lingüístico, recuperación aumentada por generación con recursos locales, y un modelo compacto (SLM). Conforme a lo documentado por Xu et al. (2024), se usarán técnicas de cuantización a 4 bits que permiten reducir los requisitos de memoria y cómputo sin pérdida crítica de calidad.
- **Alcance disciplinar:** Se ubica en la convergencia de la ingeniería informática y de sistemas, el procesamiento de lenguaje natural, la tecnología educativa y la Educación Intercultural Bilingüe. Se orienta como una investigación aplicada de alcance tecnológico-experimental, que implementa y evalúa un prototipo funcional bajo condiciones controladas.

3.2. Limitaciones

Se reconocen las siguientes limitaciones que condicionan la ejecución del proyecto:

- **Disponibilidad de corpus (Limitación de datos):** Al tratarse de una lengua de bajos recursos digitales, los datos existentes pueden ser reducidos o heterogéneos, lo cual afecta la recuperación y comprensión de los modelos (Court and Elsner, 2024). Para mitigar esto, se complementará el corpus con glosarios, materiales EIB y datos sintéticos validados.
- **Restricción dialectal:** El prototipo construido está estrictamente orientado a los rasgos fonológicos y léxicos del Quechua Collao. El sistema no está diseñado para generalizarse o atender consultas en otras variedades quechuas.
- **Restricciones de hardware (Tecnológicas):** La ejecución offline de un SLM depende estrictamente de la memoria disponible (RAM), el *runtime* y el consumo energético del dispositivo local (Xu et al., 2024). Esto restringe el tamaño del modelo utilizable y la complejidad de las consultas que puede atender con una latencia aceptable.
- **Evaluación pedagógica multidimensional:** La utilidad educativa no puede medirse únicamente con métricas automáticas (BLEU). Las interacciones generativas requieren evaluación de relevancia y seguridad (Levonian et al., 2025), lo que demanda la revisión obligatoria por parte de docentes o especialistas EIB.
- **Acceso territorial para validación:** La evaluación con usuarios reales requiere coordinación institucional con Direcciones Regionales (DRE) y Unidades de Gestión (UGEL), lo cual está condicionado por factores logísticos, distancias geográficas y autorizaciones escolares.
- **Alcance exclusivamente textual:** El prototipo no incorpora reconocimiento ni síntesis de voz. Los desafíos del habla bilingüe se consideran fuera del alcance actual y como posibles líneas de ampliación futura.
- **Dependencia de especialistas institucionales:** La selección de contenidos curriculares y la validación final del asistente dependen de la disponibilidad y experiencia de especialistas en Quechua Collao vinculados al ámbito institucional. Sin esta validación, el prototipo carecería de la fundamentación cultural necesaria.

4. Objetivos

4.1. Objetivo General

Diseñar, implementar y evaluar un asistente educativo bilingüe español-Quechua Collao basado en un Small Language Model, con funcionamiento offline, detección automática del idioma y recuperación local de contenidos curriculares, para apoyar procesos de aprendizaje en contextos rurales de Educación Intercultural Bilingüe del sur andino peruano.

4.2. Objetivos Específicos

- Caracterizar los requerimientos lingüísticos, pedagógicos y tecnológicos necesarios para un asistente educativo bilingüe español-Quechua Collao en contextos rurales de EIB, a partir de la revisión de literatura, documentos normativos del MINEDU y consulta con especialistas del ámbito institucional.
- Identificar y organizar recursos lingüísticos y educativos pertinentes, como corpus paralelos, glosarios, materiales EIB y contenidos curriculares alineados con la variedad Quechua Collao, para alimentar la base local del sistema.
- Diseñar la arquitectura funcional offline del asistente, integrando detección automática del idioma, enrutamiento lingüístico, recuperación aumentada por generación y generación de respuestas pedagógicas contextualizadas.
- Implementar un prototipo funcional del asistente educativo bilingüe, utilizando un Small Language Model con técnicas de cuantización y una base local de contenidos curriculares.
- Evaluar el desempeño técnico del prototipo considerando latencia, consumo de memoria, tokens por segundo, estabilidad offline y capacidad de respuesta en dispositivos de bajo o mediano costo.
- Evaluar la calidad lingüística mediante métricas como BLEU y chrF++, la utilidad educativa y la pertinencia intercultural de las respuestas generadas por el asistente, con participación de docentes y especialistas EIB.

4.3. Alineación con los Objetivos de Desarrollo Sostenible

La investigación se alinea con los siguientes Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030 de las Naciones Unidas:

- **ODS 4 — Educación de calidad.** El estudio contribuye a garantizar una educación inclusiva, equitativa y de calidad al proponer una herramienta de apoyo pedagógico en lengua materna para estudiantes de pueblos originarios en zonas rurales. El asistente educativo bilingüe busca reducir las barreras lingüísticas y tecnológicas que limitan el acceso a recursos de aprendizaje en contextos de Educación Intercultural Bilingüe.
- **ODS 9 — Industria, innovación e infraestructura.** La propuesta promueve la innovación tecnológica al diseñar una solución basada en modelos pequeños de lenguaje con funcionamiento offline, adaptada a condiciones de infraestructura limitada. El despliegue de un SLM cuantizado en dispositivos de bajo costo representa una contribución a la infraestructura tecnológica educativa de las comunidades rurales del sur andino.

- **ODS 10 — Reducción de las desigualdades.** El proyecto aborda directamente la brecha digital y lingüística que afecta a las comunidades quechuahablantes. Al ofrecer un asistente que funciona sin conexión a internet y que opera en Quechua Collao, se busca reducir la desigualdad en el acceso a herramientas educativas tecnológicas entre zonas urbanas y rurales.

5. Estado del Arte

El desarrollo de un asistente educativo bilingüe español-Quechua Collao requiere la integración de avances en múltiples dominios disciplinares. A continuación, se presenta una síntesis analítica y crítica de las investigaciones previas más relevantes, organizadas temáticamente.

5.1. Procesamiento de Lenguaje Natural y Traducción Automática para Quechua Collao

El procesamiento de lenguaje natural (PLN) para lenguas aglutinantes de bajos recursos como el quechua ha presentado desafíos históricos debido a su complejidad morfológica. Investigaciones recientes han abordado estas brechas mediante la construcción de corpus y el ajuste de modelos neuronales. Orcotoma Mormontoy et al. (2025) aportaron significativamente al construir un corpus paralelo Quechua Collao-español de 44 263 palabras mediante el uso de reconocimiento óptico de caracteres (OCR) sobre textos académicos de la Academia Mayor de la Lengua Quechua, logrando tasas de error de palabra (WER) de 6.59 %. Por su parte, Duran and Silberztein (2026) propusieron métodos semi-automáticos para la construcción de diccionarios quechua-español utilizando formalismos lingüísticos, lo que amplía la disponibilidad de recursos léxicos estructurados.

En cuanto a la traducción, Sulla Torres et al. (2024) demostraron que los modelos de traducción automática neuronal (NMT) optimizados con BERT pueden alcanzar puntajes aceptables (BLEU de 20.13) en la dirección quechua-español, aunque subrayaron las limitaciones impuestas por la escasez de datos. No obstante, el paradigma de traducción y PLN ha cambiado con la llegada de los Grandes Modelos de Lenguaje (LLM). En este contexto, Court and Elsner (2024) evaluaron las habilidades de aprendizaje en contexto de LLMs comerciales (GPT-4, Gemini) para traducir del quechua al español. Sus hallazgos indican que, si bien la inclusión de traducciones a nivel de morfema mejora el rendimiento, la inyección de largas reglas gramaticales o ejemplos de corpus mediante técnicas de recuperación puede, paradójicamente, degradar el rendimiento de los modelos más avanzados, generando traducciones fluidas pero infieles o estereotipadas. Esto evidencia que depender exclusivamente de LLMs en la nube mediante *prompting* no resuelve el problema de comprensión estructural en lenguas de bajos recursos.

5.2. Small Language Models y Despliegue Offline

Frente a la dependencia de conectividad y alto consumo computacional de los LLMs, el desarrollo de Small Language Models (SLM) y técnicas de optimización para hardware restringido (on-device AI) ha cobrado relevancia. La exhaustiva revisión de Xu et al. (2024) sistematiza cómo técnicas como la compartición de parámetros, la destilación de conocimiento y, fundamentalmente, la cuantización (PTQ y QAT), permiten que modelos con menos de 10 mil millones de parámetros se ejecuten eficientemente en dispositivos móviles y procesadores de bajo consumo.

La aplicación de estas tecnologías en contextos de baja conectividad fue validada empíricamente por Walusimbi et al. (2026), quienes diseñaron *Arapai*, una arquitectura de chatbot educativo offline-first. Al desplegar modelos cuantizados (como TinyLlama o Qwen) en hardware heredado (solo CPU), lograron latencias de respuesta de 1 a 3 segundos, demostrando que la inferencia local es técnicamente factible y pedagógicamente útil para el aprendizaje autodirigido en entornos con infraestructura precaria. Sin embargo, su estudio se centró en inglés y no abordó los retos de lenguas aglutinantes.

5.3. Generación Aumentada por Recuperación (RAG) y Tecnología Educativa con IA

La Generación Aumentada por Recuperación (RAG) se ha convertido en el estándar para mitigar las alucinaciones en modelos generativos, vinculando sus respuestas a corpus documentales específicos. La revisión sistemática de Li et al. (2025) confirma que los sistemas RAG mejoran significativamente la precisión factual y la personalización en aplicaciones educativas, permitiendo que la IA asuma roles de tutoría basados en el currículo local.

Sin embargo, el despliegue de RAG con modelos pequeños presenta desafíos particulares. Hevia et al. (2025) evaluaron un tutor de IA offline combinando RAG con SLMs (SmolLM), encontrando que los modelos pequeños tienen dificultades para procesar contextos recuperados extensos o ruidosos, lo que irónicamente redujo su precisión en evaluaciones de respuestas múltiples. Esto sugiere la necesidad de estrategias de recuperación y segmentación (chunking) altamente optimizadas. Adicionalmente, el despliegue de estas herramientas con estudiantes requiere garantías pedagógicas. Levonian et al. (2025) establecen que los sistemas de tutoría inteligente deben ser diseñados para generar interacciones seguras y relevantes, priorizando el andamiaje cognitivo sobre la simple provisión de respuestas directas.

5.4. Política Educativa y Educación Intercultural Bilingüe en el Perú

El desarrollo tecnológico debe alinearse con los marcos normativos y pedagógicos vigentes. El Modelo de Servicio Educativo Intercultural Bilingüe (MSEIB) del Ministerio de Educación del Perú (Ministerio de Educación del Perú, 2018) establece lineamientos para garantizar una educación pertinente a estudiantes de pueblos originarios. El MSEIB distingue escenarios de fortalecimiento lingüístico (donde el quechua es lengua materna y el español segunda lengua) y revitalización (donde el español es lengua materna). Esto exige que cualquier herramienta de asistencia educativa no sea un simple traductor bidireccional, sino un sistema capaz de alternar códigos, detectar el idioma predominante del estudiante y recuperar contenidos con pertinencia cultural e intercultural, apoyando directamente la labor del docente bilingüe.

5.5. Síntesis crítica y vacíos de investigación

La revisión de literatura demuestra que existen avances maduros, pero aislados, en los componentes necesarios para el sistema propuesto. Por un lado, se han construido corpus y evaluado LLMs para quechua (Orcotoma Mormontoy et al. 2025; Court and Elsner 2024), pero su aplicación práctica en tecnología educativa es casi nula. Por otro lado, la viabilidad de SLMs offline y sistemas RAG ha sido probada (Walusimbi et al. 2026; Hevia et al. 2025; Xu et al. 2024), pero principalmente para inglés y lenguas mayoritarias. Finalmente, la política EIB (Ministerio de Educación del Perú 2018) exige recursos pertinentes que la actual oferta de LLMs comerciales en la nube no puede satisfacer, ya sea por barreras de conectividad o por la degradación del rendimiento al inyectarles reglas complejas (Court and Elsner, 2024).

En consecuencia, el principal vacío de investigación radica en la falta de integración de estas tecnologías en un artefacto cohesionado: **no existe un asistente educativo offline basado en SLMs, optimizado mediante RAG local y afinado específicamente para la variedad Quechua Collao, que responda a los requerimientos pedagógicos del MSEIB en el sur andino peruano.** Esta brecha justifica el presente plan de tesis, cuyo propósito es articular el procesamiento de lenguaje natural de bajos recursos con la inferencia local eficiente, ofreciendo una solución tecnológica y socialmente pertinente.

6. Antecedentes

Orcotoma Mormontoy G. C. et al., (2025), *Towards the Creation of a Collao Quechua-Spanish Parallel Corpus Using Optical Character Recognition*, Universidad Andina del Cusco, Perú.

- **Objetivo:** Construir un corpus paralelo Quechua Collao-español utilizando reconocimiento óptico de caracteres (OCR) para superar la escasez de recursos digitales en esta variante.
- **Metodología:** Escaneo y procesamiento de libros de la Academia Mayor de la Lengua Quechua, seguido de extracción de texto con Tesseract OCR y corrección manual para establecer una verdad base.
- **Resultados:** Se generó un corpus de 44 263 palabras con tasas de error (CER) de 1.82 % y (WER) de 6.59 %, demostrando la eficacia de la técnica.
- **Comentario:** Esta investigación proporciona la metodología y la fuente de origen (libros de la AMLQ) que servirá como base para recolectar el corpus paralelo necesario para el afinamiento y generación aumentada del asistente propuesto.

Court S. y Elsner M., (2024), *Shortcomings of LLMs for Low-Resource Translation: Retrieval and Understanding Are Both the Problem*, The Ohio State University, Estados Unidos.

- **Objetivo:** Evaluar la capacidad de aprendizaje en contexto de Grandes Modelos de Lenguaje (LLMs) en tareas de traducción de quechua sureño a español usando recursos pedagógicos recuperados.
- **Metodología:** Evaluación de GPT-3.5, GPT-4o y Gemini usando *prompts* enriquecidos con diccionario, gramática y corpus. Se usaron métricas automáticas (BLEURT) y evaluación humana (MQM adaptado).
- **Resultados:** Aunque la traducción a nivel de morfema mejora el rendimiento en modelos más básicos, proporcionar explicaciones gramaticales complejas mediante recuperación degrada el rendimiento de modelos avanzados como GPT-4o.
- **Comentario:** Justifica la decisión de no depender de LLMs comerciales genéricos y técnicas RAG puras para reglas gramaticales complejas, apostando en su lugar por un SLM especializado o afinado para procesar correctamente las estructuras del Quechua Collao.

Walusimbi J. et al., (2026), *Arapai: An Offline-First AI Chatbot Architecture for Low-Connectivity Educational Environments*, Soroti University, Uganda.

- **Objetivo:** Presentar una arquitectura de chatbot educativo basada en LLM que funcione completamente sin conexión (offline-first) para entornos con conectividad limitada.
- **Metodología:** Implementación de LLMs cuantizados (como Qwen y Mistral) en hardware heredado (sólo CPU) y evaluación piloto con 120 estudiantes midiendo rendimiento técnico y usabilidad.
- **Resultados:** El sistema demostró una latencia de 1 a 3 segundos en CPUs estándar, proveyendo respuestas instructivas adaptables a diferentes niveles educativos con alta aceptación de usuarios.

- **Comentario:** Aporta la validación técnica directa de que los modelos de lenguaje cuantizados a 4 bits pueden ejecutarse eficientemente en dispositivos de bajo costo (sólo CPU), lo cual es el núcleo tecnológico del asistente propuesto para zonas rurales del Perú.

Xu J. et al., (2024), *On-Device Language Models: A Comprehensive Review*, Meta y Universidad del Estado de San Francisco, Estados Unidos.

- **Objetivo:** Examinar los desafíos de desplegar LLMs computacionalmente costosos en dispositivos restringidos por recursos (borde) y revisar estrategias de compresión.
- **Metodología:** Revisión sistemática integral de arquitecturas, técnicas de cuantización, poda y destilación de conocimiento para LLMs ejecutados *on-device*.
- **Resultados:** Se identificó que la cuantización (PTQ y QAT) es el enfoque más efectivo, logrando reducciones sustanciales en uso de memoria sin pérdida significativa de rendimiento.
- **Comentario:** Fundamenta las decisiones de diseño del sistema, específicamente la necesidad de utilizar técnicas de cuantización post-entrenamiento (PTQ) para poder desplegar el SLM en dispositivos locales de las instituciones EIB.

Hevia J. S., Arredondo F., y Kumar V., (2025), *Towards an Efficient, Customizable, and Accessible AI Tutor*, Rice University, Estados Unidos.

- **Objetivo:** Proponer un flujo de Generación Aumentada por Recuperación (RAG) offline emparejado con un Small Language Model (SLM) para entornos educativos de bajos recursos.
- **Metodología:** Implementación de SmolLM con un RAG sobre libros de texto de biología y evaluación de su precisión en respuestas de opción múltiple (MMLU).
- **Resultados:** Sorprendentemente, la inclusión del RAG redujo la precisión del SLM al introducir contextos extensos que el modelo pequeño luchaba por procesar de forma efectiva.
- **Comentario:** Advierte sobre la necesidad de usar técnicas avanzadas de fragmentación (chunking) semántica para evitar inyectar ruido que confunda al SLM, consideración crítica para el diseño del RAG en este proyecto de tesis.

Li Z. et al., (2025), *Retrieval-Augmented Generation for Educational Application: A Systematic Survey*, Universidad Politécnica de Hong Kong, Hong Kong.

- **Objetivo:** Analizar sistemáticamente las aplicaciones, metodologías y desafíos de la Generación Aumentada por Recuperación (RAG) en el dominio educativo.
- **Metodología:** Revisión sistemática de literatura sobre implementaciones de RAG orientadas a mitigar alucinaciones en sistemas de tutoría.
- **Resultados:** RAG mejora la pertinencia y fundamentación factual de las respuestas educativas, aunque persiste el desafío de recuperar información contextualmente alineada.

- **Comentario:** Confirma que RAG es la arquitectura idónea para garantizar que el asistente educativo recupere contenidos curriculares validados y materiales EIB específicos en lugar de depender del conocimiento paramétrico genérico.

Levonian Z. et al., (2025), *Designing Safe and Relevant Generative Chats for Math Learning in Intelligent Tutoring Systems*, Institución no especificada, Estados Unidos.

- **Objetivo:** Establecer criterios de diseño para interacciones generativas seguras y relevantes en sistemas de tutoría inteligente.
- **Metodología:** Análisis de interacciones en el aula para derivar heurísticas pedagógicas y medidas de seguridad que guíen las respuestas de la IA.
- **Resultados:** Se proponen marcos multidimensionales para evaluar la relevancia, el tono, y la alineación curricular de las respuestas generadas.
- **Comentario:** Proporciona las métricas y criterios cualitativos necesarios para estructurar la evaluación pedagógica del asistente con los docentes y especialistas EIB, yendo más allá de las simples métricas de traducción automática.

Sulla Torres J. A., Cueva Medina B., y Tuco Casquino G. F., (2024), *Development of a Neural Machine Translation Model Optimized with BERT for Translation from Quechua to Spanish*, Universidad Católica de Santa María, Perú.

- **Objetivo:** Desarrollar y evaluar un modelo de traducción automática neuronal (NMT) optimizado con BERT para la dirección quechua-español.
- **Metodología:** Pre-entrenamiento y afinamiento de un modelo transformador utilizando un corpus bilingüe quechua-español.
- **Resultados:** El modelo propuesto alcanzó un puntaje BLEU de 20.13, superando a líneas base previas pero evidenciando dificultades con la morfología aglutinante del quechua.
- **Comentario:** Define el estado del arte y un umbral base (baseline) métrico para evaluar la capacidad del SLM al momento de procesar traducciones o interpretar oraciones del Quechua Collao.

Duran M. y Silberztein M., (2026), *Semi-automatic Construction of a Quechua-Spanish Dictionary*, Université de Franche-Comté, Francia.

- **Objetivo:** Proponer un enfoque semi-automático para construir diccionarios electrónicos quechua-español a partir de textos digitalizados y corpus.
- **Metodología:** Uso de transductores de estados finitos y herramientas NooJ para alinear lemas y afijos entre ambos idiomas.
- **Resultados:** Se generó un recurso léxico estructurado que captura adecuadamente la polisemia y las correspondencias de la morfología aglutinante.
- **Comentario:** Ilustra métodos viables para estructurar diccionarios locales que posteriormente pueden ser indexados en el banco de datos RAG del asistente para recuperar traducciones precisas de vocabulario EIB.

Ministerio de Educación del Perú, (2018), *Modelo de Servicio Educativo Intercultural Bilingüe*, MINEDU, Perú.

- **Objetivo:** Establecer los componentes y la orientación pedagógica del servicio educativo para estudiantes de pueblos originarios o indígenas.
- **Metodología:** Documento normativo y pedagógico que define formas de atención (fortalecimiento, revitalización y ámbitos urbanos).
- **Resultados:** Define que la educación debe impartirse utilizando tanto la lengua materna (ej. quechua) como la segunda lengua (español), de forma articulada al currículo y prácticas culturales.
- **Comentario:** Es la base conceptual obligatoria de esta investigación. Asegura que el asistente esté alineado normativamente con las políticas del Estado Peruano en materia de interculturalidad.

7. Marco Teórico

7.1. Educación Intercultural Bilingüe (EIB)

La Educación Intercultural Bilingüe es el modelo pedagógico promovido por el Ministerio de Educación del Perú (MINEDU) para garantizar el derecho a una educación pertinente a los estudiantes de pueblos originarios. Según el Modelo de Servicio Educativo Intercultural Bilingüe (Ministerio de Educación del Perú, 2018), el enfoque busca desarrollar competencias en los estudiantes a partir de su matriz cultural, en un diálogo de saberes con otras culturas, y promover el uso comunicativo de su lengua originaria y el castellano. El modelo establece tres formas de atención principales:

- **EIB de Fortalecimiento Cultural y Lingüístico:** Orientada a estudiantes que tienen la lengua originaria (como el Quechua Collao) como lengua materna y el castellano como segunda lengua. El asistente propuesto debe apoyar el desarrollo de aprendizajes principalmente en quechua.
- **EIB de Revitalización Cultural y Lingüística:** Dirigida a estudiantes cuya lengua materna es el castellano, pero pertenecen a comunidades con herencia cultural originaria. Aquí, el asistente puede funcionar como apoyo para la enseñanza progresiva del quechua como segunda lengua.

Cualquier tecnología educativa insertada en este contexto debe respetar este enfoque de bilingüismo aditivo, donde ninguna lengua desplaza a la otra.

7.2. Quechua Collao

El Quechua Collao (qheswa sureño, variante de Cusco-Collao) pertenece a la rama Quechua II-C de la clasificación de Torero y es la variante más hablada en los Andes del sur peruano (Cusco, Puno, Arequipa, Moquegua) y Bolivia. A nivel morfosintáctico, es una lengua aglutinante y sufijadora, donde una sola palabra raíz puede recibir múltiples sufijos (derivativos y flexivos) para formar significados que en español requerirían una oración completa. A nivel fonológico, se caracteriza por poseer tres series de consonantes oclusivas y africadas: simples, aspiradas y glotizadas (ej. t, th, t'). La digitalización y procesamiento NLP de esta variante enfrentan el problema de escasez de recursos digitales estructurados

(Orcotoma Mormontoy et al., 2025), además de la alta variabilidad en la escritura debido a las tensiones entre alfabetos pentavocálicos y trivocálicos en el entorno académico (Court and Elsner, 2024).

7.3. Small Language Models

Los Small Language Models (SLM) son modelos de lenguaje fundamentados en la arquitectura Transformer que típicamente poseen menos de 10 mil millones (10B) de parámetros. A diferencia de los modelos masivos, los SLMs (como Llama 3 8B, Phi-3, Gemma-2 9B, Qwen2.5) están diseñados para operar con menores requerimientos de cómputo y memoria, siendo idóneos para despliegues locales (on-device) o *edge computing* (Xu et al., 2024). Para hacer factible su ejecución en dispositivos con limitaciones estrictas de hardware (como CPU sin GPU dedicada), se emplean técnicas de compresión. La más extendida es la **Cuantización Post-Entrenamiento (PTQ)**, la cual reduce la precisión en bits de los pesos del modelo (por ejemplo, de Float16 a Int4 o Int8), minimizando el espacio en memoria RAM requerido y acelerando la inferencia de *tokens* a expensas de una mínima pérdida de precisión teórica.

7.4. Generación Aumentada por Recuperación (RAG)

La Generación Aumentada por Recuperación (Retrieval-Augmented Generation) es una arquitectura que acopla un modelo generativo con un mecanismo de recuperación de información (Li et al., 2025). El proceso típico involucra:

1. **Indexación:** Los documentos base (ej. currículo, glosarios) se dividen en fragmentos (chunks) y se convierten en vectores mediante un modelo de incrustación (embedding), almacenándose en una base de datos vectorial local.
2. **Recuperación (Retrieval):** Cuando el usuario realiza una consulta, esta se vectoriza para buscar los fragmentos más similares semánticamente utilizando métricas de similitud de coseno.
3. **Generación:** Los fragmentos recuperados se inyectan en el contexto del *prompt* junto a la consulta original, permitiendo que el LLM/SLM genere una respuesta anclada a esa información específica.

En contextos de SLM, el tamaño y la relevancia (ausencia de ruido) de los fragmentos recuperados es crítico, ya que ventanas de contexto muy largas o ruidosas pueden degradar severamente la precisión del modelo pequeño (Hevia et al., 2025).

7.5. Detección automática de idioma

En entornos bilingües donde ocurre translengüaje o alternancia de códigos, es necesario identificar si la consulta del usuario se formula predominantemente en español, en quechua o es de naturaleza mixta. Para lenguas de bajos recursos, la detección basada en reglas combinada con modelos ligeros de clasificación de texto permite enrutar internamente la consulta al prompt específico o al índice documental correcto (español o quechua) antes de activar la generación computacionalmente pesada del SLM (Walusimbi et al., 2026).

7.6. Evaluación de sistemas educativos con IA

La evaluación de sistemas generativos en entornos educativos abarca tres dimensiones. En la dimensión técnica, se miden variables como latencia (Time-To-First-Token), consumo de memoria RAM y velocidad de generación (tokens por segundo) en hardware objetivo (Walusimbi et al., 2026). En la dimensión de procesamiento natural, se utilizan métricas de correspondencia léxica como BLEU y chrF++ para evaluar la fidelidad de traducciones frente a oraciones de referencia (Sulla Torres et al., 2024). En la dimensión pedagógica, se requiere la intervención humana (docentes y especialistas) para validar la exactitud factual de la respuesta, su adecuación al tono educativo (seguridad) y la pertinencia intercultural respecto a la edad y contexto de los estudiantes (Levonian et al., 2025).

8. Metodología

8.1. Enfoque

La presente investigación tendrá un enfoque metodológico predominantemente **cuantitativo**. Esto se debe a que la validación y evaluación de la solución se sustentará en la recolección y análisis de datos medibles para comprobar el cumplimiento de los objetivos. Se cuantificarán variables de rendimiento técnico del software (latencia, uso de memoria, tokens por segundo) y se emplearán métricas lingüísticas algorítmicas estandarizadas (BLEU, chrF++) para medir el desempeño del sistema. La evaluación pedagógica también se apoyará en escalas numéricas estandarizadas aplicadas a instrumentos de juicio de expertos.

8.2. Alcance

El alcance de la investigación será **descriptivo** con una naturaleza de investigación tecnológica-aplicada. Se implementará una arquitectura de *software* con parámetros específicos y se describirá y medirá su comportamiento individual frente a métricas predefinidas, sin la intención de buscar causalidad estadística pura (no es explicativo) ni la generalización transversal a toda otra variante de la lengua. Su propósito es resolver un problema práctico en un escenario particular mediante ingeniería y medir sus indicadores de éxito.

8.3. Diseño

El diseño de investigación adoptará el modelo **No Experimental Transversal**. No se manipularán variables independientes ni se crearán grupos de control de usuarios. En cambio, se recolectarán datos en un único momento temporal una vez que el prototipo esté completamente funcional y expuesto a las consultas del corpus de prueba o a las sesiones de validación por parte de los especialistas, describiendo los resultados de estas interacciones directas.

8.4. Metodología de desarrollo

Para la construcción del sistema basado en Inteligencia Artificial y arquitecturas SLM, se empleará el paradigma **Design Science Research (DSR)**. Esta metodología iterativa es idónea para investigaciones en sistemas de información que buscan crear un artefacto innovador para resolver problemas reales. El proceso contemplará las siguientes fases:

1. **Identificación del problema y motivación:** Caracterización de las limitaciones de conectividad y la carencia de herramientas en Quechua Collao.

2. **Definición de los objetivos de la solución:** Establecimiento de requisitos técnicos (inferencia offline, uso en CPU) y pedagógicos.
3. **Diseño y desarrollo:** Selección y cuantización del Small Language Model óptimo, diseño de la arquitectura RAG local y construcción del pipeline de detección de idioma y generación.
4. **Demostración:** Integración del prototipo funcional y curación del banco de conocimiento con el corpus de la Academia Mayor de la Lengua Quechua y textos del MINEDU.
5. **Evaluación:** Sometimiento del artefacto a pruebas de rendimiento en hardware de bajo costo, medición de calidad lingüística (BLEU) y evaluación de pertinencia por parte de especialistas EIB.
6. **Comunicación:** Documentación de resultados, arquitectura y recomendaciones de uso en la tesis final.

8.5. Población y muestra

La evaluación del artefacto requerirá poblaciones de distinta naturaleza. Por el lado de los datos de *software*, la población estará conformada por el corpus digitalizado disponible en Quechua Collao-español. La muestra de datos para el bloque RAG consistirá en manuales y currículos oficiales EIB para primaria/secundaria y los textos paralelos validados por Orcotoma Mormontoy et al. (2025). La muestra de interacción incluirá un banco de pruebas mínimo de 100 consultas estructuradas extraídas de contextos académicos reales.

Para la validación pedagógica, la población objetivo estará constituida por la comunidad educativa EIB del sur andino. La muestra será de tipo no probabilística intencional, seleccionando de 3 a 5 especialistas o docentes activos en Instituciones Educativas EIB con dominio acreditado de la variante Quechua Collao. Ellos evaluarán muestras de respuestas generadas por el sistema mediante rúbricas estandarizadas, garantizando que el diseño experimental cuente con rigor cualitativo en la comprobación final de viabilidad pedagógica.

9. Importancia del estudio

9.1. Resultados esperados

Se espera obtener los siguientes productos al culminar la investigación:

- Un prototipo funcional de asistente educativo bilingüe español-Quechua Collao, ejecutable sin conexión a internet en dispositivos de bajo o mediano costo.
- Una base local de contenidos curriculares, glosarios y materiales EIB organizados para su recuperación mediante RAG.
- Un corpus curado de recursos lingüísticos español-Quechua Collao, complementado con datos sintéticos y validado por especialistas.
- Un reporte de evaluación técnica que documente métricas de latencia, consumo de memoria, tokens por segundo y estabilidad offline del prototipo.
- Un reporte de evaluación lingüística y pedagógica con resultados de métricas automáticas (BLEU, chrF++) y valoraciones de docentes y especialistas EIB sobre la utilidad educativa y pertinencia intercultural de las respuestas generadas.

9.2. Contribuciones

- **Contribución tecnológica:** Arquitectura funcional de un asistente educativo offline que integra detección de idioma, enrutamiento lingüístico, RAG local y generación de respuestas mediante un SLM cuantizado.
- **Contribución lingüística:** Organización y curación de recursos lingüísticos para Quechua Collao orientados a tareas educativas, incluyendo corpus paralelos, glosarios y contenidos curriculares.
- **Contribución metodológica:** Marco de evaluación que combina métricas automáticas de calidad lingüística con criterios pedagógicos e interculturales, aplicable a otros proyectos de tecnología educativa en lenguas de bajos recursos.

9.3. Impacto social

El desarrollo de un asistente educativo bilingüe offline tiene el potencial de beneficiar a docentes y estudiantes de comunidades quechuahablantes del sur andino peruano que actualmente carecen de herramientas tecnológicas adaptadas a su realidad lingüística y territorial. Al operar sin conexión a internet y en Quechua Collao, el prototipo podría contribuir a reducir la brecha digital educativa en zonas rurales, fortalecer el uso de la lengua materna en contextos de aprendizaje formal y apoyar los objetivos del modelo de servicio educativo intercultural bilingüe del Ministerio de Educación.

10. Cronograma de actividades

El desarrollo de la tesis se planifica en un horizonte de doce meses a partir de la aprobación del plan. Las actividades se organizan en seis fases según la metodología Design Science Research.

Tabla 1*Cronograma de actividades por fases y meses*

Actividad	1	2	3	4	5	6	7	8	9	10	11	12
Fase 1: Identificación del problema												
Revisión de literatura y estado del arte	•	•										
Caracterización de requerimientos EIB	•	•										
Fase 2: Diseño de la solución												
Diseño de la arquitectura offline		•	•									
Selección del SLM base y técnica de cuantización			•	•								
Fase 3: Recopilación de recursos												
Curación de corpus Quechua Collao-español			•	•	•							
Organización de materiales EIB y glosarios				•	•							
Fase 4: Implementación												
Ajuste fino / configuración del SLM					•	•	•					
Módulo de detección de idioma						•	•					
Módulo RAG local con contenidos EIB							•	•				
Integración y prototipo funcional								•	•			
Fase 5: Evaluación												
Evaluación técnica (latencia, memoria, TPS)									•	•		
Evaluación lingüística (BLEU, chrF++)									•	•		
Evaluación pedagógica con especialistas EIB										•	•	
Fase 6: Documentación												
Redacción del informe final de tesis										•	•	•
Preparación de sustentación												•

11. Presupuesto

El presupuesto estimado para el desarrollo de la tesis se detalla a continuación. Se consideran los recursos necesarios para la implementación del prototipo, la evaluación y la documentación.

Tabla 2*Presupuesto estimado del proyecto*

Rubro	Cantidad	Costo (S/.)
Recursos tecnológicos		
Dispositivo de prueba (laptop/tablet gama media)	1	2 500.00
Almacenamiento externo (SSD 1TB)	1	250.00
Servicio de cómputo en la nube (entrenamiento)	3 meses	900.00
Recursos académicos		
Material bibliográfico y acceso a bases de datos	Global	300.00
Impresiones y empastados	Global	200.00
Trabajo de campo		
Transporte a zonas rurales (validación)	5 visitas	750.00
Viáticos para trabajo de campo	5 días	500.00
Material para talleres con docentes EIB	Global	200.00
Servicios profesionales		
Consulta con especialistas en Quechua Collao	3 sesiones	450.00
Validación lingüística por hablantes nativos	5 sesiones	500.00
Otros		
Imprevistos (10 %)	Global	655.00
TOTAL		7 205.00

Bibliografía

- Court, S. and Elsner, M. (2024). Shortcomings of llms for low-resource translation: Retrieval and understanding are both the problem. In *Proceedings of the Conference on Machine Translation*. Disponible en: <https://aclanthology.org/2024.wmt-1.125/>.
- Duran, M. and Silberztein, M. (2026). Semi-automatic construction of a quechua-spanish dictionary. In *Proceedings for the Ninth Workshop on Technologies for Machine Translation of Low Resource Languages*, pages 111–118. DOI: <https://doi.org/10.18653/v1/2026.loresmt-1.9>.
- Hevia, J. S., Arredondo, F., and Kumar, V. (2025). Towards an efficient, customizable, and accessible ai tutor. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2510.06255>.
- Levonian, Z., Henkel, O., Li, C., and Postle, M.-E. (2025). Designing safe and relevant generative chats for math learning in intelligent tutoring systems. *Journal of Educational Data Mining*, 17(1):66–97. DOI: <https://doi.org/10.5281/zenodo.14751365>.
- Li, Z., Wang, Z., Wang, W., Hung, K., Xie, H., and Wang, F. L. (2025). Retrieval-augmented generation for educational application: A systematic survey. *Computers and Education: Artificial Intelligence*. DOI: <https://doi.org/10.1016/j.caeai.2025.100417>.
- Ministerio de Educación del Perú (2018). Modelo de servicio educativo intercultural bilingüe. Disponible en: <https://repositorio.minedu.gob.pe/handle/20.500.12799/5971>.
- Orcotoma Mormontoy, G. C., Leon Nuñez, L., and Espetia Huamanga, H. (2025). Towards the creation of a collao quechua-spanish parallel corpus using optical character recognition. In *Proceedings of the Workshop on Beyond English*. Disponible en: <https://aclanthology.org/2025.globalnlp-1.1/>.
- Sulla Torres, J. A., Cueva Medina, B., and Tuco Casquino, G. F. (2024). Development of a neural machine translation model optimized with bert for translation from quechua to spanish. In *LACCEI*. DOI: <https://doi.org/10.18687/LACCEI2024.1.1.1636>.
- Walusimbi, J., Oguti, A. M., Ssentongo, J. B., and Ainebyona, K. (2026). Arapai: An offline-first ai chatbot architecture for low-connectivity educational environments. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2603.03339>.
- Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., and Ling, Z. (2024). On-device language models: A comprehensive review. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2409.00088>.

Anexo: Fichas de Análisis

A continuación, se presentan las fichas de análisis de las cinco fuentes más relevantes para la investigación, elaboradas conforme a las exigencias de la guía metodológica del seminario.

Ficha 1: Orcotoma Mormontoy et al. (2025)

1. **REFERENCIA COMPLETA (APA 7):** Orcotoma Mormontoy, G. C., Leon Nuñez, L., & Espetia Huamanga, H. (2025). Towards the Creation of a Collao Quechua-Spanish Parallel Corpus Using Optical Character Recognition. *Proceedings of the Workshop on Beyond English*, 1-6. <https://doi.org/10.26615/978-954-452-105-9-001>
 2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica
 3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Construir un corpus paralelo Quechua Collao-español utilizando reconocimiento óptico de caracteres (OCR) para superar la escasez de recursos digitales en esta lengua de bajos recursos.
 4. **METODOLOGÍA:** Enfoque tecnológico. Digitación y procesamiento (filtros de mediana y binarización) de libros de grado de la Academia Mayor de la Lengua Quechua, seguido de extracción de texto con Tesseract OCR y evaluación mediante Character Error Rate (CER) y Word Error Rate (WER) frente a un texto validado manualmente (ground truth).
 5. **RESULTADOS PRINCIPALES:** Se construyó un corpus de 44 263 palabras (18 179 en quechua y 26 084 en español). La evaluación del OCR mostró un CER de 1.82 % y un WER de 6.59 %, demostrando la viabilidad de la extracción automática con posprocesamiento.
 6. **CONCLUSIONES DEL AUTOR:** El uso de OCR es viable para crear corpus paralelos en Quechua Collao si se aplican métodos adecuados de preprocesamiento, lo que proporciona una metodología valiosa para preservar la lengua y entrenar futuras tecnologías NLP.
 7. **RELEVANCIA PARA MI TESIS:** Es un antecedente directo para la obtención de datos de entrenamiento y evaluación. Justifica la delimitación del proyecto al Quechua Collao al confirmar la existencia de recursos paralelos validados procedentes de la Academia Mayor de la Lengua Quechua.
 8. **CITAS TEXTUALES ÚTILES:** “The importance of the result of this study lies in providing a methodology for the development of new technologies that require Collao Quechua-Spanish parallel corpora, such as automatic translators and sentence auto-completion systems” (p. 1).
 9. **PALABRAS CLAVE ASIGNADAS:** Corpus paralelo, OCR, Quechua Collao, NLP de bajos recursos.
-

Ficha 2: Court & Elsner (2024)

1. **REFERENCIA COMPLETA (APA 7):** Court, S., & Elsner, M. (2024). Shortcomings of LLMs for Low-Resource Translation: Retrieval and Understanding Are Both the Problem. *Proceedings of the Ninth Conference on Machine Translation*, 1332-1354.
 2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica
 3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Investigar las habilidades de aprendizaje en contexto de Grandes Modelos de Lenguaje (LLMs) al traducir desde una lengua de bajos recursos (quechua sureño) hacia el español, utilizando información recuperada de diccionarios, gramáticas y corpus.
 4. **METODOLOGÍA:** Experimental cuantitativa. Se evaluó la salida de cuatro LLMs (GPT-3.5, GPT-4o, Gemini 1.5, Llama 3) bajo ocho condiciones de prompt que combinaban información de morfemas, gramática y ejemplos de corpus, usando métricas automáticas (BLEURT, BLEU) y anotación humana de errores.
 5. **RESULTADOS PRINCIPALES:** La inclusión de traducciones a nivel de morfema mejora el rendimiento de los modelos más pequeños. Sin embargo, en modelos más avanzados (GPT-4o), añadir contexto gramatical o de corpus reduce los puntajes BLEURT y aumenta la divergencia gramatical.
 6. **CONCLUSIONES DEL AUTOR:** Incluso explicaciones gramaticales relevantes ayudan poco a las generaciones más recientes de LLMs en tareas de bajos recursos. Las traducciones infieles suelen ser engañosamente fluidas en español, y en ocasiones introducen estereotipos culturales no presentes en la frase original.
 7. **RELEVANCIA PARA MI TESIS:** Demuestra que no basta con usar la técnica RAG para inyectar reglas gramaticales en un modelo genérico. Justifica la necesidad de afinar o cuantizar un Small Language Model especializado en lugar de depender únicamente del aprendizaje en contexto de un modelo en la nube.
 8. **CITAS TEXTUALES ÚTILES:** “providing additional information in the prompt’s context actually degrades GPT-4o’s ability to translate from S. Quechua to Spanish in all experimental conditions” (p. 7).
 9. **PALABRAS CLAVE ASIGNADAS:** LLMs, Quechua sureño, RAG, traducción automática, aprendizaje en contexto.
-

Ficha 3: Walusimbi et al. (2026)

1. **REFERENCIA COMPLETA (APA 7):** Walusimbi, J., Oguti, A. M., Ssentongo, J. B., & Ainebyona, K. (2026). Arapai: An Offline-First AI Chatbot Architecture for Low-Connectivity Educational Environments. *arXiv preprint arXiv:2603.03339*.
2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Diseñar y evaluar una arquitectura de LLM orientada a operar sin conexión a internet (offline-first) para asistencia educativa en entornos con baja conectividad.

4. **METODOLOGÍA:** Investigación aplicada. Se implementaron modelos cuantizados (TinyLlama, Qwen2.5-3B, Mistral-7B) ejecutados localmente en CPU. El sistema adaptativo fue evaluado cualitativa y cuantitativamente con 120 estudiantes y 9 docentes en condiciones reales.
 5. **RESULTADOS PRINCIPALES:** El sistema operó de forma estable en hardware heredado (CPU). Las consultas instructivas típicas mostraron latencias de respuesta de 1 a 3 segundos. Los usuarios reportaron una alta utilidad para el aprendizaje autodirigido a diferentes niveles de complejidad.
 6. **CONCLUSIONES DEL AUTOR:** Es viable desplegar asistentes educativos basados en IA en contextos con limitaciones de infraestructura utilizando LLMs cuantizados que se ejecutan localmente, ofreciendo una alternativa confiable a los sistemas que dependen de la nube.
 7. **RELEVANCIA PARA MI TESIS:** Es el principal antecedente arquitectónico. Valida la hipótesis de que los modelos cuantizados ejecutados en CPU son suficientemente rápidos y útiles para aplicaciones educativas offline en zonas rurales.
 8. **CITAS TEXTUALES ÚTILES:** “The system performs all inference locally using quantized language models and incorporates hardware-aware model selection to enable deployment on low-specification, CPU-only devices” (p. 1).
 9. **PALABRAS CLAVE ASIGNADAS:** Arquitectura offline-first, IA educativa, modelos cuantizados, edge AI.
-

Ficha 4: Xu et al. (2024)

1. **REFERENCIA COMPLETA (APA 7):** Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., & Ling, Z. (2024). On-Device Language Models: A Comprehensive Review. *arXiv preprint arXiv:2409.00088*.
2. **TIPO DE DOCUMENTO:** Artículo de revisión (Survey)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Examinar los desafíos de desplegar LLMs computacionalmente costosos en dispositivos con recursos limitados y explorar las soluciones innovadoras en múltiples dominios.
4. **METODOLOGÍA:** Revisión sistemática de literatura sobre arquitecturas eficientes de modelos de lenguaje en dispositivos (on-device), analizando técnicas de compresión de modelos, aceleración de hardware y despliegue colaborativo borde-nube.
5. **RESULTADOS PRINCIPALES:** Se identifican tres estrategias clave para habilitar modelos en dispositivos: compartición de parámetros, cuantización (PTQ y QAT) para reducir bits de peso/activación, y destilación de conocimiento. La cuantización int4/int8 resulta esencial para procesadores móviles.
6. **CONCLUSIONES DEL AUTOR:** La transición de la nube al borde (edge) reduce latencia y aumenta privacidad, pero requiere un equilibrio delicado entre el rendimiento del modelo (precisión) y la utilización de recursos (memoria y energía) que solo se logra combinando múltiples técnicas de compresión.

7. **RELEVANCIA PARA MI TESIS:** Proporciona el marco teórico tecnológico sobre Small Language Models y cuantización que fundamenta el diseño del asistente educativo para hardware de bajo costo.
 8. **CITAS TEXTUALES ÚTILES:** “deploying computationally expensive LLMs on resource-constrained devices poses significant challenges. The primary obstacles include limited computational power, reduced memory capacity, and energy constraints” (p. 2).
 9. **PALABRAS CLAVE ASIGNADAS:** On-Device AI, cuantización, compresión de modelos, Small Language Models.
-

Ficha 5: Hevia et al. (2025)

1. **REFERENCIA COMPLETA (APA 7):** Hevia, J. S., Arredondo, F., & Kumar, V. (2025). Towards an Efficient, Customizable, and Accessible AI Tutor. *arXiv preprint arXiv:2510.06255*.
2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Proponer un sistema tutorial de IA fuera de línea (offline) basado en Generación Aumentada por Recuperación (RAG) emparejado con un Small Language Model (SLM) para entornos de bajos recursos.
4. **METODOLOGÍA:** Experimental cuantitativa. Evaluación de modelos de la familia SmolLM (135M y 1.7B) y RAG con libros de texto de biología de OpenStax usando métricas del benchmark MMLU para evaluar el impacto del contexto en la precisión de respuesta.
5. **RESULTADOS PRINCIPALES:** Contrario a lo esperado, la inclusión de recuperación RAG en SLMs disminuyó su precisión en el MMLU (de 21.59 % a 21.81 % con RAG en SmolLM2-135M, y una caída drástica en el modelo 1.7B), debido a la incapacidad de estos modelos pequeños para manejar ventanas de contexto extendidas y ruidosas.
6. **CONCLUSIONES DEL AUTOR:** Los Small Language Models luchan por aprovechar efectivamente el contexto extendido provisto por RAG, especialmente si los fragmentos contienen información irrelevante. Es crítico usar técnicas avanzadas de chunking” (fragmentación semántica) y métricas de evaluación holísticas más allá de opciones múltiples.
7. **RELEVANCIA PARA MI TESIS:** Alerta sobre los riesgos de usar arquitectura RAG simple con SLMs en el diseño del asistente EIB. Justifica la necesidad de un preprocesamiento cuidadoso de los contenidos curriculares y glosarios locales para evitar introducir ruido en la consulta.
8. **CITAS TEXTUALES ÚTILES:** “smaller models, such as SmolLM, struggle to effectively leverage extended contexts provided by the RAG pipeline, particularly when noisy or irrelevant chunks are included” (p. 1).
9. **PALABRAS CLAVE ASIGNADAS:** RAG, AI Tutor, Small Language Model, educación fuera de línea.