

UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO
FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA
ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

Diseño y evaluación de un asistente educativo offline español–Quechua Collao basado en un modelo de lenguaje compacto, generación aumentada por recuperación y recursos lingüísticos validados para contextos de Educación Intercultural Bilingüe

Curso:

Seminario de Investigación I

Para optar al Título Profesional de:

Ingeniero Informático y de Sistemas

Presentado por:

Br. Edmil Jampier Saire Bustamante

Br. Haider Alex Carpio Hermoza

Asesora:

Ing. Gabriela Zúñiga Rojas

Cusco – Perú
2026

Resumen

La presente propuesta de plan de tesis aborda la brecha de conectividad y la carencia de herramientas tecnológicas adaptadas para la Educación Intercultural Bilingüe (EIB) en zonas rurales quechuahablantes del sur andino peruano. El problema radica en la falta de asistentes educativos que operen sin conexión a internet, en lengua materna y con contenido curricular pertinente. La investigación plantea diseñar, implementar y evaluar un prototipo funcional de asistente educativo offline español–Quechua Collao basado en un modelo de lenguaje compacto cuantizado con RAG local. Los datos bilingües que alimentan al sistema serán generados con modelos de IA y validados contra corpus de referencia existentes. La evaluación contemplará métricas técnicas de rendimiento, análisis de calidad lingüística (chrF++, RAGAS) y valoración de pertinencia pedagógica.

Palabras clave: Modelo de lenguaje compacto, RAG local, Educación Intercultural Bilingüe, Quechua Collao, asistente educativo offline, datos sintéticos validados.

Índice general

Resumen	II
Índice general	III
Índice de tablas	V
1. Problema de Investigación	1
1.1. Descripción del problema	1
1.2. Identificación del problema	1
1.3. Formulación del problema	1
2. Justificación	2
3. Alcances y limitaciones	2
3.1. Alcances	2
3.2. Limitaciones	3
4. Objetivos	4
4.1. Objetivo General	4
4.2. Objetivos Específicos	4
4.3. Alineación con los Objetivos de Desarrollo Sostenible	4
5. Estado del arte	5
5.1. Procesamiento de Lenguaje Natural y Traducción Automática para Quechua Collao	5
5.2. Small Language Models y Despliegue Offline	5
5.3. Generación Aumentada por Recuperación (RAG) y Tecnología Educa- tiva con IA	6
5.4. RAG vs. Fine-Tuning y Enfoque Híbrido para Lenguas de Bajos Recursos	6
5.5. Política Educativa y Educación Intercultural Bilingüe en el Perú . . .	6
5.6. Matriz resumida de antecedentes	7
5.7. Síntesis crítica y vacíos de investigación	7
6. Marco Teórico y Conceptual	8
6.1. Educación Intercultural Bilingüe (EIB)	8
6.2. Quechua Collao: caracterización dialectal	8
6.3. Translenguaje y alternancia de códigos	9
6.4. Procesamiento de Lenguaje Natural en Lenguas de Bajos Recursos . .	9
6.5. Modelos de lenguaje y arquitectura Transformer	10
6.6. Small Language Models y cuantización	10
6.7. Adaptación ligera: LoRA y QLoRA	11
6.8. RAFT: Retrieval-Augmented Fine-Tuning	12
6.9. Asistentes educativos inteligentes	12
6.10. Generación Aumentada por Recuperación (RAG)	12
6.11. Detección automática de idioma	12
6.12. Evaluación de sistemas educativos con IA	13
6.13. Síntesis integradora del marco teórico	13
7. Metodología	14
7.1. Tipo y diseño de investigación	14

7.2.	Hipótesis	16
7.3.	Metodología de desarrollo	16
7.4.	Población y muestra	17
7.5.	Consideraciones éticas	17
8.	Estudio de Factibilidad	18
8.1.	Enfoque híbrido adoptado	18
8.2.	Factibilidad técnica	18
8.3.	Factibilidad económica	21
8.4.	Factibilidad legal y de licencias	21
8.5.	Factibilidad operativa y gestión del alcance	22
8.6.	Ámbito pedagógico: fuentes y estrategia de enseñanza	22
8.7.	Diseño experimental	23
8.8.	Semáforo de riesgo	25
8.9.	Conclusión de viabilidad	25
9.	Importancia del estudio	25
9.1.	Resultados esperados	25
9.2.	Contribuciones	26
9.3.	Impacto social	27
10.	Cronograma de actividades	27
11.	Presupuesto	29
	Bibliografía	30
	Anexos	33

Índice de tablas

1.	Matriz resumida de antecedentes y aportes a la investigación	7
2.	Modelos candidatos evaluados y de referencia para el asistente <i>offline</i>	11
3.	Matriz de operacionalización de variables	15
4.	Matriz comparativa de enfoques para la decisión metodológica	18
5.	Flujo de datos del proyecto	20
6.	Viabilidad técnica por componente crítico	21
7.	Riesgos operativos y mitigación	22
8.	Diseño experimental	23
9.	Métricas de evaluación del proyecto	24
10.	Semáforo de riesgo por dimensión	25
11.	Cronograma de actividades por fases y meses	28
12.	Presupuesto estimado del proyecto	29

1. Problema de Investigación

1.1. Descripción del problema

La educación rural bajo el modelo de Educación Intercultural Bilingüe (EIB) en el Perú enfrenta una profunda brecha de recursos y herramientas tecnológicas adaptadas. A pesar de que el sistema EIB atiende a más de 1,2 millones de estudiantes en el país (Ministerio de Educación del Perú, 2018), su implementación en el ámbito rural se ve limitada por la falta de conectividad digital: según el INEI, apenas el 20,5 % de los hogares rurales tiene acceso a internet (INEI, 2025). Esta desconexión digital afecta de manera crítica a los departamentos del sur andino (Cusco y Puno), donde se concentra una alta proporción de población escolar quechuahablante.

En este contexto regional, la lengua originaria predominante es el Quechua Collao. Esta variedad lingüística impone desafíos complejos para los sistemas de procesamiento automático: su naturaleza aglutinante y sufijadora genera palabras de alta densidad semántica, y en la práctica educativa, los estudiantes y docentes interactúan de forma dinámica alternando constantemente entre el quechua y el español (translenguaje o alternancia de códigos). Las herramientas tecnológicas estándar no están preparadas para indexar, segmentar o tokenizar esta variedad lingüística de bajos recursos digitales, ni para discernir entre las consultas formuladas en una u otra lengua.

Por otro lado, aunque el avance de la inteligencia artificial generativa ha popularizado el uso de asistentes virtuales para el aprendizaje, las soluciones comerciales son inviables para las escuelas rurales EIB. Esto se debe a tres limitaciones estructurales: (a) requieren conexión permanente a internet para consultar modelos remotos en la nube, (b) carecen de representación real y alineación con la variedad Quechua Collao, y (c) no están adaptadas al currículo oficial del Ministerio de Educación ni siguen estrategias instruccionales de andamiaje formativo.

En consecuencia, existe una brecha técnica y pedagógica no resuelta: la ausencia de un asistente educativo bilingüe español–Quechua Collao que funcione 100 % offline, que integre un enrutamiento lingüístico automático para consultas bilingües, y que recupere localmente contenidos curriculares validados mediante una arquitectura de modelo compacto y RAG local. Esta brecha justifica el desarrollo y evaluación del prototipo propuesto.

1.2. Identificación del problema

El problema central de la investigación es la ausencia de un asistente educativo bilingüe español–Quechua Collao que funcione sin conexión a internet, basado en un modelo compacto con RAG local, para responder consultas pedagógicas en contextos de Educación Intercultural Bilingüe.

1.3. Formulación del problema

Problema general

¿Cómo diseñar, implementar y evaluar un asistente educativo offline español–Quechua Collao basado en un modelo compacto con RAG local para apoyar consultas curriculares en contextos de Educación Intercultural Bilingüe?

Subproblemas

- ¿Cuáles son los requerimientos lingüísticos, pedagógicos y tecnológicos que debe satisfacer un asistente educativo bilingüe offline para contextos rurales de EIB?

- ¿Cómo diseñar una arquitectura offline que integre detección automática del idioma, recuperación local de contenidos curriculares, recursos lingüísticos explícitos y generación de respuestas pedagógicas?
- ¿Cómo implementar y configurar un modelo compacto cuantizado para operar de forma eficiente sin conexión a internet en dispositivos de bajo costo?
- ¿Qué diferencia en rendimiento y pertinencia se registra al comparar tres configuraciones básicas del sistema: modelo base sin RAG, modelo con RAG local y modelo con el enfoque híbrido completo?
- ¿Cómo evaluar la calidad del prototipo resultante mediante métricas técnicas, lingüísticas y rúbricas de pertinencia pedagógica?

2. Justificación

Las condiciones descritas en el problema —baja conectividad rural, ausencia de herramientas en Quechua Collao y una población escolar EIB desatendida tecnológicamente— no se resuelven con las herramientas comerciales de inteligencia artificial generativa en la nube, que dependen de conectividad permanente y operan sobre lenguas de alta disponibilidad. El proyecto propone una alternativa desde tres perspectivas:

- **Justificación Teórica:** El estudio aporta a la integración del procesamiento de lenguas de bajos recursos digitales con la tecnología educativa. Aunque existen investigaciones previas sobre traducción automática o evaluación de modelos para quechua de manera aislada, no se ha propuesto un diseño que acople el entendimiento bilingüe contextualizado, la recuperación local de contenidos y mecanismos de adaptación orientados al andamiaje pedagógico para el Quechua Collao.
- **Justificación Práctica:** Propone un prototipo funcional offline de apoyo pedagógico complementario en áreas rurales de baja o nula conectividad, facilitando el acceso a materiales oficiales en la lengua originaria del estudiante.
- **Justificación Metodológica:** Diseña un marco de evaluación comparativo que permite medir el aporte real de cada componente del sistema (el modelo base, la recuperación local de contenidos y la alineación de estilo del modelo), combinando métricas automatizadas de rendimiento y calidad de texto con valoraciones cualitativas aplicadas por especialistas bilingües.

3. Alcances y limitaciones

3.1. Alcances

El presente estudio abarca el diseño, implementación y evaluación de un prototipo de asistente educativo bilingüe español–Quechua Collao basado en un modelo compacto de lenguaje. La investigación se centra en la asistencia textual para estudiantes y docentes de contextos de EIB, considerando los siguientes alcances específicos:

- **Alcance lingüístico:** Se delimita de forma exclusiva al Quechua Collao, de acuerdo con la ubicación geográfica del estudio y la disponibilidad de corpus paralelos como los construidos por Orcotoma Mormontoy et al. (2025). Esta variedad presenta rasgos

fonológicos diferenciadores (consonantes oclusivas glotizadas y aspiradas) que deben reflejarse cuidadosamente en los recursos del sistema. Esta delimitación evita prometer cobertura de otras variedades dialectales, permitiendo construir un prototipo de alta pertinencia regional.

- **Alcance pedagógico:** El primer ciclo de validación se centrará en consultas curriculares de 3.º a 6.º grado de primaria, priorizando las áreas de Comunicación y Ciencia y Tecnología según la disponibilidad de materiales EIB bilingües. Las respuestas del sistema seguirán el principio de andamiaje cognitivo, priorizando explicaciones graduales sobre respuestas directas.
- **Alcance tecnológico:** Comprende una arquitectura offline compuesta por detección automática del idioma, enrutamiento lingüístico, generación aumentada por recuperación (RAG) local y un modelo compacto de lenguaje cuantizado, preferentemente a 4 bits según las pruebas de rendimiento realizadas. El aporte tecnológico radica en la integración, configuración y evaluación comparativa de esta arquitectura.
- **Alcance disciplinar:** Se ubica en la convergencia de la ingeniería informática, el procesamiento de lenguaje natural y la tecnología educativa para contextos bilingües interculturales.
- **Alcance temporal:** El desarrollo del proyecto se planifica en un horizonte de doce meses a partir de la aprobación del plan, organizado en seis fases según la metodología Design Science Research, conforme al cronograma de actividades.

3.2. Limitaciones

Se reconocen las siguientes limitaciones que condicionan la ejecución del proyecto:

- **Disponibilidad de datos:** Al tratarse de una lengua de bajos recursos digitales, los datos bilingües se generarán con modelos de IA y se validarán contra corpus de referencia existentes (Orcotoma Mormontoy et al., 2025; Duran and Silberztein, 2026). La calidad de estos datos es crítica para el funcionamiento del sistema.
- **Cuello de botella de la tokenización:** La morfología aglutinante del quechua genera una fertilidad de tokens estimada en $\approx 3,4\times$ respecto al español, lo que penaliza la latencia en CPU e infla el consumo de la caché KV del modelo con contextos extensos.
- **Restricción dialectal:** El prototipo está orientado exclusivamente al Quechua Collao, por lo que el sistema no está diseñado para generalizarse a otras variedades dialectales.
- **Restricciones de hardware:** La ejecución offline de un modelo compacto depende de la memoria disponible (RAM) del dispositivo local, limitando el tamaño del modelo utilizable y la latencia aceptable de generación (Xu et al., 2024).
- **Validación pedagógica y lingüística:** La evaluación de pertinencia y adecuación dependerá de la validación del docente especialista EIB y del especialista lingüístico en la variedad Quechua Collao.
- **Alcance textual:** El prototipo no incorpora reconocimiento ni síntesis de voz, considerando la asistencia por audio fuera del alcance de este trabajo.

4. Objetivos

4.1. Objetivo General

Diseñar, implementar y evaluar un prototipo de asistente educativo offline español–Quechua Collao basado en un modelo de lenguaje compacto cuantizado, generación aumentada por recuperación local y recursos lingüísticos validados, orientado al apoyo de consultas curriculares en contextos rurales de Educación Intercultural Bilingüe.

4.2. Objetivos Específicos

- **Curar y estructurar** una base documental bilingüe español–Quechua Collao, integrando materiales curriculares oficiales, glosarios terminológicos, diccionarios locales y datos generados con IA validados contra corpus de referencia.
- **Diseñar** una arquitectura offline que integre detección automática del idioma, recuperación local de información y generación de respuestas pedagógicas.
- **Implementar** un prototipo funcional del asistente educativo seleccionando, cuantizando y configurando el modelo compacto base y el pipeline de recuperación.
- **Comparar** configuraciones básicas del sistema para medir el aporte real de la recuperación local, las reglas de normalización y la adaptación de estilo del modelo.
- **Evaluar** el prototipo mediante métricas técnicas de rendimiento offline, fidelidad lingüística mediante métricas automáticas y pertinencia pedagógica a través de rúbricas de juicio de expertos.
- **Documentar** las limitaciones de la arquitectura propuesta, los riesgos de transferencia dialectal y las recomendaciones de mejora.

4.3. Alineación con los Objetivos de Desarrollo Sostenible

La investigación se alinea con los siguientes Objetivos de Desarrollo Sostenible (ODS):

- **ODS 4 — Educación de calidad.** El estudio contribuye a una educación inclusiva y equitativa al proveer una herramienta de apoyo pedagógico en lengua materna para estudiantes de zonas rurales bajo el modelo EIB.
- **ODS 9 — Industria, innovación e infraestructura.** Promueve la innovación tecnológica al diseñar una solución de inteligencia artificial offline, adaptada a condiciones de hardware de bajo costo e infraestructura digital limitada.
- **ODS 10 — Reducción de las desigualdades.** Aborda la brecha digital y lingüística que afecta a comunidades quechuahablantes, facilitando el acceso a recursos educativos interactivos sin requerir conexión a internet.

5. Estado del Arte

El desarrollo de un asistente educativo bilingüe español–Quechua Collao requiere la integración de avances en múltiples dominios disciplinares. A continuación, se presenta una síntesis analítica y crítica de las investigaciones previas más relevantes, organizadas temáticamente. Las fichas de análisis detalladas de cada uno de estos trabajos se presentan en el Anexo: Fichas de Análisis.

5.1. Procesamiento de Lenguaje Natural y Traducción Automática para Quechua Collao

El procesamiento de lenguaje natural (PLN) para lenguas aglutinantes de bajos recursos como el quechua ha presentado desafíos históricos debido a su complejidad morfológica. Investigaciones recientes han abordado estas brechas mediante la construcción de corpus y el ajuste de modelos neuronales. Orcotoma Mormontoy et al. (2025) aportaron significativamente al construir un corpus paralelo Quechua Collao–español de 44 263 palabras mediante el uso de reconocimiento óptico de caracteres (OCR) sobre textos académicos de la Academia Mayor de la Lengua Quechua, logrando tasas de error de palabra (WER) de 6,59 %. Por su parte, Duran y Silberztein (2026) propusieron métodos semi-automáticos para la construcción de diccionarios quechua–español utilizando formalismos lingüísticos, lo que amplía la disponibilidad de recursos léxicos estructurados.

En cuanto a la traducción, Sulla Torres et al. (2024) demostraron que los modelos de traducción automática neuronal (NMT) optimizados con BERT pueden alcanzar puntajes aceptables (BLEU de 20,13) en la dirección quechua–español, aunque subrayaron las limitaciones impuestas por la escasez de datos. No obstante, el paradigma de traducción y PLN ha cambiado con la llegada de los Grandes Modelos de Lenguaje (LLM). En este contexto, Court y Elsner (2024) evaluaron las habilidades de aprendizaje en contexto de LLMs comerciales (GPT-4, Gemini) para traducir del quechua al español. Sus hallazgos indican que, si bien la inclusión de traducciones a nivel de morfema mejora el rendimiento, la inyección de largas reglas gramaticales o ejemplos de corpus mediante técnicas de recuperación puede, paradójicamente, degradar el rendimiento de los modelos más avanzados, generando traducciones fluidas pero infieles o estereotipadas. Esto evidencia que depender exclusivamente de LLMs en la nube mediante *prompting* no resuelve el problema de comprensión estructural en lenguas de bajos recursos.

5.2. Small Language Models y Despliegue Offline

Frente a la dependencia de conectividad y alto consumo computacional de los LLMs, el desarrollo de Small Language Models (SLM) y técnicas de optimización para hardware restringido (on-device AI) ha cobrado relevancia. La exhaustiva revisión de Xu et al. (2024) sistematiza cómo técnicas como la compartición de parámetros, la destilación de conocimiento y, fundamentalmente, la cuantización (PTQ y QAT), permiten que modelos con menos de 10 mil millones de parámetros se ejecuten eficientemente en dispositivos móviles y procesadores de bajo consumo.

La aplicación de estas tecnologías en contextos de baja conectividad fue validada empíricamente por Walusimbi et al. (2026), quienes diseñaron *Arapai*, una arquitectura de chatbot educativo orientado al funcionamiento offline. Al desplegar modelos cuantizados (como TinyLlama o Qwen) en hardware heredado (solo CPU), lograron latencias de respuesta de 1 a 3 segundos, demostrando que la inferencia local es técnicamente factible y pedagógicamente útil para el aprendizaje autodirigido en entornos con infraestructura precaria. Sin embargo,

su estudio se centró en inglés y no abordó los retos de lenguas aglutinantes.

5.3. Generación Aumentada por Recuperación (RAG) y Tecnología Educativa con IA

La Generación Aumentada por Recuperación (RAG) se ha convertido en el estándar para mitigar las alucinaciones en modelos generativos, vinculando sus respuestas a corpus documentales específicos. La revisión sistemática de Li et al. (2025) confirma que los sistemas RAG mejoran significativamente la precisión factual y la personalización en aplicaciones educativas, permitiendo que la IA asuma roles de tutoría basados en el currículo local.

Sin embargo, el despliegue de RAG con modelos pequeños presenta desafíos particulares. Hevia et al. (2025) evaluaron un tutor de IA offline combinando RAG con SLMs (SmolLM), encontrando que los modelos pequeños tienen dificultades para procesar contextos recuperados extensos o ruidosos, lo que irónicamente redujo su precisión en evaluaciones de respuestas múltiples. Esto sugiere la necesidad de estrategias de recuperación y segmentación documental altamente optimizadas. Adicionalmente, el despliegue de estas herramientas con estudiantes requiere garantías pedagógicas. Levonian et al. (2025) establecen que los sistemas de tutoría inteligente deben ser diseñados para generar interacciones seguras y relevantes, priorizando el andamiaje cognitivo sobre la simple provisión de respuestas directas.

5.4. RAG vs. Fine-Tuning y Enfoque Híbrido para Lenguas de Bajos Recursos

La decisión entre RAG y *fine-tuning* como estrategia de inyección de conocimiento es central para esta tesis. Ovadia et al. (2024) encontraron que, para incorporar conocimiento factual nuevo, RAG superó consistentemente al *fine-tuning* no supervisado, tanto para conocimiento existente como nuevo. Sin embargo, la evidencia no avala un RAG no optimizado: el cuello de botella de la tokenización en lenguas aglutinantes como el quechua infla el contexto requerido y penaliza la latencia, lo que exige un RAG disciplinado con fragmentos cortos y *top-k* pequeño.

El enfoque RAFT (*Retrieval-Augmented Fine-Tuning*) propuesto por Zhang et al. (2024) ofrece una síntesis prometedora: en lugar de entrenar al modelo a memorizar conocimiento, le enseña a usar el contexto RAG de forma resiliente, distinguiendo fragmentos relevantes de distractores. El antecedente más directo para esta tesis es el modelo QueEn (Chen et al., 2024), que demostró empíricamente que la hibridación de RAG sobre recursos lingüísticos combinada con adaptación LoRA elevó el puntaje BLEU de 1,5 a 17,6 en traducciones quechua-inglés, validando que la combinación de RAG con adaptación paramétrica ligera produce mejoras significativas para lenguas de bajos recursos.

5.5. Política Educativa y Educación Intercultural Bilingüe en el Perú

El desarrollo tecnológico debe alinearse con los marcos normativos y pedagógicos vigentes. El Modelo de Servicio Educativo Intercultural Bilingüe (MSEIB) del Ministerio de Educación del Perú (Ministerio de Educación del Perú, 2018) establece lineamientos para garantizar una educación pertinente a estudiantes de pueblos originarios, en concordancia con el Currículo Nacional de la Educación Básica (Ministerio de Educación del Perú, 2016). El MSEIB distingue escenarios de fortalecimiento lingüístico (donde el quechua es lengua materna y el español segunda lengua) y revitalización (donde el español es lengua materna). Esto exige que cualquier herramienta de asistencia educativa no sea un simple traductor bidireccional,

sino un sistema capaz de alternar códigos, detectar el idioma predominante del estudiante y recuperar contenidos con pertinencia cultural e intercultural, apoyando directamente la labor del docente bilingüe.

5.6. Matriz resumida de antecedentes

Para consolidar la revisión precedente, la Tabla 1 sintetiza los antecedentes empíricos y tecnológicos más directamente relacionados con el diseño del asistente, contrastando los objetivos, métodos, resultados clave y el aporte específico de cada trabajo a la presente investigación.

Tabla 1

Matriz resumida de antecedentes y aportes a la investigación

Autor(es)	Objetivo	Método	Resultados clave	Aporte a la tesis
Orcotoma Mor-montoy et al. (2025)	Crear corpus paralelo español-Quechua Collao.	OCR en textos académicos e indexación.	Corpus de 44 263 palabras con WER de 6,59 %.	Provee el corpus de texto base para poblar el RAG local.
Sulla Torres et al. (2024)	Optimizar traducción quechua-español.	NMT basado en codificador BERT y fine-tuning.	Alcanzó un puntaje BLEU de 20,13.	Evidencia las limitaciones de modelos de traducción pura.
Duran y Silberztein (2026)	Construir diccionarios quechua-español.	Métodos semi-automáticos con formalismos léxicos.	Diccionario bilingüe estructurado de alta precisión.	Fuente léxica para las reglas de normalización del RAG.
Court y Elsner (2024)	Evaluar LLMs comerciales en quechua.	In-context learning con reglas gramaticales inyectadas.	Reglas extensas degradan fidelidad; prompt simple es insuficiente.	Justifica no usar LLMs comerciales en la nube y diseñar sistema local.
Chen et al. (2024)	Optimizar traducción quechua-inglés.	Enfoque híbrido: RAG léxico + LoRA.	Aumento de BLEU de 1,5 a 17,6.	Precedente directo de la viabilidad de acoplar RAG y adaptadores.
Walusimbi et al. (2026)	Desarrollar asistente educativo offline.	Inferencia de SLM cuantizado en CPU.	Latencia de 1–3s en hardware de baja gama en aulas sin internet.	Valida la viabilidad técnica del despliegue offline.

5.7. Síntesis crítica y vacíos de investigación

La revisión de literatura demuestra que existen avances maduros, pero aislados, en los componentes necesarios para el sistema propuesto. Por un lado, se han construido corpus y evaluado LLMs para quechua (Orcotoma Mormontoy et al., 2025; Court y Elsner, 2024), y se ha demostrado que la hibridación de RAG con adaptación ligera produce mejoras significativas

(Chen et al., 2024). Por otro lado, la viabilidad de SLMs *offline* y sistemas RAG ha sido probada (Walusimbi et al. 2026; Hevia et al. 2025; Xu et al. 2024), pero principalmente para inglés y lenguas mayoritarias. La evidencia comparada confirma que RAG supera al *fine-tuning* para inyección de conocimiento (Ovadia et al., 2024), pero que un RAG no optimizado con modelos pequeños puede degradar el rendimiento. La técnica RAFT (Zhang et al., 2024) ofrece una vía para resolver este problema, pero no ha sido aplicada al Quechua Collao. Finalmente, la política EIB (Ministerio de Educación del Perú 2018) exige recursos pertinentes que la actual oferta de LLMs comerciales en la nube no puede satisfacer, ya sea por barreras de conectividad o por la degradación del rendimiento al inyectarles reglas complejas (Court y Elsner, 2024).

En consecuencia, el vacío de investigación se ubica en la ausencia de un prototipo integrado de asistente educativo offline español–Quechua Collao que combine un modelo compacto cuantizado, RAG local disciplinado, recursos lingüísticos validados y criterios pedagógicos EIB para apoyar consultas curriculares en contextos rurales del sur andino peruano.

6. Marco Teórico y Conceptual

El presente marco teórico articula los fundamentos conceptuales que sustentan el diseño de un asistente educativo bilingüe español–Quechua Collao con capacidad de operación *offline*. Su construcción sigue una organización jerárquica que avanza desde los marcos normativos y sociolingüísticos más generales —la Educación Intercultural Bilingüe y la caracterización del Quechua Collao— hacia los componentes técnicos progresivamente más específicos que definen el artefacto propuesto: el procesamiento de lenguas de bajos recursos, los modelos de lenguaje y su comprensión, la adaptación paramétrica ligera, la Generación Aumentada por Recuperación y los criterios de evaluación educativa. Esta secuencia busca evidenciar no solo qué es cada concepto, sino cómo se relaciona con el problema de investigación y de qué modo su integración fundamenta las decisiones de diseño que se operacionalizan en la metodología.

6.1. Educación Intercultural Bilingüe (EIB)

La Educación Intercultural Bilingüe es el modelo pedagógico promovido por el Ministerio de Educación del Perú (MINEDU) para garantizar el derecho a una educación pertinente a los estudiantes de pueblos originarios (Ministerio de Educación del Perú, 2018). El modelo establece dos formas de atención principales:

- **EIB de Fortalecimiento Cultural y Lingüístico:** Orientada a estudiantes que tienen la lengua originaria (como el Quechua Collao) como lengua materna y el castellano como segunda lengua.
- **EIB de Revitalización Cultural y Lingüística:** Dirigida a estudiantes cuya lengua materna es el castellano, pero pertenecen a comunidades con herencia cultural originaria.

Cualquier tecnología educativa insertada en este contexto debe respetar el enfoque de bilingüismo aditivo, en el que ninguna lengua desplaza a la otra.

6.2. Quechua Collao: caracterización dialectal

El Quechua Collao es la variedad predominante en Puno, Moquegua y el sur de Arequipa, con presencia también en partes de Cusco. A nivel morfosintáctico, es una lengua aglutinante y sufijadora: una sola raíz puede recibir múltiples sufijos derivativos y flexivos para expresar significados que en español requerirían varias palabras. A nivel fonológico, se caracteriza por

la presencia de consonantes oclusivas glotizadas y aspiradas, rasgos fonológicos diferenciadores que deben considerarse en el procesamiento del texto. Adicionalmente, la digitalización de esta variante enfrenta el problema de escasez de recursos estructurados y alta variabilidad ortográfica (Orcotoma Mormontoy et al., 2025).

6.3. Translengüaje y alternancia de códigos

El translengüaje es el proceso por el cual los hablantes bilingües utilizan su repertorio lingüístico completo de manera dinámica y estratégica (García, 2009). La alternancia de códigos (*code-switching*) es una manifestación de este fenómeno que implica el cambio sistemático entre dos lenguas dentro de una misma interacción. Para el asistente educativo propuesto, el sistema debe ser capaz de identificar el idioma predominante en entradas mixtas, reconocer segmentos alternados y responder en el idioma más pertinente.

6.4. Procesamiento de Lenguaje Natural en Lenguas de Bajos Recursos

El procesamiento de lenguaje natural (PLN) para lenguas de bajos recursos digitales (*low-resource languages*), como el Quechua Collao, enfrenta dos desafíos teóricos principales: la escasez de datos paralelos estructurados para el entrenamiento de representaciones vectoriales, y la complejidad morfosintáctica de la lengua.

Como se señaló en la caracterización dialectal, su morfología aglutinante hace que una sola palabra concentre el significado de una frase completa en español, lo que dificulta la tokenización estándar y la alineación léxica. Por esta razón, el Entendimiento del Lenguaje Natural (NLU) en este tipo de lenguas se beneficia del uso de mecanismos de inyección de conocimiento explícito (diccionarios, glosarios y reglas gramaticales) y arquitecturas de recuperación, en lugar de depender exclusivamente de la representación paramétrica de los modelos probabilísticos generales.

Cuello de botella de la tokenización en lenguas aglutinantes

La fragmentación del texto en unidades mínimas o tokens representa un punto crítico en el procesamiento de lenguas aglutinantes. Los tokenizadores basados en subpalabras (como BPE o SentencePiece) tienden a dividir las palabras complejas del quechua en múltiples morfemas breves e independientes. Este fenómeno se describe cuantitativamente a través de la *fertilidad de tokens*, que mide el ratio de tokens generados para un texto en quechua frente a su equivalente en español. Para el Quechua Collao, la literatura reporta estimaciones de hasta aproximadamente $3,4\times$ respecto al español; este valor es preliminar y se validará empíricamente sobre el corpus del proyecto.

La alta fertilidad de tokens se proyecta con dos consecuencias principales en el diseño del sistema:

- **Carga en memoria:** La caché de clave-valor (KV cache) del Transformer almacena los estados de atención de los tokens previos; a mayor cantidad de tokens generados, mayor es el consumo de RAM.
- **Complejidad computacional:** La autoatención tiene una complejidad cuadrática $O(N^2 \cdot D)$ respecto a la longitud de la secuencia N . La inflación de tokens penaliza directamente la latencia de inferencia en dispositivos locales CPU.

Por ello, un diseño optimizado exige limitar el tamaño de los fragmentos recuperados en el RAG (250–400 tokens) y el número de contextos inyectados (*top-k* entre 3 y 5) para no saturar la ventana de contexto.

Traducción automática neuronal

La Traducción Automática Neuronal (NMT, *Neural Machine Translation*) es un enfoque de traducción basado en redes neuronales profundas (típicamente arquitecturas de codificador-decodificador con atención). Aunque la NMT logra una gran fluidez al modelar relaciones contextuales completas, su precisión disminuye drásticamente ante la escasez de datos bilingües alineados. En lenguas de bajos recursos, los modelos de traducción pura son propensos a cometer errores de fidelidad semántica o a generar frases fluidas en el idioma de salida pero inconexas con el significado original. Esto fundamenta el uso de un enfoque asistido por recuperación semántica local para asegurar que la generación se ancle a documentos de control preexistentes.

6.5. Modelos de lenguaje y arquitectura Transformer

Un modelo de lenguaje es un sistema estadístico entrenado para modelar la distribución de probabilidad de secuencias de tokens en una lengua. Los modelos de lenguaje modernos se basan en la arquitectura Transformer (Vaswani et al., 2017), que introduce mecanismos de autoatención multi-cabeza para capturar dependencias de largo alcance en el texto sin recurrir a estructuras recurrentes. Esta arquitectura permitió escalar el entrenamiento a corpus de cientos de miles de millones de tokens, dando origen a los Grandes Modelos de Lenguaje (LLM, *Large Language Models*), como GPT-4, Llama y Gemini.

Los LLM poseen capacidades notables de generación, razonamiento y comprensión, pero su tamaño —que puede superar los 70 mil millones de parámetros— los hace inaccesibles para el despliegue en hardware de bajo costo sin conectividad permanente a la nube. Esta limitación es determinante para el contexto rural del sur andino peruano, donde la conectividad es escasa y los dispositivos disponibles son de gama baja o media.

6.6. Small Language Models y cuantización

Los Small Language Models (SLM) son modelos basados en Transformers optimizados para operar con menos de 10 mil millones (10B) de parámetros. Para viabilizar su ejecución local (*on-device*) en dispositivos de consumo sin GPU dedicada, se aplican técnicas de compresión. La más extendida es la **Cuantización Post-Entrenamiento (PTQ, *Post-Training Quantization*)**, la cual reduce la precisión en bits de los pesos del modelo (por ejemplo, de Float16 a Int4 o Int8), minimizando el espacio en memoria RAM requerido y acelerando la inferencia de *tokens* con una pérdida mínima de calidad (Xu et al., 2024).

Para el presente proyecto, el modelo base candidato principal es **Qwen2.5-7B** (Yang et al., 2024) (o su variante de 3B), por cuatro razones: (1) soporte multilingüe nativo para más de 29 idiomas, incluido el español, con mejor manejo de morfemas no latinos que modelos entrenados mayoritariamente en inglés; (2) rendimiento competitivo en *benchmarks* de comprensión en configuraciones cuantizadas preferentemente a 4 bits; (3) validación empírica de ejecución *offline* en hardware CPU-only en contextos educativos de baja conectividad (Walusimbi et al., 2026); (4) requerimientos de RAM en cuantización Q4_K_M estimados en aproximadamente 4,5 GB según pruebas preliminares de literatura, compatibles con equipos de gama media. La selección definitiva se realizará en la Fase 2 del Design Science Research mediante evaluación comparativa de latencia, consumo de memoria y calidad de respuesta.

Tabla 2*Modelos candidatos evaluados y de referencia para el asistente offline*

Modelo	Params.	RAM (Q4_K_M)	ES / CPU	Rol en el proyecto
Qwen2.5-7B-Instruct	7,6B	~4,7 GB	Sí / Sí	Candidato principal — equipos 16 GB
Qwen2.5-3B-Instruct	3,1B	~2,1 GB	Sí / Sí	Candidato base — equipos 8 GB
Llama 3.2 3B-Instruct	3,2B	~2,0 GB	Sí / Sí	Alternativa viable; buena instrucción
Phi-3.5-mini-Instruct	3,8B	~2,5 GB	Parcial / Sí	Razonamiento fuerte; menos multilingüe
Gemma 2 2B-IT	2,6B	~1,7 GB	Sí / Sí	Alternativa de alta calidad (Team Gemma, 2024)
SmolLM2-1.7B-Instruct	1,7B	~1,1 GB	Parcial / Sí	Hardware muy restringido (<4 GB RAM)
Llama 3.2 1B-Instruct	1,2B	~0,7 GB	Limitado / Sí	Dispositivos ultra-restringidos
TinyLlama-1.1B	1,1B	~0,8 GB	No / Sí	Descartado — sin soporte multilingüe

Nota: Los valores de memoria RAM son aproximados y serán verificados empíricamente durante la fase de evaluación del prototipo en el hardware disponible. Los modelos marcados como «candidato» serán evaluados empíricamente en la Fase 2 del DSR. Los modelos de generación complementarios (como Gemma 2 o variantes compactas de Mistral) representan opciones a considerar en trabajos derivados o en una segunda iteración del prototipo si el cronograma lo permite.

6.7. Adaptación ligera: LoRA y QLoRA

La adaptación de bajo rango (*Low-Rank Adaptation*, LoRA) permite ajustar el comportamiento de un modelo sin modificar todos sus parámetros. En lugar de reentrenar la matriz de pesos original $W_0 \in \mathbb{R}^{d \times k}$, se inyecta una descomposición de bajo rango de los cambios necesarios $\Delta W = B \cdot A$, donde $B \in \mathbb{R}^{d \times r}$ y $A \in \mathbb{R}^{r \times k}$, siendo el rango $r \ll \min(d, k)$. Durante el entrenamiento, los pesos del modelo base permanecen congelados y solo se actualizan los parámetros de las matrices A y B , lo que reduce los requisitos de memoria del optimizador.

QLoRA combina la cuantización de los pesos del modelo base a un tipo de datos de 4 bits optimizado (*NormalFloat4*) con la adición de adaptadores LoRA de precisión Float16. En el contexto de asistentes bilingües, esta técnica se utiliza para refinar el estilo pedagógico de respuesta del modelo o su resiliencia terminológica ante contextos de RAG, sin alterar el conocimiento factual básico del modelo base.

6.8. RAFT: Retrieval-Augmented Fine-Tuning

RAFT es una estrategia conceptual de ajuste fino orientada a adaptar modelos de lenguaje para tareas de RAG de dominio específico. El objetivo no es inyectar conocimientos factuales dentro de los pesos del modelo, sino entrenar al modelo a: (a) extraer citas textuales y pruebas directas de los documentos provistos en el prompt; y (b) ignorar fragmentos de información irrelevante o dialectalmente incorrecta (distractores) inyectados en la ventana de contexto.

6.9. Asistentes educativos inteligentes

Los Sistemas de Tutoría Inteligente (ITS, *Intelligent Tutoring Systems*) son sistemas informáticos diseñados para proporcionar instrucción personalizada adaptada al nivel de comprensión del estudiante, sin intervención humana directa en tiempo real. Los ITS modernos basados en modelos de lenguaje incorporan principios pedagógicos como el andamiaje cognitivo (*scaffolding*), que consiste en ofrecer apoyos estructurados que el aprendiz retira progresivamente a medida que adquiere competencia; la Zona de Desarrollo Próximo (ZDP) de Vygotsky (1978), que delimita el rango de tareas que el estudiante puede realizar con guía pero no de forma autónoma; y el *feedback* formativo, que orienta al estudiante hacia la comprensión correcta en lugar de limitarse a confirmar o refutar respuestas.

El asistente educativo propuesto se inscribe en este marco conceptual. Su propósito no es reemplazar al docente bilingüe sino proveer un apoyo adicional disponible fuera del horario de clase y en entornos sin conectividad, respondiendo consultas curriculares con un tono pedagógico adecuado a la edad y al nivel educativo del usuario. Levonian et al. (2025) establecen que los sistemas de tutoría generativa deben diseñarse para generar interacciones seguras y relevantes, priorizando el andamiaje cognitivo sobre la simple provisión de respuestas directas, criterio que guía el diseño del pipeline de generación del presente proyecto.

6.10. Generación Aumentada por Recuperación (RAG)

La Generación Aumentada por Recuperación (RAG) es una arquitectura que acopla un modelo de lenguaje con un sistema de búsqueda externa sobre un corpus documental delimitado. El pipeline conceptual consta de tres etapas:

1. **Indexación:** Segmentación del corpus documental en fragmentos cortos (*chunks*), generación de incrustaciones vectoriales (*embeddings*) y almacenamiento en una base vectorial local.
2. **Recuperación:** Búsqueda de los fragmentos semánticamente más similares a la consulta del usuario utilizando métricas de distancia (como similitud de coseno).
3. **Generación:** Inyección de los fragmentos recuperados en el prompt de contexto para que el SLM formule una respuesta factual y anclada a las fuentes locales.

6.11. Detección automática de idioma

En interacciones bilingües donde se manifiesta la alternancia de códigos, la detección automática de idioma actúa como un enrutador lógico. Este clasificador liviano evalúa el texto del usuario para determinar la lengua predominante. Esto permite seleccionar la plantilla de prompt pedagógico correspondiente y el índice de documentos RAG específico antes de ejecutar la inferencia del modelo generativo, reduciendo la latencia general del sistema.

6.12. Evaluación de sistemas educativos con IA

La validación de estas arquitecturas requiere una evaluación multidimensional:

- **Evaluación Técnica:** Medición objetiva de la latencia (tiempo hasta el primer token), consumo de memoria RAM y velocidad de generación (tokens/s) en el hardware local CPU.
- **Evaluación Lingüística:** Uso de métricas automáticas basadas en n-gramas de caracteres (como chrF++) para medir la correspondencia léxica frente a referencias traducidas y normalizadas.
- **Evaluación Pedagógica:** Uso de rúbricas cualitativas y juicio de expertos para validar la exactitud de los contenidos, el andamiaje bilingüe y la adecuación intercultural de las respuestas.

6.13. Síntesis integradora del marco teórico

Los conceptos de este marco no operan de forma indistinta, sino que desempeñan roles independientes y complementarios en la arquitectura del asistente:

- **Educación Intercultural Bilingüe (EIB):** Proporciona el marco pedagógico y normativo (bilingüismo aditivo, pertinencia regional), estableciendo la necesidad de un sistema conversacional contextualizado y adaptado a las dinámicas del translenguaje.
- **Sistemas de Tutoría Inteligente (ITS):** Guían el diseño conversacional del asistente, implementando la lógica de andamiaje formativo gradual (explicaciones, pistas, retroalimentación) en lugar de respuestas directas o traducciones mecánicas.
- **Generación Aumentada por Recuperación (RAG) local:** Funciona como la base de conocimiento factual externa. Aloja los contenidos curriculares y glosarios oficiales fuera del modelo base, reduciendo alucinaciones factuales sin requerir reentrenamiento del modelo.
- **Adaptación ligera (QLoRA):** Ajusta exclusivamente el comportamiento y estilo del modelo (el cómo responder), enseñándole a adherirse al tono del andamiaje educativo y a extraer de forma resiliente la información inyectada por el RAG local.
- **Traducción Automática (NMT) y Métricas:** Actúan únicamente como herramientas de evaluación lingüística y referencia comparativa para verificar la fidelidad semántica de las generaciones del asistente, sin que el sistema constituya un traductor estadístico autónomo.

Esta delimitación de roles fundamenta las decisiones centrales del artefacto: se prioriza el RAG local para el conocimiento factual (Ovadia et al., 2024); se reserva QLoRA para alinear el estilo pedagógico y el uso del contexto (Dettmers et al., 2023); y se selecciona un modelo compacto cuantizado por su factibilidad en CPU local sin conectividad (Walusimbi et al., 2026; Xu et al., 2024). Con esta base conceptual, la metodología operacionaliza dichas decisiones bajo el paradigma Design Science Research, definiendo el diseño experimental (experimentos E1–E3) y los instrumentos de evaluación técnica, lingüística y pedagógica.

7. Metodología

7.1. Tipo y diseño de investigación

La investigación es de tipo **aplicada y tecnológica**, orientada al diseño, implementación y evaluación de un prototipo funcional de asistente educativo para solucionar un problema real de soporte curricular en EIB.

El enfoque es **mixto con predominio cuantitativo**, bajo un diseño de integración **convergente**: los datos cuantitativos (métricas automáticas de rendimiento técnico y calidad lingüística) y los cualitativos (rúbricas de juicio de expertos) se recolectan sobre el mismo banco de consultas patrón y se triangulan para valorar el prototipo. Esta elección responde directamente a la naturaleza de la pregunta de investigación: determinar *en qué medida* cada componente de la arquitectura mejora el desempeño del asistente exige medición numérica y comparación controlada entre configuraciones (componente cuantitativo); mientras que la adecuación dialectal al Quechua Collao y la pertinencia pedagógica del andamiaje no son plenamente capturables por métricas automáticas y requieren la interpretación de especialistas (componente cualitativo). Un enfoque cuantitativo puro dejaría sin evaluar la dimensión pedagógica e intercultural del artefacto; un enfoque cualitativo puro no permitiría atribuir con rigor la contribución de cada componente técnico ni garantizar la reproducibilidad de la comparación.

El estudio se estructura sobre la base de una relación de causalidad tecnológica, donde la manipulación de la **Variable Independiente (VI)** —la arquitectura del asistente— produce efectos medibles sobre las **Variables Dependientes (VD)** del sistema, agrupadas en dimensiones de rendimiento técnico, calidad lingüística y pertinencia pedagógica.

La **Variable Independiente (VI)** es cualitativa nominal y representa la configuración del chatbot, evaluada a través de tres niveles experimentales: (i) *E1 (Modelo Base)*: inferencia local del SLM base cuantizado; (ii) *E2 (SLM + RAG local)*: SLM con inyección de contexto RAG y normalización morfo-léxica; y (iii) *E3 (Híbrido)*: SLM con RAG, reglas y adaptadores QLoRA.

Las **Variables Dependientes (VD)** abarcan: (a) *Rendimiento técnico (cuantitativas continuas)*: latencia (ms), velocidad (tokens/s) y consumo de memoria RAM (GB); (b) *Calidad lingüística (mixtas)*: correspondencia léxica (chrF++ y SacreBLEU), consistencia semántica (faithfulness Ragas) y adecuación dialectal (Likert 1-5); y (c) *Pertinencia pedagógica (cualitativas ordinales)*: nivel de andamiaje formativo y relevancia curricular (Likert 1-5). Para asegurar la validez metodológica, la Tabla 3 detalla la operacionalización de estas variables.

Tabla 3

Matriz de operacionalización de variables

Variable	Tipo	Dimensión	Definición Operacional	Indicador	Instrumento / Herramienta
VI: Arquitectura del asistente	Cualitativa nominal	Arquitectura de software	Configuración del stack interno y uso de recursos para métricos y de recuperación.	Configuración evaluada: E1, E2, E3	Scripts de orquestación en Python y compilador <code>llama.cpp</code> .
VD1: Latencia	Cuantitativa continua	Rendimiento técnico	Medición del tiempo de respuesta del sistema bajo inferencia local CPU.	Tiempo de respuesta en milisegundos (ms)	Librería <code>time</code> de Python, logs de <code>llama.cpp</code> .
VD2: Velocidad de tokens	Cuantitativa continua	Rendimiento técnico	Cantidad de unidades mínimas generadas por unidad de tiempo.	Tokens generados por segundo (tokens/s)	Profiler de ejecución de <code>llama.cpp</code> .
VD3: Memoria RAM	Cuantitativa continua	Rendimiento técnico	Espacio de almacenamiento temporal ocupado por el proceso del modelo.	Memoria RAM en Gigabytes (GB)	Monitor de recursos del sistema operativo (<code>psutil</code>).
VD4: Correspondencia léxica	Cuantitativa continua	Calidad lingüística	Medición estadística de similitud con oraciones de control.	Puntajes automáticos chrF++ y SacreBLEU	Script de evaluación automática en Python.
VD5: Coherencia semántica RAG	Cuantitativa continua	Calidad lingüística	Evaluación de anclaje y veracidad factual del contexto inyectado.	Métrica de <i>faithfulness</i> y precisión de respuesta	Framework de evaluación RAGs.
VD6: Adecuación dialectal	Cualitativa ordinal	Calidad lingüística	Conformidad fonológico-ortográfica con el Quechua Collao estándar.	Escala Likert de 1 a 5 (Consistencia de morfemas y glotización)	Rúbrica de evaluación lingüística para especialista.
VD7: Nivel de andamiaje	Cualitativa ordinal	Pertinencia pedagógica	Estructura gradual de ayuda pedagógica (preguntas, pistas y ejemplos).	Escala Likert de 1 a 5 (Progresión cognitiva y bilingüismo)	Rúbrica de evaluación pedagógica para docente EIB.
VD8: Pertinencia curricular	Cualitativa ordinal	Pertinencia pedagógica	Adecuación temática y lingüística a las áreas de Comunicación y CyT.	Escala Likert de 1 a 5 (Grado de correspondencia oficial)	Rúbrica de evaluación curricular para docente EIB.

El diseño metodológico adoptado es **comparativo-experimental sobre el artefacto**. Se manipularán configuraciones técnicas internas del sistema para contrastar su desempeño, complementado con un diseño descriptivo para la validación humana mediante juicio de expertos (docente EIB y validador lingüístico Collao). Las dimensiones de evaluación corresponden a las variables dependientes especificadas, permitiendo aislar la contribución de cada componente tecnológico en la inferencia offline.

7.2. Hipótesis

Dado el carácter comparativo-experimental del diseño, se formulan las siguientes hipótesis estadísticas sobre el banco de consultas patrón:

- **Hipótesis nula (H_0):** No existe diferencia significativa en la calidad lingüística (chrF++), la consistencia semántica (*faithfulness*) ni la pertinencia pedagógica (rúbricas Likert) entre las tres configuraciones del asistente (E1, E2 y E3) al responder el banco de consultas patrón.
- **Hipótesis alternativa (H_1):** La configuración híbrida completa (E3) alcanza valores significativamente superiores a los de E1 y E2 en las dimensiones de calidad lingüística y consistencia semántica, manteniendo un rendimiento técnico viable para la inferencia local en CPU (latencia y consumo de memoria dentro de los límites del hardware objetivo).

Dado que las tres configuraciones se evalúan sobre el mismo banco de consultas (diseño de medidas repetidas) y que no puede garantizarse la normalidad en la distribución de los puntajes, el contraste se realizará con pruebas no paramétricas: la prueba de Friedman para la comparación global de las tres configuraciones y pruebas post-hoc de Wilcoxon de rangos con signo con corrección de Bonferroni para las comparaciones por pares, con un nivel de significancia de $\alpha = 0,05$. Si el valor p de la prueba global es menor que α , se rechaza H_0 .

7.3. Metodología de desarrollo

El desarrollo del prototipo de asistente bilingüe sigue el paradigma **Design Science Research (DSR)**, estructurado en las siguientes fases:

1. **Identificación del problema y motivación:** Delimitación de las brechas de conectividad y la carencia de recursos bilingües contextualizados en el ámbito rural.
2. **Definición de objetivos de la solución:** Establecimiento de requisitos funcionales y de restricciones técnicas offline.
3. **Diseño y desarrollo:** Selección, cuantización del modelo base, diseño de la base vectorial local, estructuración de las reglas gramaticales y configuración opcional de adaptadores QLoRA.
4. **Demostración:** Integración del prototipo funcional alimentado con el corpus bilingüe seleccionado.
5. **Evaluación:** Comparación de tres configuraciones básicas (modelo base sin RAG, RAG local y enfoque híbrido completo) mediante métricas automáticas y juicios cualitativos de expertos.
6. **Comunicación:** Documentación de hallazgos, límites del prototipo y recomendaciones metodológicas.

Para garantizar la **reproducibilidad** del estudio, el código del prototipo y los scripts de evaluación se gestionarán en un repositorio Git con documentación de las versiones de librerías y modelos empleados; los parámetros de inferencia (temperatura, *top-k*, semillas aleatorias) y de recuperación quedarán fijados en archivos de configuración versionados; y se publicarán el banco de consultas patrón, las rúbricas de evaluación y los resultados por configuración, de modo que terceros puedan replicar la comparación entre E1, E2 y E3.

7.4. Población y muestra

La **población** de estudio está constituida por el universo de consultas curriculares que estudiantes y docentes de contextos EIB pueden formular sobre las áreas de Comunicación y Ciencia y Tecnología de 3.º a 6.º grado de primaria, en español, en Quechua Collao o de forma bilingüe. Dado que este universo no es enumerable, la **muestra** se construye mediante **muestreo no probabilístico intencional estratificado**: el banco de 100 consultas patrón se distribuye de manera balanceada por área curricular, grado escolar y lengua de formulación (español, quechua y mixta), garantizando la representación de los escenarios de uso previstos del asistente. Sobre esta base, la definición de las unidades de análisis se organiza bajo tres dimensiones de control:

- **Unidad documental:** Compuesta por materiales curriculares de EIB del MINEDU para primaria (3.º a 6.º grado) en Comunicación y Ciencia y Tecnología, glosarios terminológicos de Quechua Collao del Ministerio de Educación y el corpus bilingüe de referencia.
- **Unidad de prueba:** Un banco compuesto por 100 consultas patrón. Las consultas serán elaboradas a partir de contenidos curriculares oficiales y validadas por el docente especialista en EIB para asegurar pertinencia temática, nivel educativo y equilibrio lingüístico.
- **Unidad de validación humana:** Evaluadores especializados conformados por: (i) un (1) docente especialista en Educación Intercultural Bilingüe (EIB) activo, encargado de definir las pautas pedagógicas del asistente y validar la adecuación del andamiaje formativo; y (ii) un (1) especialista lingüístico en la variedad Quechua Collao (hablante nativo), encargado de validar la adecuación dialectal y ortográfica de las respuestas generadas.

7.5. Consideraciones éticas

Dado que el proyecto no involucra la participación de estudiantes menores de edad y se basa en la reutilización de materiales educativos y la validación por especialistas adultos, el protocolo se rige por los siguientes principios éticos:

1. **Propiedad intelectual y atribución:** Se respetará el derecho de autor de todos los recursos del MINEDU y corpus de referencia empleados, utilizándolos de forma estrictamente académica y con la debida citación de fuentes.
2. **Rigor científico y honestidad académica:** La generación de datos asistida por IA se somete a validación cruzada y revisión manual por el especialista para evitar la distorsión del idioma originario y garantizar la pertinencia cultural.

8. Estudio de Factibilidad

El estudio de factibilidad determina si el proyecto puede ejecutarse con éxito dentro de las restricciones reales de tiempo, hardware, datos y recursos propios. El proyecto **es factible como prototipo académico de validación conceptual**: se selecciona, cuantiza y despliega un SLM preentrenado con RAG local, recursos lingüísticos explícitos y una adaptación ligera (QLoRA), en lugar de entrenar un modelo desde cero (Xu et al., 2024; Walusimbi et al., 2026).

8.1. Enfoque híbrido adoptado

Se evaluaron tres opciones arquitectónicas. La Tabla 4 resume el análisis comparativo que fundamenta la elección.

Tabla 4
Matriz comparativa de enfoques para la decisión metodológica

Opción	Ventaja principal	Riesgo principal	Ajuste	Veredicto
A. Fine-tuning de SLM	Mejora estilo y terminología si hay corpus válido	Corpus Collao escaso; riesgo de sobreajuste y olvido catastrófico	Parcial	Solo como brazo comparativo
B. SLM cuantizado + RAG local	Mejor facticidad; actualización fácil; offline realista	Depende de la calidad de segmentación y recuperación	Muy alto	<i>Línea base</i> obligatoria
C. Híbrido (B + reglas + QLoRA)	Combina anclaje factual con adaptación lingüística y pedagógica	Más ingeniería que B	Máximo	Opción adoptada

La razón principal para descartar A como vía principal es de **escala de datos y riesgo metodológico**. El trabajo de Ovadia et al. (2024) encontró que, para inyección de conocimiento, RAG superó consistentemente al fine-tuning no supervisado tanto para conocimiento existente como nuevo. En lenguas de bajos recursos como el Quechua Collao, el corpus disponible ($\approx 44\,263$ palabras) es valioso como semilla, pero demasiado pequeño para sostener una aspiración de “modelo bilingüe entrenado” sin riesgo de sobreajuste o mejoras frágiles. En cambio, RAG permite alojar el conocimiento curricular **fuera de los pesos del modelo**, actualizarlo sin reentrenar y reducir alucinaciones si la recuperación está cuidadosamente diseñada.

8.2. Factibilidad técnica

Hardware e inferencia local

El archivo GGUF de **Qwen2.5-3B-Instruct** en **Q4_K_M** pesa **2,1 GB** y consume aproximadamente **3 GB de RAM** en ejecución. En una laptop de gama media con 8 GB de RAM, esta es la opción segura. El modelo **Qwen2.5-7B-Instruct** (4,68 GB en disco, $\sim 6\text{--}7$ GB en RAM) se reserva como variante de calidad para equipos de 16 GB. La inferencia en CPU genera **10–25 tokens/s** (3B) y **8–12 tokens/s** (7B), velocidades aceptables para turnos educativos cortos. La cuantización se realiza con `llama.cpp` en CPU o en Kaggle/Colab (GPU T4 gratuita).

Estrategia de datos: generación con IA y validación contra corpus

La obtención de datos bilingües español–Quechua Collao es la **base operativa** de todo el proyecto. Dado que el corpus digital disponible en Quechua Collao es extremadamente limitado ($\approx 44\,263$ palabras del corpus OCR de Orcotoma Mormontoy et al., 2025), la estrategia de datos se estructura en tres etapas:

1. **Generación sintética con IA:** Se utilizarán modelos de lenguaje de gran escala (GPT-4o, Gemini) para generar pares bilingües español–Quechua Collao en el dominio pedagógico EIB: oraciones, diálogos, definiciones de vocabulario, ejercicios y explicaciones curriculares para las áreas de Comunicación y Ciencia y Tecnología (3.º a 6.º grado de primaria). Los prompts se diseñarán con especificaciones dialectales explícitas (variedad Collao, no Chanka ni Cusqueño) y con ejemplos semilla extraídos del corpus validado.
2. **Validación cruzada contra corpus existentes:** Los datos generados se contrastarán bajo tres criterios de control, con umbrales definidos para decidir su aceptación o descarte:
 - **Criterio léxico y de raíces (Umbral: $\geq 95\%$):** Las raíces de los verbos y sustantivos quechuas de cada par sintético deben tener correspondencia exacta con las entradas del diccionario de Duran and Silberztein (2026) o los glosarios oficiales de la AMLQ. Se descartan de forma automática los pares con discrepancias léxicas en palabras clave.
 - **Criterio ortográfico y dialectal (Umbral de descarte absoluto):** Se verifica que las palabras quechuas empleen el inventario fonológico del Quechua Collao (como la presencia de oclusivas glotizadas /p', t', k', q', ch'/ y aspiradas /ph, th, kh, qh, chh/). Se descartan de inmediato los pares con grafías propias de otras variantes dialectales (ej. uso de "sh" del quechua chanka o norteno).
 - **Criterio de alineación semántica (Umbral: similitud de coseno $\geq 0,82$):** Se calcula la similitud vectorial entre la oración en español y la oración en quechua utilizando el modelo de incrustación `multilingual-e5-small`. Aquellos pares que se ubiquen por debajo del umbral de 0,82 serán descartados por potencial infidelidad de traducción.

Una muestra aleatoria del lote resultante será sometida a la revisión manual del especialista lingüístico; si la muestra reporta una tasa de error morfológico o sintáctico superior al 5 %, el lote completo es rechazado y se itera en la ingeniería de prompts.

3. **Limpieza y adaptación al dominio:** Los datos que superen el proceso de validación se someterán a un pipeline de posprocesamiento (normalización de mayúsculas/minúsculas, eliminación de duplicados exactos y corrección de signos de puntuación) y se organizarán por área curricular y grado escolar. Esta base documental curada conformará los fragmentos (*chunks*) de conocimiento del RAG.

Sobre el corpus de referencia de Orcotoma Mormontoy et al. (2025) —digitalizado por OCR a partir de cinco libros de la Academia Mayor de la Lengua Quechua (AMLQ)— cabe precisar que su cifra corresponde a un conteo de palabras, no de pares de oraciones, y que el propio artículo advierte que no se aplicó limpieza *post-OCR*. Como recursos complementarios de dominio público se identifican: el corpus monolingüe `Llamacha/monolingual-quechua-iic` (base del modelo QuBERT para quechua sureño), datos de AmericasNLP 2023 —que

comprenden aproximadamente 154 000 pares quechua–español de entrenamiento— y materiales curriculares EIB abiertos del MINEDU.

Advertencia dialectal crítica: la variante *qwy* utilizada en AmericasNLP corresponde al Quechua Chanka (Ayacucho), no al Quechua Collao (Cusco–Puno). Su uso exige validación y normalización ortográfica previa. Construir la base RAG en doce meses es **realista** porque no entrena el modelo desde cero; solo requiere curar, segmentar (*chunking*) y vectorizar documentos.

Mitigación del cuello de botella de tokenización: Como se fundamentó en la sección anterior, la alta fertilidad de tokens en Quechua Collao ($\approx 3,4\times$) exige restringir el tamaño del contexto del RAG. En consecuencia, la preparación del corpus documental aplicará una segmentación corta (250–400 tokens para prosa curricular y una entrada por fragmento para glosarios) y limitará el enrutamiento a un *top-k* máximo de 3 a 5 fragmentos, garantizando la viabilidad de la inferencia local en CPU.

La evidencia más prometedora para compensar la escasez de datos está en **datos sintéticos cuidadosamente controlados**. Dhawan et al. (2026) reportaron mejoras consistentes en traducción quechua–español cuando añadieron datos sintéticos con preprocesamiento específico, usando **chrF++** como métrica principal. Esto sugiere que la tesis puede beneficiarse de aumentación de datos, pero con datos normalizados y revisados por hablantes nativos, no con generación automática sin validar.

El carácter multilingüe de Qwen2.5 no debe confundirse con competencia real en Quechua Collao: el *model card* declara soporte para español y más de 29 idiomas, pero **no garantiza soporte específico de Quechua Collao** (Court y Elsner, 2024). La pertinencia en esta variedad dependerá del corpus recuperado, los glosarios curados y los *prompts* diseñados con revisión de hablantes nativos, no del conocimiento paramétrico del modelo.

Tabla 5

Flujo de datos del proyecto

Fuente	Uso	Escala	Tratamiento
Generación sintética con IA	Pares bilingües pedagógicos para RAG y evaluación	Variable (objetivo: 5 000+ pares)	Validación cruzada + limpieza
Corpus OCR Collao–español (Orcotoma Mormontoy et al., 2025)	Referencia de validación y semillas de generación	44 263 palabras	Limpieza post-OCR
Glosarios AMLQ y diccionarios	Validación léxica y chunks de vocabulario	Escala léxica	Indexación individual
Materiales EIB del MINEDU	Contenido curricular para RAG pedagógico	Áreas de Comunicación y CyT, 3.º–6.º grado	Segmentación por grado y área

Stack tecnológico

El desarrollo se fundamenta en software libre y local: **llama.cpp** (Gerganov, 2024) u Ollama (Ollama Team, 2024) para inferencia; FAISS (Johnson et al., 2019) como base vectorial local; modelos de incrustación livianos como **multilingual-e5-small** (Wang et al., 2022); recuperación híbrida BM25 (Robertson and Zaragoza, 2009) + densa; y LangChain (Chase, 2022) o desarrollo modular en Python para la orquestación. La segmentación y el *top-k* siguen

los límites ya definidos en la mitigación del cuello de botella de tokenización, añadiendo un traslape de 50–80 tokens entre fragmentos de prosa.

Matriz técnica de factibilidad

Tabla 6

Viabilidad técnica por componente crítico

Componente	Estado	Justificación	Contingencia
Inferencia CPU-only	Viable	Proyectada en literatura (Walusimbi et al., 2026); estimación de 10–25 tok/s (3B)	Iniciar con 3B; escalar a 7B si el equipo lo soporta
Datos bilingües	Por generar y validar	Generación con IA + validación cruzada contra corpus existentes	Acotar dominio a un área y grado si los datos son insuficientes
Tokenización aglutinante	Identificado	Fertilidad estimada en $\approx 3,4\times$; segmentación y $top-k \leq 5$ como mitigación	Monitorear fertilidad como métrica
Adaptación QLoRA	Factible	Viable en Kaggle/Colab (GPU T4 gratuita) para modelos $\leq 7B$	Solo como configuración experimental complementaria

8.3. Factibilidad económica

El proyecto se ejecuta íntegramente con **recursos personales** de los investigadores. La infraestructura de cómputo (laptop personal) ya está disponible. El cómputo puntual para cuantización y QLoRA se cubrirá con niveles gratuitos de Kaggle y Google Colab. No se requieren APIs de pago, servidores en la nube ni infraestructura externa. El presupuesto detallado se presenta en la Sección 11.

8.4. Factibilidad legal y de licencias

El proyecto reutiliza materiales de terceros cuyo régimen de uso debe verificarse antes de su incorporación al corpus, por lo que la licencia de cada recurso se documentará en el manifiesto de datos. Los materiales curriculares y guías docentes del MINEDU son de acceso público y su uso con fines académicos y de investigación es admisible citando la fuente; no obstante, su incorporación al prototipo se limitará a fragmentos indexados para recuperación (RAG), sin republicar las obras completas. El corpus paralelo Quechua Collao–español (Orcotoma Mormontoy et al., 2025) y los recursos vinculados a la Academia Mayor de la Lengua Quechua (AMLQ) se emplearán conforme a los términos de sus autores y con el debido reconocimiento; cuando la licencia no sea explícita, se gestionará la autorización correspondiente o se restringirá el recurso a uso interno de validación. Los recursos externos (AmericasNLP, NLLB, FLORES) se utilizarán únicamente bajo sus licencias de investigación y con etiquetado dialectal, evitando su redistribución como si correspondieran al Quechua Collao. El modelo base y las herramientas del *stack* (`llama.cpp`, FAISS, LangChain, entre otras) se distribuyen bajo licencias de código abierto compatibles con el uso académico. Finalmente, el estudio no contempla la participación de estudiantes menores de edad: la validación del prototipo se realiza mediante juicio de especialistas adultos (docente EIB y

especialista lingüístico), conforme a las consideraciones éticas detalladas en la metodología. En síntesis, no se identifican impedimentos legales críticos, siempre que se respete la atribución de fuentes, se limite la redistribución a fragmentos y se documente la licencia de cada recurso.

8.5. Factibilidad operativa y gestión del alcance

Operativamente, el proyecto es más viable que una tesis dependiente de sistemas empresariales, porque el artefacto propuesto es un **prototipo autónomo** que no requiere acceso a código fuente, APIs internas o bases de datos corporativas. Sin embargo, mantiene dos dependencias operativas serias: la coordinación con docentes o especialistas EIB para la validación pedagógica, y el acceso a materiales curriculares en escenarios de prueba con pertinencia lingüística responsable.

Tabla 7

Riesgos operativos y mitigación

Factor de riesgo	Mitigación
Calidad insuficiente de datos generados	Validación cruzada obligatoria contra corpus de referencia; descarte de pares no validados; iteración del proceso de generación.
Mezcla dialectal no controlada	Etiquetar todo recurso por variedad; no mezclar Chanka y Collao sin normalización previa.
Sobreextensión del alcance	Limitar la interfaz a CLI/web local mínima; acotar el dominio curricular a Comunicación y CyT de primaria.

8.6. Ámbito pedagógico: fuentes y estrategia de enseñanza

El asistente no es un traductor automático ni un chatbot genérico: es una herramienta de **andamiaje cognitivo bilingüe**. Para lograr esto, la información pedagógica que alimenta el sistema proviene de fuentes específicas y se estructura con una estrategia instruccional definida.

Fuentes de contenido pedagógico

- **Cuadernos de trabajo EIB del MINEDU:** Material oficial bilingüe para escuelas EIB de primaria (3.º a 6.º grado) en las áreas de Comunicación y Ciencia y Tecnología. Estos cuadernos contienen ejercicios, lecturas y vocabulario graduado por nivel.
- **Guías docentes EIB:** Orientaciones metodológicas del MINEDU para docentes de aulas bilingües, que incluyen estrategias de enseñanza con alternancia de lenguas.
- **Textos y glosarios de la AMLQ:** Diccionarios normativos y textos académicos de la Academia Mayor de la Lengua Quechua que proporcionan terminología estandarizada en la variedad Collao.
- **Datos sintéticos pedagógicos generados con IA:** Pares pregunta-respuesta, definiciones de vocabulario, ejemplos de uso y ejercicios, generados con modelos de IA y validados contra los corpus de referencia (ver Sección 8.2).

Estrategia instruccional del asistente

El sistema seguirá un patrón de **andamiaje gradual** en sus respuestas, evitando dar respuestas directas y priorizando la construcción progresiva del conocimiento:

1. **Pregunta orientadora:** Ante una consulta del estudiante, el sistema primero plantea una pregunta que guíe la reflexión (ej. “*¿Imapaqtaq kay simita riqsinki?*” — “¿Para qué conoces esta palabra?”).
2. **Pista contextual:** Ofrece una pista o ejemplo parcial que conecte con el conocimiento previo del estudiante, en la lengua predominante de la consulta.
3. **Explicación bilingüe:** Proporciona la explicación completa en español y Quechua Collao, utilizando vocabulario apropiado al grado escolar.
4. **Ejemplo de aplicación:** Cierra con un ejemplo concreto de uso en contexto pedagógico.

Organización de los fragmentos pedagógicos

Cada fragmento (*chunk*) indexado en la base RAG incluirá metadatos estructurados: **grado escolar** (3.°, 4.°, 5.° o 6.°), **área curricular** (Comunicación o Ciencia y Tecnología), **tipo de contenido** (vocabulario, explicación, ejercicio, lectura) y **lengua predominante** (español, quechua o bilingüe). Esto permite que la recuperación sea precisa y pertinente al nivel del estudiante.

8.7. Diseño experimental

La investigación compara directamente las **tres configuraciones básicas** declaradas en los objetivos:

Tabla 8

Diseño experimental

ID	Sistema	Propósito
E1	SLM base cuantizado sin RAG	Establecer la línea base de rendimiento de la representación interna del modelo
E2	SLM + RAG local + reglas	Medir el impacto de la inyección de fragmentos curriculares y la normalización bilingüe
E3	SLM + RAG + reglas + QLoRA	Evaluar el enfoque híbrido completo acoplando recuperación y adaptación estilística

Las tres configuraciones corresponden directamente a las declaradas en los objetivos y conforman un **diseño escalonado**: cada configuración añade un componente sobre la anterior, de modo que la diferencia de desempeño entre configuraciones consecutivas se atribuye al componente incorporado. Este diseño permite demostrar empíricamente el aporte del RAG local con reglas de normalización (E2 vs. E1) y el aporte adicional de la adaptación ligera QLoRA (E3 vs. E2). La factibilidad de ejecución está asegurada: E1 y E2 son ejecutables **sin GPU** en la laptop de desarrollo, y E3 requiere solo sesiones puntuales de entrenamiento QLoRA en Kaggle/Colab (GPU T4 gratuita), con inferencia final igualmente local en CPU.

Para garantizar la validez, el corpus se dividirá en tres particiones disjuntas: (i) *Ingesta RAG* ($\approx 70\%$), utilizada para la base vectorial en E2 y E3; (ii) *Entrenamiento QLoRA* ($\approx 20\%$), empleada únicamente en E3; y (iii) *Evaluación* ($\approx 10\%$), un banco de consultas patrón no indexadas ni entrenadas.

Métricas de evaluación

Las métricas cumplen una doble función: evaluar el rendimiento del modelo **y** detectar si los datos generados con IA son de calidad suficiente. Si chrF++ es bajo o RAGAS reporta baja fidelidad, el problema puede estar en la calidad de los datos del RAG (fragmentos ruidosos, dialectalmente inconsistentes o mal segmentados), no necesariamente en el modelo. Este diagnóstico diferencial es crítico para iterar el proceso de curación de datos.

Tabla 9

Métricas de evaluación del proyecto

Dimensión	Métrica automática	Métrica humana
Calidad lingüística	chrF++, SacreBLEU (Post, 2018), BERTScore (Zhang et al., 2019)	Adecuación, fluidez, terminología dialectal
Fidelidad RAG	<i>Faithfulness</i> RAGAS (Es et al., 2024), Recall@k, MRR	Veracidad y trazabilidad de la fuente
Pertinencia pedagógica	Ninguna automática basta	Andamiaje, claridad, retroalimentación accionable
Rendimiento técnico	Latencia (ms), tokens/s, RAM	Satisfacción de uso

La métrica **chrF++** es especialmente importante: opera a nivel de *n-gramas* de caracteres, lo que la hace robusta frente a la variación morfológica del quechua. **RAGAS** permite separar los problemas de recuperación de los problemas de generación: si el sistema falla, permite saber si el problema está en los datos del RAG o en el SLM.

8.8. Semáforo de riesgo

Tabla 10

Semáforo de riesgo por dimensión

Dimensión	Nivel	Justificación
Técnica (hardware / inferencia)	VERDE	Modelos y herramientas referenciados; inferencia en CPU proyectada en literatura.
Económica	VERDE	Solo recursos propios; cómputo puntual en capas gratuitas.
Diseño experimental	VERDE	Experimentos E1–E4 y E7 ejecutables sin GPU; E5–E6 requieren sesiones puntuales; métricas bien definidas y herramientas disponibles.
Datos (corpus Collao)	AMARILLO	Corpus base disponible (Orcotoma Mormontoy et al., 2025) pero pequeño, sin limpieza <i>post-OCR</i> ; variantes dialectales (Chanka vs. Collao) exigen validación; cuello de botella de tokenización identificado pero mitigable.
Operativo (acceso EIB / alcance)	AMARILLO	Depende de trámites con DRE/UGEL/AMLQ y de disciplina de alcance para evitar <i>scope creep</i> .
Legal / licencias	VERDE	Materiales MINEDU de acceso público y <i>stack</i> de código abierto; uso limitado a fragmentos indexados con atribución de fuente; licencias documentadas en el manifiesto de datos.
GLOBAL	AMARILLO	Factible con gestión activa de los riesgos de datos y operativos. El enfoque híbrido reduce significativamente el riesgo técnico y económico respecto a alternativas de entrenamiento.

8.9. Conclusión de viabilidad

El proyecto es factible con recursos propios. La decisión de no entrenar un modelo desde cero, sino orquestar un SLM preentrenado cuantizado con RAG local y datos generados con IA y validados contra corpus de referencia, reduce las exigencias de cómputo y presupuesto. El mayor riesgo —la calidad de los datos— se mitiga con el flujo de generación, validación cruzada y limpieza descrito.

9. Importancia del estudio

9.1. Resultados esperados

El artefacto principal de esta investigación es un **prototipo funcional de sistema informático**: un asistente educativo bilingüe español–Quechua Collao ejecutable sin conexión a internet en dispositivos de bajo o mediano costo. Este prototipo no constituye un modelo de lenguaje nuevo ni entrena el modelo base desde cero. Implementa un **enfoque híbrido** que integra un modelo compacto pre-entrenado y cuantizado, un canal RAG local disciplinado, recursos lingüísticos explícitos (glosarios, diccionarios, reglas de normalización) y, de ser

factible, una adaptación ligera complementaria (QLoRA), orientado a responder consultas pedagógicas en contextos EIB del sur andino peruano. Los productos derivados de su construcción y evaluación son:

- Una base local de contenidos curriculares, glosarios terminológicos, diccionarios y materiales EIB en español y Quechua Collao, organizados para su recuperación híbrida (léxica + densa) y orientados al nivel primaria (3.º a 6.º grado), con posibilidad de ampliación posterior hacia secundaria básica en futuras iteraciones.
- Un corpus curado de datos bilingües español–Quechua Collao, generado con modelos de IA y validado contra corpus de referencia existentes (Orcotoma et al., AMLQ).
- Un reporte comparativo de las configuraciones experimentales (*línea base* sin RAG, RAG disciplinado y enfoque híbrido completo) que documente la contribución de cada componente del sistema.
- Un reporte de evaluación técnica que documente métricas de latencia, consumo de memoria, tokens por segundo y estabilidad del prototipo en hardware de bajo o mediano costo de forma local.
- Un reporte de evaluación lingüística y pedagógica con resultados de métricas automáticas (chrF++, RAGAS, Recall@k) y valoraciones del docente especialista EIB y del especialista lingüístico en Quechua Collao sobre la utilidad educativa, pertinencia intercultural y adecuación pedagógica de las respuestas generadas.

El logro de estos resultados se verificará con criterios de éxito explícitos: (i) el prototipo debe operar íntegramente sin conexión a internet en el hardware de desarrollo, con consumo de memoria dentro de la RAM disponible y una velocidad de generación utilizable en turnos educativos cortos (referencia: 10–25 tokens/s para el modelo de 3B parámetros, según el estudio de factibilidad); (ii) la configuración híbrida completa (E3) debe superar significativamente a la línea base (E1) en calidad lingüística (chrF++) y consistencia semántica (*faithfulness*), conforme a las hipótesis y pruebas estadísticas definidas en la metodología; y (iii) las valoraciones de los especialistas sobre adecuación dialectal y pertinencia pedagógica deben alcanzar una mediana no menor a 4 sobre 5 en las rúbricas correspondientes.

9.2. Contribuciones

- **Contribución tecnológica:** Arquitectura híbrida funcional que integra detección de idioma, enrutamiento lingüístico, RAG local disciplinado, recursos lingüísticos explícitos, adaptación ligera QLoRA como configuración experimental y generación de respuestas mediante un modelo compacto cuantizado, ejecutable sin conexión a internet en dispositivos de bajo o mediano costo.
- **Contribución educativa:** Base de conocimiento local organizada con materiales curriculares EIB en español y Quechua Collao, orientada a apoyar consultas pedagógicas de estudiantes y docentes en zonas rurales, junto con un corpus curado de recursos lingüísticos para la variedad Quechua Collao aplicados a tareas de educación intercultural bilingüe.
- **Contribución metodológica:** Diseño de comparación escalonada que cuantifica la contribución de cada componente del enfoque híbrido, combinando métricas automáticas de calidad lingüística (chrF++), calidad de recuperación (RAGAS) y criterios pedagógicos e interculturales validados por los especialistas, aplicable a otros proyectos de tecnología educativa en lenguas indígenas de bajos recursos del sur andino.

9.3. Impacto social

El desarrollo de un asistente educativo bilingüe offline beneficia potencialmente a docentes y estudiantes de comunidades quechuahablantes del sur andino peruano (Cusco y Puno), en un sistema EIB que atiende a más de 1,2 millones de estudiantes a nivel nacional (Ministerio de Educación del Perú, 2018) y en un contexto rural donde solo el 20,5 % de los hogares cuenta con acceso a internet (INEI, 2025). El **impacto inmediato** del proyecto consiste en entregar un prototipo funcional validado, una base de contenidos curriculares bilingües organizada y un corpus curado en Quechua Collao: recursos abiertos que docentes, investigadores y desarrolladores pueden reutilizar directamente. El **impacto potencial**, si el prototipo se adopta y escala, es triple: reducir la brecha digital educativa en zonas rurales sin exigir conectividad ni hardware costoso, fortalecer el uso de la lengua materna en contextos de aprendizaje formal, y apoyar los objetivos del modelo de servicio educativo intercultural bilingüe del Ministerio de Educación. Estos beneficios se alinean con los ODS 4 (Educación de calidad), 9 (Industria, innovación e infraestructura) y 10 (Reducción de las desigualdades) declarados en los aspectos generales de este plan.

10. Cronograma de actividades

El desarrollo de la tesis se planifica en un horizonte de doce meses a partir de la aprobación del plan. Las actividades se organizan en seis fases según la metodología Design Science Research.

Tabla 11
Cronograma de actividades por fases y meses

Actividad	1	2	3	4	5	6	7	8	9	10	11	12
Fase 1: Preparación y permisos												
Revisión de literatura y estado del arte	•	•										
Caracterización de requerimientos EIB	•	•										
Permisos institucionales y validación ética	•	•	•									
Fase 2: Diseño de la solución												
Diseño de la arquitectura híbrida <i>offline</i>		•	•									
Selección del modelo compacto base			•	•								
Fase 3: Recursos y corpus												
Curación, depuración y normalización de corpus			•	•	•							
Glosarios, diccionarios y base curricular				•	•							
Construcción del banco de consultas				•	•							
Fase 4: Implementación												
Cuantización y configuración local del modelo					•	•	•					
Módulo de detección e integración de RAG local						•	•	•				
Adaptación ligera QLoRA (condicionada)*								•	•			
Integración final del prototipo								•	•			
Fase 5: Evaluación												
Diseño de rúbricas y experimentos E1–E3									•			
Evaluación técnica y lingüística									•	•		
Validación con docente EIB y especialista lingüístico										•	•	
Análisis y procesamiento de resultados											•	
Fase 6: Documentación												
Redacción del informe de tesis										•	•	•
Revisión final con asesor y sustentación												•

**Nota: La adaptación QLoRA (Fase 4) se considera opcional y condicionada a la disponibilidad de recursos de cómputo y a la escala del corpus curricular validado.*

11. Presupuesto

El proyecto se ejecuta íntegramente con recursos propios de los investigadores. La laptop de desarrollo y pruebas es un recurso personal ya disponible. El cómputo puntual para cuantización y QLoRA se cubrirá con niveles gratuitos de Kaggle y Google Colab.

Tabla 12

Presupuesto estimado del proyecto

Rubro	Cantidad	Costo (S/)
Recursos tecnológicos		
Almacenamiento SSD 1 TB (modelos y corpus)	1	500,00
Recursos académicos		
Material bibliográfico y acceso a bases de datos	Global	300,00
Impresiones y empastados	Global	200,00
Otros		
Imprevistos (10 %)	Global	100,00
TOTAL		1 100,00

Bibliografía

- Chase, H. (2022). Langchain. <https://github.com/langchain-ai/langchain>.
- Chen, Z., Liu, J., Dong, R., and Mao, H. (2024). Queen: Leveraging rag and llm-based agents for quechua-english translation. In *Proceedings of the Conference on Machine Translation*. Disponible en: <https://aclanthology.org/2024.wmt-1.126/>.
- Court, S. and Elsner, M. (2024). Shortcomings of llms for low-resource translation: Retrieval and understanding are both the problem. In *Proceedings of the Conference on Machine Translation*. Disponible en: <https://aclanthology.org/2024.wmt-1.125/>.
- Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. (2023). Qlora: Efficient finetuning of quantized language models. *Advances in Neural Information Processing Systems*, 36. Disponible en: <https://arxiv.org/abs/2305.14314>.
- Dhawan, A., Kann, K., and Oncevay, A. (2026). Improving machine translation for indigenous languages of the americas with synthetic data and language-specific preprocessing. In *Proceedings of the Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*. DOI: <https://doi.org/10.18653/v1/2026.americasnlp-1>.
- Duran, M. and Silberztein, M. (2026). Semi-automatic construction of a quechua-spanish dictionary. In *Proceedings for the Ninth Workshop on Technologies for Machine Translation of Low Resource Languages*, pages 111–118. DOI: <https://doi.org/10.18653/v1/2026.loresmt-1.9>.
- Es, S., James, J., Espinosa-Anke, L., and Schockaert, S. (2024). Ragas: Automated evaluation of retrieval augmented generation. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2309.15217>.
- García, O. (2009). *Bilingual Education in the 21st Century: A Global Perspective*. Wiley-Blackwell, Malden, MA.
- Gerganov, G. (2024). llama.cpp: Inference of llama model in pure c/c++. <https://github.com/ggerganov/llama.cpp>.
- Hevia, J. S., Arredondo, F., and Kumar, V. (2025). Towards an efficient, customizable, and accessible ai tutor. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2510.06255>.
- INEI (2025). Estadísticas de las tecnologías de la información y comunicación en los hogares: Primer trimestre 2025. Technical report, Instituto Nacional de Estadística e Informática. Disponible en: <https://www.inei.gob.pe/>.
- Johnson, J., Douze, M., and Jégou, H. (2019). Billion-scale similarity search with gpus. *IEEE Transactions on Big Data*, 7(3):535–547.

- Levonian, Z., Henkel, O., Li, C., and Postle, M.-E. (2025). Designing safe and relevant generative chats for math learning in intelligent tutoring systems. *Journal of Educational Data Mining*, 17(1):66–97. DOI: <https://doi.org/10.5281/zenodo.14751365>.
- Li, Z., Wang, Z., Wang, W., Hung, K., Xie, H., and Wang, F. L. (2025). Retrieval-augmented generation for educational application: A systematic survey. *Computers and Education: Artificial Intelligence*. DOI: <https://doi.org/10.1016/j.caeai.2025.100417>.
- Ministerio de Educación del Perú (2016). Currículo nacional de la educación básica. Disponible en: <https://www.minedu.gob.pe/curriculo/>.
- Ministerio de Educación del Perú (2018). Modelo de servicio educativo intercultural bilingüe. Disponible en: <https://repositorio.minedu.gob.pe/handle/20.500.12799/5971>.
- Ollama Team (2024). Ollama: Run llama 3, mistral, gemma, and other large language models locally. <https://github.com/ollama/ollama>.
- Orcotoma Mormontoy, G. C., Leon Nuñez, L., and Espetia Huamanga, H. (2025). Towards the creation of a collao quechua-spanish parallel corpus using optical character recognition. In *Proceedings of the Workshop on Beyond English*. Disponible en: <https://aclanthology.org/2025.globalnlp-1.1/>.
- Ovadia, O., Brief, M., Mishaeli, M., and Sigal, O. (2024). Fine-tuning or retrieval? comparing knowledge injection in llms. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2312.05934>.
- Post, M. (2018). A call for clarity in reporting bleu scores. In *Proceedings of the Third Conference on Machine Translation: Research Papers*, pages 186–191. DOI: <https://doi.org/10.18653/v1/W18-6319>.
- Robertson, S. and Zaragoza, H. (2009). The probabilistic relevance framework: Bm25 and beyond. In *Information Retrieval*, volume 3, pages 333–380. Now Publishers.
- Sulla Torres, J. A., Cueva Medina, B., and Tuco Casquino, G. F. (2024). Development of a neural machine translation model optimized with bert for translation from quechua to spanish. In *LACCEI*. DOI: <https://doi.org/10.18687/LACCEI2024.1.1.1636>.
- Team Gemma (2024). Gemma 2: Improving open language models at a practical scale. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2408.00118>.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30. Disponible en: <https://arxiv.org/abs/1706.03762>.
- Vygotsky, L. S. (1978). *Mind in Society: The Development of Higher Psychological Processes*. Harvard University Press, Cambridge, MA.
- Walusimbi, J., Oguti, A. M., Ssentongo, J. B., and Ainebyona, K. (2026). Arapai: An offline-first ai chatbot architecture for low-connectivity educational environments. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2603.03339>.
- Wang, L., Yang, N., Huang, X., Yang, L., Jiang, D., Bhalerao, R., and Zhou, M. (2022). Text embeddings by weakly-supervised contrastive pre-training. *arXiv preprint arXiv:2212.03533*.

- Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., and Ling, Z. (2024). On-device language models: A comprehensive review. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2409.00088>.
- Yang, A., Yang, B., Hui, B., Zheng, B., Yu, B., Zhou, C., Li, C., Li, C., Liu, D., Huang, F., et al. (2024). Qwen2.5 technical report. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2412.15115>.
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., and Artzi, Y. (2019). Bertscore: Evaluating text generation with bert. In *International Conference on Learning Representations*. Disponible en: <https://arxiv.org/abs/1904.09675>.
- Zhang, T., Patil, S. G., Jain, N., Shen, S., Zaharia, M., Stoica, I., and Gonzalez, J. E. (2024). Raft: Adapting language model to domain specific rag. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2403.10131>.

Anexo: Fichas de Análisis

A continuación, se presentan las fichas de análisis de las nueve fuentes más relevantes para la investigación, las cuales sustentan críticamente el estado del arte y el marco conceptual del asistente propuesto. Cada ficha ha sido elaborada siguiendo la estructura metodológica exigida por la guía de trabajo del seminario.

Ficha 1: Orcotoma Mormontoy et al. (2025)

1. **REFERENCIA COMPLETA (APA 7):** Orcotoma Mormontoy, G. C., Leon Nuñez, L., & Espetia Huamanga, H. (2025). Towards the Creation of a Collao Quechua-Spanish Parallel Corpus Using Optical Character Recognition. *Proceedings of the Workshop on Beyond English*, 1-6. <https://doi.org/10.26615/978-954-452-105-9-001>
2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Construir un corpus paralelo Quechua Collao-español utilizando reconocimiento óptico de caracteres (OCR) para superar la escasez de recursos digitales en esta lengua de bajos recursos.
4. **METODOLOGÍA:** Enfoque tecnológico. Digitación y procesamiento (filtros de mediana y binarización) de libros de grado de la Academia Mayor de la Lengua Quechua, seguido de extracción de texto con Tesseract OCR y evaluación mediante Character Error Rate (CER) y Word Error Rate (WER) frente a un texto validado manualmente (ground truth).
5. **RESULTADOS PRINCIPALES:** Se construyó un corpus de 44 263 palabras (18 179 en quechua y 26 084 en español). La evaluación del OCR mostró un CER de 1,82 % y un WER de 6,59 %, demostrando la viabilidad de la extracción automática con posprocesamiento.
6. **CONCLUSIONES DEL AUTOR:** El uso de OCR es viable para crear corpus paralelos en Quechua Collao si se aplican métodos adecuados de preprocesamiento, lo que proporciona una metodología valiosa para preservar la lengua y entrenar futuras tecnologías NLP.
7. **LIMITACIONES DEL ESTUDIO:** El corpus resultante contiene cierto nivel de ruido ortográfico derivado del proceso OCR dado que no se implementó un posprocesamiento de corrección automática profunda, además de estar limitado en escala léxica (44 263 palabras) frente a lenguas mayoritarias.
8. **RELEVANCIA PARA MI TESIS:** Es un antecedente directo para la obtención de datos de entrenamiento y evaluación. Justifica la delimitación del proyecto al Quechua Collao al confirmar la existencia de recursos paralelos validados procedentes de la Academia Mayor de la Lengua Quechua.
9. **CITAS TEXTUALES ÚTILES:** “The importance of the result of this study lies in providing a methodology for the development of new technologies that require Collao Quechua-Spanish parallel corpora, such as automatic translators and sentence auto-completion systems” (p. 1).
10. **PALABRAS CLAVE ASIGNADAS:** Corpus paralelo, OCR, Quechua Collao, NLP de bajos recursos.

Ficha 2: Court & Elsner (2024)

1. **REFERENCIA COMPLETA (APA 7):** Court, S., & Elsner, M. (2024). Shortcomings of LLMs for Low-Resource Translation: Retrieval and Understanding Are Both the Problem. *Proceedings of the Ninth Conference on Machine Translation*, 1332-1354.
 2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica
 3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Investigar las habilidades de aprendizaje en contexto de Grandes Modelos de Lenguaje (LLMs) al traducir desde una lengua de bajos recursos (quechua sureño) hacia el español, utilizando información recuperada de diccionarios, gramáticas y corpus.
 4. **METODOLOGÍA:** Experimental cuantitativa. Se evaluó la salida de cuatro LLMs (GPT-3.5, GPT-4o, Gemini 1.5, Llama 3) bajo ocho condiciones de prompt que combinaban información de morfemas, gramática y ejemplos de corpus, usando métricas automáticas (BLEURT, BLEU) y anotación humana de errores.
 5. **RESULTADOS PRINCIPALES:** La inclusión de traducciones a nivel de morfema mejora el rendimiento de los modelos más pequeños. Sin embargo, en modelos más avanzados (GPT-4o), añadir contexto gramatical o de corpus reduce los puntajes BLEURT y aumenta la divergencia gramatical.
 6. **CONCLUSIONES DEL AUTOR:** Incluso explicaciones gramaticales relevantes ayudan poco a las generaciones más recientes de LLMs en tareas de bajos recursos. Las traducciones infieles suelen ser engañosamente fluidas en español, y en ocasiones introducen estereotipos culturales no presentes en la frase original.
 7. **LIMITACIONES DEL ESTUDIO:** La evaluación se restringió al uso de APIs comerciales basadas en la nube bajo esquemas de prompting (in-context learning), sin analizar el rendimiento de modelos compactos locales (SLM) cuantizados ni restricciones de latencia offline.
 8. **RELEVANCIA PARA MI TESIS:** Demuestra que no basta con usar la técnica RAG para inyectar reglas gramaticales en un modelo genérico. Justifica la necesidad de afinar o cuantizar un Small Language Model especializado en lugar de depender únicamente del aprendizaje en contexto de un modelo en la nube.
 9. **CITAS TEXTUALES ÚTILES:** “providing additional information in the prompt’s context actually degrades GPT-4o’s ability to translate from S. Quechua to Spanish in all experimental conditions” (p. 7).
 10. **PALABRAS CLAVE ASIGNADAS:** LLMs, Quechua sureño, RAG, traducción automática, aprendizaje en contexto.
-

Ficha 3: Walusimbi et al. (2026)

1. **REFERENCIA COMPLETA (APA 7):** Walusimbi, J., Oguti, A. M., Ssentongo, J. B., & Ainebyona, K. (2026). Arapai: An Offline-First AI Chatbot Architecture for Low-Connectivity Educational Environments. *arXiv preprint arXiv:2603.03339*.
 2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)
 3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Diseñar y evaluar una arquitectura de LLM orientada a operar sin conexión a internet (offline-first) para asistencia educativa en entornos con baja conectividad.
 4. **METODOLOGÍA:** Investigación aplicada. Se implementaron modelos cuantizados (TinyLlama, Qwen2.5-3B, Mistral-7B) ejecutados localmente en CPU. El sistema adaptativo fue evaluado cualitativa y cuantitativamente con 120 estudiantes y 9 docentes en condiciones reales.
 5. **RESULTADOS PRINCIPALES:** El sistema operó de forma estable en hardware heredado (CPU). Las consultas instructivas típicas mostraron latencias de respuesta de 1 a 3 segundos. Los usuarios reportaron una alta utilidad para el aprendizaje autodirigido a diferentes niveles de complejidad.
 6. **CONCLUSIONES DEL AUTOR:** Es viable desplegar asistentes educativos basados en IA en contextos con limitaciones de infraestructura utilizando LLMs cuantizados que se ejecutan localmente, ofreciendo una alternativa confiable a los sistemas que dependen de la nube.
 7. **LIMITACIONES DEL ESTUDIO:** El prototipo fue evaluado exclusivamente con contenido bilingüe en inglés, por lo que el estudio no aborda las particularidades de tokenización, morfología aglutinante ni la variabilidad dialectal de lenguas indígenas.
 8. **RELEVANCIA PARA MI TESIS:** Es el principal antecedente arquitectónico. Valida la hipótesis de que los modelos cuantizados ejecutados en CPU son suficientemente rápidos y útiles para aplicaciones educativas offline en zonas rurales.
 9. **CITAS TEXTUALES ÚTILES:** “The system performs all inference locally using quantized language models and incorporates hardware-aware model selection to enable deployment on low-specification, CPU-only devices” (p. 1).
 10. **PALABRAS CLAVE ASIGNADAS:** Arquitectura offline-first, IA educativa, modelos cuantizados, edge AI.
-

Ficha 4: Xu et al. (2024)

1. **REFERENCIA COMPLETA (APA 7):** Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., & Ling, Z. (2024). On-Device Language Models: A Comprehensive Review. *arXiv preprint arXiv:2409.00088*.
2. **TIPO DE DOCUMENTO:** Artículo de revisión (Survey)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Examinar los desafíos de desplegar LLMs computacionalmente costosos en dispositivos con recursos limitados y explorar las soluciones innovadoras en múltiples dominios.

4. **METODOLOGÍA:** Revisión sistemática de literatura sobre arquitecturas eficientes de modelos de lenguaje en dispositivos (on-device), analizando técnicas de compresión de modelos, aceleración de hardware y despliegue colaborativo borde-nube.
 5. **RESULTADOS PRINCIPALES:** Se identifican tres estrategias clave para habilitar modelos en dispositivos: compartición de parámetros, cuantización (PTQ y QAT) para reducir bits de peso/activación, y destilación de conocimiento. La cuantización int4/int8 resulta esencial para procesadores móviles.
 6. **CONCLUSIONES DEL AUTOR:** La transición de la nube al borde (edge) reduce latencia y aumenta privacidad, pero requiere un equilibrio delicado entre el rendimiento del modelo (precisión) y la utilización de recursos (memoria y energía) que solo se logra combinando múltiples técnicas de compresión.
 7. **LIMITACIONES DEL ESTUDIO:** Al ser un artículo de revisión general (survey), carece de una propuesta arquitectónica propia o experimentación de campo aplicada al procesamiento de lenguas minoritarias y aglutinantes.
 8. **RELEVANCIA PARA MI TESIS:** Proporciona el marco teórico tecnológico sobre Small Language Models y cuantización que fundamenta el diseño del asistente educativo para hardware de bajo costo.
 9. **CITAS TEXTUALES ÚTILES:** “deploying computationally expensive LLMs on resource-constrained devices poses significant challenges. The primary obstacles include limited computational power, reduced memory capacity, and energy constraints” (p. 2).
 10. **PALABRAS CLAVE ASIGNADAS:** On-Device AI, cuantización, compresión de modelos, Small Language Models.
-

Ficha 5: Hevia et al. (2025)

1. **REFERENCIA COMPLETA (APA 7):** Hevia, J. S., Arredondo, F., & Kumar, V. (2025). Towards an Efficient, Customizable, and Accessible AI Tutor. *arXiv preprint arXiv:2510.06255*.
2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Proponer un sistema tutorial de IA fuera de línea (offline) basado en Generación Aumentada por Recuperación (RAG) emparejado con un Small Language Model (SLM) para entornos de bajos recursos.
4. **METODOLOGÍA:** Experimental cuantitativa. Evaluación de modelos de la familia SmolLM (135M y 1.7B) y RAG con libros de texto de biología de OpenStax usando métricas del benchmark MMLU para evaluar el impacto del contexto en la precisión de respuesta.
5. **RESULTADOS PRINCIPALES:** Contrario a lo esperado, la inclusión de recuperación RAG en SLMs disminuyó drásticamente la precisión en el MMLU para el modelo SmolLM2-1,7B (de 41,00 % a 33,04 % con RAG), mientras que los modelos de 135M solo mostraron una variación mínima marginal (de 21,59 % a 21,81 % con RAG en SmolLM2-135M), lo que evidencia la incapacidad de estos modelos pequeños para manejar ventanas de contexto extendidas y ruidosas.

6. **CONCLUSIONES DEL AUTOR:** Los Small Language Models luchan por aprovechar efectivamente el contexto extendido provisto por RAG, especialmente si los fragmentos contienen información irrelevante. Es crítico usar técnicas avanzadas de “*chunking*” (fragmentación semántica) y métricas de evaluación holísticas más allá de opciones múltiples.
 7. **LIMITACIONES DEL ESTUDIO:** La fragmentación (chunking) documental fue simplista (corte de tokens estático), introduciendo ruido, y la evaluación de precisión se restringió al benchmark de opciones múltiples MMLU, sin examinar respuestas de texto libre.
 8. **RELEVANCIA PARA MI TESIS:** Alerta sobre los riesgos de usar arquitectura RAG simple con SLMs en el diseño del asistente EIB. Justifica la necesidad de un preprocesamiento cuidadoso de los contenidos curriculares y glosarios locales para evitar introducir ruido en la consulta.
 9. **CITAS TEXTUALES ÚTILES:** “smaller models, such as SmolLM, struggle to effectively leverage extended contexts provided by the RAG pipeline, particularly when noisy or irrelevant chunks are included” (p. 1).
 10. **PALABRAS CLAVE ASIGNADAS:** RAG, AI Tutor, Small Language Model, educación fuera de línea.
-

Ficha 6: Chen et al. (2024)

1. **REFERENCIA COMPLETA (APA 7):** Chen, Z., Liu, J., Dong, R., & Mao, H. (2024). QueEn: Leveraging RAG and LLM-Based Agents for Quechua-English Translation. *Proceedings of the Conference on Machine Translation*. <https://aclanthology.org/2024.wmt-1.126/>
2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Mejorar la traducción automática quechua-inglés mediante un sistema multi-agente que combina RAG sobre recursos lingüísticos con adaptación paramétrica ligera (LoRA).
4. **METODOLOGÍA:** Experimental cuantitativa. Implementación de un pipeline multi-agente que integra recuperación de diccionarios y reglas gramaticales con ajuste LoRA sobre un modelo base. Evaluación con BLEU y chrF++ sobre conjuntos de prueba estándar de WMT.
5. **RESULTADOS PRINCIPALES:** La hibridación de RAG con LoRA elevó el puntaje BLEU de 1,5 (línea base sin contexto) a 17,6, demostrando que la combinación de RAG con adaptación paramétrica ligera produce mejoras significativas para lenguas de bajos recursos.
6. **CONCLUSIONES DEL AUTOR:** La combinación de agentes RAG especializados con ajuste paramétrico ligero supera significativamente tanto al prompting directo como al RAG puro para traducción de lenguas de bajos recursos como el quechua.

- 7. LIMITACIONES DEL ESTUDIO:** Se enfoca en un sistema puramente orientado a la traducción de oraciones quechua-inglés en un canal online, sin abordar el andamiaje pedagógico bilingüe interactivo ni la optimización para hardware offline local.
 - 8. RELEVANCIA PARA MI TESIS:** Es el antecedente más directo del enfoque híbrido propuesto. Valida empíricamente que la arquitectura RAG + LoRA es la vía más prometedora para el quechua, fundamentando la decisión de combinar RAG disciplinado con QLoRA en el asistente EIB.
 - 9. CITAS TEXTUALES ÚTILES:** “Our system integrates dictionary-based retrieval, grammar rule application, and fine-tuned translation models to handle the morphological complexity of Quechua” (p. 1).
 - 10. PALABRAS CLAVE ASIGNADAS:** RAG, LoRA, quechua, traducción automática, sistema multi-agente.
-

Ficha 7: Zhang et al. (2024)

- 1. REFERENCIA COMPLETA (APA 7):** Zhang, T., Patil, S. G., Jain, N., Shen, S., Zaharia, M., Stoica, I., & Gonzalez, J. E. (2024). RAFT: Adapting Language Model to Domain Specific RAG. *arXiv preprint arXiv:2403.10131*.
- 2. TIPO DE DOCUMENTO:** Artículo científico (Preprint)
- 3. OBJETIVO O PREGUNTA DEL ESTUDIO:** Proponer un método de ajuste fino que enseña a los modelos de lenguaje a usar el contexto RAG de forma resiliente, distinguiendo fragmentos relevantes de distractores.
- 4. METODOLOGÍA:** Experimental cuantitativa. Entrenamiento de modelos con datasets que incluyen documentos relevantes mezclados con distractores, evaluando la capacidad del modelo para generar respuestas ancladas únicamente en la evidencia pertinente.
- 5. RESULTADOS PRINCIPALES:** RAFT mejoró consistentemente el rendimiento en benchmarks de dominio específico frente a tanto RAG puro como fine-tuning sin contexto, demostrando que entrenar al modelo a “ignorar distractores” es tan importante como entrenarlo a “usar contexto”.
- 6. CONCLUSIONES DEL AUTOR:** La combinación de fine-tuning con entrenamiento en presencia de distractores produce modelos más robustos para aplicaciones RAG de dominio específico.
- 7. LIMITACIONES DEL ESTUDIO:** El método exige realizar un ajuste fino supervisado completo (SFT) sobre los pesos del modelo, lo que implica requerimientos de cómputo elevados (múltiples GPUs comerciales de alta gama) inviables para despliegues locales sencillos.
- 8. RELEVANCIA PARA MI TESIS:** Fundamenta teóricamente la capa de adaptación ligera del enfoque híbrido: el QLoRA del asistente EIB debe enseñar al modelo no solo a responder pedagógicamente, sino a distinguir fragmentos dialectalmente correctos (Collao) de distractores (Cusqueño, Chanka).

9. **CITAS TEXTUALES ÚTILES:** “RAFT learns to ignore distractor documents and cite the relevant sequence from the oracle document to generate the answer” (p. 3).
 10. **PALABRAS CLAVE ASIGNADAS:** RAFT, RAG, fine-tuning, distractores, adaptación de dominio.
-

Ficha 8: Sulla-Torres et al. (2024)

1. **REFERENCIA COMPLETA (APA 7):** Sulla Torres, J. A., Cueva Medina, B., & Tuco Casquino, G. F. (2024). Development of a Neural Machine Translation Model Optimized with BERT for Translation from Quechua to Spanish. *LACCEI*, 1-10.
 2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica
 3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Optimizar la traducción automática neuronal del quechua al español utilizando un modelo neural optimizado mediante codificadores semánticos (BERT).
 4. **METODOLOGÍA:** Enfoque neuronal profundo. Se realizó un ajuste fino de un codificador bilingüe BERT sobre un corpus estructurado quechua-español y se evaluó su desempeño mediante métricas estándar de traducción automática (BLEU).
 5. **RESULTADOS PRINCIPALES:** Se obtuvo un puntaje BLEU de 20,13 para la dirección quechua a español, considerado aceptable pero evidenciando las limitaciones impuestas por la escasez de pares de oraciones paralelas.
 6. **CONCLUSIONES DEL AUTOR:** El uso de arquitecturas basadas en BERT es viable para tareas de procesamiento morfosintáctico de lenguas indígenas, pero los resultados están condicionados críticamente por el volumen y representatividad del corpus.
 7. **LIMITACIONES DEL ESTUDIO:** El modelo requiere un corpus paralelo grande y balanceado para el entrenamiento de los pesos, no contempla el translenguaje dinámico y posee requerimientos de procesamiento medios en hardware CPU.
 8. **RELEVANCIA PARA MI TESIS:** Es el principal antecedente empírico de traducción neuronal quechua-español. Valida la hipótesis de que las técnicas basadas únicamente en traducción automática pura sufren ante la escasez de datos, lo que justifica la adopción de un enfoque híbrido de SLM + RAG.
 9. **CITAS TEXTUALES ÚTILES:** “The model optimized with BERT reached a BLEU score of 20.13, showing that deep learning architectures are viable for low-resource languages but are highly constrained by the available vocabulary size” (p. 5).
 10. **PALABRAS CLAVE ASIGNADAS:** Traducción automática neuronal, BERT, quechua, escasez de datos.
-

Ficha 9: Duran & Silberztein (2026)

1. **REFERENCIA COMPLETA (APA 7):** Duran, M., & Silberztein, M. (2026). Semi-automatic Construction of a Quechua-Spanish Dictionary. *Proceedings for the Ninth Workshop on Technologies for Machine Translation of Low Resource Languages*, 111-118.
2. **TIPO DE DOCUMENTO:** Artículo de taller científico (Workshop)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Proponer un método semi-automático para la construcción de diccionarios quechua-español utilizando formalismos lingüísticos estructurados.
4. **METODOLOGÍA:** Aplicación de reglas y formalismos de procesamiento léxico en la plataforma NooJ para procesar textos, aislar raíces de sufijos flexivos y generar correspondencias bilingües.
5. **RESULTADOS PRINCIPALES:** Se construyó un diccionario léxico estructurado de alta precisión que normaliza variaciones ortográficas y dialectales de las raíces quechua sureñas.
6. **CONCLUSIONES DEL AUTOR:** El uso de formalismos y diccionarios estructurados por reglas es fundamental para el procesamiento de lenguas morfológicamente complejas, mitigando la variabilidad de escritura y la escasez de corpus paralelos.
7. **LIMITACIONES DEL ESTUDIO:** Depende del trabajo manual especializado de expertos lingüistas para estructurar y validar las reglas morfológicas, dificultando su expansión y actualización rápida.
8. **RELEVANCIA PARA MI TESIS:** Proporciona el sustento metodológico para incorporar diccionarios locales y reglas de normalización ortográfica en el preprocesamiento del asistente, mitigando errores derivados de variaciones ortográficas de los estudiantes en la consulta.
9. **CITAS TEXTUALES ÚTILES:** “Semi-automatic construction of lexicons allows the structuring of rules that handle the morphosyntactic complexity of Quechua, mitigating spelling variations” (p. 2).
10. **PALABRAS CLAVE ASIGNADAS:** Diccionario bilingüe, formalismo lingüístico, NooJ, normalización morfológica.