UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO
FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA
ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

Diseño e implementación de una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao

Curso:
Seminario de Investigación II

Docente:
Msc. Raúl Huillca Huallparimachi

Para optar al Título Profesional de:
Ingeniero Informático y de Sistemas

Presentado por:
Br. Edmil Jampier Saire Bustamante

Cusco – Perú
2026

Resumen

La presente propuesta de investigación aborda el desafío del procesamiento de lenguaje natural en lenguas originarias de bajos recursos digitales y morfología aglutinante, focalizándose en el Quechua Collao en entornos sin conectividad. El problema radica en que los modelos de lenguaje compactos (SLMs) desplegados de forma local presentan fallas de utilización de contexto y alucinaciones factuales cuando se les acopla un sistema estándar de generación aumentada por recuperación (RAG). Para mitigar esta limitación, la investigación plantea diseñar, implementar y evaluar una arquitectura SLM–RAG offline potenciada mediante adaptadores ligeros (QLoRA) acoplados al modelo cuantizado, optimizando la asimilación y anclaje factual de la información recuperada localmente. La base documental bilingüe es estructurada y validada mediante filtros léxico-dialectales rigurosos contra corpus de referencia. La evaluación se realiza de forma estrictamente computacional y reproducible mediante métricas de rendimiento (latencia y memoria en hardware de bajo costo), calidad lingüística (chrF++, SacreBLEU) y fidelidad factual de recuperación (métricas Ragas).
Palabras clave: Modelos de lenguaje compactos, generación aumentada por recuperación, Quechua Collao, QLoRA, adaptadores de bajo rango, inferencia offline.

Índice general

Resumen II
Índice general III
Índice de figuras V
Índice de tablas VI
Índice de algoritmos VII
Lista de abreviaturas VIII
Lista de símbolos IX
Índice de ecuaciones X
Índice de anexos XI
Glosario de términos XII
1. Aspectos Generales de la Investigación 1
   1.1. Introducción 1
   1.2. Problema de Investigación 1
   1.3. Objetivos de la Investigación 3
   1.4. Hipótesis de la Investigación 4
   1.5. Justificación de la Investigación 4
   1.6. Alcances y Limitaciones 5
   1.7. Matriz de Consistencia Metodológica 6
2. Estado del arte 8
   2.1. Procesamiento de Lenguaje Natural y Recursos para Quechua Collao 8
   2.2. Small Language Models y Despliegue Offline On-Device 9
   2.3. Generación Aumentada por Recuperación (RAG) y Cuello de Botella de Contexto 9
   2.4. RAG vs. Fine-Tuning y Adaptación Eficiente (PEFT/QLoRA) 9
   2.5. Matriz resumida de antecedentes 10
   2.6. Síntesis crítica y vacíos de investigación 11
3. Marco Teórico y Conceptual 13
   3.1. Procesamiento de Lenguaje Natural en Lenguas de Bajos Recursos . . 13
   3.2. Quechua Collao: caracterización morfológica computacional 13
   3.3. Alternancia de códigos y bilingüismo computacional 13
   3.4. Cuello de botella de la tokenización en transformadores 14
   3.5. Modelos de Lenguaje Compactos (SLMs) y Cuantización 14
   3.6. Adaptación Eficiente de Modelos: LoRA y QLoRA 15
   3.7. Mecanismos de Atención y Adaptación con QLoRA para RAG 16
   3.8. Generación Aumentada por Recuperación (RAG) Local 16
   3.9. Marco de Evaluación Computacional Automatizada 18
   3.10. Síntesis integradora del marco teórico 19
4. Metodología 20
   4.1. Tipo y diseño de investigación 20
   4.2. Metodología de desarrollo: Design Science Research (DSR) 22
   4.3. Unidades de análisis y banco de evaluación 23

4.4. Consideraciones éticas 23
5. Estudio de Factibilidad 24
5.1. Enfoque híbrido adoptado 24
5.2. Factibilidad técnica 24
5.3. Factibilidad legal y de licencias 27
5.4. Factibilidad operativa y gestión del alcance 27
5.5. Estructuración de la base de conocimiento y metadatos 28
5.6. Diseño experimental 28
5.7. Semáforo de riesgo 30
5.8. Conclusión de viabilidad 30
6. Aspectos Administrativos 31
6.1. Viabilidad y sostenibilidad del proyecto 31
6.2. Cronograma de actividades (DSR) 31
6.3. Estructura tentativa del informe de tesis 33
Bibliografía 35
Anexos 37

Índice de figuras

1. Árbol de problemas: causas tecnológicas (naranja, tríada PE1–PE3) y efectos computacionales (rojo) 2
2. Árbol de objetivos: medios de ingeniería (teal, fases específicas) y fines de impacto (verde, alineación ODS) 4
3. Taxonomía de las investigaciones previas por dominio tecnológico 8
4. Esquema de adaptación de bajo rango (QLoRA): descomposición sobre pesos base cuantizados a 4 bits 15
5. Pipeline computacional de la arquitectura SLM–RAG con adaptadores QLoRA local offline 17
6. Ciclo de las seis fases del *Design Science Research* (DSR) aplicado a la ingeniería del artefacto 22
7. Arquitectura de software modular para inferencia local offline 27
8. Pipeline del diseño experimental y protocolo de evaluación computacional (E1–E3) 29
9. Diagrama de Gantt del cronograma de actividades por fases DSR (6 Meses) . 32

Índice de tablas

1. Matriz de consistencia metodológica del proyecto de tesis 7
2. Comparación de estrategias computacionales de inyección de conocimiento . 10
3. Matriz resumida de antecedentes tecnológicos del estado del arte 11
4. Modelos de lenguaje compactos candidatos para inferencia offline 15
5. Matriz de operacionalización de variables computacionales 21
6. Matriz comparativa de enfoques para la decisión metodológica 24
7. Flujo y particionamiento de datos del proyecto 25
8. Inventario de fuentes de datos, repositorios y modelos del proyecto 26
9. Riesgos computacionales y estrategias de mitigación 27
10. Configuraciones del diseño experimental 28
11. Métricas de evaluación computacional del proyecto 29
12. Semáforo de riesgo técnico y operativo 30
13. Cronograma de actividades por fases DSR y períodos calendario (6 Meses, 2026–2027) 33

Índice de algoritmos

1. Pipeline de inferencia local offline SLM–RAG con adaptadores QLoRA . . . 18

Lista de abreviaturas

Abreviatura / Sigla	Significado y Descripción Técnica
AMLQ	Academia Mayor de la Lengua Quechua (Cusco, Perú).
BLEU	*Bilingual Evaluation Understudy* (métrica de concordancia de n-gramas léxicos).
chrF++	*Character n-gram F-score with word n-grams* (métrica estándar para morfología aglutinante).
CPU	*Central Processing Unit* (unidad central de procesamiento).
DSR	*Design Science Research* (marco metodológico de investigación en ciencias del diseño).
EIB	Educación Intercultural Bilingüe.
FAISS	*Facebook AI Similarity Search* (biblioteca de búsqueda vectorial densa eficiente).
GGUF	*GPT-Generated Unified Format* (formato binario para cuantización e inferencia local eficiente).
GPU	*Graphics Processing Unit* (unidad de procesamiento gráfico acelerado).
HE	Hipótesis Específica (HE1, HE2, HE3).
HG	Hipótesis General de la investigación.
LLM	*Large Language Model* (modelo de lenguaje de gran escala, $>$ 7B parámetros).
LoRA	*Low-Rank Adaptation* (técnica de adaptación mediante descomposición de bajo rango).
NF4	*NormalFloat 4-bit* (tipo de dato no linealmente espaciado óptimo para cuantización de pesos).
ODS	Objetivos de Desarrollo Sostenible de las Naciones Unidas (ODS 9 y ODS 10).
OE	Objetivo Específico (OE1, OE2, OE3).
OG	Objetivo General de la investigación.
PE	Problema Específico (PE1, PE2, PE3).
PEFT	*Parameter-Efficient Fine-Tuning* (ajuste fino eficiente en parámetros).
PG	Problema General de la investigación.
PLN	Procesamiento de Lenguaje Natural (equivalente a NLP en inglés).
PPL	Perplejidad (*Perplexity*, métrica intrínseca de incertidumbre probabilística).
PTQ	*Post-Training Quantization* (cuantización post-entrenamiento de pesos).
QLoRA	*Quantized Low-Rank Adaptation* (adaptadores de bajo rango sobre pesos base en 4 bits).
RAG	*Retrieval-Augmented Generation* (generación aumentada por recuperación).
RAFT	*Retrieval-Augmented Fine-Tuning* (ajuste fino aumentado por recuperación).
RAM	*Random Access Memory* (memoria principal del sistema).
SLM	*Small Language Model* (modelo de lenguaje compacto, $\leq$ 3B parámetros).
TPS	*Tokens Per Second* (rendimiento de generación de tokens por segundo).
VRAM	*Video Random Access Memory* (memoria gráfica de video dedicada).
WER	*Word Error Rate* (tasa de error de palabra en reconocimiento de texto/OCR).

Lista de símbolos

Símbolo / Notación	Definición y Rol Computacional
W_0	Matriz de pesos preentrenada original del SLM congelada en 4 bits ($W_0 \in \mathbb{R}^{d\times k}$).
ΔW	Matriz de actualización adaptativa acumulada sobre los pesos del modelo ($\Delta W \in \mathbb{R}^{d\times k}$).
A	Matriz de proyección de bajo rango inicializada de forma gaussiana ($A \in \mathbb{R}^{r\times k}$).
B	Matriz de proyección de bajo rango inicializada en ceros ($B \in \mathbb{R}^{d\times r}$).
r	Rango intrínseco de los adaptadores LoRA ($r \ll \text{mín}(d, k)$, fijado empíricamente en $r = 16$).
α	Factor constante de escalamiento para la actualización LoRA ($\alpha = 32$).
x	Vector de activación de entrada a la capa Transformer (tokens de consulta + contexto RAG).
h	Vector de activación adaptado de salida: $h = W_0x + \frac{\alpha}{r}(B \cdot A)x$.
Q, K, V	Matrices de Consulta (*Query*), Clave (*Key*) y Valor (*Value*) en las capas de autoatención.
W_q, W_k, W_v, W_o	Matrices de proyección lineal de los cabezales de atención objetivo del ajuste fino QLoRA.
d_k	Dimensión de escalamiento de los vectores de clave en el producto escalar de autoatención.
$\mathbf{e}_q$	Vector de incrustación denso (*embedding*) de la consulta formulada por el usuario.
$\mathbf{e}_d$	Vector de incrustación denso del fragmento documental indexado en la base de conocimiento.
$\text{sim}(q, d)$	Similitud del coseno normalizada entre los vectores de consulta y fragmento documental.
$\mathcal{D}$	Colección curada de fragmentos documentales bilingües indexados en la base vectorial local.
$\mathcal{C}_k$	Conjunto de los k fragmentos documentales de mayor afinidad semántica recuperados.
P_{aug}	Secuencia de tokens del prompt estructurado aumentado (instrucción + contexto + consulta).
PPL	Perplejidad intrínseca calculada sobre el conjunto de evaluación en Quechua Collao.

Índice de ecuaciones

Ecuación	Descripción Matemática y Teórica	Página
Ecuación (1)	Descomposición de bajo rango para adaptación eficiente de pesos (LoRA / QLoRA)	15
Ecuación (2)	Proyecciones lineales de Consulta (Q), Clave (K) y Valor (V) en capas Transformer	15
Ecuación (3)	Mecanismo de autoatención con producto escalar escalado (*Scaled Dot-Product Attention*)	15
Ecuación (4)	Proyección lineal de salida multicabezal del bloque de atención Transformer	15
Ecuación (5)	Métrica de similitud del coseno para recuperación densa de fragmentos documentales	17

Índice de anexos

Identificador	Título y Contenido del Anexo	Página
Anexo A	Fichas de análisis y extracción crítica de antecedentes científicos (Fichas 1 a 6)	37
Anexo B	Matriz de consistencia metodológica del proyecto de tesis (Problemas, Objetivos, Hipótesis)	7
Anexo C	Banco de 100 consultas patrón de prueba con contexto de referencia (*ground-truth*)	29

Glosario de términos

Aglutinación: Propiedad morfológica del Quechua Collao donde las palabras se componen de una raíz léxica invariable a la cual se concatenan múltiples sufijos ordenados jerárquicamente, condensando funciones sintácticas extensas en vocablos individuales.

Alucinación semántica: Fenómeno en el cual un modelo de lenguaje generativo produce afirmaciones gramaticalmente fluidas pero fácticamente erróneas, no sustentadas en los datos de entrada o contrarias a la realidad empírica.

Cuantización (GGUF / NF4): Técnica de compresión numérica post-entrenamiento que reduce la precisión de los pesos de la red neuronal (de punto flotante de 16 bits a enteros o cuantizaciones no lineales de 4 bits), disminuyendo drásticamente el uso de memoria RAM/VRAM con mínima pérdida de perplejidad.

Design Science Research (DSR): Marco metodológico riguroso de ingeniería en informática y sistemas orientado a la creación iterativa y evaluación formal de artefactos tecnológicos diseñados para solucionar problemas prácticos específicos.

Dispersión atencional (*Attention Dispersion*): Incapacidad observada en modelos compactos no adaptados para concentrar la masa de probabilidad de autoatención sobre los fragmentos documentales relevantes inyectados por el RAG, provocando la omisión del contexto.

Fidelidad factual (*Faithfulness*): Métrica computacional objetiva (del marco Ragas) que cuantifica la proporción de afirmaciones generadas por el modelo que pueden derivarse e inferirse lógicamente a partir del contexto recuperado.

Generación Aumentada por Recuperación (RAG): Arquitectura computacional que complementa la generación de un modelo de lenguaje vinculándolo a un almacén documental externo dinámico mediante búsqueda vectorial por similitud semántica.

Inferencia local *on-device*: Ejecución autónoma y desatendida de un modelo de aprendizaje profundo directamente en el hardware del usuario final (CPU o GPU modesta) sin requerir transmisión de datos ni llamadas a APIs en la nube.

NormalFloat4 (NF4): Tipo de cuantización no lineal estadísticamente óptimo para pesos de redes neuronales distribuidos normalmente con media cero, base fundamental del método QLoRA.

QLoRA (*Quantized Low-Rank Adaptation*): Método de ajuste fino eficiente que congela el modelo base cuantizado en 4 bits e inyecta pares de matrices entrenables de bajo rango (A y B) en las capas de atención, reduciendo en más del 80 % el consumo de VRAM.

Quechua Collao: Variante dialectal de la familia Quechua Sureño hablada en las regiones de Cusco y Puno, caracterizada por un inventario fonológico con oclusivas simples, glotizadas y aspiradas, y una ortografía oficial normalizada por el Ministerio de Educación del Perú.

Small Language Model (SLM): Modelo de lenguaje compacto con una escala paramétrica inferior o igual a 3 mil millones de parámetros ($\leq$ 3B), diseñado para ofrecer inferencia interactiva sobre computadoras personales o dispositivos de borde.

1. Aspectos Generales de la Investigación

1.1. Introducción

El vertiginoso desarrollo del procesamiento de lenguaje natural (PLN) y de los modelos fundacionales basados en la arquitectura Transformer ha transformado la interacción hombre–máquina a escala global. No obstante, este avance técnico ha beneficiado primordialmente a lenguas de alta disponibilidad de datos digitales (como el inglés y el español), consolidando una profunda asimetría tecnológica respecto a las lenguas originarias de bajos recursos computacionales. En el contexto peruano, el Quechua Collao (variedad predominante en los departamentos de Cusco y Puno) carece de herramientas modernas de generación de lenguaje fidedignas y adaptadas a sus particularidades morfosintácticas aglutinantes.

A esta brecha digital se añade un condicionamiento de infraestructura crítico: un porcentaje sustantivo de las comunidades andinas quechuahablantes habita en zonas con conectividad a internet inexistente o intermitente, lo que invalida el empleo de servicios comerciales de inteligencia artificial en la nube. Esta realidad exige el desarrollo de soluciones computacionales autónomas que operen en modo estrictamente local (*on-device*) sobre equipos de cómputo convencionales y de presupuesto accesible ($\leq$ 4 GB de VRAM o ejecución en CPU).

La conjunción de Modelos de Lenguaje Pequeños (SLMs, $\leq$ 3 mil millones de parámetros cuantizados a 4 bits) y sistemas de Generación Aumentada por Recuperación (RAG local) emerge como la respuesta técnica más viable para almacenar conocimiento documental fuera de los pesos del modelo. Sin embargo, los modelos compactos estándar sufren de un cuello de botella intrínseco al asimilar contexto externo (*context utilization bottleneck*): su limitada capacidad atencional no logra focalizar los morfemas quechuas pertinentes, induciendo alucinaciones factuales o forzando la respuesta hacia el español. Frente a este desafío, la presente investigación propone, implementa y evalúa una arquitectura de ingeniería que acopla adaptadores de ajuste fino de bajo rango (QLoRA) en las capas de atención del SLM cuantizado para condicionar y maximizar la asimilación del contexto RAG en Quechua Collao dentro de un entorno computacional 100 % offline.

1.2. Problema de Investigación

Descripción del problema

El procesamiento de lenguaje natural (PLN) para lenguas originarias de bajos recursos digitales enfrenta una severa brecha tecnológica en entornos sin conectividad digital. En regiones del sur andino peruano como Cusco y Puno, la lengua originaria predominante es el Quechua Collao. Esta variedad lingüística impone desafíos complejos para los sistemas computacionales modernos: su estructura morfológica aglutinante y sufijadora genera palabras de alta densidad semántica y una tasa de fertilidad de tokens estimada en $\approx$3,4 veces superior respecto al español, penalizando severamente el consumo de memoria y la latencia en arquitecturas basadas en Transformers.

Por otro lado, aunque los modelos de lenguaje de gran escala (LLMs) comerciales en la nube han alcanzado altos niveles de fluidez, son inviables para despliegues locales y aislados debido a tres limitaciones estructurales: (a) dependen estrictamente de conexión permanente a internet para interactuar con servidores remotos, (b) carecen de representación factual y dialectal adecuada para el Quechua Collao, propiciando alucinaciones severas, y (c) presentan un alto costo de cómputo inalcanzable para hardware convencional.

La alternativa técnica radica en el uso de Modelos de Lenguaje Pequeños (SLMs, $\leq$ 3 mil millones de parámetros) cuantizados a 4 bits ejecutados de forma local (*on-device*). Sin embargo, los SLMs presentan una capacidad de memoria paramétrica intrínseca muy

limitada para almacenar conocimiento factual en lenguas de bajos recursos. Al acoplarles un sistema estándar de Generación Aumentada por Recuperación (RAG, *Retrieval-Augmented Generation*) para inyectar información externa sin reentrenar todo el modelo, surge un cuello de botella crítico de ingeniería: los SLMs convencionales exhiben fallas sistemáticas en la atención y utilización del contexto recuperado (*context utilization bottleneck*), resultando en alucinaciones, respuestas truncadas o desvío no deseado hacia el español.

Entrenar un modelo desde cero o realizar un ajuste fino completo (*Full Fine-Tuning*) resulta contraproducente y técnicamente inviable ante la escasez de corpus paralelos masivos en Quechua Collao, acarreando riesgos de sobreajuste y olvido catastrófico. En consecuencia, existe una brecha técnica abierta en la ingeniería de inteligencia artificial: la necesidad de una arquitectura SLM–RAG offline que adapte eficientemente las matrices de pesos del modelo (mediante técnicas de ajuste fino de bajo rango, PEFT/QLoRA) para maximizar la asimilación del contexto recuperado y garantizar la generación fidedigna en Quechua Collao sobre hardware de recursos limitados.

Identificación del problema

El problema central de la investigación es la limitada capacidad de los modelos de lenguaje compactos cuantizados para asimilar y procesar con precisión contextos recuperados en Quechua Collao bajo arquitecturas RAG en entornos computacionales desconectados.

La Figura 1 sintetiza, mediante un árbol de problemas, las causas identificadas y los efectos derivados del problema central.

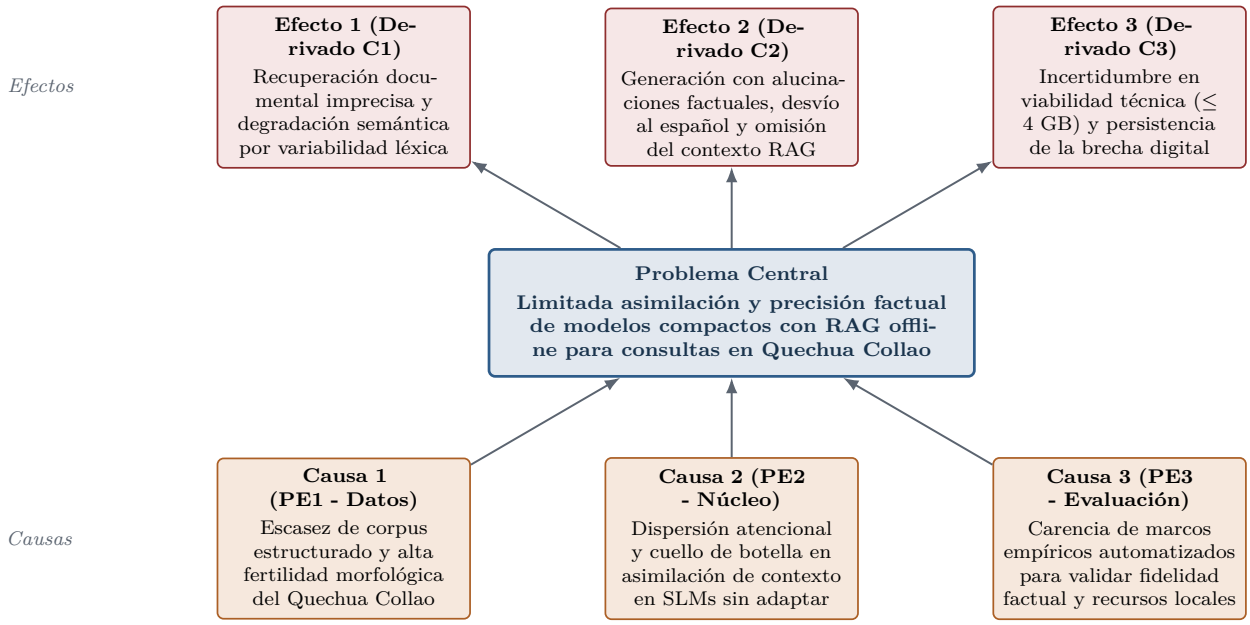


Figura 1
Árbol de problemas: causas tecnológicas (naranja, tríada PE1–PE3) y efectos computacionales (rojo)

Formulación del problema

Problema general. ¿De qué manera el diseño e implementación de una arquitectura SLM–RAG con QLoRA influye en la generación contextualizada en Quechua Collao dentro de un entorno computacional offline?

Problemas específicos.

- **PE1 (Datos y Recuperación):** ¿Cómo estructurar e indexar semánticamente una base de conocimiento documental bilingüe para optimizar la recuperación local en Quechua Collao?
- **PE2 (Núcleo Técnico y Adaptación):** ¿De qué manera los adaptadores QLoRA en un SLM cuantizado optimizan la utilización del contexto recuperado bajo restricciones de hardware local?
- **PE3 (Evaluación Computacional):** ¿Qué nivel de fidelidad léxica, consistencia factual y eficiencia computacional alcanza la arquitectura integrada frente al modelo base y a la recuperación estándar?

1.3. Objetivos de la Investigación

Objetivo General

Diseñar e implementar una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao dentro de un entorno computacional offline.

Objetivos Específicos

- **OE1 (Datos y Recuperación):** Curar, estructurar e indexar semánticamente una base de conocimiento documental bilingüe para optimizar la recuperación local en Quechua Collao.
- **OE2 (Núcleo Técnico y Adaptación):** Implementar y acoplar adaptadores QLoRA en el SLM cuantizado para maximizar la asimilación del contexto RAG en inferencia offline.
- **OE3 (Evaluación Computacional):** Evaluar computacionalmente el rendimiento técnico, la fidelidad lingüística y el anclaje factual de la arquitectura frente al SLM base y al RAG estándar mediante métricas objetivas de PLN y RAG.

La Figura 2 presenta el árbol de objetivos, organizado en correspondencia directa con el árbol de problemas: los objetivos específicos actúan como hitos cronológicos de ingeniería para lograr el objetivo central, alineado con los Objetivos de Desarrollo Sostenible (ODS).

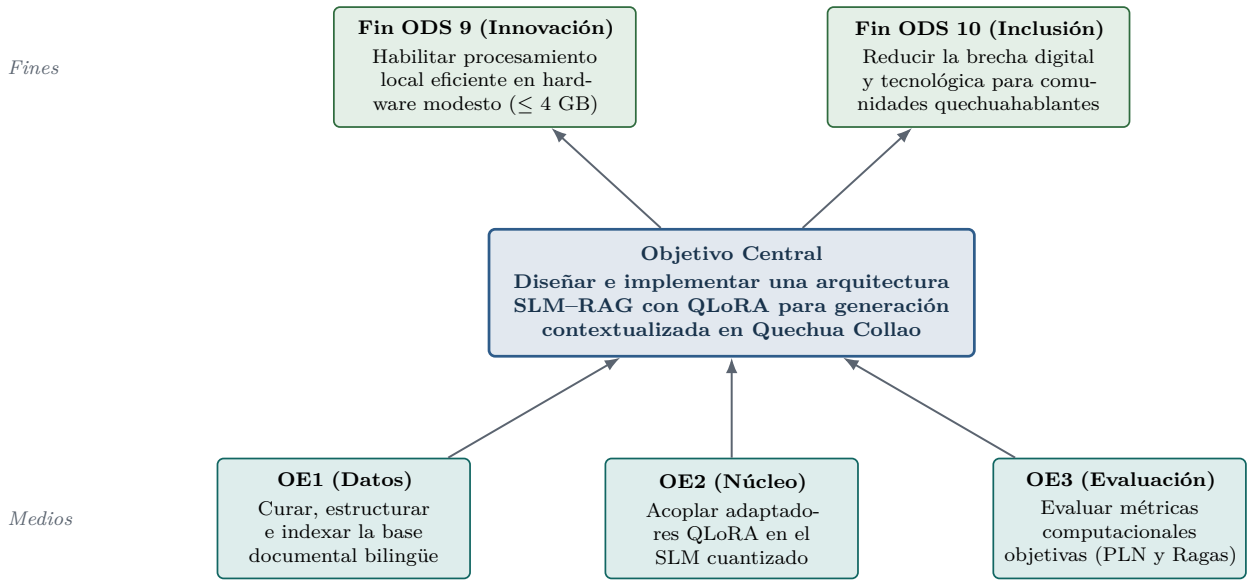


Figura 2
Árbol de objetivos: medios de ingeniería (teal, fases específicas) y fines de impacto (verde, alineación ODS)

1.4. Hipótesis de la Investigación

Hipótesis General

La implementación de la arquitectura SLM–RAG con adaptadores QLoRA optimiza la asimilación del contexto e incrementa la fidelidad factual y calidad lingüística en Quechua Collao dentro de un entorno computacional offline.

Hipótesis Específicas

- **HE1 (Datos y Recuperación):** La segmentación morfo-léxica e indexación semántica local en `sqlite-vec`/FAISS maximizan la precisión de recuperación de fragmentos documentales pertinentes frente a la recuperación léxica directa.
- **HE2 (Núcleo Técnico y Adaptación):** El acoplamiento de adaptadores QLoRA en las matrices de proyección de atención (W_q, W_k, W_v, W_o) del SLM cuantizado incrementa la utilización del contexto RAG sin superar la restricción de hardware local ($\leq$ 4 GB de VRAM/RAM).
- **HE3 (Evaluación Computacional):** La arquitectura integrada con adaptadores QLoRA supera significativamente al SLM base y al RAG estándar en concordancia morfológica (chrF++) y fidelidad factual (métrica *faithfulness* de Ragas).

1.5. Justificación de la Investigación

La investigación se justifica técnicamente porque los enfoques convencionales de inteligencia artificial generativa dependen de centros de datos en la nube y asumen disponibilidad masiva de textos, condiciones inexistentes para el Quechua Collao en escenarios desconectados. El proyecto aborda esta necesidad desde cuatro perspectivas de ingeniería:

- **Justificación Teórica:** Contribuye al estudio del procesamiento de lenguaje natural en lenguas polisintéticas y de bajos recursos. Analiza teóricamente la interacción

entre la fertilidad de tokens de la morfología quechua, los mecanismos de atención en transformadores compactos y el impacto de la descomposición de bajo rango (LoRA) para condicionar la asimilación de fragmentos recuperados sin sufrir degradación paramétrica.

- **Justificación Práctica:** Desarrolla un sistema funcional 100 % offline, optimizado para ejecutarse en computadoras y dispositivos de consumo de bajo costo (compatibles con CPU y $\leq$ 4 GB de VRAM), permitiendo consultar y obtener respuestas precisas en su propia lengua originaria sin requerir enlace a internet.

- **Justificación Metodológica:** Establece un marco experimental riguroso, cuantitativo y reproducible de ingeniería de software e IA. Se diseñan pruebas comparativas controladas que miden el aporte independiente de cada componente (modelo base, RAG local y adaptadores QLoRA) mediante métricas computacionales directas de rendimiento y anclaje semántico.

- **Justificación Tecnológica y Social:** Se alinea formalmente con los Objetivos de Desarrollo Sostenible (ODS):

  - **ODS 9 — Industria, innovación e infraestructura:** Fomenta la innovación en ingeniería de software e inteligencia artificial eficiente, habilitando procesamiento de lenguaje de última generación en dispositivos locales de bajo costo sin dependencia de infraestructura de telecomunicaciones avanzada.
  - **ODS 10 — Reducción de las desigualdades:** Reduce la brecha tecnológica y de acceso computacional para comunidades hablantes de lenguas originarias como el Quechua Collao, democratizando herramientas inteligentes en su propio idioma.

1.6. Alcances y Limitaciones

Alcances

El presente estudio abarca el diseño, implementación y evaluación experimental de una arquitectura SLM–RAG con QLoRA para inferencia local offline en Quechua Collao:

- **Alcance tecnológico:** Comprende la selección, cuantización a 4 bits (formato GGUF con `llama.cpp`) y ajuste fino de bajo rango (QLoRA) sobre un SLM abierto (modelo base target: serie Qwen2.5 de hasta 3B parámetros), integrado a un motor de base de datos vectorial local para recuperación densa semántica.

- **Alcance lingüístico:** Se delimita de forma exclusiva a la variedad Quechua Collao (Cusco–Puno). Se adoptan los lineamientos ortográficos normalizados y su inventario fonológico distintivo (oclusivas glotizadas y aspiradas), evitando la generalización hacia otras familias dialectales como el Quechua Chanka o Ancash.

- **Alcance experimental y métrico:** La evaluación se circunscribe a pruebas computacionales automatizadas y reproducibles: eficiencia en hardware (latencia, tokens/s, consumo de RAM/VRAM), correspondencia morfológica y léxica (chrF++, SacreBLEU) y fidelidad factual de recuperación (métricas del framework Ragas: *faithfulness*, *context recall* y *answer relevancy*).

- **Alcance disciplinar:** Se ubica estrictamente dentro de la Ciencia de la Computación, la Inteligencia Artificial y la Ingeniería de Sistemas, en las subáreas de Procesamiento de Lenguaje Natural y Sistemas Distribuidos/Edge Computing.

Limitaciones

Se reconocen las siguientes limitaciones del estudio:

- **Escasez de datos de entrenamiento:** El volumen de corpus paralelo nativo en Quechua Collao es reducido (≈44 263 palabras validadas). Se mitiga mediante la generación controlada de pares bilingües con LLMs de gran escala sometidos a filtros léxicos y dialectales estrictos.
- **Fertilidad de subpalabras:** La tokenización aglutinante genera fragmentaciones excesivas en vocabulario quechua (≈3,4× frente al español), limitando el tamaño admisible de la ventana de contexto en inferencia offline.
- **Capacidad de hardware local:** La inferencia y ejecución del artefacto están acotadas a configuraciones modestas (entornos con hasta 8 GB de RAM de sistema y tarjetas gráficas de entrada con 4 GB de VRAM, como GTX 1050 Ti o CPU pura), restringiendo el tamaño de los pesos del modelo a un máximo de 3 mil millones de parámetros cuantizados.
- **Modalidad textual:** El sistema procesa y genera exclusivamente texto digital; el procesamiento de habla (reconocimiento y síntesis de voz) queda fuera de la delimitación del presente proyecto.

1.7. Matriz de Consistencia Metodológica

La Tabla 1 consolida la correspondencia matemática y metodológica entre los problemas de investigación, objetivos específicos, hipótesis de trabajo, variables asociadas e instrumentos de medición, evidenciando la consistencia estricta de las tres fases de ingeniería.

Tabla 1

Matriz de consistencia metodológica del proyecto de tesis

Problema	Objetivo	Hipótesis	Variable(s)	Instrumento / Métrica
Nivel General				
¿De qué manera el diseño e implementación de una arquitectura SLM–RAG con QLoRA influye en la generación contextualizada en Quechua Collao?	Diseñar e implementar una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao.	La arquitectura SLM–RAG con QLoRA optimiza la asimilación del contexto e incrementa la fidelidad factual en Quechua Collao en inferencia offline.	**VI:** Arquitectura SLM–RAG con QLoRA. **VDs:** Rendimiento computacional, calidad PLN y fidelidad RAG.	Entorno de inferencia local (`llama.cpp`), framework Ragas, métricas chrF++ y SacreBLEU.
Nivel Específico (Fases Metodológicas de Ingeniería)				
PE1 (Datos y Recuperación): ¿Cómo estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación local en Quechua Collao?	**OE1:** Curar, estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación local en Quechua Collao.	**HE1:** La segmentación morfo-léxica e indexación semántica local maximizan la precisión de recuperación de fragmentos relevantes.	Calidad de indexación y recuperación documental.	Base vectorial local (`sqlite-vec` / FAISS), modelo `multilingual-e5-small`, precisión@k.
PE2 (Núcleo y Adaptación): ¿De qué manera los adaptadores QLoRA del SLM cuantizado optimizan la utilización de contexto bajo restricciones offline?	**OE2:** Implementar y acoplar adaptadores QLoRA en el SLM cuantizado para maximizar la utilización del contexto RAG en inferencia offline.	**HE2:** La adaptación de bajo rango con QLoRA incrementa la fidelidad factual sin comprometer la ejecución en hardware modesto.	Latencia (ms), throughput (tokens/s), uso de RAM/VRAM (GB).	`llama.cpp`, `peft`, librería de monitoreo `psutil`.
PE3 (Evaluación Computacional): ¿Qué nivel de fidelidad léxica, consistencia factual y eficiencia alcanza la arquitectura frente al modelo base y RAG estándar?	**OE3:** Evaluar computacionalmente el rendimiento, fidelidad lingüística y anclaje factual frente al SLM base y RAG estándar.	**HE3:** La arquitectura con QLoRA supera significativamente al SLM base y al RAG estándar en chrF++ y métricas Ragas.	Fidelidad lingüística (chrF++, BLEU) y anclaje RAG (*faithfulness*, *context recall*).	Scripts de evaluación en Python, SacreBLEU, framework Ragas, pruebas estadísticas Friedman/Wilcoxon.

2. Estado del Arte

El desarrollo de una arquitectura SLM–RAG con QLoRA para Quechua Collao en entornos desconectados requiere articular investigaciones multidisciplinares en el campo de la Inteligencia Artificial y la Ciencia de la Computación. A continuación, se presenta una síntesis analítica y crítica de los antecedentes científicos más relevantes organizados por dominios tecnológicos. Las fichas de análisis detalladas de cada uno de estos trabajos se presentan en el Anexo: Fichas de Análisis.

La Figura 3 organiza taxonómicamente estos antecedentes según el dominio técnico al que contribuyen dentro de la arquitectura propuesta.

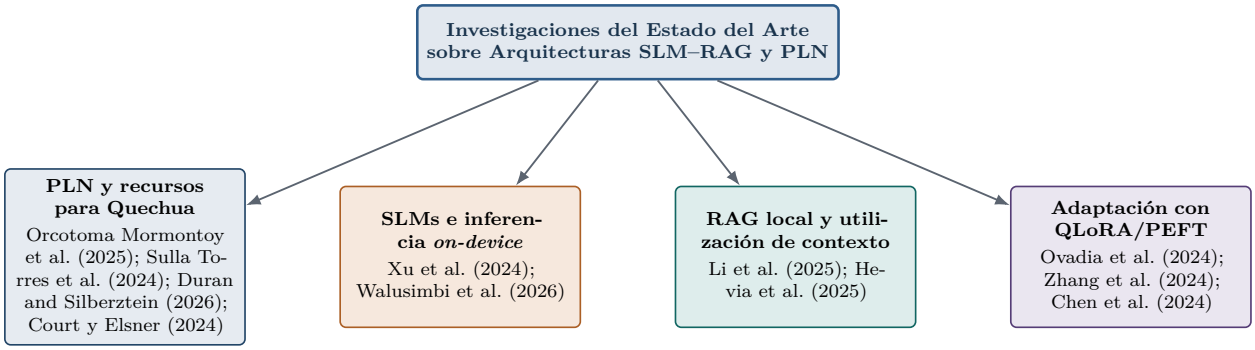


Figura 3

Taxonomía de las investigaciones previas por dominio tecnológico

2.1. Procesamiento de Lenguaje Natural y Recursos para Quechua Collao

El procesamiento de lenguaje natural (PLN) para lenguas aglutinantes de bajos recursos como el quechua ha presentado desafíos históricos debido a su complejidad morfológica. Investigaciones recientes han abordado estas brechas mediante la construcción de corpus y el ajuste de modelos neuronales. Orcotoma Mormontoy et al. (2025) aportaron significativamente al construir un corpus paralelo Quechua Collao–español de 44 263 palabras mediante el uso de reconocimiento óptico de caracteres (OCR) sobre textos académicos de la Academia Mayor de la Lengua Quechua, logrando tasas de error de palabra (WER) de 6,59 %. Por su parte, Duran y Silberztein (2026) propusieron métodos semi-automáticos para la construcción de diccionarios quechua–español utilizando formalismos lingüísticos, lo que amplía la disponibilidad de recursos léxicos estructurados para la indexación y validación dialectal.

En cuanto a la traducción y generación, Sulla Torres et al. (2024) demostraron que los modelos de traducción automática neuronal (NMT) optimizados con BERT pueden alcanzar puntajes aceptables (BLEU de 20,13) en la dirección quechua–español, aunque subrayaron las limitaciones impuestas por la escasez de datos paralelos masivos. Por otro lado, Court y Elsner (2024) evaluaron las capacidades de aprendizaje en contexto (*in-context learning*) de modelos de lenguaje comerciales (GPT-4, Gemini) para la traducción del quechua al español. Sus hallazgos indican que, si bien la inclusión de traducciones a nivel de morfema mejora el rendimiento, la inyección directa de extensas reglas gramaticales o fragmentos de corpus mediante *prompting* ingenuo degrada el rendimiento de los modelos, generando salidas fluidas pero semánticamente infieles o alucinadas. Esto demuestra que el *prompting* aislado en la nube resulta insuficiente para gobernar la morfología de lenguas de bajos recursos y justifica la necesidad de una arquitectura con adaptación paramétrica explícita.

2.2. Small Language Models y Despliegue Offline On-Device

Frente a la dependencia de conectividad y alto consumo computacional de los LLMs masivos, el desarrollo de Small Language Models (SLM) y técnicas de optimización para hardware restringido (*on-device AI*) representa una línea de investigación prioritaria en sistemas computacionales. La exhaustiva revisión de Xu et al. (2024) sistematiza cómo técnicas como la cuantización post-entrenamiento (PTQ) y la compresión de pesos permiten que modelos con menos de 3 mil millones de parámetros operen eficientemente en procesadores de bajo consumo y sin GPU dedicada.

La aplicación de estas tecnologías en contextos desconectados fue validada empíricamente por Walusimbi et al. (2026), quienes diseñaron la arquitectura *Arapai* para inferencia offline. Al desplegar modelos compactos cuantizados (como TinyLlama o Qwen) en hardware de consumo básico (solo CPU), lograron latencias interactivas de 1 a 3 segundos, demostrando que la inferencia local es técnicamente factible en entornos sin infraestructura de red. Sin embargo, su estudio se restringió a la lengua inglesa y no consideró los cuellos de botella morfológicos de lenguas polisintéticas.

2.3. Generación Aumentada por Recuperación (RAG) y Cuello de Botella de Contexto

La Generación Aumentada por Recuperación (RAG) es la arquitectura canónica para mitigar las alucinaciones factuales, desacoplando la memoria paramétrica del modelo del almacenamiento documental externo (Li et al., 2025).

No obstante, el despliegue de RAG sobre modelos pequeños presenta desafíos computacionales particulares. Hevia et al. (2025) evaluaron el rendimiento de SLMs (SmolLM) combinados con RAG offline, descubriendo un fenómeno contraproducente: la inyección de fragmentos extensos o con ruido contextual redujo drásticamente la precisión del modelo en tareas de razonamiento frente a la línea base sin RAG. Este hallazgo evidencia la incapacidad intrínseca de los SLMs pequeños para atender y filtrar eficazmente el contexto recuperado (*context utilization bottleneck*), lo que fundamenta la necesidad de acoplar adaptadores QLoRA específicos en las capas de atención del modelo para condicionarlo a extraer la información pertinente.

2.4. RAG vs. Fine-Tuning y Adaptación Eficiente (PEFT/QLoRA)

La decisión entre RAG puro, ajuste fino tradicional y enfoques híbridos es un eje central en la literatura. Ovadia et al. (2024) demostraron que, para la inyección de conocimiento factual, RAG supera de forma consistente al *fine-tuning* supervisado tradicional, evitando el olvido catastrófico. Sin embargo, en lenguas aglutinantes como el quechua, la alta fertilidad de tokens satura la memoria del RAG, exigiendo tanto fragmentaciones cortas como mecanismos para que el modelo interprete adecuadamente la evidencia inyectada.

El método RAFT (*Retrieval-Augmented Fine-Tuning*) propuesto por Zhang et al. (2024) abordó esta brecha: en lugar de forzar al modelo a memorizar datos, se entrenan sus pesos para procesar el contexto RAG de forma resiliente, distinguiendo fragmentos relevantes de distractores. El antecedente más directo para esta propuesta es el modelo QueEn (Chen et al., 2024), que demostró empíricamente que acoplar RAG léxico con ajuste de bajo rango (LoRA) elevó el puntaje BLEU de 1,5 a 17,6 en quechua, validando que la adaptación de matrices de pesos combinada con recuperación local es la estrategia superior para lenguas de bajos recursos digitales.

La Tabla 2 sintetiza las diferencias teóricas entre las estrategias de inyección de conocimiento analizadas.

Tabla 2
Comparación de estrategias computacionales de inyección de conocimiento

Dimensión	*Fine-tuning* Completo	RAG Estándar	Híbrido: RAG + QLoRA
Requerimiento de datos	Masivo: riesgo de sobreajuste y olvido catastrófico	Bajo: explota corpus documental sin etiquetar	Moderado: pares de adaptación para alineación de atención
Costo computacional	Muy alto: inviable en hardware modesto	Muy bajo: solo vectorización e inferencia	Eficiente: entrenamiento con QLoRA ($\leq$ 4 GB VRAM)
Factualidad y alucinaciones	Baja: tiende a alucinar hechos no memorizados	Media: alucinación si el SLM no asimila el contexto	Máxima: atención condicionada a la evidencia documental
Desempeño en Quechua Collao	Frágil por escasez de datos masivos (Sulla Torres et al., 2024)	Regular: penalizado por fertilidad de tokens (Court and Elsner, 2024)	Favorable: demostrado empíricamente por Chen et al. (2024)

2.5. Matriz resumida de antecedentes

La Tabla 3 consolida los antecedentes empíricos y computacionales más directamente vinculados a la propuesta, contrastando objetivos, metodologías, métricas y su contribución concreta al diseño de la arquitectura.

Tabla 3
Matriz resumida de antecedentes tecnológicos del estado del arte

Autor(es)	Objetivo	Método	Resultados clave	Aporte al Proyecto
Orcotoma Mormontoy et al. (2025)	Construir corpus paralelo Quechua Collao–español.	OCR en libros académicos AMLQ e indexación.	44 263 palabras con WER de 6,59 %.	Provee el corpus documental para la base de conocimiento local.
Sulla Torres et al. (2024)	Evaluar traducción neuronal quechua–español.	NMT con codificador BERT y fine-tuning.	BLEU de 20,13.	Evidencia las limitaciones del entrenamiento puro sin RAG.
Duran y Silberztein (2026)	Desarrollar diccionarios formales Quechua–Español.	Gramáticas léxicas NooJ semi-automáticas.	Diccionario estructurado de alta precisión.	Fuente léxica para la normalización dialectal y tokenización.
Court y Elsner (2024)	Evaluar LLMs comerciales en quechua.	In-context learning con inyección de reglas.	Reglas extensas degradan fidelidad; alucinación frecuente.	Justifica descartar modelos en la nube y diseñar arquitectura local adaptada.
Chen et al. (2024)	Optimizar traducción quechua–inglés.	Enfoque híbrido: RAG léxico + LoRA.	Incremento de BLEU de 1,5 a 17,6.	Precedente directo de la sinergia entre RAG y adaptación paramétrica.
Walusimbi et al. (2026)	Inferencia de SLMs en hardware desconectado.	Cuantización a 4 bits sobre CPU local.	Latencia de 1–3s en hardware modesto sin internet.	Valida la viabilidad técnica del despliegue offline con `llama.cpp`.
Hevia et al. (2025)	Evaluar SLMs con RAG offline.	SmolLM + vectorización documental en CPU.	Degradación de precisión por sobrecarga de contexto.	Demuestra la necesidad de adaptar matrices de atención para asimilar RAG.

2.6. Síntesis crítica y vacíos de investigación

La revisión del estado del arte demuestra avances significativos pero fragmentados en las disciplinas que convergen en este estudio:

1. Existen recursos léxicos y corpus recientes para Quechua Collao (Orcotoma Mormontoy et al., 2025; Duran and Silberztein, 2026), pero no han sido articulados en bases de conocimiento vectoriales locales para inferencia desconectada.

2. Los modelos comerciales en la nube no resuelven la brecha en zonas sin conectividad y alucinan ante morfologías aglutinantes complejas (Court and Elsner, 2024).

3. La viabilidad de SLMs cuantizados en CPU ha sido comprobada (Walusimbi et al.,

2026), pero su combinación ingenua con RAG genera degradación atencional cuando el modelo no ha sido adaptado (Hevia et al., 2025).

4. Aunque la hibridación de RAG con adaptadores de bajo rango ha mostrado resultados sobresalientes en tareas bilingües (Chen et al., 2024; Zhang et al., 2024), esta técnica no ha sido investigada ni optimizada para inferencia offline en Quechua Collao.

En consecuencia, el vacío de investigación radica en la ausencia de una arquitectura computacional integrada SLM–RAG offline para Quechua Collao que adapte específicamente las matrices de atención del modelo compacto cuantizado (QLoRA) para maximizar la asimilación del contexto documental recuperado y garantizar la fidelidad factual bajo restricciones de hardware local.

3. Marco Teórico y Conceptual

El presente marco teórico articula los fundamentos conceptuales que sustentan el diseño e implementación de una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao con capacidad de operación *offline*. Su construcción sigue una organización jerárquica que avanza desde la caracterización lingüística computacional del Quechua Collao hacia los componentes técnicos de ingeniería de software e inteligencia artificial: el procesamiento de lenguas aglutinantes de bajos recursos, los modelos de lenguaje compactos, la compresión por cuantización, los adaptadores de bajo rango (LoRA/QLoRA), la Generación Aumentada por Recuperación (RAG) y los marcos de evaluación computacional automatizada.

3.1. Procesamiento de Lenguaje Natural en Lenguas de Bajos Recursos

El procesamiento de lenguaje natural (PLN) para lenguas de bajos recursos digitales (*low-resource languages*) enfrenta dos desafíos teóricos cardinales: la escasez de datos paralelos estructurados para el entrenamiento de representaciones vectoriales densas, y la alta complejidad morfosintáctica. En lenguas originarias amerindias, el Entendimiento del Lenguaje Natural (NLU) se ve obstaculizado cuando se emplean modelos probabilísticos preentrenados mayoritariamente sobre corpus anglosajones o romances. Por ello, la inyección explícita de conocimiento estructurado mediante recuperación documental representa una alternativa superior a pretender que el modelo memorice el conocimiento factual en sus pesos internos.

3.2. Quechua Collao: caracterización morfológica computacional

El Quechua Collao (Cusco–Puno) es una lengua polisintética, aglutinante y predominantemente sufijadora. Desde una perspectiva computacional:

- **Morfología Aglutinante:** Una raíz léxica nominal o verbal puede incorporar múltiples sufijos derivativos y flexivos en cascada, concentrando en un único token gráfico el contenido semántico y sintáctico equivalente a una oración completa en lenguas analíticas como el español.
- **Inventario Fonológico Complejo:** Presenta consonantes oclusivas glotizadas (eyectivas: /p', t', k', q', ch'/) y aspiradas (/ph, th, kh, qh, chh/), lo cual exige esquemas de normalización ortográfica estricta para evitar la fragmentación errática de subpalabras durante el proceso de tokenización.
- **Escasez de Corpus Paralelos:** La disponibilidad de corpus alineados en formato digital es extremadamente reducida (≈44 263 palabras formalmente documentadas en trabajos como el de Orcotoma Mormontoy et al. (2025)), requiriendo técnicas eficientes de aumentación de datos y filtrado léxico dialectal.

3.3. Alternancia de códigos y bilingüismo computacional

En comunidades andinas bilingües, los usuarios emplean frecuentemente la alternancia de códigos (*code-switching*), alternando segmentos en español y en Quechua Collao dentro de una misma interacción. Un sistema de inferencia debe incorporar clasificadores livianos o enrutadores lingüísticos capaces de determinar la lengua predominante en la entrada para direccionar adecuadamente el espacio de incrustaciones (*embeddings*) y las plantillas de generación del prompt sin introducir latencia apreciable.

3.4. Cuello de botella de la tokenización en transformadores

La fragmentación de texto en unidades mínimas o tokens mediante algoritmos de subpalabras (como BPE o SentencePiece) presenta anomalías severas al aplicarse a lenguas aglutinantes. Los tokenizadores estándar, no entrenados sobre corpus quechuas densos, descomponen cada término en fragmentos diminutos e inconexos. Este fenómeno se cuantifica mediante la *fertilidad de tokens*:

$$\text{Fertilidad} = \frac{\text{Número de tokens generados en Quechua}}{\text{Número de tokens del texto paralelo en Español}}$$

Para el Quechua Collao, se estima una fertilidad de aproximadamente 3,4× respecto al español. La inflación de tokens genera dos impactos críticos en hardware de bajo costo:

- **Crecimiento de la memoria KV Cache:** La caché de claves y valores escala linealmente con la longitud de la secuencia N, saturando la memoria RAM/VRAM en equipos de recursos limitados.
- **Sobrecarga en la autoatención:** La complejidad temporal y espacial del mecanismo de autoatención $O(N^2 \cdot d)$ penaliza severamente el rendimiento en inferencia CPU local.

Por ello, la arquitectura RAG offline exige fragmentos documentales cortos (250–400 tokens) y un número acotado de contextos recuperados (*top-k* entre 3 y 5).

3.5. Modelos de Lenguaje Compactos (SLMs) y Cuantización

Los Modelos de Lenguaje Pequeños (SLMs, *Small Language Models*) son redes basadas en la arquitectura Transformer (Vaswani et al., 2017) con una escala paramétrica optimizada ($\leq$ 3 mil millones de parámetros). Frente a los LLMs masivos que requieren granjas de servidores en la nube, los SLMs permiten la ejecución local e independiente (*on-device*) en dispositivos personales.

Para viabilizar su ejecución en procesadores convencionales y tarjetas gráficas modestas ($\leq$ 4 GB VRAM), se aplica **Cuantización Post-Entrenamiento (PTQ)**. Esta técnica mapea los pesos de coma flotante de alta precisión (Float16) a representaciones enteras de bajo número de bits (formato entero de 4 bits, Q4_K_M o NormalFloat4):

$$W_{\text{quant}} = \text{round}\left(\frac{W}{\text{scale}}\right) + \text{zero_point}$$

Esto reduce el tamaño del modelo de ∼6 GB a solo 2,1 GB en disco y memoria RAM, permitiendo velocidades de 10 a 25 tokens/s en CPU local mediante motores de inferencia C++ como `llama.cpp` (Xu et al., 2024). Para esta investigación, el modelo base seleccionado es **Qwen2.5-3B-Instruct** (Yang et al., 2024), debido a su arquitectura multilingüe nativa y sobresaliente retención de capacidades lógicas en formatos cuantizados (Tabla 4).

Tabla 4
Modelos de lenguaje compactos candidatos para inferencia offline

Modelo	Parámetros	RAM (Q4_K_M)	Soporte CPU	Rol en la Arquitectura
Qwen2.5-3B-Instruct	3,1B	∼2,1 GB	Sí	**Modelo base seleccionado**
Qwen2.5-7B-Instruct	7,6B	∼4,7 GB	Sí	Variante de referencia para equipos 16 GB
Llama 3.2 3B-Instruct	3,2B	∼2,0 GB	Sí	Modelo comparativo de control
SmolLM2-1.7B-Instruct	1,7B	∼1,1 GB	Sí	Modelo para evaluación ultra-restringida

3.6. Adaptación Eficiente de Modelos: LoRA y QLoRA

El ajuste fino completo (*Full Fine-Tuning*) de una red neuronal actualiza todas las matrices de pesos $W \in \mathbb{R}^{d\times k}$, requiriendo almacenar gradientes y estados del optimizador que quintuplican el consumo de memoria. Para solventar esto, Hu et al. (2022) propusieron la Adaptación de Bajo Rango (LoRA, *Low-Rank Adaptation*), la cual congela los pesos preentrenados W_0 y descompone la matriz de actualización ΔW en dos matrices de rango intrínseco reducido $r \ll \min(d, k)$:

$$W = W_0 + \Delta W = W_0 + \frac{\alpha}{r}(B \cdot A)$$

donde $A \in \mathbb{R}^{r\times k}$ se inicializa mediante una distribución gaussiana y $B \in \mathbb{R}^{d\times r}$ se inicializa en ceros, con α como hiperparámetro constante de escalamiento.

QLoRA (Dettmers et al., 2023) optimiza este paradigma al cuantizar la matriz base congelada W_0 en formato *NormalFloat4* (NF4), aplicando además doble cuantización de constantes de escala y paginado de memoria para evitar picos de VRAM. Esto posibilita el entrenamiento de adaptadores en hardware de consumo doméstico ($\leq$ 4 GB de VRAM).

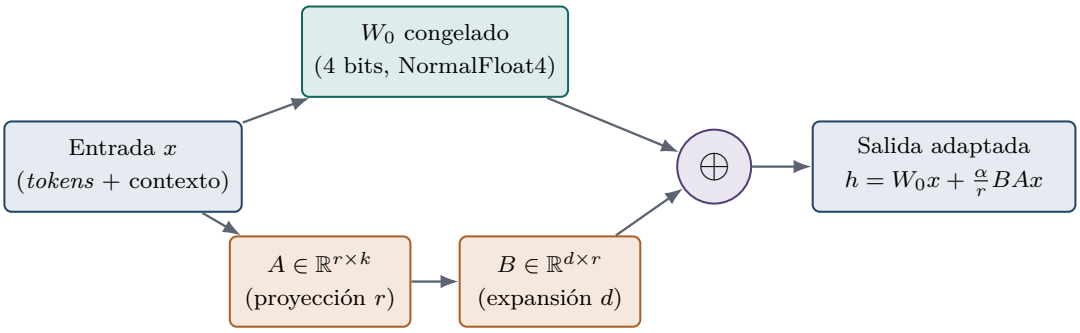


Figura 4
Esquema de adaptación de bajo rango (QLoRA): descomposición sobre pesos base cuantizados a 4 bits

3.7. Mecanismos de Atención y Adaptación con QLoRA para RAG

El cuello de botella central al acoplar un SLM con RAG en lenguas de bajos recursos radica en los mecanismos de autoatención. En una capa Transformer, las representaciones de entrada X se proyectan en matrices de Consulta (Q), Clave (K) y Valor (V):

$$Q = XW_q, \quad K = XW_k, \quad V = XW_v$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

$$\text{Output} = \text{Attention}(Q, K, V)W_o$$

Cuando se inyecta contexto externo recuperado por el RAG en Quechua Collao, las capas de atención de un SLM estándar sufren de *dispersión atencional*: los pesos de atención calculados por el producto escalar QK^T asignan baja probabilidad a los morfemas quechuas relevantes del contexto, ignorando la evidencia factual recuperada y favoreciendo alucinaciones o respuestas en español.

Mediante adaptadores QLoRA focalizados específicamente en las proyecciones de atención (W_q, W_k, W_v, W_o), el modelo aprende a: (a) identificar y alinear semánticamente las consultas bilingües con las claves del contexto recuperado; (b) focalizar los coeficientes de atención sobre los fragmentos documentales pertinentes; y (c) mitigar alucinaciones sintetizando la respuesta anclada estrictamente a la evidencia documental externa (Ovadia et al., 2024).

3.8. Generación Aumentada por Recuperación (RAG) Local

La Generación Aumentada por Recuperación desacopla la memoria paramétrica del modelo del conocimiento factual específico. La arquitectura consta de una etapa de indexación fuera de línea y una etapa de consulta en tiempo de ejecución (Figura 5):

1. **Indexación Offline:** Los documentos bilingües y glosarios normalizados se segmentan en bloques semánticos (*chunks*), los cuales se vectorizan mediante un modelo de embeddings denso (`multilingual-e5-small`) y se indexan en un motor vectorial local (`sqlite-vec` / FAISS).

2. **Recuperación en Tiempo de Inferencia:** Al recibir una consulta, se extraen los fragmentos más afines mediante similitud del coseno:

$$\text{sim}(q, d) = \frac{\mathbf{e}_q \cdot \mathbf{e}_d}{\|\mathbf{e}_q\|\|\mathbf{e}_d\|}$$

3. **Generación Condicionada:** Los fragmentos recuperados se estructuran en una plantilla de prompt aumentado que alimenta al SLM con adaptadores QLoRA para sintetizar la respuesta en Quechua Collao.

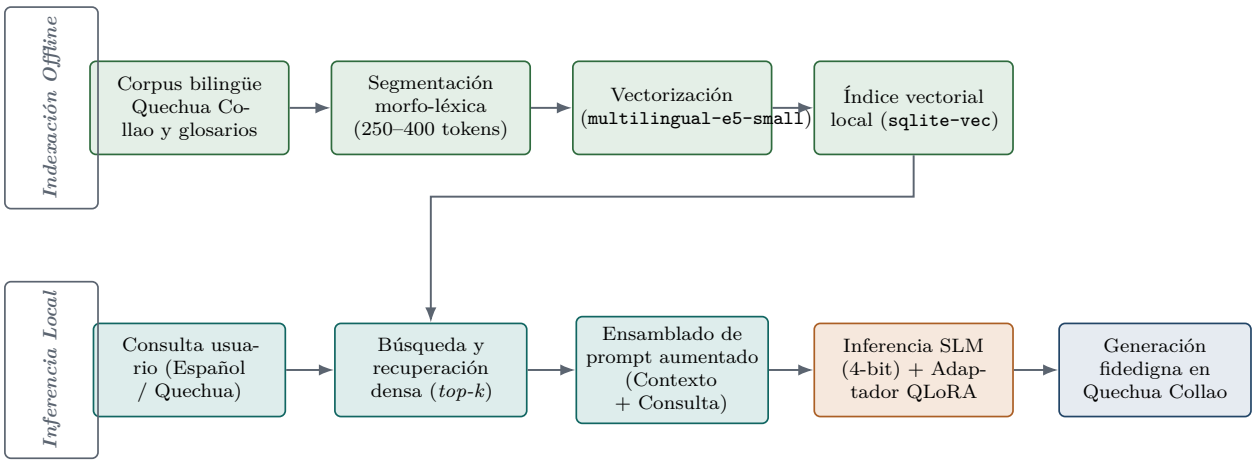


Figura 5

Pipeline computacional de la arquitectura SLM–RAG con adaptadores QLoRA local offline

El funcionamiento algorítmico detallado de este pipeline se formaliza en el Algoritmo 1.

Entrada: Consulta de usuario q (español o quechua), base documental indexada $\mathcal{D} = \{(d_i, \mathbf{e}_i)\}_{i=1}^{N}$, modelo base cuantizado $W_0 \in$ NF4, adaptadores QLoRA $\{A_l, B_l\}_{l \in \mathcal{L}}$, hiperparámetro de recuperación $k \in \mathbb{N}$.
Salida: Respuesta fidedigna generada y en Quechua Collao contextualizada.

1. **Codificación semántica de la consulta:** Calcular la incrustación densa $\mathbf{e}_q = \text{Encoder}(q)$ mediante el modelo `multilingual-e5-small`.
2. **Recuperación semántica densa (k-NN):**
   - Evaluar la similitud del coseno $\text{sim}(q, d_i) = \frac{\mathbf{e}_q \cdot \mathbf{e}_i}{\|\mathbf{e}_q\| \|\mathbf{e}_i\|}$ para cada fragmento $d_i \in \mathcal{D}$ en el índice `sqlite-vec`.
   - Extraer los k fragmentos más relevantes: $\mathcal{C}_k = \{d_{(1)}, d_{(2)}, \ldots, d_{(k)}\}$.
3. **Ensamblado de prompt aumentado (*Augmented Prompt Injection*):**
   - Estructurar el bloque de contexto documental: $\text{Contexto} = \bigcup_{j=1}^{k} d_{(j)}$.
   - Construir la plantilla instruccional: $P_{\text{aug}} = \text{Plantilla}(\text{Instrucción}, \text{Contexto}, q)$.
4. **Tokenización y proyección inicial:** Tokenizar P_{aug} obteniendo la secuencia de representaciones $X \in \mathbb{R}^{T \times d}$.
5. **Inferencia Transformer con adaptación QLoRA:** Para cada capa $l \in \mathcal{L}$:
   - Proyectar proyecciones de atención adaptadas: $W = W_0 + \frac{\alpha}{r}(B_l \cdot A_l)$ para matrices W_q, W_k, W_v, W_o.
   - Calcular pesos de atención condicionados al contexto recuperado: $H_l = \text{Attention}_{\text{QLoRA}}(X)$.
6. **Decodificación y generación de salida:** Generar la secuencia autorregresiva de tokens hasta alcanzar el token de fin de secuencia (`<|im_end|>`) o límite de tokens: $y \sim P(y \mid P_{\text{aug}}, W_0, A, B)$.
7. **Retornar:** Secuencia textual y validada en Quechua Collao.

Algoritmo 1
Pipeline de inferencia local offline SLM–RAG con adaptadores QLoRA

3.9. Marco de Evaluación Computacional Automatizada

Para garantizar objetividad y reproducibilidad, la evaluación descarta valoraciones cualitativas subjetivas y se fundamenta en tres familias de métricas computacionales:

- **Métricas de Eficiencia Computacional:** Latencia de inferencia en milisegundos (ms), tasa de generación en tokens por segundo (t/s) y consumo pico de memoria RAM/VRAM en Gigabytes (GB) mediante telemetría directa de `llama.cpp` y `psutil`.
- **Métricas de Calidad de Generación Textual (PLN):**
  - **chrF++:** Métrica de precisión y exhaustividad de n-gramas de caracteres y palabras. Es el estándar de oro en lenguas aglutinantes ya que penaliza con justicia variaciones morfológicas sin requerir tokenización perfecta.
  - **SacreBLEU:** Métrica estándar reproducible de concordancia de n-gramas léxicos frente a conjuntos de control.

- **Perplejidad (PPL):** Medida intrínseca de incertidumbre probabilística del modelo sobre secuencias de prueba en Quechua Collao.

- **Métricas de Anclaje y Fidelidad Factual RAG (Framework Ragas):**
  - ***Faithfulness* (Fidelidad factual):** Cuantifica qué fracción de las afirmaciones generadas se deriva matemáticamente de los fragmentos inyectados por el RAG, midiendo directamente la supresión de alucinaciones.
  - ***Context Precision*:** Evalúa si los fragmentos recuperados en el ranking por el motor de búsqueda son pertinentes para contestar la consulta.
  - ***Answer Relevancy*:** Mide la similitud semántica y completitud de la respuesta generada con respecto a la consulta inicial.

3.10. Síntesis integradora del marco teórico

La articulación teórica de la propuesta define una clara jerarquía tecnológica:

1. El **RAG local** almacena el conocimiento documental factual fuera del modelo, resolviendo la imposibilidad de memorizar conocimientos en lenguas de bajos recursos sin reentrenar.

2. La **cuantización a 4 bits (GGUF)** reduce el modelo base a 2,1 GB, asegurando la viabilidad de ejecución en computadoras personales modestas sin conexión a internet.

3. Los **adaptadores QLoRA** sobre las matrices de atención (W_q, W_k, W_v, W_o) acondicionan al SLM para atender y sintetizar eficazmente la información en Quechua Collao entregada por el RAG.

4. La **evaluación experimental pura** mide de manera automatizada y reproducible la ganancia en fidelidad y el costo en latencia/memoria a través de las configuraciones E1, E2 y E3.

4. Metodología

4.1. Tipo y diseño de investigación

La investigación es de tipo **aplicada y tecnológica**, orientada al diseño, implementación y evaluación experimental de un artefacto de software de inteligencia artificial dentro del área de Ciencia de la Computación e Ingeniería de Sistemas.

El enfoque metodológico es **cuantitativo y experimental puro sobre el artefacto**. Se manipula de forma controlada la **Variable Independiente (VI)** —la arquitectura y presencia de adaptadores QLoRA— para medir de manera objetiva sus efectos sobre las **Variables Dependientes (VD)** de eficiencia computacional, fidelidad léxica y efectividad RAG.

La **Variable Independiente (VI)** se estructura en tres niveles o tratamientos experimentales:

1. **E1 (SLM Base Cuantizado):** Modelo Qwen2.5-3B en Q4_K_M bajo inferencia local sin inyección de contexto RAG (Línea base).

2. **E2 (SLM Cuantizado + RAG Estándar):** Modelo base con recuperación vectorial densa local (*vanilla RAG*).

3. **E3 (SLM con QLoRA + RAG Local):** Modelo cuantizado con adaptadores QLoRA en proyecciones de atención acoplado al RAG local.

Las **Variables Dependientes (VD)** son cuantitativas continuas: (a) Rendimiento computacional: latencia (ms), tokens/s, consumo de RAM y VRAM (GB); (b) Calidad lingüística: chrF++, SacreBLEU y perplejidad; (c) Efectividad RAG: *faithfulness*, *context precision* y *answer relevancy*. La Tabla 5 formaliza la matriz de operacionalización.

Tabla 5

Matriz de operacionalización de variables computacionales

Variable	Tipo	Dimensión	Definición Operacional	Indicador	Instrumento / Herramienta
VI: Arquitectura y adaptación	Cualitativa nominal	Arquitectura de software	Nivel de integración y adaptadores QLoRA del pipeline.	Tratamiento evaluado: E1, E2 o E3	Scripts en Python, `llama.cpp`, PEFT/QLoRA.
VD1: Latencia	Cuantitativa continua	Rendimiento técnico	Tiempo total transcurrido en la generación local de la respuesta.	Milisegundos (ms)	Librería `time` de Python, logs de `llama.cpp`.
VD2: Tasa de tokens	Cuantitativa continua	Rendimiento técnico	Velocidad de generación de unidades léxicas por unidad de tiempo.	Tokens generados por segundo (t/s)	Profiler de inferencia de `llama.cpp`.
VD3: Memoria RAM/VRAM	Cuantitativa continua	Rendimiento técnico	Consumo máximo de memoria del sistema y acelerador gráfico.	Gigabytes (GB)	Monitor de recursos del sistema (`psutil`, `pynvml`).
VD4: chrF++	Cuantitativa continua	Calidad lingüística	Similitud estadística de n-gramas de caracteres y palabras morfológicas.	Coeficiente chrF++ (0–100)	Librería oficial `sacrebleu` en Python.
VD5: SacreBLEU	Cuantitativa continua	Calidad lingüística	Precisión acumulada de n-gramas frente a respuestas de referencia.	Coeficiente BLEU (0–100)	Script formal de evaluación en Python.
VD6: Perplejidad (PPL)	Cuantitativa continua	Calidad lingüística	Incertidumbre en la modelación del lenguaje Quechua Collao.	Valor escalar PPL	Herramienta `llama-perplexity` de `llama.cpp`.
VD7: Fidelidad factual	Cuantitativa continua	Efectividad RAG	Grado de anclaje de la respuesta en los fragmentos RAG recuperados.	Métrica de *faithfulness* (0,0–1,0)	Framework de evaluación Ragas.
VD8: Relevancia RAG	Cuantitativa continua	Efectividad RAG	Correspondencia semántica directa entre la consulta y la salida generada.	Métrica de *answer relevancy* (0,0–1,0)	Framework de evaluación Ragas.

4.2. Metodología de desarrollo: Design Science Research (DSR)

El desarrollo de la arquitectura sigue el marco de investigación en ciencias del diseño (**Design Science Research, DSR**), estructurado en seis fases iterativas (Figura 6):

1. **Identificación del problema:** Limitaciones de utilización de contexto y alucinaciones en SLMs ejecutados offline sobre Quechua Collao.
2. **Definición de objetivos de la solución:** Diseñar una arquitectura eficiente con QLoRA que maximice el anclaje RAG con un consumo ≤ 4 GB de memoria.
3. **Diseño y desarrollo:** Curaduría e indexación de la base vectorial, cuantización del modelo base a 4 bits con `llama.cpp` y entrenamiento de adaptadores QLoRA en proyecciones de atención.
4. **Demostración:** Despliegue del pipeline local integrado procesando consultas bilingües en condiciones 100 % offline.
5. **Evaluación:** Ejecución del protocolo experimental automatizado contrastando E1, E2 y E3 sobre el banco de pruebas mediante pruebas de significancia estadística (Friedman y Wilcoxon).
6. **Comunicación:** Redacción de resultados experimentales, curvas de trade-off latencia/precisión y publicación del repositorio de código abierto reproducible.

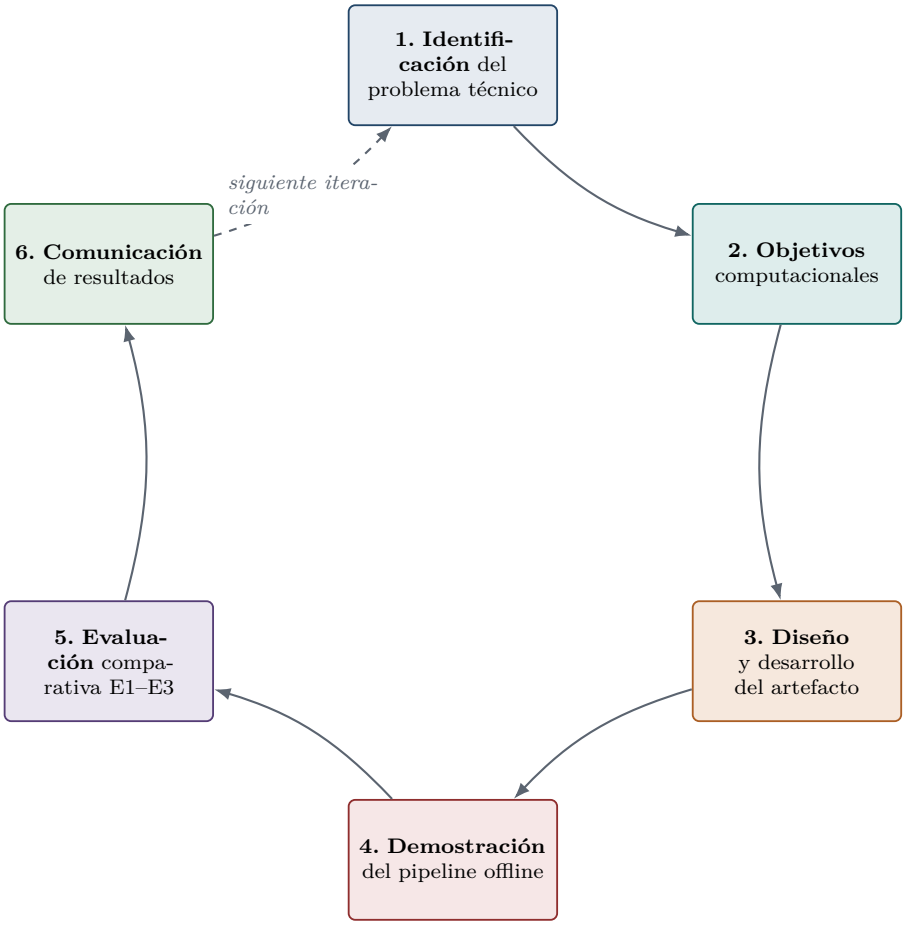


Figura 6
Ciclo de las seis fases del Design Science Research (DSR) aplicado a la ingeniería del artefacto

4.3. Unidades de análisis y banco de evaluación

La experimentación computacional se estructura sobre dos unidades técnicas:

- **Base de Conocimiento Indexada:** Colección curada de fragmentos documentales bilingües, diccionarios y glosarios normalizados en Quechua Collao, preprocesados en fragmentos de 250 a 400 tokens e indexados vectorialmente en `sqlite-vec`.
- **Banco de Consultas de Prueba (*Test Benchmark*):** Conjunto estandarizado de 100 consultas de prueba representativas formuladas en español y Quechua Collao, cada una asociada a: (i) el fragmento documental de referencia (*ground-truth context*); y (ii) la respuesta fidedigna esperada (*gold-standard response*) validada morfosintácticamente para permitir la ejecución desatendida de los pipelines de evaluación automática (Ragas y SacreBLEU).

4.4. Consideraciones éticas

La investigación se desarrolla bajo estrictos principios éticos aplicados al software y manejo de datos:

1. **Licenciamiento y atribución de fuentes:** Se respeta el licenciamiento de los corpus públicos y modelos abiertos empleados (Qwen2.5, AmericasNLP, diccionarios lingüísticos), dando el debido crédito a sus autores en el manifiesto de datos del proyecto.
2. **Transparencia y reproducibilidad:** El código fuente, los pesos de los adaptadores entrenados y los scripts de evaluación automatizada se dispondrán de forma abierta y documentada, garantizando que los experimentos sean replicables por la comunidad científica sin sesgos arbitrarios.

5. Estudio de Factibilidad

El estudio de factibilidad determina si el proyecto puede ejecutarse con éxito dentro de las restricciones reales de tiempo, hardware, datos y recursos propios. El proyecto **es plenamente factible como prototipo académico y experimental de ingeniería**: se selecciona, cuantiza y despliega un SLM preentrenado con RAG local, recursos lingüísticos estructurados y adaptadores ligeros (QLoRA), en lugar de entrenar un modelo desde cero (Xu et al., 2024; Walusimbi et al., 2026).

5.1. Enfoque híbrido adoptado

Se evaluaron tres opciones arquitectónicas. La Tabla 6 resume el análisis comparativo que fundamenta la elección.

Tabla 6
Matriz comparativa de enfoques para la decisión metodológica

Opción	Ventaja principal	Riesgo principal	Ajuste	Veredicto
A. Fine-tuning completo	Adapta pesos si hay corpus masivo	Escasez de datos; riesgo de sobreajuste y olvido catastrófico	Parcial	Descartado
B. SLM cuantizado + RAG local	Mejor factualidad; actualización fácil; inferencia offline	Cuello de botella de utilización de contexto en el SLM	Muy alto	Línea base comparativa
C. Híbrido (RAG local + QLoRA)	Combina anclaje factual con adaptadores de bajo rango	Requiere entrenamiento de adaptadores en GPU modesta	Máximo	**Opción adoptada**

La razón principal para descartar el entrenamiento completo como vía principal radica en la **escala de datos y el riesgo de degradación paramétrica**. El trabajo de Ovadia et al. (2024) demostró que, para inyección de conocimiento, RAG superó consistentemente al fine-tuning no supervisado. En lenguas de bajos recursos como el Quechua Collao, el corpus disponible (≈44 263 palabras) es valioso como base documental de referencia, pero insuficiente para sostener un entrenamiento generalizado sin sobreajuste. En cambio, RAG permite alojar el conocimiento factual **fuera de los pesos del modelo**, mientras que los adaptadores QLoRA acondicionan la autoatención del SLM para asimilar el contexto recuperado sin alterar los pesos cuantizados base.

5.2. Factibilidad técnica

Hardware e inferencia local

El archivo GGUF de **Qwen2.5-3B-Instruct en Q4_K_M pesa 2,1 GB** y consume aproximadamente **3 GB de RAM** en ejecución. En una computadora convencional con 8 GB de RAM y tarjeta gráfica modesta (GTX 1050 Ti de 4 GB o CPU pura), esta configuración opera de forma fluida. La inferencia genera entre **10 y 25 tokens/s** en CPU, velocidad adecuada para consultas interactivas. La cuantización y despliegue se realizan con `llama.cpp`, mientras que el entrenamiento de los adaptadores QLoRA requiere únicamente sesiones puntuales en entornos de GPU gratuita (Kaggle / Google Colab con GPU T4).

Estrategia de datos: generación asistida y validación contra corpus

La preparación de datos bilingües español–Quechua Collao se estructura en tres etapas sistemáticas:

1. **Generación asistida con LLMs de frontera:** Se emplean modelos de gran escala para formular pares pregunta-respuesta, definiciones terminológicas y consultas bilingües con respuestas ancladas en Quechua Collao, utilizando prompts con especificaciones dialectales explícitas (variedad Collao de Cusco–Puno, no Chanka) y semillas tomadas de textos normados.

2. **Validación cruzada contra corpus y filtros dialectales:**

   - **Criterio léxico y de raíces ($\geq 95\,\%$):** Las raíces verbales y nominales deben coincidir con entradas del diccionario de Duran and Silberztein (2026) o glosarios normados de la AMLQ.
   - **Criterio ortográfico y dialectal:** Verificación estricta del inventario de oclusivas glotizadas (/p', t', k', q', ch'/) y aspiradas (/ph, th, kh, qh, chh/), descartando grafías de otras variantes (ej. sufijos oclusivos del quechua norteño).
   - **Criterio de alineación semántica (similitud de coseno $\geq 0{,}82$):** Verificación de correspondencia semántica entre el texto en español y quechua mediante embeddings densos (`multilingual-e5-small`).

3. **Limpieza y segmentación en fragmentos (*chunks*):** Los datos validados se normalizan morfosintácticamente y se fragmentan en bloques de 250 a 400 tokens para poblar el índice vectorial RAG.

Tabla 7
Flujo y particionamiento de datos del proyecto

Fuente	**Uso**	**Escala**	**Tratamiento**
Generación con LLM	Pares de ajuste QLoRA y banco RAG	5 000+ pares	Validación cruzada + filtros
Corpus OCR (Orcotoma Mormontoy et al., 2025)	Referencia de validación y semillas	44 263 palabras	Limpieza post-OCR
Glosarios AMLQ y diccionarios	Validación léxica y normalización	Escala léxica	Indexación semántica
Textos bilingües abiertos	Base de conocimiento para RAG	Dominio temático variado	Segmentación (250–400 t)

Inventario de fuentes de datos, repositorios y modelos

La Tabla 8 detalla el inventario de recursos computacionales, modelos y repositorios empleados en la investigación.

Tabla 8
Inventario de fuentes de datos, repositorios y modelos del proyecto

Recurso / Data	Tipo y Alcance	Repositorio / DOI / URL	Archivo / Ruta Local
Corpus Paralelo Quechua Collao	44 263 palabras OCR de libros AMLQ (Orcotoma Mormontoy et al., 2025)	https://aclanthology.org/2025.globalnlp-1.1/ DOI: https://doi.org/10.26615/978-954-452-105-9-001	PDF-Referencias/2025.globalnlp-1.1.pdf
Diccionario Quechua–Español	Gramáticas y léxico formal NooJ (Duran and Silberztein, 2026)	DOI: https://doi.org/10.18653/v1/2026.loresmt-1.9	PDF-Referencias/2026.loresmt-1.9.pdf
Benchmark AmericasNLP	154 000+ pares de entrenamiento MT	GitHub: https://github.com/americasnlp/americasnlp2021	datos/crudos/external/
Corpus Monolingüe Llamacha	Base Quechua Sureño / QuBERT	HF: https://huggingface.co/datasets/Llamacha/monolingual-quechua-iic	datos/crudos/external/
Qwen2.5-3B-Instruct (GGUF)	SLM causal cuantizado Q4_K_M	HF GGUF: https://huggingface.co/Qwen/Qwen2.5-3B-Instruct-GGUF	modelos/gguf/qwen2.5-3b...gguf
multilingual-e5-small	Embeddings densos (384 dim) (Wang et al., 2022)	HF: https://huggingface.co/intfloat/multilingual-e5-small	modelos/embeddings/
Framework Ragas	Métricas automáticas RAG (Es et al., 2024)	GitHub: https://github.com/explodinggradients/ragas	Entorno Python local

Stack tecnológico

El desarrollo se fundamenta en herramientas de código abierto: `llama.cpp` (Gerganov, 2024) para inferencia C++ local cuantizada; FAISS (Johnson et al., 2019) o `sqlite-vec` para almacenamiento vectorial embebido; `multilingual-e5-small` para representaciones densas; y bibliotecas en Python (`peft`, `transformers`, `bitsandbytes`) para el entrenamiento de bajo rango QLoRA.

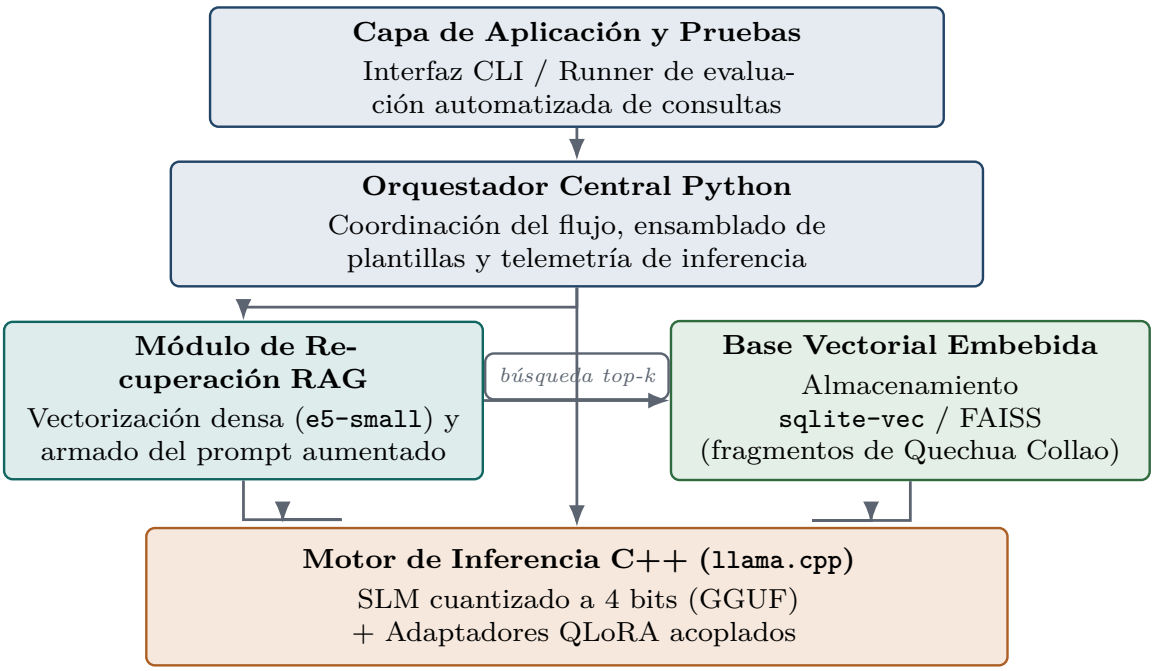


Figura 7
Arquitectura de software modular para inferencia local offline

5.3. Factibilidad legal y de licencias

El proyecto reutiliza modelos y recursos bajo licenciamiento académico y de código abierto permisivo (Apache 2.0, MIT, Creative Commons). El modelo base Qwen2.5 y las librerías del stack (`llama.cpp`, FAISS, Ragas) cuentan con licencias abiertas que admiten investigación. El corpus paralelo (Orcotoma Mormontoy et al., 2025) y los glosarios de la AMLQ se emplean citando la fuente y manteniendo los términos de atribución correspondientes. Al tratarse de un estudio estrictamente computacional basado en datos públicos y generación controlada sin participación de sujetos humanos ni recolección de datos personales, no existen restricciones de confidencialidad ni bioética humana.

5.4. Factibilidad operativa y gestión del alcance

La factibilidad operativa es alta: el artefacto es un **sistema de software autónomo y local** que no requiere trámites burocráticos externos, acceso a bases de datos protegidas ni convenios interinstitucionales. Toda la experimentación, medición y validación se realiza mediante scripts de benchmarking reproducibles.

Tabla 9
Riesgos computacionales y estrategias de mitigación

Factor de riesgo	Mitigación
Calidad de pares bilingües generados	Validación cruzada automatizada (léxica, ortográfica y similitud semántica $\geq 0{,}82$).
Contaminación o mezcla dialectal	Etiquetado estricto por variante; descarte de patrones ortográficos ajenos al Quechua Collao.
Consumo de memoria en CPU local	Segmentación de fragmentos cortos (250–400 tokens) y *top-k* acotado a 3 fragmentos.

5.5. Estructuración de la base de conocimiento y metadatos

La base de conocimiento RAG se construye a partir de fuentes documentales normalizadas en Quechua Collao:

- **Corpus paralelo formalizado:** Fragmentos extraídos de publicaciones académicas de la AMLQ y corpus bilingües validados.
- **Diccionarios y formalismos léxicos:** Entradas normalizadas derivadas del trabajo de Duran and Silberztein (2026) y glosarios oficiales.
- **Pares pregunta-respuesta aumentados:** Consultas representativas con evidencia contextual curada en Quechua Collao.

Cada fragmento (*chunk*) indexado en la base de datos vectorial incorpora metadatos computacionales estructurados: longitud en tokens, identificador de fuente, variante dialectal etiquetada y vector de incrustación normalizado, permitiendo un filtrado y ordenamiento determinístico durante la recuperación.

5.6. Diseño experimental

La investigación compara directamente las **tres configuraciones básicas** declaradas:

Tabla 10
Configuraciones del diseño experimental

ID	Configuración	Propósito Experimental
E1	SLM base cuantizado sin RAG	Establecer la línea base de capacidad paramétrica del modelo sin contexto externo.
E2	SLM base + RAG local estándar	Medir el impacto directo de la inyección de contexto documental (*vanilla RAG*).
E3	SLM con QLoRA + RAG	Evaluar el impacto de los adaptadores QLoRA en proyecciones de atención para asimilar el RAG.

El corpus se distribuye en tres particiones disjuntas:

1. *Ingesta RAG* (≈70 %): fragmentos indexados en la base vectorial para E2 y E3.
2. *Entrenamiento QLoRA* (≈20 %): pares bilingües con contexto empleado para adaptar las proyecciones de atención en E3.
3. *Banco de Evaluación* (≈10 %): 100 consultas patrón con ground-truth no expuestas en el entrenamiento ni indexación.

Métricas de evaluación computacional

La evaluación se ejecuta de forma automatizada y sin intervención subjetiva mediante métricas objetivas (Tabla 11).

Tabla 11
Métricas de evaluación computacional del proyecto

Dimensión	Métrica	Herramienta / Instrumento
Eficiencia de hardware	Latencia (ms), TPS, RAM/VRAM (GB)	`llama.cpp` telemetría y `psutil`
Calidad de lenguaje (PLN)	chrF++, SacreBLEU, Perplejidad (PPL)	Librería `sacrebleu` y `llama-perplexity`
Fidelidad RAG	*Faithfulness*, *Context Precision*, *Relevancy*	Framework automatizado Ragas (Es et al., 2024)

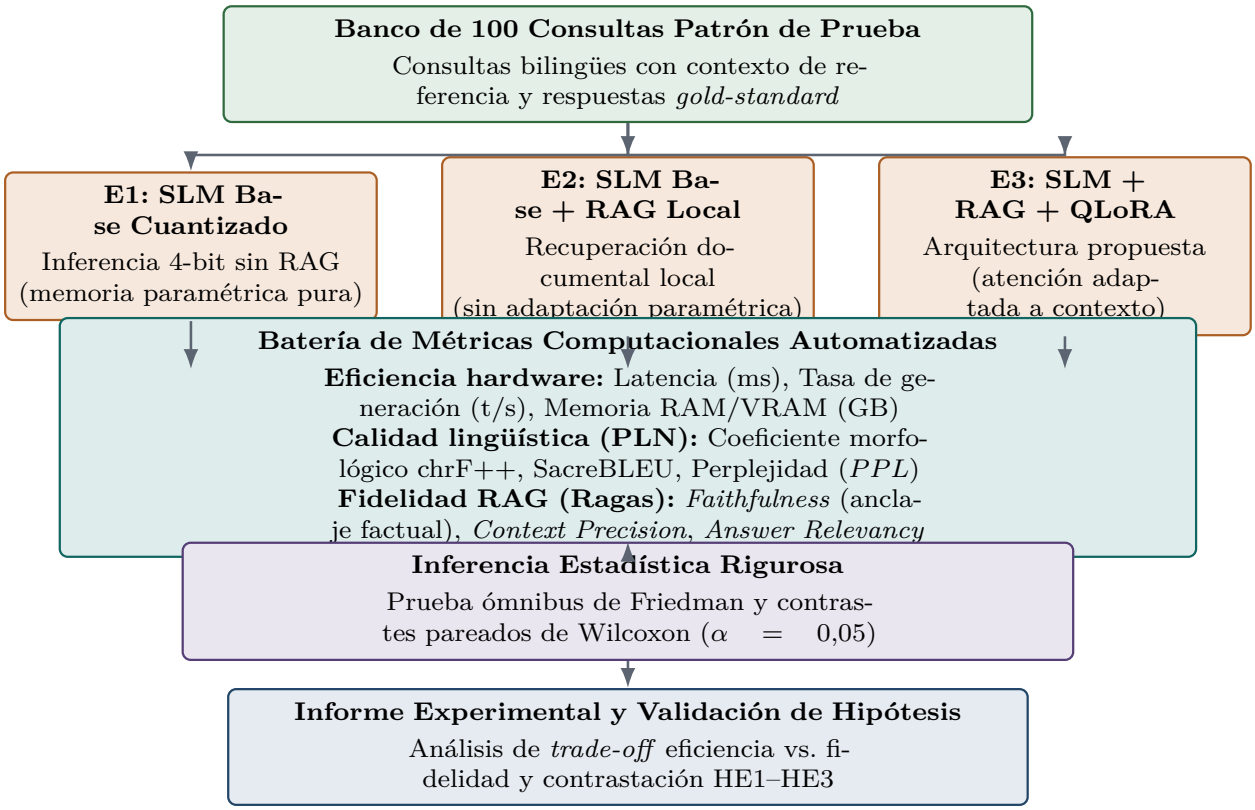


Figura 8
Pipeline del diseño experimental y protocolo de evaluación computacional (E1–E3)

5.7. Semáforo de riesgo

Tabla 12
Semáforo de riesgo técnico y operativo

Dimensión	Nivel	Justificación
Técnica (hardware e inferencia)	**VERDE**	Modelos compactos y cuantización 4 bits verificados con `llama.cpp` en CPU.
Económica	**VERDE**	Cero costos de API o servidores; marcos de software libre.
Diseño experimental	**VERDE**	Protocolo E1–E3 ejecutable en hardware local y GPU gratuita (Kaggle/Colab).
Datos (corpus Quechua Collao)	**VERDE**	Mitigado mediante generación controlada y triple filtro de validación cruzada.
Operativa y de licencias	**VERDE**	Autonomía total sin dependencias burocráticas; benchmarks y código abiertos.
GLOBAL	**VERDE**	**Proyecto completamente viable en el ámbito de Ciencia de la Computación e IA.**

5.8. Conclusión de viabilidad

El proyecto es plenamente viable con recursos propios y hardware accesible. La decisión de acoplar un SLM cuantizado con RAG local y adaptación de matrices de atención mediante QLoRA garantiza un aporte científico riguroso, reproducible y alineado al perfil profesional de la Ingeniería Informática y de Sistemas.

6. Aspectos Administrativos

6.1. Viabilidad y sostenibilidad del proyecto

El proyecto es totalmente viable en los aspectos técnico, computacional y operativo:

- **Viabilidad técnica:** Los experimentos se ejecutan de manera 100 % autolocal en hardware de consumo accesible (computadora convencional con CPU de gama media, 8 GB RAM y acelerador modesto $\leq$ 4 GB de VRAM, ejecutable vía `llama.cpp` cuantizado a 4 bits). No se requiere infraestructura de servidor dedicada ni clusters de alta gama.
- **Viabilidad económica:** Se utilizan modelos de código abierto (Qwen2.5-3B-Instruct) bajo licencias comunitarias permisivas y marcos de desarrollo de código libre. El costo recurrente por consumo de APIs en la nube es \$0,00.
- **Viabilidad operativa:** Al operar sin conexión a internet y basarse en datos abiertos y generación controlada reproducible, el proyecto no depende de trámites burocráticos, permisos institucionales ni trabajo de campo con sujetos humanos.
- **Sostenibilidad lingüística:** La curación e indización bilingüe (español–Quechua Collao) respetan el marco normativo ortográfico y protegen el patrimonio lingüístico mediante herramientas abiertas e independientes de plataformas propietarias.

6.2. Cronograma de actividades (DSR)

El plan de trabajo comprende un período de 6 meses (M1–M6, agosto 2026 – enero 2027) organizado en seis fases metodológicas bajo el enfoque *Design Science Research* (DSR).

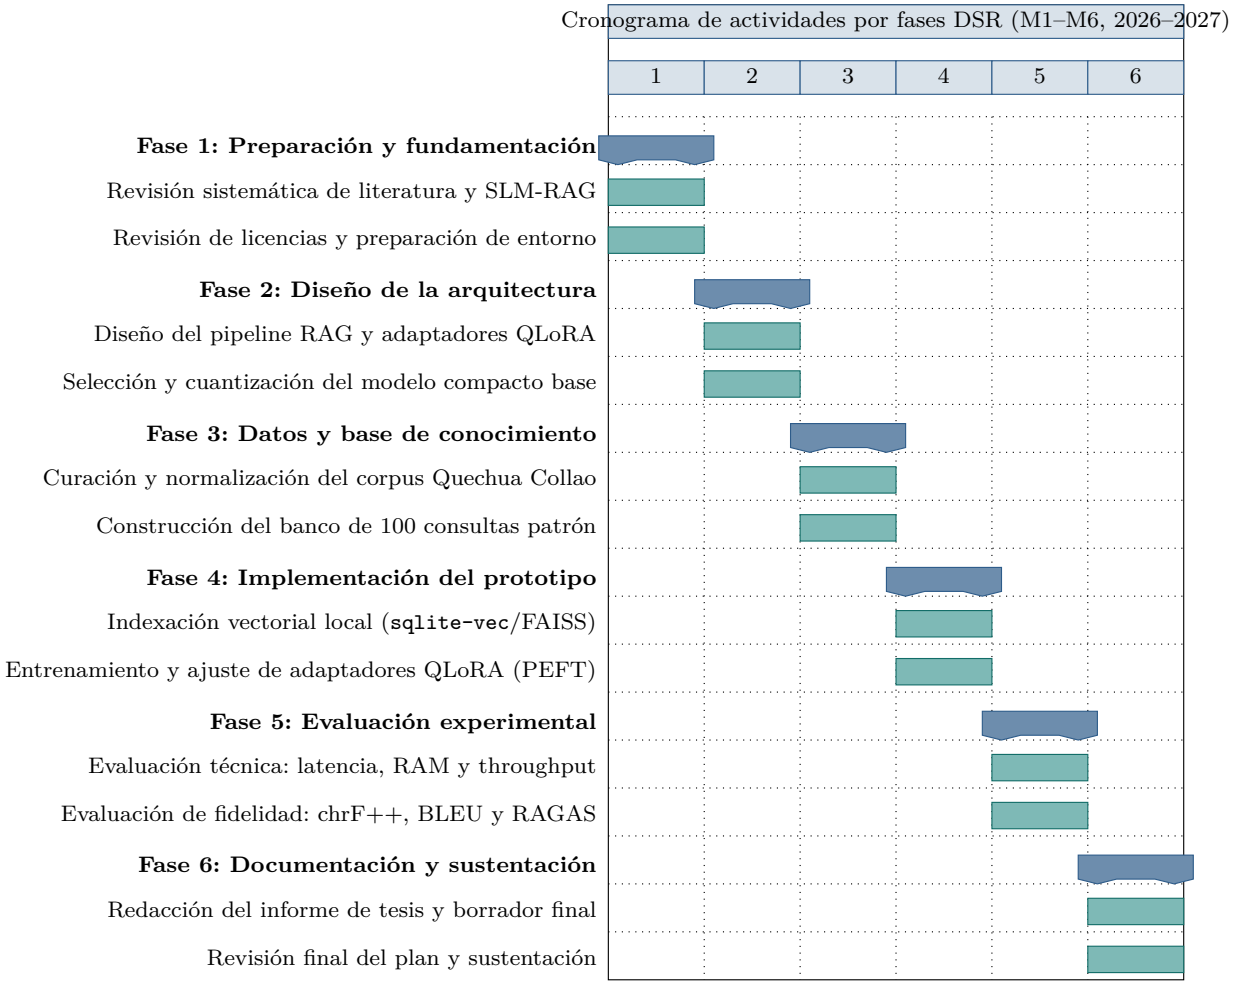


Figura 9

Diagrama de Gantt del cronograma de actividades por fases DSR (6 Meses)

Tabla 13
Cronograma de actividades por fases DSR y períodos calendario (6 Meses, 2026–2027)

Fase / Actividad	Período Calendario	Meses
Fase 1: Preparación y fundamentación		
Revisión sistemática de literatura y SLM-RAG	Agosto 2026	M1
Revisión de licencias y preparación de entorno	Agosto 2026	M1
Fase 2: Diseño de la arquitectura		
Diseño del pipeline RAG y adaptadores QLoRA	Septiembre 2026	M2
Selección y cuantización del modelo compacto base (Qwen2.5-3B)	Septiembre 2026	M2
Fase 3: Datos y base de conocimiento		
Curación y normalización del corpus Quechua Collao	Octubre 2026	M3
Construcción del banco de 100 consultas patrón y ground-truth	Octubre 2026	M3
Fase 4: Implementación del prototipo		
Indexación vectorial local (`sqlite-vec` / FAISS)	Noviembre 2026	M4
Entrenamiento y ajuste de adaptadores QLoRA (PEFT)	Noviembre 2026	M4
Fase 5: Evaluación experimental		
Evaluación técnica de hardware (latencia, RAM, tokens/s)	Diciembre 2026	M5
Evaluación computacional de fidelidad (chrF++, BLEU, RAGAS)	Diciembre 2026	M5
Fase 6: Documentación y sustentación		
Redacción del informe de tesis y borrador final	Enero 2027	M6
Revisión final del plan y sustentación	Enero 2027	M6

6.3. Estructura tentativa del informe de tesis

La memoria final de tesis se estructurará conforme a la directiva de la Facultad de Ingeniería Eléctrica, Electrónica, Informática y Mecánica de la UNSAAC:

1. **Capítulo I: Introducción.** Planteamiento del problema de ingeniería, formulación de preguntas de investigación, objetivos (general y específicos), hipótesis y justificación (técnica, científica y metodológica).

2. **Capítulo II: Marco Teórico y Estado del Arte.** Fundamentos de modelos de lenguaje compactos (SLM), cuantización (GGUF, 4 bits), generación aumentada por recuperación (RAG), mecanismos de atención Transformer, adaptadores de bajo rango (LoRA/QLoRA), procesamiento de lenguaje natural en Quechua Collao y revisión crítica de trabajos previos.

3. **Capítulo III: Metodología y Diseño de la Arquitectura.** Aplicación del marco DSR, arquitectura del pipeline offline, enrutamiento bilingüe, indexación vectorial local,

entrenamiento de adaptadores QLoRA y diseño del benchmark de evaluación.

4. **Capítulo IV: Implementación Computacional.** Detalles de ingeniería del sistema, cuantización del modelo Qwen2.5-3B, configuración de almacenamiento vectorial embebido y pipeline de inferencia con `llama.cpp`.

5. **Capítulo V: Resultados y Evaluación Experimental.** Presentación de resultados cuantitativos: eficiencia en hardware (latencia, TPS, RAM/VRAM), métricas de PLN (chrF++, BLEU, perplejidad), métricas Ragas (*faithfulness*, *context recall*), análisis comparativo de configuraciones E1, E2 y E3, e inferencia estadística (Friedman / Wilcoxon).

6. **Capítulo VI: Conclusiones y Trabajos Futuros.** Síntesis de hallazgos computacionales, lecciones aprendidas sobre adaptadores QLoRA en lenguas aglutinantes de bajos recursos y recomendaciones técnicas de escalabilidad.

Bibliografía

Chen, Z., Liu, J., Dong, R., and Mao, H. (2024). Queen: Leveraging rag and llm-based agents for quechua-english translation. In *Proceedings of the Conference on Machine Translation*. Disponible en: https://aclanthology.org/2024.wmt-1.126/.

Court, S. and Elsner, M. (2024). Shortcomings of llms for low-resource translation: Retrieval and understanding are both the problem. In *Proceedings of the Conference on Machine Translation*. Disponible en: https://aclanthology.org/2024.wmt-1.125/.

Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. (2023). Qlora: Efficient finetuning of quantized language models. *Advances in Neural Information Processing Systems*, 36. Disponible en: https://arxiv.org/abs/2305.14314.

Duran, M. and Silberztein, M. (2026). Semi-automatic construction of a quechua-spanish dictionary. In *Proceedings for the Ninth Workshop on Technologies for Machine Translation of Low Resource Languages*, pages 111–118. DOI: https://doi.org/10.18653/v1/2026.loresmt-1.9.

Es, S., James, J., Espinosa-Anke, L., and Schockaert, S. (2024). Ragas: Automated evaluation of retrieval augmented generation. *arXiv preprint*. Disponible en: https://arxiv.org/abs/2309.15217.

Gerganov, G. (2024). llama.cpp: Inference of llama model in pure c/c++. https://github.com/ggerganov/llama.cpp.

Hevia, J. S., Arredondo, F., and Kumar, V. (2025). Towards an efficient, customizable, and accessible ai tutor. *arXiv preprint*. Disponible en: https://arxiv.org/abs/2510.06255.

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., and Chen, W. (2022). Lora: Low-rank adaptation of large language models. In *International Conference on Learning Representations*. Disponible en: https://arxiv.org/abs/2106.09685.

Johnson, J., Douze, M., and Jégou, H. (2019). Billion-scale similarity search with gpus. *IEEE Transactions on Big Data*, 7(3):535–547.

Li, Z., Wang, Z., Wang, W., Hung, K., Xie, H., and Wang, F. L. (2025). Retrieval-augmented generation for educational application: A systematic survey. *Computers and Education: Artificial Intelligence*. DOI: https://doi.org/10.1016/j.caeai.2025.100417.

Orcotoma Mormontoy, G. C., Leon Nuñez, L., and Espetia Huamanga, H. (2025). Towards the creation of a collao quechua-spanish parallel corpus using optical character recognition. In *Proceedings of the Workshop on Beyond English*. Disponible en: https://aclanthology.org/2025.globalnlp-1.1/.

Ovadia, O., Brief, M., Mishaeli, M., and Sigal, O. (2024). Fine-tuning or retrieval? comparing knowledge injection in llms. *arXiv preprint*. Disponible en: https://arxiv.org/abs/2312.05934.

Sulla Torres, J. A., Cueva Medina, B., and Tuco Casquino, G. F. (2024). Development of a neural machine translation model optimized with bert for translation from quechua to spanish. In *LACCEI*. DOI: https://doi.org/10.18687/LACCEI2024.1.1.1636.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30. Disponible en: https://arxiv.org/abs/1706.03762.

Walusimbi, J., Oguti, A. M., Ssentongo, J. B., and Ainebyona, K. (2026). Arapai: An offline-first ai chatbot architecture for low-connectivity educational environments. *arXiv preprint*. Disponible en: https://arxiv.org/abs/2603.03339.

Wang, L., Yang, N., Huang, X., Yang, L., Jiang, D., Bhalerao, R., and Zhou, M. (2022). Text embeddings by weakly-supervised contrastive pre-training. *arXiv preprint arXiv:2212.03533*.

Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., and Ling, Z. (2024). On-device language models: A comprehensive review. *arXiv preprint*. Disponible en: https://arxiv.org/abs/2409.00088.

Yang, A., Yang, B., Hui, B., Zheng, B., Yu, B., Zhou, C., Li, C., Li, C., Liu, D., Huang, F., et al. (2024). Qwen2.5 technical report. *arXiv preprint*. Disponible en: https://arxiv.org/abs/2412.15115.

Zhang, T., Patil, S. G., Jain, N., Shen, S., Zaharia, M., Stoica, I., and Gonzalez, J. E. (2024). Raft: Adapting language model to domain specific rag. *arXiv preprint*. Disponible en: https://arxiv.org/abs/2403.10131.

Anexo: Fichas de Análisis

A continuación, se presentan las fichas de análisis de las nueve fuentes más relevantes para la investigación, las cuales sustentan críticamente el estado del arte y el marco conceptual de la arquitectura SLM–RAG propuesta. Cada ficha ha sido elaborada siguiendo la estructura metodológica exigida por la guía de trabajo del seminario.

Ficha 1: Orcotoma Mormontoy et al. (2025)

1. REFERENCIA COMPLETA (APA 7): Orcotoma Mormontoy, G. C., Leon Nuñez, L., & Espetia Huamanga, H. (2025). Towards the Creation of a Collao Quechua-Spanish Parallel Corpus Using Optical Character Recognition. *Proceedings of the Workshop on Beyond English*, 1-6. https://doi.org/10.26615/978-954-452-105-9-001

2. TIPO DE DOCUMENTO: Artículo de conferencia científica

3. OBJETIVO O PREGUNTA DEL ESTUDIO: Construir un corpus paralelo Quechua Collao-español utilizando reconocimiento óptico de caracteres (OCR) para superar la escasez de recursos digitales en esta lengua de bajos recursos.

4. METODOLOGÍA: Enfoque tecnológico. Digitación y procesamiento (filtros de mediana y binarización) de libros de grado de la Academia Mayor de la Lengua Quechua, seguido de extracción de texto con Tesseract OCR y evaluación mediante Character Error Rate (CER) y Word Error Rate (WER) frente a un texto validado manualmente (ground truth).

5. RESULTADOS PRINCIPALES: Se construyó un corpus de 44 263 palabras (18 179 en quechua y 26 084 en español). La evaluación del OCR mostró un CER de 1,82 % y un WER de 6,59 %, demostrando la viabilidad de la extracción automática con posprocesamiento.

6. CONCLUSIONES DEL AUTOR: El uso de OCR es viable para crear corpus paralelos en Quechua Collao si se aplican métodos adecuados de preprocesamiento, lo que proporciona una metodología valiosa para preservar la lengua y entrenar futuras tecnologías NLP.

7. LIMITACIONES DEL ESTUDIO: El corpus resultante contiene cierto nivel de ruido ortográfico derivado del proceso OCR dado que no se implementó un posprocesamiento de corrección automática profunda, además de estar limitado en escala léxica (44 263 palabras) frente a lenguas mayoritarias.

8. RELEVANCIA PARA MI TESIS: Es un antecedente directo para la obtención de datos de entrenamiento y evaluación. Justifica la delimitación del proyecto al Quechua Collao al confirmar la existencia de recursos paralelos validados procedentes de la Academia Mayor de la Lengua Quechua.

9. CITAS TEXTUALES ÚTILES: "The importance of the result of this study lies in providing a methodology for the development of new technologies that require Collao Quechua-Spanish parallel corpora, such as automatic translators and sentence autocompletion systems" (p. 1).

10. PALABRAS CLAVE ASIGNADAS: Corpus paralelo, OCR, Quechua Collao, NLP de bajos recursos.

Ficha 2: Court & Elsner (2024)

1. **REFERENCIA COMPLETA (APA 7):** Court, S., & Elsner, M. (2024). Shortcomings of LLMs for Low-Resource Translation: Retrieval and Understanding Are Both the Problem. *Proceedings of the Ninth Conference on Machine Translation*, 1332-1354.

2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica

3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Investigar las habilidades de aprendizaje en contexto de Grandes Modelos de Lenguaje (LLMs) al traducir desde una lengua de bajos recursos (quechua sureño) hacia el español, utilizando información recuperada de diccionarios, gramáticas y corpus.

4. **METODOLOGÍA:** Experimental cuantitativa. Se evaluó la salida de cuatro LLMs (GPT-3.5, GPT-4o, Gemini 1.5, Llama 3) bajo ocho condiciones de prompt que combinaban información de morfemas, gramática y ejemplos de corpus, usando métricas automáticas (BLEURT, BLEU) y anotación humana de errores.

5. **RESULTADOS PRINCIPALES:** La inclusión de traducciones a nivel de morfema mejora el rendimiento de los modelos más pequeños. Sin embargo, en modelos más avanzados (GPT-4o), añadir contexto gramatical o de corpus reduce los puntajes BLEURT y aumenta la divergencia gramatical.

6. **CONCLUSIONES DEL AUTOR:** Incluso explicaciones gramaticales relevantes ayudan poco a las generaciones más recientes de LLMs en tareas de bajos recursos. Las traducciones infieles suelen ser engañosamente fluidas en español, y en ocasiones introducen estereotipos culturales no presentes en la frase original.

7. **LIMITACIONES DEL ESTUDIO:** La evaluación se restringió al uso de APIs comerciales basadas en la nube bajo esquemas de prompting (in-context learning), sin analizar el rendimiento de modelos compactos locales (SLM) cuantizados ni restricciones de latencia offline.

8. **RELEVANCIA PARA MI TESIS:** Demuestra que no basta con usar la técnica RAG para inyectar reglas gramaticales en un modelo genérico. Justifica la necesidad de afinar o cuantizar un Small Language Model especializado en lugar de depender únicamente del aprendizaje en contexto de un modelo en la nube.

9. **CITAS TEXTUALES ÚTILES:** "providing additional information in the prompt's context actually degrades GPT-4o's ability to translate from S. Quechua to Spanish in all experimental conditions" (p. 7).

10. **PALABRAS CLAVE ASIGNADAS:** LLMs, Quechua sureño, RAG, traducción automática, aprendizaje en contexto.

Ficha 3: Walusimbi et al. (2026)

1. **REFERENCIA COMPLETA (APA 7):** Walusimbi, J., Oguti, A. M., Ssentongo, J. B., & Ainebyona, K. (2026). Arapai: An Offline-First AI Chatbot Architecture for Low-Connectivity Educational Environments. *arXiv preprint arXiv:2603.03339*.

2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)

3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Diseñar y evaluar una arquitectura de LLM orientada a operar sin conexión a internet (offline-first) para asistencia educativa en entornos con baja conectividad.

4. **METODOLOGÍA:** Investigación aplicada. Se implementaron modelos cuantizados (TinyLlama, Qwen2.5-3B, Mistral-7B) ejecutados localmente en CPU. El sistema adaptativo fue evaluado cualitativa y cuantitativamente con más de 120 usuarios en condiciones reales.

5. **RESULTADOS PRINCIPALES:** El sistema operó de forma estable en hardware heredado (CPU). Las consultas instructivas típicas mostraron latencias de respuesta de 1 a 3 segundos. Los usuarios reportaron una alta utilidad para el aprendizaje autodirigido a diferentes niveles de complejidad.

6. **CONCLUSIONES DEL AUTOR:** Es viable desplegar asistentes educativos basados en IA en contextos con limitaciones de infraestructura utilizando LLMs cuantizados que se ejecutan localmente, ofreciendo una alternativa confiable a los sistemas que dependen de la nube.

7. **LIMITACIONES DEL ESTUDIO:** El prototipo fue evaluado exclusivamente con contenido bilingüe en inglés, por lo que el estudio no aborda las particularidades de tokenización, morfología aglutinante ni la variabilidad dialectal de lenguas indígenas.

8. **RELEVANCIA PARA MI TESIS:** Es el principal antecedente arquitectónico. Valida la hipótesis de que los modelos cuantizados ejecutados en CPU son suficientemente rápidos y útiles para aplicaciones de inferencia offline en zonas sin conectividad.

9. **CITAS TEXTUALES ÚTILES:** "The system performs all inference locally using quantized language models and incorporates hardware-aware model selection to enable deployment on low-specification, CPU-only devices" (p. 1).

10. **PALABRAS CLAVE ASIGNADAS:** Aquitectura offline-first, IA educativa, modelos cuantizados, edge AI.

Ficha 4: Xu et al. (2024)

1. **REFERENCIA COMPLETA (APA 7):** Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., & Ling, Z. (2024). On-Device Language Models: A Comprehensive Review. *arXiv preprint arXiv:2409.00088*.

2. **TIPO DE DOCUMENTO:** Artículo de revisión (Survey)

3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Examinar los desafíos de desplegar LLMs computacionalmente costosos en dispositivos con recursos limitados y explorar las soluciones innovadoras en múltiples dominios.

4. **METODOLOGÍA:** Revisión sistemática de literatura sobre arquitecturas eficientes de modelos de lenguaje en dispositivos (on-device), analizando técnicas de compresión de modelos, aceleración de hardware y despliegue colaborativo borde-nube.

5. **RESULTADOS PRINCIPALES:** Se identifican tres estrategias clave para habilitar modelos en dispositivos: compartición de parámetros, cuantización (PTQ y QAT) para reducir bits de peso/activación, y destilación de conocimiento. La cuantización int4/int8 resulta esencial para procesadores móviles.

6. **CONCLUSIONES DEL AUTOR:** La transición de la nube al borde (edge) reduce latencia y aumenta privacidad, pero requiere un equilibrio delicado entre el rendimiento del modelo (precisión) y la utilización de recursos (memoria y energía) que solo se logra combinando múltiples técnicas de compresión.

7. **LIMITACIONES DEL ESTUDIO:** Al ser un artículo de revisión general (survey), carece de una propuesta arquitectónica propia o experimentación de campo aplicada al procesamiento de lenguas minoritarias y aglutinantes.

8. **RELEVANCIA PARA MI TESIS:** Proporciona el marco teórico tecnológico sobre Small Language Models y cuantización que fundamenta el diseño de la arquitectura SLM–RAG offline para hardware de bajo costo.

9. **CITAS TEXTUALES ÚTILES:** "deploying computationally expensive LLMs on resource-constrained devices poses significant challenges. The primary obstacles include limited computational power, reduced memory capacity, and energy constraints" (p. 2).

10. **PALABRAS CLAVE ASIGNADAS:** On-Device AI, cuantización, compresión de modelos, Small Language Models.

Ficha 5: Hevia et al. (2025)

1. **REFERENCIA COMPLETA (APA 7):** Hevia, J. S., Arredondo, F., & Kumar, V. (2025). Towards an Efficient, Customizable, and Accessible AI Tutor. *arXiv preprint arXiv:2510.06255*.

2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)

3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Proponer un sistema tutorial de IA fuera de línea (offline) basado en Generación Aumentada por Recuperación (RAG) emparejado con un Small Language Model (SLM) para entornos de bajos recursos.

4. **METODOLOGÍA:** Experimental cuantitativa. Evaluación de modelos de la familia SmolLM (135M y 1.7B) y RAG con libros de texto de biología de OpenStax usando métricas del benchmark MMLU para evaluar el impacto del contexto en la precisión de respuesta.

5. **RESULTADOS PRINCIPALES:** Contrario a lo esperado, la inclusión de recuperación RAG en SLMs disminuyó drásticamente la precisión en el MMLU para el modelo SmolLM2-1,7B (de 41,00 % a 33,04 % con RAG), mientras que los modelos de 135M solo mostraron una variación mínima marginal (de 21,59 % a 21,81 % con RAG en SmolLM2-135M), lo que evidencia la incapacidad de estos modelos pequeños para manejar ventanas de contexto extendidas y ruidosas.

6. **CONCLUSIONES DEL AUTOR:** Los Small Language Models luchan por aprovechar efectivamente el contexto extendido provisto por RAG, especialmente si los fragmentos contienen información irrelevante. Es crítico usar técnicas avanzadas de *"chunking"* (fragmentación semántica) y métricas de evaluación holísticas más allá de opciones múltiples.

7. **LIMITACIONES DEL ESTUDIO:** La fragmentación (chunking) documental fue simplista (corte de tokens estático), introduciendo ruido, y la evaluación de precisión se restringió al benchmark de opciones múltiples MMLU, sin examinar respuestas de texto libre.

8. **RELEVANCIA PARA MI TESIS:** Alerta sobre los riesgos de usar arquitectura RAG simple con SLMs sin adaptar. Justifica la necesidad de adaptadores QLoRA orientados a la asimilación del contexto y una segmentación cuidadosa de los fragmentos documentales para evitar introducir ruido en la consulta.

9. **CITAS TEXTUALES ÚTILES:** "smaller models, such as SmolLM, struggle to effectively leverage extended contexts provided by the RAG pipeline, particularly when noisy or irrelevant chunks are included" (p. 1).

10. **PALABRAS CLAVE ASIGNADAS:** RAG, AI Tutor, Small Language Model, educación fuera de línea.

Ficha 6: Chen et al. (2024)

1. **REFERENCIA COMPLETA (APA 7):** Chen, Z., Liu, J., Dong, R., & Mao, H. (2024). QueEn: Leveraging RAG and LLM-Based Agents for Quechua-English Translation. *Proceedings of the Conference on Machine Translation.* https://aclanthology.org/2024.wmt-1.126/

2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica

3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Mejorar la traducción automática quechua–inglés mediante un sistema multi-agente que combina RAG sobre recursos lingüísticos con adaptación paramétrica ligera (LoRA).

4. **METODOLOGÍA:** Experimental cuantitativa. Implementación de un pipeline multi-agente que integra recuperación de diccionarios y reglas gramaticales con ajuste LoRA sobre un modelo base. Evaluación con BLEU y chrF++ sobre conjuntos de prueba estándar de WMT.

5. **RESULTADOS PRINCIPALES:** La hibridación de RAG con LoRA elevó el puntaje BLEU de 1,5 (línea base sin contexto) a 17,6, demostrando que la combinación de RAG con adaptación paramétrica ligera produce mejoras significativas para lenguas de bajos recursos.

6. **CONCLUSIONES DEL AUTOR:** La combinación de agentes RAG especializados con ajuste paramétrico ligero supera significativamente tanto al prompting directo como al RAG puro para traducción de lenguas de bajos recursos como el quechua.

7. **LIMITACIONES DEL ESTUDIO:** Se enfoca en un sistema puramente orientado a la traducción de oraciones quechua-inglés en un canal online, sin abordar la optimización para hardware offline local ni la integración de modelos compactos de inferencia CPU.

8. **RELEVANCIA PARA MI TESIS:** Es el antecedente más directo del enfoque híbrido propuesto. Valida empíricamente que la arquitectura RAG + LoRA es la vía más prometedora para el quechua, fundamentando la decisión de combinar RAG disciplinado con adaptadores QLoRA para Quechua Collao.

9. **CITAS TEXTUALES ÚTILES:** "Our system integrates dictionary-based retrieval, grammar rule application, and fine-tuned translation models to handle the morphological complexity of Quechua" (p. 1).

10. **PALABRAS CLAVE ASIGNADAS:** RAG, LoRA, quechua, traducción automática, sistema multi-agente.

Ficha 7: Zhang et al. (2024)

1. **REFERENCIA COMPLETA (APA 7):** Zhang, T., Patil, S. G., Jain, N., Shen, S., Zaharia, M., Stoica, I., & Gonzalez, J. E. (2024). RAFT: Adapting Language Model to Domain Specific RAG. *arXiv preprint arXiv:2403.10131*.

2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)

3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Proponer un método de ajuste fino que enseña a los modelos de lenguaje a usar el contexto RAG de forma resiliente, distinguiendo fragmentos relevantes de distractores.

4. **METODOLOGÍA:** Experimental cuantitativa. Entrenamiento de modelos con datasets que incluyen documentos relevantes mezclados con distractores, evaluando la capacidad del modelo para generar respuestas ancladas únicamente en la evidencia pertinente.

5. **RESULTADOS PRINCIPALES:** RAFT mejoró consistentemente el rendimiento en benchmarks de dominio específico frente a tanto RAG puro como fine-tuning sin contexto, demostrando que entrenar al modelo a "ignorar distractores" es tan importante como entrenarle a "usar contexto".

6. **CONCLUSIONES DEL AUTOR:** La combinación de fine-tuning con entrenamiento en presencia de distractores produce modelos más robustos para aplicaciones RAG de dominio específico.

7. **LIMITACIONES DEL ESTUDIO:** El método exige realizar un ajuste fino supervisado completo (SFT) sobre los pesos del modelo, lo que implica requerimientos de cómputo elevados (múltiples GPUs comerciales de alta gama) inviables para despliegues locales sencillos.

8. **RELEVANCIA PARA MI TESIS:** Fundamenta teóricamente la capa de adaptación ligera del enfoque híbrido: los adaptadores QLoRA deben acondicionar al modelo a extraer evidencia fidedigna del contexto y distinguir fragmentos dialectalmente correctos (Collao) de distractores.

9. CITAS TEXTUALES ÚTILES: "RAFT learns to ignore distractor documents and cite the relevant sequence from the oracle document to generate the answer" (p. 3).

10. PALABRAS CLAVE ASIGNADAS: RAFT, RAG, fine-tuning, distractores, adaptación de dominio.

Ficha 8: Sulla-Torres et al. (2024)

1. REFERENCIA COMPLETA (APA 7): Sulla Torres, J. A., Cueva Medina, B., & Tuco Casquino, G. F. (2024). Development of a Neural Machine Translation Model Optimized with BERT for Translation from Quechua to Spanish. *LACCEI*, 1-10.

2. TIPO DE DOCUMENTO: Artículo de conferencia científica

3. OBJETIVO O PREGUNTA DEL ESTUDIO: Optimizar la traducción automática neuronal del quechua al español utilizando un modelo neural optimizado mediante codificadores semánticos (BERT).

4. METODOLOGÍA: Enfoque neuronal profundo. Se realizó un ajuste fino de un codificador bilingüe BERT sobre un corpus estructurado quechua-español y se evaluó su desempeño mediante métricas estándar de traducción automática (BLEU).

5. RESULTADOS PRINCIPALES: Se obtuvo un puntaje BLEU de 20,13 para la dirección quechua a español, considerado aceptable pero evidenciando las limitaciones impuestas por la escasez de pares de oraciones paralelas.

6. CONCLUSIONES DEL AUTOR: El uso de arquitecturas basadas en BERT es viable para tareas de procesamiento morfosintáctico de lenguas indígenas, pero los resultados están condicionados críticamente por el volumen y representatividad del corpus.

7. LIMITACIONES DEL ESTUDIO: El modelo requiere un corpus paralelo grande y balanceado para el entrenamiento de los pesos, no contempla el translengüaje dinámico y posee requerimientos de procesamiento medios en hardware CPU.

8. RELEVANCIA PARA MI TESIS: Es el principal antecedente empírico de traducción neuronal quechua-español. Valida la hipótesis de que las técnicas basadas únicamente en traducción automática pura sufren ante la escasez de datos, lo que justifica la adopción de un enfoque híbrido de SLM + RAG.

9. CITAS TEXTUALES ÚTILES: "The model optimized with BERT reached a BLEU score of 20.13, showing that deep learning architectures are viable for low-resource languages but are highly constrained by the available vocabulary size" (p. 5).

10. PALABRAS CLAVE ASIGNADAS: Traducción automática neuronal, BERT, quechua, escasez de datos.

Ficha 9: Duran & Silberztein (2026)

1. **REFERENCIA COMPLETA (APA 7):** Duran, M., & Silberztein, M. (2026). Semi-automatic Construction of a Quechua-Spanish Dictionary. *Proceedings for the Ninth Workshop on Technologies for Machine Translation of Low Resource Languages*, 111-118.

2. **TIPO DE DOCUMENTO:** Artículo de taller científico (Workshop)

3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Proponer un método semi-automático para la construcción de diccionarios quechua-español utilizando formalismos lingüísticos estructurados.

4. **METODOLOGÍA:** Aplicación de reglas y formalismos de procesamiento léxico en la plataforma NooJ para procesar textos, aislar raíces de sufijos flexivos y generar correspondencias bilingües.

5. **RESULTADOS PRINCIPALES:** Se construyó un diccionario léxico estructurado de alta precisión que normaliza variaciones ortográficas y dialectales de las raíces quechua sureñas.

6. **CONCLUSIONES DEL AUTOR:** El uso de formalismos y diccionarios estructurados por reglas es fundamental para el procesamiento de lenguas morfológicamente complejas, mitigando la variabilidad de escritura y la escasez de corpus paralelos.

7. **LIMITACIONES DEL ESTUDIO:** Depende del trabajo manual especializado de expertos lingüistas para estructurar y validar las reglas morfológicas, dificultando su expansión y actualización rápida.

8. **RELEVANCIA PARA MI TESIS:** Proporciona el sustento metodológico para incorporar diccionarios locales y reglas de normalización ortográfica en el preprocesamiento del pipeline RAG, mitigando errores derivados de variaciones ortográficas en las consultas de entrada.

9. **CITAS TEXTUALES ÚTILES:** "Semi-automatic construction of lexicons allows the structuring of rules that handle the morphosyntactic complexity of Quechua, mitigating spelling variations" (p. 2).

10. **PALABRAS CLAVE ASIGNADAS:** Diccionario bilingüe, formalismo lingüístico, NooJ, normalización morfológica.