

UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO
FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA
ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

Diseño y evaluación de un asistente educativo offline español–Quechua Collao basado en un modelo de lenguaje compacto y generación aumentada por recuperación para contextos de Educación Intercultural Bilingüe

Curso:

Seminario de Investigación I

Para optar al Título Profesional de:

Ingeniero Informático y de Sistemas

Presentado por:

Br. Edmil Jampier Saire Bustamante

Br. Haider Alex Carpio Hermoza

Asesora:

Ing. Gabriela Zúñiga Rojas

Cusco – Perú
2026

Resumen

La presente propuesta de plan de tesis aborda la brecha de conectividad y la carencia de recursos tecnológicos adaptados para las lenguas originarias en contextos rurales de Educación Intercultural Bilingüe (EIB). El problema radica en las limitaciones de acceso digital y la falta de herramientas educativas de apoyo pedagógico contextualizadas en lengua materna. Ante este escenario, la investigación plantea diseñar, implementar y evaluar un prototipo de asistente educativo ejecutable de manera local sin conexión a internet. El método propuesto se sustenta en el uso de un modelo de lenguaje compacto cuantizado y una arquitectura de generación aumentada por recuperación, enriquecida con recursos lingüísticos y curriculares locales. La evaluación del prototipo contemplará pruebas de rendimiento técnico, análisis de la calidad lingüística de las respuestas generadas y validación de pertinencia pedagógica mediante juicio de expertos con docentes y especialistas EIB. Se espera que la propuesta represente una contribución tecnológica y social al facilitar el acceso equitativo a recursos de aprendizaje y promover el fortalecimiento de la lengua materna Quechua Collao en zonas rurales.

Palabras clave: Modelo de lenguaje compacto, Generación Aumentada por Recuperación, Educación Intercultural Bilingüe, Quechua Collao, asistencia educativa offline.

Índice general

Resumen	II
Índice general	III
Índice de tablas	V
1. Problema de Investigación	1
1.1. Descripción del problema	1
1.2. Identificación del problema	2
1.3. Formulación del problema	2
2. Justificación	2
3. Alcances y limitaciones	3
3.1. Alcances	3
3.2. Limitaciones	3
4. Objetivos	4
4.1. Objetivo General	4
4.2. Objetivos Específicos	4
4.3. Alineación con los Objetivos de Desarrollo Sostenible	5
5. Estado del arte	6
5.1. Procesamiento de Lenguaje Natural y Traducción Automática para Quechua Collao	6
5.2. Small Language Models y Despliegue Offline	6
5.3. Generación Aumentada por Recuperación (RAG) y Tecnología Educa- tiva con IA	7
5.4. RAG vs. Fine-Tuning y Enfoque Híbrido para Lenguas de Bajos Recursos	7
5.5. Política Educativa y Educación Intercultural Bilingüe en el Perú	7
5.6. Síntesis crítica y vacíos de investigación	8
6. Marco Teórico y Conceptual	8
6.1. Antecedentes de la investigación	8
6.2. Educación Intercultural Bilingüe (EIB)	9
6.3. Quechua Collao: caracterización dialectal	10
6.4. Translenguaje y alternancia de códigos	10
6.5. Procesamiento de Lenguaje Natural en Lenguas de Bajos Recursos	10
6.6. Modelos de lenguaje y arquitectura Transformer	11
6.7. Small Language Models y cuantización	11
6.8. Adaptación ligera: LoRA y QLoRA	13
6.9. RAFT: Retrieval-Augmented Fine-Tuning	13
6.10. Asistentes educativos inteligentes	13
6.11. Generación Aumentada por Recuperación (RAG)	14
6.12. Detección automática de idioma	14
6.13. Evaluación de sistemas educativos con IA	14
7. Metodología	15
7.1. Tipo y diseño de investigación	15
7.2. Metodología de desarrollo	15

7.3.	Población y muestra	15
7.4.	Consideraciones éticas	16
8.	Estudio de Factibilidad	17
8.1.	Justificación del enfoque híbrido	17
8.2.	Factibilidad técnica y de datos	18
8.3.	Factibilidad económica e infraestructura	21
8.4.	Factibilidad operativa y gestión del alcance	22
8.5.	Factibilidad del diseño experimental y la validación	22
8.6.	Semáforo de riesgo tecnológico	25
8.7.	Conclusión de viabilidad	26
9.	Importancia del estudio	26
9.1.	Resultados esperados	26
9.2.	Contribuciones	27
9.3.	Impacto social	27
10.	Cronograma de actividades	27
11.	Presupuesto	29
	Bibliografía	30
	Anexos	33

Índice de tablas

1.	Matriz resumida de antecedentes y aportes a la investigación	9
2.	Modelos candidatos evaluados y de referencia para el asistente <i>offline</i>	12
3.	Matriz comparativa de enfoques para la decisión metodológica	18
4.	Inventario de recursos de datos y su aplicabilidad al proyecto	20
5.	Matriz de viabilidad técnica aplicada al proyecto	21
6.	Factores de riesgo operativo y estrategias de mitigación	22
7.	Diseño experimental escalonado propuesto	23
8.	Framework de métricas de evaluación para el proyecto	24
9.	Semáforo de riesgo por dimensión	25
10.	Cronograma de actividades por fases y meses	28
11.	Presupuesto estimado del proyecto	29

1. Problema de Investigación

1.1. Descripción del problema

A nivel global, la educación en lenguas indígenas y minoritarias enfrenta una brecha tecnológica persistente. Más de la mitad de los niños en edad escolar no aprende en su lengua materna durante los primeros años de escolaridad, lo que afecta negativamente su comprensión lectora, su identidad cultural y sus trayectorias educativas a largo plazo (UNESCO, 2022). El acceso a recursos pedagógicos culturalmente pertinentes —adaptados a la lengua y al contexto del estudiante— representa una necesidad urgente y aún no resuelta, especialmente en regiones rurales con limitaciones de infraestructura digital.

En América Latina, esta problemática adquiere una dimensión étnica y lingüística particular. Más de 45 millones de personas pertenecen a pueblos indígenas distribuidos en 23 países, con lenguas que en su mayoría carecen de recursos digitales estructurados para la enseñanza formal. Los estados de la región han avanzado normativamente hacia la Educación Intercultural Bilingüe (EIB), pero la brecha entre el mandato normativo y la disponibilidad real de herramientas tecnológicas pertinentes permanece amplia.

En el Perú, esta tensión se manifiesta de manera crítica. El sistema EIB atiende a más de 1,2 millones de estudiantes en aproximadamente 26 400 instituciones educativas (Ministerio de Educación del Perú, 2018), concentradas principalmente en el sur andino y la Amazonía. Según datos del INEI, al primer trimestre de 2025 solo el 20,5 % de los hogares del área rural cuenta con acceso a internet, frente al promedio nacional que supera el 58 % (INEI, 2025). Esta brecha digital se profundiza especialmente en los departamentos del sur andino —Cusco, Apurímac, Ayacucho, Puno y Huancavelica—, donde se concentra una proporción importante del alumnado EIB y persisten limitaciones significativas de acceso a herramientas tecnológicas adaptadas.

Dentro de este ámbito regional, la lengua originaria predominante es el Quechua Collao. Esta variedad posee particularidades lingüísticas de alta relevancia para el diseño de recursos tecnológicos: su morfología aglutinante permite construir palabras de gran complejidad semántica mediante sufijación encadenada, y su fonología incluye rasgos consonánticos que no tienen equivalente en el español. Estas características la convierten en una lengua especialmente compleja para los sistemas de procesamiento automático del lenguaje. Adicionalmente, los estudiantes de estas comunidades frecuentemente alternan entre el quechua y el español en una misma interacción (translengüaje o alternancia de códigos), lo que exige que cualquier herramienta de apoyo educativo sea capaz de operar en ambas lenguas y de identificar el idioma predominante de cada consulta.

Frente a este escenario, los avances recientes en inteligencia artificial generativa han abierto posibilidades para el desarrollo de asistentes educativos capaces de responder preguntas, explicar contenidos y apoyar procesos de aprendizaje. Sin embargo, la gran mayoría de estas soluciones presentan limitaciones estructurales que restringen su aplicabilidad en el contexto EIB rural: primero, dependen de conectividad estable a internet para acceder a modelos alojados en servidores remotos; segundo, están diseñadas con datos de lenguas de alta disponibilidad, con escasa o nula representación del Quechua Collao; tercero, no están adaptadas a contenidos curriculares ni a la realidad pedagógica de las aulas EIB.

El problema se agrava cuando los estudiantes formulan consultas bilingües. En estos casos, un sistema de apoyo debe identificar el idioma predominante, reconocer posibles segmentos alternados y recuperar materiales adecuados al contexto de forma local. El reto no es únicamente técnico, sino también pedagógico y lingüístico.

En consecuencia, existe una brecha de investigación y desarrollo: no se identifica una solución integrada de asistente educativo bilingüe español–Quechua Collao que funcione *offline*, combine un modelo compacto cuantizado con generación aumentada por recuperación

(RAG) local y recursos lingüísticos validados, incorpore detección automática del idioma y recupere contenido curricular local. Esta brecha justifica el diseño de una propuesta que articule las capas lingüística, pedagógica y tecnológica en un prototipo funcional evaluable.

1.2. Identificación del problema

El problema central de la investigación es la ausencia de un asistente educativo bilingüe español–Quechua Collao, ejecutable sin conexión a internet, basado en una arquitectura híbrida de modelo compacto cuantizado, generación aumentada por recuperación local y recursos lingüísticos validados, para responder consultas pedagógicas en contextos rurales de Educación Intercultural Bilingüe.

1.3. Formulación del problema

Problema general

¿Cómo diseñar, implementar y evaluar un asistente educativo offline español–Quechua Collao que apoye consultas curriculares en contextos rurales de Educación Intercultural Bilingüe mediante una arquitectura basada en un modelo compacto cuantizado, generación aumentada por recuperación local y recursos lingüísticos validados?

Subproblemas

- ¿Cuáles son los requerimientos lingüísticos, pedagógicos y tecnológicos que debe satisfacer un asistente educativo bilingüe offline para contextos rurales de EIB?
- ¿Cómo diseñar una arquitectura offline que integre detección automática del idioma, recuperación local de contenidos curriculares, recursos lingüísticos explícitos y generación de respuestas pedagógicas?
- ¿Cómo implementar y configurar un modelo compacto cuantizado para operar de forma eficiente sin conexión a internet en dispositivos de bajo costo?
- ¿Qué diferencia en rendimiento y pertinencia se registra al comparar tres configuraciones básicas del sistema: modelo base sin RAG, modelo con RAG local y modelo con el enfoque híbrido completo?
- ¿Cómo evaluar la calidad del prototipo resultante mediante métricas técnicas, lingüísticas y rúbricas de pertinencia pedagógica?

2. Justificación

La investigación se justifica porque las condiciones descritas en el problema —escasa conectividad rural, ausencia de herramientas tecnológicas en Quechua Collao y más de 1,2 millones de estudiantes EIB desatendidos tecnológicamente (Ministerio de Educación del Perú, 2018)— no se resuelven suficientemente con las herramientas de inteligencia artificial generativa comerciales en la nube, las cuales dependen de conectividad permanente y operan mayoritariamente sobre lenguas de alta disponibilidad. El proyecto propone una alternativa a esa brecha desde tres perspectivas:

- **Justificación Teórica:** El estudio aporta a la integración del procesamiento de lenguas de bajos recursos digitales con la tecnología educativa. Aunque existen investigaciones

previas sobre traducción automática o evaluación de modelos para quechua de manera aislada, no se ha propuesto un diseño que acople el entendimiento bilingüe contextualizado, la recuperación local de contenidos y mecanismos de adaptación orientados al andamiaje pedagógico para el Quechua Collao.

- **Justificación Práctica:** Propone un prototipo funcional offline de apoyo pedagógico complementario en áreas rurales de baja o nula conectividad, facilitando el acceso a materiales oficiales en la lengua originaria del estudiante.
- **Justificación Metodológica:** Diseña un marco de evaluación comparativo que permite medir el aporte real de cada componente del sistema (el modelo base, la recuperación local de contenidos y la alineación de estilo del modelo), combinando métricas automatizadas de rendimiento y calidad de texto con valoraciones cualitativas aplicadas por especialistas bilingües.

3. Alcances y limitaciones

3.1. Alcances

El presente estudio abarca el diseño, implementación y evaluación de un prototipo de asistente educativo bilingüe español–Quechua Collao basado en un modelo compacto de lenguaje. La investigación se centra en la asistencia textual para estudiantes y docentes de contextos de EIB, considerando los siguientes alcances específicos:

- **Alcance lingüístico:** Se delimita de forma exclusiva al Quechua Collao, de acuerdo con la ubicación geográfica del estudio y la disponibilidad de corpus paralelos como los construidos por Orcotoma Mormontoy et al. (2025). Esta variedad presenta rasgos fonológicos diferenciadores (consonantes oclusivas glotizadas y aspiradas) que deben reflejarse cuidadosamente en los recursos del sistema. Esta delimitación evita prometer cobertura de otras variedades dialectales, permitiendo construir un prototipo de alta pertinencia regional.
- **Alcance pedagógico:** El primer ciclo de validación se centrará en consultas curriculares de 3.º a 6.º grado de primaria, priorizando las áreas de Comunicación y Ciencia y Tecnología según la disponibilidad de materiales EIB bilingües. Las respuestas del sistema seguirán el principio de andamiaje cognitivo, priorizando explicaciones graduales sobre respuestas directas.
- **Alcance tecnológico:** Comprende una arquitectura offline compuesta por detección automática del idioma, enrutamiento lingüístico, generación aumentada por recuperación (RAG) local y un modelo compacto de lenguaje cuantizado, preferentemente a 4 bits según las pruebas de rendimiento realizadas. El aporte tecnológico radica en la integración, configuración y evaluación comparativa de esta arquitectura.
- **Alcance disciplinar:** Se ubica en la convergencia de la ingeniería informática, el procesamiento de lenguaje natural y la tecnología educativa para contextos bilingües interculturales.

3.2. Limitaciones

Se reconocen las siguientes limitaciones que condicionan la ejecución del proyecto:

- **Disponibilidad de datos:** Al tratarse de una lengua de bajos recursos digitales, el corpus paralelo disponible es reducido y heterogéneo (Court y Elsner, 2024). Para mitigar esto, se complementará el banco de RAG con glosarios, materiales EIB y datos sintéticos validados por hablantes nativos (Dhawan et al., 2026).
- **Cuello de botella de la tokenización:** La morfología aglutinante del quechua genera una fertilidad de tokens estimada en $\approx 3,4\times$ respecto al español, lo que penaliza la latencia en CPU e infla el consumo de la caché KV del modelo con contextos extensos.
- **Restricción dialectal:** El prototipo está orientado exclusivamente al Quechua Collao, por lo que el sistema no está diseñado para generalizarse a otras variedades dialectales.
- **Restricciones de hardware:** La ejecución offline de un modelo compacto depende de la memoria disponible (RAM) del dispositivo local, limitando el tamaño del modelo utilizable y la latencia aceptable de generación (Xu et al., 2024).
- **Validación pedagógica y lingüística:** La evaluación de pertinencia y adecuación dependerá del acceso real a docentes EIB, especialistas y hablantes nativos, así como de las autorizaciones institucionales correspondientes.
- **Alcance textual:** El prototipo no incorpora reconocimiento ni síntesis de voz, considerando la asistencia por audio fuera del alcance de este trabajo.

4. Objetivos

4.1. Objetivo General

Diseñar, implementar y evaluar un prototipo de asistente educativo offline español–Quechua Collao basado en un modelo de lenguaje compacto cuantizado y generación aumentada por recuperación local, orientado al apoyo de consultas curriculares en contextos rurales de Educación Intercultural Bilingüe.

4.2. Objetivos Específicos

- **Curar y estructurar** una base documental bilingüe español–Quechua Collao, integrando materiales curriculares oficiales, glosarios terminológicos, diccionarios locales y datos sintéticos validados.
- **Diseñar** una arquitectura offline que integre detección automática del idioma, recuperación local de información y generación de respuestas pedagógicas.
- **Implementar** un prototipo funcional del asistente educativo seleccionando, cuantizando y configurando el modelo compacto base y el pipeline de recuperación.
- **Comparar** configuraciones básicas del sistema para medir el aporte real de la recuperación local, las reglas de normalización y la adaptación de estilo del modelo.
- **Evaluar** el prototipo mediante métricas técnicas de rendimiento offline, fidelidad lingüística mediante métricas automáticas y pertinencia pedagógica a través de rúbricas de juicio de expertos.
- **Documentar** las limitaciones de la arquitectura propuesta, los riesgos de transferencia dialectal y las recomendaciones de mejora.

4.3. Alineación con los Objetivos de Desarrollo Sostenible

La investigación se alinea con los siguientes Objetivos de Desarrollo Sostenible (ODS):

- **ODS 4 — Educación de calidad.** El estudio contribuye a una educación inclusiva y equitativa al proveer una herramienta de apoyo pedagógico en lengua materna para estudiantes de zonas rurales bajo el modelo EIB.
- **ODS 9 — Industria, innovación e infraestructura.** Promueve la innovación tecnológica al diseñar una solución de inteligencia artificial offline, adaptada a condiciones de hardware de bajo costo e infraestructura digital limitada.
- **ODS 10 — Reducción de las desigualdades.** Aborda la brecha digital y lingüística que afecta a comunidades quechuahablantes, facilitando el acceso a recursos educativos interactivos sin requerir conexión a internet.

5. Estado del Arte

El desarrollo de un asistente educativo bilingüe español–Quechua Collao requiere la integración de avances en múltiples dominios disciplinares. A continuación, se presenta una síntesis analítica y crítica de las investigaciones previas más relevantes, organizadas temáticamente. Las fichas de análisis detalladas de cada uno de estos trabajos se presentan en el Anexo: Fichas de Análisis.

5.1. Procesamiento de Lenguaje Natural y Traducción Automática para Quechua Collao

El procesamiento de lenguaje natural (PLN) para lenguas aglutinantes de bajos recursos como el quechua ha presentado desafíos históricos debido a su complejidad morfológica. Investigaciones recientes han abordado estas brechas mediante la construcción de corpus y el ajuste de modelos neuronales. Orcotoma Mormontoy et al. (2025) aportaron significativamente al construir un corpus paralelo Quechua Collao–español de 44 263 palabras mediante el uso de reconocimiento óptico de caracteres (OCR) sobre textos académicos de la Academia Mayor de la Lengua Quechua, logrando tasas de error de palabra (WER) de 6.59 %. Por su parte, Duran y Silberstein (2026) propusieron métodos semi-automáticos para la construcción de diccionarios quechua–español utilizando formalismos lingüísticos, lo que amplía la disponibilidad de recursos léxicos estructurados.

En cuanto a la traducción, Sulla Torres et al. (2024) demostraron que los modelos de traducción automática neuronal (NMT) optimizados con BERT pueden alcanzar puntajes aceptables (BLEU de 20.13) en la dirección quechua–español, aunque subrayaron las limitaciones impuestas por la escasez de datos. No obstante, el paradigma de traducción y PLN ha cambiado con la llegada de los Grandes Modelos de Lenguaje (LLM). En este contexto, Court y Elsner (2024) evaluaron las habilidades de aprendizaje en contexto de LLMs comerciales (GPT-4, Gemini) para traducir del quechua al español. Sus hallazgos indican que, si bien la inclusión de traducciones a nivel de morfema mejora el rendimiento, la inyección de largas reglas gramaticales o ejemplos de corpus mediante técnicas de recuperación puede, paradójicamente, degradar el rendimiento de los modelos más avanzados, generando traducciones fluidas pero infieles o estereotipadas. Esto evidencia que depender exclusivamente de LLMs en la nube mediante *prompting* no resuelve el problema de comprensión estructural en lenguas de bajos recursos.

5.2. Small Language Models y Despliegue Offline

Frente a la dependencia de conectividad y alto consumo computacional de los LLMs, el desarrollo de Small Language Models (SLM) y técnicas de optimización para hardware restringido (on-device AI) ha cobrado relevancia. La exhaustiva revisión de Xu et al. (2024) sistematiza cómo técnicas como la compartición de parámetros, la destilación de conocimiento y, fundamentalmente, la cuantización (PTQ y QAT), permiten que modelos con menos de 10 mil millones de parámetros se ejecuten eficientemente en dispositivos móviles y procesadores de bajo consumo.

La aplicación de estas tecnologías en contextos de baja conectividad fue validada empíricamente por Walusimbi et al. (2026), quienes diseñaron *Arapai*, una arquitectura de chatbot educativo orientado al funcionamiento offline. Al desplegar modelos cuantizados (como TinyLlama o Qwen) en hardware heredado (solo CPU), lograron latencias de respuesta de 1 a 3 segundos, demostrando que la inferencia local es técnicamente factible y pedagógicamente útil para el aprendizaje autodirigido en entornos con infraestructura precaria. Sin embargo,

su estudio se centró en inglés y no abordó los retos de lenguas aglutinantes.

5.3. Generación Aumentada por Recuperación (RAG) y Tecnología Educativa con IA

La Generación Aumentada por Recuperación (RAG) se ha convertido en el estándar para mitigar las alucinaciones en modelos generativos, vinculando sus respuestas a corpus documentales específicos. La revisión sistemática de Li et al. (2025) confirma que los sistemas RAG mejoran significativamente la precisión factual y la personalización en aplicaciones educativas, permitiendo que la IA asuma roles de tutoría basados en el currículo local.

Sin embargo, el despliegue de RAG con modelos pequeños presenta desafíos particulares. Hevia et al. (2025) evaluaron un tutor de IA offline combinando RAG con SLMs (SmolLM), encontrando que los modelos pequeños tienen dificultades para procesar contextos recuperados extensos o ruidosos, lo que irónicamente redujo su precisión en evaluaciones de respuestas múltiples. Esto sugiere la necesidad de estrategias de recuperación y segmentación documental altamente optimizadas. Adicionalmente, el despliegue de estas herramientas con estudiantes requiere garantías pedagógicas. Levonian et al. (2025) establecen que los sistemas de tutoría inteligente deben ser diseñados para generar interacciones seguras y relevantes, priorizando el andamiaje cognitivo sobre la simple provisión de respuestas directas.

5.4. RAG vs. Fine-Tuning y Enfoque Híbrido para Lenguas de Bajos Recursos

La decisión entre RAG y *fine-tuning* como estrategia de inyección de conocimiento es central para esta tesis. Ovadia et al. (2024) encontraron que, para incorporar conocimiento factual nuevo, RAG superó consistentemente al *fine-tuning* no supervisado, tanto para conocimiento existente como nuevo. Sin embargo, la evidencia no avala un RAG no optimizado: el cuello de botella de la tokenización en lenguas aglutinantes como el quechua infla el contexto requerido y penaliza la latencia, lo que exige un RAG disciplinado con fragmentos cortos y *top-k* pequeño.

El enfoque RAFT (*Retrieval-Augmented Fine-Tuning*) propuesto por Zhang et al. (2024) ofrece una síntesis prometedora: en lugar de entrenar al modelo a memorizar conocimiento, le enseña a usar el contexto RAG de forma resiliente, distinguiendo fragmentos relevantes de distractores. El antecedente más directo para esta tesis es el modelo QueEn (Chen et al., 2024), que demostró empíricamente que la hibridación de RAG sobre recursos lingüísticos combinada con adaptación LoRA elevó el puntaje BLEU de 1,5 a 17,6 en traducciones quechua-inglés, validando que la combinación de RAG con adaptación paramétrica ligera produce mejoras significativas para lenguas de bajos recursos.

5.5. Política Educativa y Educación Intercultural Bilingüe en el Perú

El desarrollo tecnológico debe alinearse con los marcos normativos y pedagógicos vigentes. El Modelo de Servicio Educativo Intercultural Bilingüe (MSEIB) del Ministerio de Educación del Perú (Ministerio de Educación del Perú, 2018) establece lineamientos para garantizar una educación pertinente a estudiantes de pueblos originarios. El MSEIB distingue escenarios de fortalecimiento lingüístico (donde el quechua es lengua materna y el español segunda lengua) y revitalización (donde el español es lengua materna). Esto exige que cualquier herramienta de asistencia educativa no sea un simple traductor bidireccional, sino un sistema capaz de

alternar códigos, detectar el idioma predominante del estudiante y recuperar contenidos con pertinencia cultural e intercultural, apoyando directamente la labor del docente bilingüe.

5.6. Síntesis crítica y vacíos de investigación

La revisión de literatura demuestra que existen avances maduros, pero aislados, en los componentes necesarios para el sistema propuesto. Por un lado, se han construido corpus y evaluado LLMs para quechua (Orcotoma Mormontoy et al., 2025; Court y Elsner, 2024), y se ha demostrado que la hibridación de RAG con adaptación ligera produce mejoras significativas (Chen et al., 2024). Por otro lado, la viabilidad de SLMs *offline* y sistemas RAG ha sido probada (Walusimbi et al. 2026; Hevia et al. 2025; Xu et al. 2024), pero principalmente para inglés y lenguas mayoritarias. La evidencia comparada confirma que RAG supera al *fine-tuning* para inyección de conocimiento (Ovadia et al., 2024), pero que un RAG no optimizado con modelos pequeños puede degradar el rendimiento. La técnica RAFT (Zhang et al., 2024) ofrece una vía para resolver este problema, pero no ha sido aplicada al Quechua Collao. Finalmente, la política EIB (Ministerio de Educación del Perú 2018) exige recursos pertinentes que la actual oferta de LLMs comerciales en la nube no puede satisfacer, ya sea por barreras de conectividad o por la degradación del rendimiento al inyectarles reglas complejas (Court y Elsner, 2024).

En consecuencia, el vacío de investigación se ubica en la ausencia de un prototipo integrado de asistente educativo offline español–Quechua Collao que combine un modelo compacto cuantizado, RAG local disciplinado, recursos lingüísticos validados y criterios pedagógicos EIB para apoyar consultas curriculares en contextos rurales del sur andino peruano.

6. Marco Teórico y Conceptual

6.1. Antecedentes de la investigación

La Tabla 1 resume los trabajos empíricos y desarrollos tecnológicos previos que fundamentan la presente investigación, detallando sus objetivos, metodologías, hallazgos clave y el aporte específico que brindan al diseño del asistente educativo.

Tabla 1*Matriz resumida de antecedentes y aportes a la investigación*

Autor(es)	Objetivo	Método	Resultados clave	Aporte a la tesis
Orcotoma Mor-montoy et al. (2025)	Crear corpus paralelo español-Quechua Collao.	OCR en textos académicos e indexación.	Corpus de 44 263 palabras con WER de 6.59 %.	Provee el corpus de texto base para poblar el RAG local.
Sulla Torres et al. (2024)	Optimizar traducción quechua-español.	NMT basado en codificador BERT y fine-tuning.	Alcanzó un puntaje BLEU de 20.13.	Evidencia las limitaciones de modelos de traducción pura.
Duran y Silberztein (2026)	Construir diccionarios quechua-español.	Métodos semi-automáticos con formalismos léxicos.	Diccionario bilingüe estructurado de alta precisión.	Fuente léxica para las reglas de normalización del RAG.
Court y Elsner (2024)	Evaluar LLMs comerciales en quechua.	In-context learning con reglas gramaticales inyectadas.	Reglas extensas degradan fidelidad; prompt simple es insuficiente.	Justifica no usar LLMs comerciales en la nube y diseñar sistema local.
Chen et al. (2024)	Optimizar traducción quechua-inglés.	Enfoque híbrido: RAG léxico + LoRA.	Aumento de BLEU de 1.5 a 17.6.	Precedente directo de la viabilidad de acoplar RAG y adaptadores.
Walusimbi et al. (2026)	Desarrollar asistente educativo offline.	Inferencia de SLM cuantizado en CPU.	Latencia de 1–3s en hardware de baja gama en aulas sin internet.	Valida la viabilidad técnica del despliegue offline.

6.2. Educación Intercultural Bilingüe (EIB)

La Educación Intercultural Bilingüe es el modelo pedagógico promovido por el Ministerio de Educación del Perú (MINEDU) para garantizar el derecho a una educación pertinente a los estudiantes de pueblos originarios (Ministerio de Educación del Perú, 2018). El modelo establece dos formas de atención principales:

- **EIB de Fortalecimiento Cultural y Lingüístico:** Orientada a estudiantes que tienen la lengua originaria (como el Quechua Collao) como lengua materna y el castellano como segunda lengua.
- **EIB de Revitalización Cultural y Lingüística:** Dirigida a estudiantes cuya lengua materna es el castellano, pero pertenecen a comunidades con herencia cultural originaria.

Cualquier tecnología educativa insertada en este contexto debe respetar el enfoque de bilingüismo aditivo, en el que ninguna lengua desplaza a la otra.

6.3. Quechua Collao: caracterización dialectal

El Quechua Collao es la variedad predominante en Puno, Moquegua y el sur de Arequipa, con presencia también en partes de Cusco. A nivel morfosintáctico, es una lengua aglutinante y sufijadora: una sola raíz puede recibir múltiples sufijos derivativos y flexivos para expresar significados que en español requerirían varias palabras. A nivel fonológico, se caracteriza por la presencia de consonantes oclusivas glotizadas y aspiradas, rasgos fonológicos diferenciadores que deben considerarse en el procesamiento del texto. Adicionalmente, la digitalización de esta variante enfrenta el problema de escasez de recursos estructurados y alta variabilidad ortográfica (Orcotoma Mormontoy et al., 2025).

6.4. Translengüaje y alternancia de códigos

El translengüaje es el proceso por el cual los hablantes bilingües utilizan su repertorio lingüístico completo de manera dinámica y estratégica. La alternancia de códigos (*code-switching*) es una manifestación de este fenómeno que implica el cambio sistemático entre dos lenguas dentro de una misma interacción. Para el asistente educativo propuesto, el sistema debe ser capaz de identificar el idioma predominante en entradas mixtas, reconocer segmentos alternados y responder en el idioma más pertinente.

6.5. Procesamiento de Lenguaje Natural en Lenguas de Bajos Recursos

El procesamiento de lenguas morfológicamente complejas y de bajos recursos digitales (*low-resource languages*) como el Quechua Collao impone restricciones severas a las arquitecturas estándar. Su naturaleza aglutinante y sufijadora implica que una sola palabra contiene información semántica equivalente a una oración completa en español, lo que dificulta la tokenización y la generación de incrustaciones vectoriales (*embeddings*). Asimismo, la escasez de corpus paralelos digitalizados e indexados impide construir modelos de lenguaje de alta calidad mediante métodos de aprendizaje masivo tradicionales.

En este contexto, el Entendimiento del Lenguaje Natural (NLU) se aborda de forma dirigida: en lugar de depender exclusivamente de la representación paramétrica interna del modelo, se inyecta información léxica y contextual validada mediante un pipeline RAG local. Esto permite al modelo diferenciar intenciones de consulta (vocabulario, explicación o aplicación pedagógica) basándose en documentos específicos del dominio, mitigando las alucinaciones típicas que ocurren al procesar lenguas sin suficiente representación.

Cuello de botella de la tokenización en lenguas aglutinantes

Un problema técnico crítico para el diseño de sistemas RAG en Quechua Collao es el *cuello de botella de la tokenización*. La morfología aglutinante del quechua permite construir palabras de gran complejidad semántica mediante sufijación encadenada. Cuando estas palabras son procesadas por tokenizadores sub-palabra (como BPE o SentencePiece), cada palabra quechua se fragmenta en múltiples tokens, generando una *fertilidad de tokens* estimada en aproximadamente $3,4\times$ respecto al español según la literatura técnica disponible. Esto significa de manera estimada que una oración en quechua consume alrededor de 3,4 veces más tokens que su equivalente en español, lo cual será verificado empíricamente durante la fase de evaluación.

Las implicaciones técnicas de esta inflación son significativas: (i) la caché de clave-valor (KV cache) del mecanismo de atención crece linealmente con la longitud de la secuencia, aumentando de manera aproximada el consumo de RAM; (ii) la complejidad computacional del

mecanismo de autoatención escala cuadráticamente como $O(N^2 \cdot D)$, donde N es la longitud de la secuencia y D la dimensión del modelo según los formalismos de la arquitectura, lo que penaliza asintóticamente la latencia en CPU. Para un SLM ejecutado en CPU, este fenómeno teórico representa una limitación para el uso de un RAG no optimizado con fragmentos largos, lo que fundamenta de forma preliminar dos decisiones de diseño del presente proyecto: (a) *chunking* corto y disciplinado (250–400 tokens para prosa curricular; una entrada por *chunk* para glosarios), y (b) un *top-k* final pequeño (3–5 fragmentos) para evitar la saturación de la ventana de contexto (Hevia et al., 2025).

Traducción automática neuronal

La Traducción Automática Neuronal (NMT, *Neural Machine Translation*) es el paradigma actual en traducción automática, basado en redes neuronales profundas de arquitectura encoder-decoder con mecanismos de atención. A diferencia de los enfoques estadísticos anteriores, los modelos NMT aprenden representaciones contextuales de las lenguas fuente y objetivo, produciendo traducciones más fluidas y coherentes. Sin embargo, su eficacia depende de la disponibilidad de corpus paralelos de gran tamaño.

En el par español–Quechua Collao, la escasez de datos limita el rendimiento de los modelos NMT: Sulla Torres et al. (2024) reportaron un BLEU de 20.13, considerado bajo según los estándares para lenguas con recursos abundantes. Adicionalmente, Court y Elsner (2024) evaluaron la capacidad de los Grandes Modelos de Lenguaje comerciales (GPT-4, Gemini) para traducir quechua sureño mediante técnicas de recuperación en contexto, encontrando que la inyección de reglas gramaticales complejas puede paradójicamente degradar el rendimiento de los modelos más avanzados, generando traducciones fluidas pero semánticamente infieles. Este hallazgo refuerza la decisión de no depender de LLMs comerciales en la nube para la lengua objetivo y justifica el diseño de un sistema con recursos locales especializados.

En el presente proyecto, la generación en Quechua Collao no es una tarea de traducción aislada, sino parte de la capacidad general del asistente de responder en el idioma del usuario. La métrica chrF++ se empleará para evaluar la coherencia lingüística de las respuestas generadas en Quechua Collao respecto a referencias validadas por especialistas.

6.6. Modelos de lenguaje y arquitectura Transformer

Un modelo de lenguaje es un sistema estadístico entrenado para modelar la distribución de probabilidad de secuencias de tokens en una lengua. Los modelos de lenguaje modernos se basan en la arquitectura Transformer (Vaswani et al., 2017), que introduce mecanismos de autoatención multi-cabeza para capturar dependencias de largo alcance en el texto sin recurrir a estructuras recurrentes. Esta arquitectura permitió escalar el entrenamiento a corpus de cientos de miles de millones de tokens, dando origen a los Grandes Modelos de Lenguaje (LLM, *Large Language Models*), como GPT-4, Llama y Gemini.

Los LLM poseen capacidades notables de generación, razonamiento y comprensión, pero su tamaño —que puede superar los 70 mil millones de parámetros— los hace inaccesibles para el despliegue en hardware de bajo costo sin conectividad permanente a la nube. Esta limitación es determinante para el contexto rural del sur andino peruano, donde la conectividad es escasa y los dispositivos disponibles son de gama baja o media.

6.7. Small Language Models y cuantización

Los Small Language Models (SLM) son modelos de lenguaje fundamentados en la arquitectura Transformer que típicamente poseen menos de 10 mil millones (10B) de parámetros. A diferencia de los LLM masivos, los SLM (como Llama 3 8B, Phi-3-mini, Gemma-2 9B,

Qwen2.5) están diseñados para operar con menores requerimientos de cómputo y memoria, siendo idóneos para despliegues locales (*on-device*) o en dispositivos de borde (*edge computing*) (Xu et al., 2024).

Para hacer factible su ejecución en dispositivos con limitaciones estrictas de hardware (como CPU sin GPU dedicada), se emplean técnicas de compresión. La más extendida es la **Cuantización Post-Entrenamiento (PTQ, *Post-Training Quantization*)**, la cual reduce la precisión en bits de los pesos del modelo (por ejemplo, de Float16 a Int4 o Int8), minimizando el espacio en memoria RAM requerido y acelerando la inferencia de *tokens* con una pérdida mínima de calidad (Xu et al., 2024).

Para el presente proyecto, el modelo base candidato principal es **Qwen2.5-7B** (o su variante de 3B), por cuatro razones: (1) soporte multilingüe nativo para más de 29 idiomas, incluido el español, con mejor manejo de morfemas no latinos que modelos entrenados mayoritariamente en inglés; (2) rendimiento competitivo en *benchmarks* de comprensión en configuraciones cuantizadas preferentemente a 4 bits; (3) validación empírica de ejecución *offline* en hardware CPU-only en contextos educativos de baja conectividad (Walusimbi et al., 2026); (4) requerimientos de RAM en cuantización Q4_K_M estimados en aproximadamente 4,5 GB según pruebas preliminares de literatura, compatibles con equipos de gama media. La selección definitiva se realizará en la Fase 2 del Design Science Research mediante evaluación comparativa de latencia, consumo de memoria y calidad de respuesta.

Tabla 2

Modelos candidatos evaluados y de referencia para el asistente offline

Modelo	Params.	RAM (Q4_K_M)	ES / CPU	Rol en el proyecto
Qwen2.5-7B-Instruct	7,6B	~4,7 GB	Sí / Sí	Candidato principal — equipos 16 GB
Qwen2.5-3B-Instruct	3,1B	~2,1 GB	Sí / Sí	Candidato base — equipos 8 GB
Llama 3.2 3B-Instruct	3,2B	~2,0 GB	Sí / Sí	Alternativa viable; buena instrucción
Phi-3.5-mini-Instruct	3,8B	~2,5 GB	Parcial / Sí	Razonamiento fuerte; menos multilingüe
Gemma 2 2B-IT	2,6B	~1,7 GB	Sí / Sí	Alternativa de alta calidad (Google, 2024)
SmolLM2-1.7B-Instruct	1,7B	~1,1 GB	Parcial / Sí	Hardware muy restringido (<4 GB RAM)
Llama 3.2 1B-Instruct	1,2B	~0,7 GB	Limitado / Sí	Dispositivos ultra-restringidos
TinyLlama-1.1B	1,1B	~0,8 GB	No / Sí	Descartado — sin soporte multilingüe

Nota: Los valores de memoria RAM son aproximados y serán verificados empíricamente durante la fase de evaluación del prototipo en el hardware disponible. Los modelos marcados

como «candidato» serán evaluados empíricamente en la Fase 2 del DSR. Los modelos de generación complementarios (como Gemma 2 o variantes compactas de Mistral) representan opciones a considerar en trabajos derivados o en una segunda iteración del prototipo si el cronograma lo permite.

6.8. Adaptación ligera: LoRA y QLoRA

La adaptación de bajo rango (*Low-Rank Adaptation*, LoRA) es una técnica de ajuste paramétrico eficiente que, en lugar de modificar todos los pesos de un modelo preentrenado, inyecta matrices de bajo rango en las capas de atención del Transformer. Esto permite adaptar el comportamiento del modelo —estilo de respuesta, formato pedagógico, consistencia terminológica— con un número muy reducido de parámetros entrenables (típicamente <1 % del total), reduciendo drásticamente los requerimientos de memoria y tiempo de entrenamiento.

QLoRA (*Quantized LoRA*) combina la cuantización a 4 bits del modelo base con la inyección de adaptadores LoRA, permitiendo ajustar modelos de hasta 7B parámetros en GPUs de 24 GB de VRAM (Dettmers et al., 2023). La adaptación ligera mediante QLoRA se considera una configuración experimental complementaria, condicionada a la disponibilidad de corpus validado y recursos computacionales, no como requisito obligatorio del prototipo base. De ser factible, se reservará únicamente para alinear el comportamiento pedagógico del modelo (andamiaje, formato de respuesta, consistencia terminológica), no para inyectar conocimiento factual. La evidencia reciente demuestra que, para inyección de conocimiento, RAG supera consistentemente al *fine-tuning* paramétrico (Ovadia et al., 2024); sin embargo, la adaptación ligera sí aporta valor cuando el objetivo es enseñar al modelo *cómo* usar el contexto recuperado, no *qué* conocimiento contener.

6.9. RAFT: Retrieval-Augmented Fine-Tuning

Este enfoque se considera como referencia conceptual para justificar la adaptación ligera del modelo y enseñarle a ignorar distractores, pero no constituye un componente obligatorio del prototipo inicial. Su utilidad teórica radica en el potencial para filtrar distractores dialectales derivados de otras variedades quechuas (como el Chanka o Cusqueño), entrenando al modelo a responder de forma coherente y anclada únicamente en la base documental de control.

6.10. Asistentes educativos inteligentes

Los Sistemas de Tutoría Inteligente (ITS, *Intelligent Tutoring Systems*) son sistemas informáticos diseñados para proporcionar instrucción personalizada adaptada al nivel de comprensión del estudiante, sin intervención humana directa en tiempo real. Los ITS modernos basados en modelos de lenguaje incorporan principios pedagógicos como el andamiaje cognitivo (*scaffolding*), que consiste en ofrecer apoyos estructurados que el aprendiz retira progresivamente a medida que adquiere competencia; la Zona de Desarrollo Próximo (ZDP) de Vygotsky, que delimita el rango de tareas que el estudiante puede realizar con guía pero no de forma autónoma; y el *feedback* formativo, que orienta al estudiante hacia la comprensión correcta en lugar de limitarse a confirmar o refutar respuestas.

El asistente educativo propuesto se inscribe en este marco conceptual. Su propósito no es reemplazar al docente bilingüe sino proveer un apoyo adicional disponible fuera del horario de clase y en entornos sin conectividad, respondiendo consultas curriculares con un tono pedagógico adecuado a la edad y al nivel educativo del usuario. Levonian et al. (2025) establecen que los sistemas de tutoría generativa deben diseñarse para generar interacciones seguras y relevantes, priorizando el andamiaje cognitivo sobre la simple provisión de respuestas directas, criterio que guía el diseño del pipeline de generación del presente proyecto.

6.11. Generación Aumentada por Recuperación (RAG)

La Generación Aumentada por Recuperación (*Retrieval-Augmented Generation*, RAG) es una arquitectura que acopla un modelo generativo con un mecanismo de recuperación de información (Li et al., 2025). El proceso típico involucra tres etapas:

1. **Indexación:** Los documentos base (currículo, glosarios, materiales EIB) se dividen en fragmentos (*chunks*) y se convierten en vectores mediante un modelo de incrustación (*embedding*), almacenándose en una base de datos vectorial local.
2. **Recuperación (*Retrieval*):** Cuando el usuario realiza una consulta, esta se vectoriza para buscar los fragmentos más similares semánticamente, utilizando métricas de similitud de coseno.
3. **Generación:** Los fragmentos recuperados se inyectan en el contexto del *prompt* junto a la consulta original, permitiendo que el SLM genere una respuesta anclada a esa información específica.

La revisión sistemática de Li et al. (2025) confirma que los sistemas RAG mejoran significativamente la precisión factual y la personalización en aplicaciones educativas, permitiendo que la IA asuma roles de tutoría basados en el currículo local en lugar de depender del conocimiento paramétrico genérico del modelo.

En contextos de SLM, el tamaño y la relevancia (ausencia de ruido) de los fragmentos recuperados es crítico, ya que ventanas de contexto muy largas o ruidosas pueden degradar severamente la precisión del modelo pequeño (Hevia et al., 2025). Por ello, la estrategia de fragmentado semántico y la selección del número óptimo de fragmentos recuperados por consulta constituyen decisiones de diseño determinantes para el rendimiento del asistente propuesto.

6.12. Detección automática de idioma

En entornos bilingües en los que ocurre el translengüaje o la alternancia de códigos, es necesario identificar si la consulta del usuario se formula predominantemente en español, en Quechua Collao o tiene naturaleza mixta. Para lenguas de bajos recursos, la detección basada en reglas combinada con modelos ligeros de clasificación de texto permite enrutar internamente la consulta al *prompt* específico o al índice documental correcto (español o quechua) antes de activar la generación computacionalmente más costosa del SLM (Walusimbi et al., 2026). La precisión de este módulo tiene impacto directo en la pertinencia de la respuesta final: un error de detección produce respuestas en el idioma equivocado, lo que rompe la experiencia pedagógica del usuario.

6.13. Evaluación de sistemas educativos con IA

La evaluación de sistemas generativos en entornos educativos abarca tres dimensiones complementarias. En la **dimensión técnica**, se miden variables como latencia (*Time-To-First-Token*), consumo de memoria RAM y velocidad de generación (tokens por segundo) en el hardware objetivo (Walusimbi et al., 2026). En la **dimensión lingüística**, se utilizan métricas de correspondencia léxica como chrF++ para evaluar la coherencia de las respuestas generadas en Quechua Collao frente a referencias validadas por especialistas (Sulla Torres et al., 2024). En la **dimensión pedagógica**, se requiere la intervención de docentes y especialistas EIB para validar la exactitud factual, la adecuación al tono educativo, la seguridad del contenido y la pertinencia intercultural de las respuestas generadas. Levonian et al. (2025) proponen

marcos multidimensionales que incorporan criterios de relevancia curricular, tono apropiado al nivel educativo y ausencia de contenidos dañinos o culturalmente inadecuados, superando así la evaluación basada exclusivamente en métricas automáticas.

7. Metodología

7.1. Tipo y diseño de investigación

La investigación es de tipo **aplicada y tecnológica**, orientada al diseño, implementación y evaluación de un artefacto informático para solucionar un problema real de soporte educativo.

El enfoque es **mixto con predominio cuantitativo**. Es cuantitativo al medir variables técnicas de rendimiento (latencia, uso de RAM, tokens por segundo), métricas de correspondencia léxica (chrF++, SacreBLEU) y puntuaciones estructuradas en rúbricas de evaluación. Es cualitativo al recoger apreciaciones y observaciones del juicio de expertos sobre la adecuación cultural y pertinencia del andamiaje pedagógico.

El diseño metodológico adoptado es **comparativo-experimental sobre el artefacto**. Se manipularán configuraciones técnicas internas del sistema para contrastar su desempeño, complementado con un diseño descriptivo para la validación humana mediante juicio de expertos. Las dimensiones de evaluación serán: rendimiento técnico, calidad lingüística, calidad de recuperación, pertinencia pedagógica y adecuación intercultural.

7.2. Metodología de desarrollo

El desarrollo del prototipo de asistente bilingüe sigue el paradigma **Design Science Research (DSR)**, estructurado en las siguientes fases:

1. **Identificación del problema y motivación:** Delimitación de las brechas de conectividad y la carencia de recursos bilingües contextualizados en el ámbito rural.
2. **Definición de objetivos de la solución:** Establecimiento de requisitos funcionales y de restricciones técnicas offline.
3. **Diseño y desarrollo:** Selección, cuantización del modelo base, diseño de la base vectorial local, estructuración de las reglas gramaticales y configuración opcional de adaptadores QLoRA.
4. **Demostración:** Integración del prototipo funcional alimentado con el corpus bilingüe seleccionado.
5. **Evaluación:** Comparación de tres configuraciones básicas (modelo base sin RAG, RAG local y enfoque híbrido completo) mediante métricas automáticas y juicios cualitativos de expertos.
6. **Comunicación:** Documentación de hallazgos, límites del prototipo y recomendaciones metodológicas.

7.3. Población y muestra

La definición de las unidades de análisis se organiza bajo cuatro dimensiones de control:

- **Unidad documental:** Compuesta por materiales curriculares de EIB del MINEDU para primaria (3.º a 6.º grado) en Comunicación y Ciencia y Tecnología, glosarios

terminológicos de Quechua Collao del Ministerio de Educación y el corpus bilingüe digitalizado (Orcotoma Mormontoy et al., 2025).

- **Unidad de prueba:** Un banco compuesto por 100 consultas patrón. Las consultas serán elaboradas a partir de contenidos curriculares oficiales y revisadas por docentes EIB para asegurar pertinencia temática, nivel educativo y equilibrio lingüístico.
- **Unidad de validación humana:** Evaluadores especializados conformados por dos paneles: (i) de 3 a 5 especialistas lingüísticos (hablantes nativos quechua, vinculados a la AMLQ) para validar adecuación dialectal; y (ii) de 8 a 15 docentes EIB activos en el sur andino para calificar pertinencia pedagógica.
- **Piloto exploratorio con estudiantes:** Muestra de 20 a 40 estudiantes del nivel primario en escuelas EIB seleccionadas. Esta validación es de carácter exploratorio y opcional, sin constituir una dependencia crítica para los hitos principales del cronograma.

7.4. Consideraciones éticas

Dado que el piloto exploratorio contempla la interacción potencial con estudiantes menores de edad, el protocolo de investigación se somete a salvaguardas éticas estrictas:

1. **Permisos y autorizaciones:** Firma previa del consentimiento informado por parte de los padres o apoderados legales, el asentimiento del estudiante menor de edad, y la autorización de los directores de las Instituciones Educativas coordinadas con el aval de la UGEL/DRE correspondiente.
2. **Protección y privacidad de datos:** Anonimización completa de los registros de interacción. El prototipo operará offline y no recopilará datos personales, datos biométricos ni información sensible de los usuarios.
3. **Mitigación de riesgos de contenido:** El RAG local disciplinado actúa como un filtro restrictivo de seguridad, reduciendo la probabilidad de respuestas no pertinentes, alucinaciones o contenidos inapropiados para menores.

8. Estudio de Factibilidad

El estudio de factibilidad determina si el proyecto puede ejecutarse con éxito dentro de las restricciones reales de tiempo, hardware, presupuesto, datos y acceso institucional. Se estructura en cuatro dimensiones: viabilidad técnica, viabilidad económica, viabilidad operativa y viabilidad del diseño experimental.

La conclusión preliminar indica que el proyecto **resulta factible como prototipo académico y de validación conceptual**, mas **no** como un sistema de producción comercial a escala ni como un modelo entrenado desde cero. La razón es que el plan reduce correctamente el riesgo al proponer un **enfoque híbrido: seleccionar, cuantizar y desplegar** un SLM preentrenado con RAG local disciplinado, recursos lingüísticos explícitos (glosarios, diccionarios, reglas de normalización) y una adaptación ligera (LoRA/QLoRA), en lugar de entrenar un LLM desde cero. Esta estrategia es coherente con la literatura reciente sobre despliegue *on-device* (Xu et al., 2024) y educación *offline* en entornos de baja conectividad (Walusimbi et al., 2026). La calificación global del proyecto, con la información disponible, se sitúa en un **rango de factibilidad favorable**: el mayor riesgo no es el modelo base, sino la curación de datos, la pertinencia lingüística y la validación pedagógica intercultural.

8.1. Justificación del enfoque híbrido

La evidencia comparada de la literatura reciente permite descartar rutas inviables y fundamentar la elección arquitectónica del proyecto. Se evaluaron tres opciones:

- **Opción A — Fine-tuning de SLM:** busca modificar los pesos del modelo para “enseñarle” Quechua Collao mediante ajuste paramétrico (LoRA, QLoRA o entrenamiento continuado).
- **Opción B — SLM cuantizado + RAG local:** mantiene el modelo intacto y externaliza el conocimiento curricular en una base de documentos recuperables (*Retrieval-Augmented Generation*).
- **Opción C — Enfoque híbrido:** combina RAG local disciplinado con diccionarios/glosarios, normalización ortográfica y, de ser factible, una adaptación ligera complementaria (QLoRA) únicamente para alinear el comportamiento pedagógico del modelo, no para inyectar conocimiento factual.

Tabla 3

Matriz comparativa de enfoques para la decisión metodológica

Opción	Ventaja principal	Riesgo principal	Ajuste	Veredicto
A. Fine-tuning de SLM	Mejora estilo, instrucciones y terminología si hay corpus válido	Corpus Collao escaso ($\approx 44\,000$ palabras); riesgo de sobreajuste y olvido catastrófico; más complejidad experimental	Parcial	Solo como brazo comparativo
B. SLM cuantizado + RAG local	Mejor facticidad; actualización fácil; offline realista; menor costo	Depende críticamente de la calidad de la segmentación, las incrustaciones vectoriales y la recuperación	Muy alto	<i>Línea base</i> obligatoria
C. Híbrido (B + reglas + QLoRA ligero)	Combina <i>anclaje</i> factual con adaptación lingüística y pedagógica	Más ingeniería que B, aunque mucho menos que A fuerte	Máximo	Opción recomendada

La razón principal para descartar A como vía principal es de **escala de datos y riesgo metodológico**. El trabajo de Ovadia et al. encontró que, para inyección de conocimiento, RAG superó consistentemente al fine-tuning no supervisado tanto para conocimiento existente como nuevo. En lenguas de bajos recursos como el Quechua Collao, el corpus disponible ($\approx 44\,263$ palabras) es valioso como semilla, pero demasiado pequeño para sostener una aspiración de “modelo bilingüe entrenado” sin riesgo de sobreajuste o mejoras frágiles. En cambio, RAG permite alojar el conocimiento curricular **fuera de los pesos del modelo**, actualizarlo sin reentrenar y reducir alucinaciones si la recuperación está cuidadosamente diseñada.

Sin embargo, la evidencia **no avala un RAG no optimizado**. El *cuello de botella de la tokenización* del quechua — lengua aglutinante con una fertilidad de tokens estimada en $\approx 3,4\times$ respecto al español— infla el consumo de la caché KV con complejidad asintótica $O(N^2 \cdot D)$, donde N es la longitud de la secuencia y D la dimensión del modelo. Esto penaliza severamente la latencia en CPU cuando el contexto recuperado es largo. El trabajo de Hevia et al. (2025) con un tutor offline basado en SLM+RAG mostró que los modelos pequeños **no aprovechan bien contextos largos o ruidosos**: si el pipeline recupera demasiado texto o fragmentos mal delimitados, la precisión empeora en lugar de mejorar.

Por ello, la opción C es la metodológicamente más adecuada: el **RAG** lleva el peso del conocimiento factual y curricular con fragmentos cortos y disciplinados; la **adaptación ligera** (QLoRA de bajo rango) mejora el comportamiento pedagógico y la consistencia terminológica; y las **reglas, glosarios y diccionarios** cubren casos donde la morfología aglutinante, la dialectalidad o la terminología especializada hacen poco confiable al modelo generalista. Este enfoque es consistente con la técnica RAFT (*Retrieval-Augmented Fine-Tuning*), que enseña al modelo a **usar el contexto RAG de forma resiliente**, distinguiendo fragmentos relevantes de distractores, en lugar de obligarlo a memorizar conocimiento en sus pesos.

8.2. Factibilidad técnica y de datos

La viabilidad técnica es **realista dentro de un perímetro bien acotado**. El plan propone un asistente textual *offline* con detección de idioma, enrutamiento lingüístico, RAG

local disciplinado y un SLM cuantizado; excluye voz y sitúa la contribución en la integración y evaluación del *pipeline* completo, no en el entrenamiento de un modelo nuevo. Esa acotación reduce el riesgo de sobreingeniería y hace el proyecto ejecutable dentro del plazo de una tesis.

Hardware e inferencia local

El archivo GGUF de **Qwen2.5-7B-Instruct** en cuantización **Q4_K_M** pesa **4,68 GB**; el de **Qwen2.5-3B-Instruct** pesa **2,1 GB**. El consumo real de RAM en ejecución es mayor que el tamaño del archivo, porque incluye los pesos, la caché KV y la sobrecarga (*overhead*) del entorno de ejecución: aproximadamente **6–7 GB** para el modelo de 7B y **3 GB** para el de 3B. La regla práctica de ingeniería es que un modelo 4-bit necesita aproximadamente **parámetros $\times$ 0,5 bytes** más la sobrecarga de la caché KV y el contexto. Esto implica que en una laptop con **16 GB de RAM**, el 7B opera con margen suficiente de memoria; en una con **8 GB**, el 7B es marginal y el **3B es la opción segura**. A efectos de este proyecto, se adopta el **Qwen2.5-3B como configuración base** (equipos de 8 GB) y el **Qwen2.5-7B como variante de calidad** (equipos de 16 GB).

La inferencia en CPU está limitada por el ancho de banda de memoria, no por la frecuencia del procesador. En una laptop de gama media (Intel Core i5 de 10.^a a 13.^a generación o AMD Ryzen 5, con memoria DDR4/DDR5), un 7B Q4_K_M genera aproximadamente **8–12 tokens por segundo** y un 3B genera **10–25 tokens por segundo**. Estas velocidades son aceptables para un asistente educativo de turnos cortos. La cuantización no exige GPU; se realiza con utilidades de `llama.cpp` en CPU o, para acelerar la conversión, en el nivel gratuito de Google Colab (GPU T4) o Kaggle, sin costo adicional.

Otros modelos candidatos viables son **Llama 3.2** (variantes de 1B y 3B orientadas a *edge*) y **variantes compactas de Mistral**. La decisión final se tomará durante la fase de *líneas base* (experimentos E1–E2), comparando calidad de generación, latencia y consumo de RAM en el hardware real disponible.

Datos y corpus disponible

El corpus paralelo Quechua Collao–español de Orcotoma Mormontoy et al. (2025) está confirmado: **44 263 palabras** digitalizadas por OCR a partir de cinco libros de la Academia Mayor de la Lengua Quechua (AMLQ). Es un conteo de palabras, no de pares de oraciones; el propio artículo advierte que no se aplicó limpieza *post-OCR*. Como recursos complementarios de dominio público se identifican: el corpus monolingüe `Llamacha/monolingual-quechua-iic` (base del modelo QuBERT para quechua sureño), datos de AmericasNLP 2023 —que comprenden aproximadamente 154 000 pares quechua–español de entrenamiento— y materiales curriculares EIB abiertos del MINEDU.

Advertencia dialectal crítica: la variante *qwy* utilizada en AmericasNLP corresponde al Quechua Chanka (Ayacucho), no al Quechua Collao (Cusco–Puno). Su uso exige validación y normalización ortográfica previa. Construir la base RAG en doce meses es **realista** porque no entrena el modelo desde cero; solo requiere curar, segmentar (*chunking*) y vectorizar documentos.

Mitigación del cuello de botella de tokenización: Como se fundamentó en la sección anterior, la alta fertilidad de tokens en Quechua Collao ($\approx 3,4\times$) exige restringir el tamaño del contexto del RAG. En consecuencia, la preparación del corpus documental aplicará una segmentación corta (250–400 tokens para prosa curricular y una entrada por fragmento para glosarios) y limitará el enrutamiento a un *top-k* máximo de 3 a 5 fragmentos, garantizando la viabilidad de la inferencia local en CPU.

La evidencia más prometedora para compensar la escasez de datos está en **datos sintéticos cuidadosamente controlados**. Dhawan et al. (2026) reportaron mejoras consistentes

en traducción quechua-español cuando añadieron datos sintéticos con preprocesamiento específico, usando **chrF++** como métrica principal. Esto sugiere que la tesis puede beneficiarse de aumentación de datos, pero con datos normalizados y revisados por hablantes nativos, no con generación automática sin validar.

El carácter multilingüe de Qwen2.5 no debe confundirse con competencia real en Quechua Collao: el *model card* declara soporte para español y más de 29 idiomas, pero **no garantiza soporte específico de Quechua Collao** (Court y Elsner, 2024). La pertinencia en esta variedad dependerá del corpus recuperado, los glosarios curados y los *prompts* diseñados con revisión de hablantes nativos, no del conocimiento paramétrico del modelo.

Tabla 4

Inventario de recursos de datos y su aplicabilidad al proyecto

Recurso	Uso en la tesis	Escala	Riesgo	Prioridad
Corpus paralelo Collao-español OCR (Orcotoma Mormontoy et al., 2025)	<i>Línea base</i> de traducción y glosario bilingüe	44 263 palabras	Pequeño; ruido OCR; cobertura limitada	Muy alta
Currículo nacional, materiales EIB, libros y guías docentes	Núcleo de RAG factual y pedagógico	No especificado	Derechos, OCR, heterogeneidad	Muy alta
Glosarios terminológicos y diccionarios locales	Reglas, normalización y <i>chunks</i> léxicos	No especificado	Ortografía / dialectalidad	Muy alta
Recursos de Quechua en AmericasNLP / NLLB / FLORES	<i>Líneas base</i> y transferencia controlada	Amplios, pero no Collao puro	Mezcla dialectal	Media
Datos sintéticos validados por hablantes/docentes	Aumentación para adaptación ligera	Escala variable	Amplificación de errores	Alta (si hay validación)

Stack tecnológico y configuración RAG

El desarrollo se fundamenta en un ecosistema de software libre y local para garantizar la ejecución offline. Para la inferencia y cuantización del SLM se utilizará `llama.cpp` (Gerganov, 2024) como entorno de ejecución principal, el cual permite ejecutar modelos en formato GGUF directamente en CPU con un consumo optimizado de recursos. La base de datos vectorial local se gestionará mediante FAISS (Johnson et al., 2019) o Milvus Lite (Milvus Team, 2024), procesando vectores generados por modelos de incrustación livianos como `multilingual-e5-small` (Wang et al., 2022) o `BGE-M3` (Xiao et al., 2024). La recuperación semántica se complementará con recuperación léxica mediante BM25 (Robertson and Zaragoza, 2009) para asegurar la fidelidad en términos exactos de glosarios. La orquestación general del canal de procesamiento se construirá mediante LangChain (Chase, 2022) o un desarrollo modular directo en Python.

Para mitigar el cuello de botella de la tokenización, la configuración del RAG local aplicará un diseño disciplinado: (i) los fragmentos de prosa curricular se limitarán a un rango de 250 a 400 tokens con un traslape (*overlap*) de 50 a 80 tokens; (ii) las entradas de glosarios y diccionarios se indexarán individualmente (una entrada por fragmento); (iii) se empleará recuperación híbrida (lexical BM25 + semántica densa) recuperando un *top-k* máximo de 3 a 5 fragmentos; y (iv) se evaluará un paso opcional de reordenamiento (*reranking*) liviano

siempre que no degrade la latencia del sistema en CPU. Esta configuración estructurada minimiza el ruido de contexto y previene la saturación de la memoria caché KV en el SLM.

Matriz técnica de factibilidad

Tabla 5

Matriz de viabilidad técnica aplicada al proyecto

Componente crítico	Estado actual	ac-	Justificación	Contingencia
Cómputo para inferencia (CPU-only)	Por gestionar		Inferencia local validada en literatura (Walusimbi et al., 2026); $\sim 8\text{--}25$ tok/s en laptop gama media según tamaño de modelo	Iniciar con 3B; escalar a 7B solo si el equipo lo soporta
Dataset y corpus para RAG	Por gestionar		Corpus base disponible (Orcotoma Mormontoy et al., 2025); pequeño, requiere limpieza y complemento curricular	Acotar dominio a un área y grado; curación manual validada por especialista AMLQ
Cuello de botella de tokenización	Identificado		Fertilidad $\approx 3,4\times$; penaliza caché KV y latencia en CPU con fragmentos largos	Segmentación corta (250–400 tokens); <i>top-k</i> ≤ 5 ; monitorear fertilidad como métrica
Adaptación ligera (QLoRA)	Factible con GPU gratuita		Viable en Kaggle/Colab (GPU T4) o alquiler por demanda ($\sim$ US\$ 0,69/h) para modelos $\leq 7B$	Solo como configuración experimental complementaria; no para inyectar conocimiento factual
Stack tecnológico	Parcialmente cubierto		<i>Stack</i> abierto y documentado; soporte Qwen en ecosistemas estándar (Xu et al., 2024)	Congelar versiones con <code>requirements.txt</code> ; evitar dependencias de pago
Riesgo de sobreingeniería	Alto si no se contiene		Viable como prototipo textual; riesgo si se agrega voz, app móvil o despliegue institucional masivo (Hevia et al., 2025)	Interfaz mínima (CLI/web local); priorizar evaluación del <i>pipeline</i>

8.3. Factibilidad económica e infraestructura

Económicamente, el proyecto es altamente viable ya que el presupuesto total consolidado es de S/ 6 962,00 (detallado en la Sección 11), el cual será asumido con recursos propios de los investigadores. Al optar por una arquitectura local basada en un modelo de lenguaje de código abierto e inferencia offline, los costos operativos y recurrentes de APIs comerciales en producción se reducen a cero, eliminando dependencias externas de suscripción.

El cómputo requerido para el ajuste QLoRA experimental y la cuantización de modelos consiste en tareas puntuales que no requieren servidores GPU permanentes. Estas tareas

pueden cubrirse principalmente con recursos gratuitos de desarrollo (ej. Kaggle o Google Colab en sus capas de acceso libre con GPU T4) y créditos académicos. Ante saturación en las cuotas gratuitas, se contempla una partida de S/ 150,00 para el alquiler por demanda de GPUs comerciales (como RTX 4090 o similares en plataformas en la nube), donde el costo relevante corresponde al proceso iterativo de experimentación. Adicionalmente, el presupuesto asigna S/ 500,00 para la adquisición de una unidad SSD de alta velocidad de 1 TB para almacenar de forma persistente los modelos base en formato GGUF y el corpus bilingüe local. Por consiguiente, no se identifican riesgos financieros críticos que comprometan el desarrollo del proyecto.

8.4. Factibilidad operativa y gestión del alcance

Operativamente, el proyecto es más viable que una tesis dependiente de sistemas empresariales, porque el artefacto propuesto es un **prototipo autónomo** que no requiere acceso a código fuente, APIs internas o bases de datos corporativas. Sin embargo, mantiene dos dependencias operativas serias: la coordinación con docentes o especialistas EIB para la validación pedagógica, y el acceso a materiales curriculares en escenarios de prueba con pertinencia lingüística responsable.

Tabla 6

Factores de riesgo operativo y estrategias de mitigación

Factor de riesgo	Estrategia de mitigación / delimitación
Acceso a validadores EIB (DRE/UGEL/AMLQ)	Iniciar gestiones institucionales desde el arranque del proyecto; tener plan B de validación remota con panel reducido de especialistas.
Riesgo de sobreextensión del desarrollo UI/UX	Limitar la interfaz a un mínimo funcional (CLI o web local tipo Streamlit); concentrar el esfuerzo en el canal de procesamiento SLM+RAG y su evaluación. El valor académico no está en la interfaz, sino en la arquitectura bilingüe (Hevia et al., 2025).
Indefinición del criterio de parada	Fijar umbrales de éxito <i>ex ante</i> : (i) técnicos — latencia, $RAM \leq$ capacidad del equipo objetivo, tok/s, estabilidad <i>offline</i> ; (ii) lingüísticos — chrF++ sobre corpus de prueba Collao-español; (iii) pedagógicos — rúbricas de docentes EIB.
Sobreextensión del corpus y alcance	Acotar el dominio curricular a áreas de Comunicación y Ciencia y Tecnología para el primer ciclo de validación; no intentar cubrir toda la EIB en una sola iteración.
Mezcla dialectal no controlada	Etiquetar todo recurso externo por variedad dialectal; no mezclar datos Chanka y Collao sin normalización previa validada por especialista AMLQ.

8.5. Factibilidad del diseño experimental y la validación

El diseño experimental se sustenta en una **comparación escalonada**: la investigación gana rigor metodológico al comparar explícitamente las opciones A, B y C en subtareas diferenciadas, dado que cada enfoque presenta rendimientos diferenciados según la subtarea evaluada.

Experimentos propuestos

Tabla 7

Diseño experimental escalonado propuesto

ID	Sistema	Propósito
E1	SLM base cuantizado sin RAG	Establecer el piso real de rendimiento del modelo generalista
E2	SLM + RAG local	Medir la ganancia factual y pedagógica de la <i>configuración base B</i>
E3	SLM + reglas/glosario sin RAG	Medir el aporte lingüístico sin recuperación
E4	SLM + RAG + reglas	Primer híbrido simple (B + reglas)
E5	SLM + QLoRA ligero sin RAG	Medir si la adaptación paramétrica mejora estilo/terminología por sí sola
E6	SLM + RAG + QLoRA + reglas	Evaluar el enfoque C completo
E7	Ablaciones de segmentación/ <i>top-k</i> /incrustación	Identificar los cuellos de botella del canal de procesamiento RAG

Este diseño permite demostrar empíricamente **por qué RAG solo no basta** (comparando E2 vs. E4 vs. E6) y **por qué el fine-tuning solo tampoco basta** (comparando E5 vs. E6). La factibilidad de ejecutar los siete experimentos depende de que la infraestructura (GPU gratuita para QLoRA, CPU local para inferencia) esté disponible; los experimentos E1–E4 y E7 son ejecutables **sin GPU**, y E5–E6 requieren solo sesiones puntuales en Kaggle/Colab.

Para evitar la contaminación experimental y garantizar la validez de los resultados, se implementará un **protocolo estricto de aislamiento de datos** entre el entrenamiento QLoRA (ajuste paramétrico) y la base vectorial del RAG. El corpus terminológico y curricular bilingüe se dividirá en tres particiones disjuntas: (i) *Partición de Ingesta RAG* ($\approx 70\%$ del corpus), utilizada para poblar la base de datos vectorial en E2, E4 y E6; (ii) *Partición de Entrenamiento* ($\approx 20\%$ del corpus), empleada únicamente para el ajuste de adaptadores QLoRA en E5 y E6; y (iii) *Partición de Evaluación* ($\approx 10\%$ del corpus), compuesta por un banco de 100 consultas patrón que no serán indexadas en la base vectorial ni utilizadas en el entrenamiento de adaptadores. Esto asegura que la evaluación mida la generalización real ante datos no vistos.

Métricas de evaluación multidimensional

Las métricas deben ser multidimensionales. Para una tesis sobre una lengua de bajos recursos con aplicación pedagógica, usar solo BLEU sería insuficiente.

Tabla 8*Framework de métricas de evaluación para el proyecto*

Dimensión	Métrica automática	Métrica humana
Traducción	chrF++, SacreBLEU (Post, 2018), COMET (Rei et al., 2020), BERTScore (Zhang et al., 2019)	Adecuación, fluidez, terminología, adecuación dialectal
QA factual	Exact match / F1 (cuando aplique); <i>faithfulness</i> RAGAS (Es et al., 2024)	Veracidad y cita de fuente
Recuperación	Recall@k, MRR, nDCG	Relevancia del fragmento recuperado
Pedagogía	Ninguna automática basta por sí sola	Andamiaje, claridad, retroalimentación (<i>feedback</i>) accionable
Usabilidad	SUS (Brooke, 1996) o escala Likert	Utilidad percibida, confianza, carga cognitiva
Rendimiento técnico	Latencia (ms), tokens/s, RAM/VRAM, estabilidad	Satisfacción de uso
Sostenibilidad	Wh por consulta, CO ₂ e estimado	No aplica

La métrica **chrF++** es especialmente importante para este proyecto: en lenguas morfológicamente complejas y de bajos recursos como el Quechua Collao, chrF++ opera a nivel de *n-gramas* de caracteres en lugar de palabras completas, lo que la hace más robusta frente a la variación morfológica y la fragmentación de tokens. Trabajos recientes en traducción de lenguas indígenas la han adoptado como métrica principal. **RAGAS** es crítico para separar los problemas de recuperación de los problemas de generación: si el sistema falla, se necesita saber si el problema está en el SLM o en el RAG.

Panel de validación humana

La validación humana constituye un componente esencial de la validez del artefacto en esta tesis; no representa un elemento accesorio. Un esquema prudente y factible para una tesis de pregrado comprende:

- **3–5 evaluadores lingüísticos** para normalización, terminología y adecuación dialectal (hablantes nativos del Quechua Collao, idealmente vinculados a la AMLQ).
- **8–15 docentes EIB** para valoración pedagógica de respuestas y escenarios de aula (vinculados a DRE/UGEL de Cusco o Puno).
- **20–40 estudiantes** (si la logística escolar lo permite) para un piloto con protocolo ético, consentimiento informado y tareas acotadas.

8.6. Semáforo de riesgo tecnológico

Tabla 9

Semáforo de riesgo por dimensión

Dimensión	Nivel	Justificación
Técnica (hardware / inferencia / cuantización)	VERDE	Modelos y herramientas probados; inferencia en CPU validada; cuantización en nivel gratuito.
Stack / tooling	VERDE	Maduro, abierto, documentado; la penalización por tokenización aglutinante ($\approx 3,4\times$) se mitiga con la estrategia híbrida, segmentación corta y <i>top-k</i> pequeño.
Económica / nube	VERDE	Costos cubribles; nube gratuita (Kaggle/Colab) cubre tareas <i>puntuales</i> ; QLoRA absorbible por presupuesto ($\sim S/ 50-200$); presupuesto corregido suficiente.
Adaptación ligera (QLoRA)	VERDE	Viable en GPU gratuita para modelos $\leq 7B$; el riesgo se contiene limitando QLoRA a comportamiento pedagógico, no a inyección de conocimiento.
Diseño experimental	VERDE	Experimentos E1–E4 y E7 ejecutables sin GPU; E5–E6 requieren sesiones puntuales; métricas bien definidas y herramientas disponibles.
Datos (corpus Collao)	AMARILLO	Corpus base disponible (Orcotoma Mormontoy et al., 2025) pero pequeño, sin limpieza <i>post-OCR</i> ; variantes dialectales (Chanka vs. Collao) exigen validación; cuello de botella de tokenización identificado pero mitigable.
Operativo (acceso EIB / alcance)	AMARILLO	Depende de trámites con DRE/UGEL/AMLQ y de disciplina de alcance para evitar <i>scope creep</i> .
GLOBAL	AMARILLO	Factible con gestión activa de los riesgos de datos y operativos. El enfoque híbrido reduce significativamente el riesgo técnico y económico respecto a alternativas de entrenamiento.

La viabilidad global del proyecto se consolidará bajo el cumplimiento de las siguientes condiciones de control técnico y operativo: usar un modelo comprimido de entre 3B y 7B parámetros; mantener el sistema estrictamente textual y *offline*; delimitar la base de conocimiento local a áreas curriculares específicas de nivel primaria; y contar con un panel de revisores pedagógicos y lingüísticos. Por el contrario, se identifican como desviaciones críticas de riesgo: el intento de entrenar o realizar un ajuste paramétrico intensivo y masivo como objetivo primario; la dependencia estructural de APIs comerciales en la nube; o la implementación de un RAG no optimizado con ventanas de contexto saturadas que degraden el rendimiento en CPU.

8.7. Conclusión de viabilidad

En síntesis, el proyecto se sitúa en un rango de factibilidad favorable. La decisión de no entrenar un modelo desde cero ni depender de APIs de pago en la nube, sino implementar un enfoque híbrido local —orquestando un SLM preentrenado cuantizado con un RAG local disciplinado y reglas de normalización— reduce drásticamente las exigencias de cómputo y presupuesto. De este modo, la investigación resulta viable bajo los escenarios de infraestructura locales y los recursos asignados en el presente plan.

9. Importancia del estudio

9.1. Resultados esperados

El artefacto principal de esta investigación es un **prototipo de sistema informático**: un asistente educativo bilingüe español–Quechua Collao ejecutable sin conexión a internet en dispositivos de bajo o mediano costo. Este prototipo no constituye un modelo de lenguaje nuevo ni realiza entrenamiento del modelo base desde cero, sino que implementa un **enfoque híbrido** que integra un modelo compacto pre-entrenado y cuantizado con un canal de procesamiento RAG local disciplinado, recursos lingüísticos explícitos (glosarios, diccionarios, reglas de normalización) y, de ser factible, una adaptación ligera complementaria (QLoRA) como configuración experimental, adaptado específicamente para responder consultas pedagógicas en contextos EIB del sur andino peruano. Los productos derivados de su construcción y evaluación son:

- Un prototipo funcional de asistente educativo bilingüe español–Quechua Collao, ejecutable sin conexión a internet en dispositivos de bajo o mediano costo, basado en un modelo compacto cuantizado con canal de procesamiento RAG disciplinado y, de ser factible, adaptación ligera complementaria.
- Una base local de contenidos curriculares, glosarios terminológicos, diccionarios y materiales EIB en español y Quechua Collao, organizados para su recuperación híbrida (léxica + densa) y orientados al nivel primaria (3.º a 6.º grado), con posibilidad de ampliación posterior hacia secundaria básica en futuras iteraciones.
- Un corpus curado de recursos lingüísticos español–Quechua Collao, complementado con datos sintéticos y validado por especialistas hablantes nativos.
- Un reporte comparativo de las configuraciones experimentales (*línea base* sin RAG, RAG disciplinado y enfoque híbrido completo) que documente la contribución de cada componente del sistema.
- Un reporte de evaluación técnica que documente métricas de latencia, consumo de memoria, tokens por segundo y estabilidad del prototipo en hardware de bajo o mediano costo de forma local.
- Un reporte de evaluación lingüística y pedagógica con resultados de métricas automáticas (chrF++, RAGAS, Recall@k) y valoraciones de docentes y especialistas EIB sobre la utilidad educativa, pertinencia intercultural y adecuación pedagógica de las respuestas generadas.

9.2. Contribuciones

- **Contribución tecnológica:** Arquitectura híbrida funcional de un asistente educativo orientado al funcionamiento offline que integra detección de idioma, enrutamiento lingüístico, RAG local disciplinado y recursos lingüísticos explícitos, incorporando adaptación ligera mediante QLoRA como configuración experimental complementaria, y la generación de respuestas mediante un modelo compacto cuantizado, ejecutable en dispositivos de bajo o mediano costo sin conexión a internet.
- **Contribución educativa:** Base de conocimiento local organizada con materiales curriculares EIB en español y Quechua Collao, orientada a apoyar consultas pedagógicas de estudiantes y docentes en zonas rurales, junto con un corpus curado de recursos lingüísticos para la variedad Quechua Collao aplicados a tareas de educación intercultural bilingüe.
- **Contribución metodológica:** Diseño de comparación escalonada que cuantifica la contribución de cada componente del enfoque híbrido, combinando métricas automáticas de calidad lingüística (chrF++), calidad de recuperación (RAGAS) y criterios pedagógicos e interculturales validados por especialistas EIB, aplicable a otros proyectos de tecnología educativa en lenguas indígenas de bajos recursos del sur andino.

9.3. Impacto social

El desarrollo de un asistente educativo bilingüe offline tiene el potencial de beneficiar a docentes y estudiantes de comunidades quechuahablantes del sur andino peruano que actualmente carecen de herramientas tecnológicas adaptadas a su realidad lingüística y territorial. Al operar sin conexión a internet y en Quechua Collao, el prototipo podría contribuir a reducir la brecha digital educativa en zonas rurales, fortalecer el uso de la lengua materna en contextos de aprendizaje formal y apoyar los objetivos del modelo de servicio educativo intercultural bilingüe del Ministerio de Educación.

10. Cronograma de actividades

El desarrollo de la tesis se planifica en un horizonte de doce meses a partir de la aprobación del plan. Las actividades se organizan en seis fases según la metodología Design Science Research.

Tabla 10
Cronograma de actividades por fases y meses

Actividad	1	2	3	4	5	6	7	8	9	10	11	12
Fase 1: Preparación y permisos												
Revisión de literatura y estado del arte	•	•										
Caracterización de requerimientos EIB	•	•										
Permisos institucionales y validación ética	•	•	•									
Fase 2: Diseño de la solución												
Diseño de la arquitectura híbrida <i>offline</i>		•	•									
Selección del modelo compacto base			•	•								
Fase 3: Recursos y corpus												
Curación, depuración y normalización de corpus			•	•	•							
Glosarios, diccionarios y base curricular				•	•							
Construcción del banco de consultas				•	•							
Fase 4: Implementación												
Cuantización y configuración local del modelo					•	•	•					
Módulo de detección e integración de RAG local						•	•	•				
Adaptación ligera QLoRA (condicionada)*								•	•			
Integración final del prototipo								•	•			
Fase 5: Evaluación												
Diseño de rúbricas y experimentos E1–E7									•			
Evaluación técnica y lingüística									•	•		
Prueba piloto exploratoria y juicio de expertos EIB										•	•	
Análisis y procesamiento de resultados											•	
Fase 6: Documentación												
Redacción del informe de tesis										•	•	•
Revisión final con asesor y sustentación												•

**Nota: La adaptación QLoRA (Fase 4) se considera opcional y condicionada a la disponibilidad de recursos de cómputo y a la escala del corpus curricular validado.*

11. Presupuesto

El presupuesto estimado para el desarrollo de la tesis se detalla a continuación. Se consideran los recursos necesarios para la implementación del prototipo, la evaluación y la documentación.

Tabla 11

Presupuesto estimado del proyecto

Rubro	Cantidad	Costo (S/.)
Recursos tecnológicos		
Dispositivo de prueba (laptop de gama media)	1	2 579.00
Almacenamiento externo (SSD 1 TB)	1	500.00
Servicio de cómputo en la nube (cuantización y vectorización)	Puntual	200.00
Adaptación QLoRA (GPU por demanda)	Puntual	150.00
Recursos académicos		
Material bibliográfico y acceso a bases de datos	Global	300.00
Impresiones y empastados	Global	200.00
Trabajo de campo		
Transporte a zonas rurales (validación)	5 visitas	750.00
Viáticos para trabajo de campo	5 días	500.00
Material para talleres con docentes EIB	Global	200.00
Servicios profesionales		
Consulta con especialistas en Quechua Collao	3 sesiones	450.00
Validación lingüística por hablantes nativos	5 sesiones	500.00
Otros		
Imprevistos (10 %)	Global	633.00
TOTAL		6 962.00

Nota: El uso de servicios de cómputo en la nube se restringe exclusivamente a tareas puntuales de desarrollo experimental (cuantización y afinamiento ligero) y no forma parte del funcionamiento final del asistente, el cual opera de forma 100 % offline. Los honorarios de especialistas y hablantes nativos corresponden a retribuciones por sesiones de validación lingüística y pedagógica del corpus y del prototipo.

Bibliografía

- Brooke, J. (1996). Sus: A quick and dirty usability scale. In Jordan, P. W., Thomas, B., Weerdmeester, B. A., and McClelland, I. L., editors, *Usability Evaluation in Industry*, pages 189–194. Taylor & Francis.
- Chase, H. (2022). Langchain. <https://github.com/langchain-ai/langchain>.
- Chen, Z., Liu, J., Dong, R., and Mao, H. (2024). Queen: Leveraging rag and llm-based agents for quechua-english translation. In *Proceedings of the Conference on Machine Translation*. Disponible en: <https://aclanthology.org/2024.wmt-1.126/>.
- Court, S. and Elsner, M. (2024). Shortcomings of llms for low-resource translation: Retrieval and understanding are both the problem. In *Proceedings of the Conference on Machine Translation*. Disponible en: <https://aclanthology.org/2024.wmt-1.125/>.
- Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. (2023). Qlora: Efficient finetuning of quantized language models. *Advances in Neural Information Processing Systems*, 36. Disponible en: <https://arxiv.org/abs/2305.14314>.
- Dhawan, A., Kann, K., and Oncevay, A. (2026). Improving machine translation for indigenous languages of the americas with synthetic data and language-specific preprocessing. In *Proceedings of the Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*. DOI: <https://doi.org/10.18653/v1/2026.americasnlp-1>.
- Duran, M. and Silberztein, M. (2026). Semi-automatic construction of a quechua-spanish dictionary. In *Proceedings for the Ninth Workshop on Technologies for Machine Translation of Low Resource Languages*, pages 111–118. DOI: <https://doi.org/10.18653/v1/2026.loresmt-1.9>.
- Es, S., James, J., Espinosa-Anke, L., and Schockaert, S. (2024). Ragas: Automated evaluation of retrieval augmented generation. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2309.15217>.
- Gerganov, G. (2024). llama.cpp: Inference of llama model in pure c/c++. <https://github.com/ggerganov/llama.cpp>.
- Hevia, J. S., Arredondo, F., and Kumar, V. (2025). Towards an efficient, customizable, and accessible ai tutor. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2510.06255>.
- INEI (2025). Estadísticas de las tecnologías de la información y comunicación en los hogares: Primer trimestre 2025. Technical report, Instituto Nacional de Estadística e Informática. Disponible en: <https://www.inei.gob.pe/>.
- Johnson, J., Douze, M., and Jégou, H. (2019). Billion-scale similarity search with gpus. *IEEE Transactions on Big Data*, 7(3):535–547.

- Levonian, Z., Henkel, O., Li, C., and Postle, M.-E. (2025). Designing safe and relevant generative chats for math learning in intelligent tutoring systems. *Journal of Educational Data Mining*, 17(1):66–97. DOI: <https://doi.org/10.5281/zenodo.14751365>.
- Li, Z., Wang, Z., Wang, W., Hung, K., Xie, H., and Wang, F. L. (2025). Retrieval-augmented generation for educational application: A systematic survey. *Computers and Education: Artificial Intelligence*. DOI: <https://doi.org/10.1016/j.caeai.2025.100417>.
- Milvus Team (2024). Milvus lite: Lightweight vector database for local development. <https://github.com/milvus-io/milvus-lite>.
- Ministerio de Educación del Perú (2018). Modelo de servicio educativo intercultural bilingüe. Disponible en: <https://repositorio.minedu.gob.pe/handle/20.500.12799/5971>.
- Orcotoma Mormontoy, G. C., Leon Nuñez, L., and Espetia Huamanga, H. (2025). Towards the creation of a collao quechua-spanish parallel corpus using optical character recognition. In *Proceedings of the Workshop on Beyond English*. Disponible en: <https://aclanthology.org/2025.globalnlp-1.1/>.
- Ovadia, O., Brief, M., Mishaeli, M., and Sigal, O. (2024). Fine-tuning or retrieval? comparing knowledge injection in llms. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2312.05934>.
- Post, M. (2018). A call for clarity in reporting bleu scores. In *Proceedings of the Third Conference on Machine Translation: Research Papers*, pages 186–191. DOI: <https://doi.org/10.18653/v1/W18-6319>.
- Rei, R., Stewart, C., Farinha, A. C., and Lavie, A. (2020). Comet: A neural framework for mt evaluation. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pages 2685–2702. DOI: <https://doi.org/10.18653/v1/2020.emnlp-main.213>.
- Robertson, S. and Zaragoza, H. (2009). The probabilistic relevance framework: Bm25 and beyond. In *Information Retrieval*, volume 3, pages 333–380. Now Publishers.
- Sulla Torres, J. A., Cueva Medina, B., and Tuco Casquino, G. F. (2024). Development of a neural machine translation model optimized with bert for translation from quechua to spanish. In *LACCEI*. DOI: <https://doi.org/10.18687/LACCEI2024.1.1.1636>.
- UNESCO (2022). State of the world’s indigenous peoples: Education and language. Technical report, United Nations Educational, Scientific and Cultural Organization. Disponible en: <https://unesdoc.unesco.org/>.
- Walusimbi, J., Oguti, A. M., Ssentongo, J. B., and Ainebyona, K. (2026). Arapai: An offline-first ai chatbot architecture for low-connectivity educational environments. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2603.03339>.
- Wang, L., Yang, N., Huang, X., Yang, L., Jiang, D., Bhalerao, R., and Zhou, M. (2022). Text embeddings by weakly-supervised contrastive pre-training. *arXiv preprint arXiv:2212.03533*.
- Xiao, S., Liu, Z., Zhang, Y., and Muennighoff, N. (2024). Bge-m3: A multi-function, multi-lingual, multi-granularity language model for retrieval. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2402.03216>.

- Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., and Ling, Z. (2024). On-device language models: A comprehensive review. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2409.00088>.
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., and Artzi, Y. (2019). Bertscore: Evaluating text generation with bert. In *International Conference on Learning Representations*. Disponible en: <https://arxiv.org/abs/1904.09675>.
- Zhang, T., Patil, S. G., Jain, N., Shen, S., Zaharia, M., Stoica, I., and Gonzalez, J. E. (2024). Raft: Adapting language model to domain specific rag. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2403.10131>.

Anexo: Fichas de Análisis

A continuación, se presentan las fichas de análisis de las siete fuentes más relevantes para la investigación, elaboradas conforme a las exigencias de la guía metodológica del seminario.

Ficha 1: Orcotoma Mormontoy et al. (2025)

1. **REFERENCIA COMPLETA (APA 7):** Orcotoma Mormontoy, G. C., Leon Nuñez, L., & Espetia Huamanga, H. (2025). Towards the Creation of a Collao Quechua-Spanish Parallel Corpus Using Optical Character Recognition. *Proceedings of the Workshop on Beyond English*, 1-6. <https://doi.org/10.26615/978-954-452-105-9-001>
 2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica
 3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Construir un corpus paralelo Quechua Collao-español utilizando reconocimiento óptico de caracteres (OCR) para superar la escasez de recursos digitales en esta lengua de bajos recursos.
 4. **METODOLOGÍA:** Enfoque tecnológico. Digitación y procesamiento (filtros de mediana y binarización) de libros de grado de la Academia Mayor de la Lengua Quechua, seguido de extracción de texto con Tesseract OCR y evaluación mediante Character Error Rate (CER) y Word Error Rate (WER) frente a un texto validado manualmente (ground truth).
 5. **RESULTADOS PRINCIPALES:** Se construyó un corpus de 44 263 palabras (18 179 en quechua y 26 084 en español). La evaluación del OCR mostró un CER de 1.82 % y un WER de 6.59 %, demostrando la viabilidad de la extracción automática con posprocesamiento.
 6. **CONCLUSIONES DEL AUTOR:** El uso de OCR es viable para crear corpus paralelos en Quechua Collao si se aplican métodos adecuados de preprocesamiento, lo que proporciona una metodología valiosa para preservar la lengua y entrenar futuras tecnologías NLP.
 7. **RELEVANCIA PARA MI TESIS:** Es un antecedente directo para la obtención de datos de entrenamiento y evaluación. Justifica la delimitación del proyecto al Quechua Collao al confirmar la existencia de recursos paralelos validados procedentes de la Academia Mayor de la Lengua Quechua.
 8. **CITAS TEXTUALES ÚTILES:** “The importance of the result of this study lies in providing a methodology for the development of new technologies that require Collao Quechua-Spanish parallel corpora, such as automatic translators and sentence auto-completion systems” (p. 1).
 9. **PALABRAS CLAVE ASIGNADAS:** Corpus paralelo, OCR, Quechua Collao, NLP de bajos recursos.
-

Ficha 2: Court & Elsner (2024)

1. **REFERENCIA COMPLETA (APA 7):** Court, S., & Elsner, M. (2024). Shortcomings of LLMs for Low-Resource Translation: Retrieval and Understanding Are Both the Problem. *Proceedings of the Ninth Conference on Machine Translation*, 1332-1354.
 2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica
 3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Investigar las habilidades de aprendizaje en contexto de Grandes Modelos de Lenguaje (LLMs) al traducir desde una lengua de bajos recursos (quechua sureño) hacia el español, utilizando información recuperada de diccionarios, gramáticas y corpus.
 4. **METODOLOGÍA:** Experimental cuantitativa. Se evaluó la salida de cuatro LLMs (GPT-3.5, GPT-4o, Gemini 1.5, Llama 3) bajo ocho condiciones de prompt que combinaban información de morfemas, gramática y ejemplos de corpus, usando métricas automáticas (BLEURT, BLEU) y anotación humana de errores.
 5. **RESULTADOS PRINCIPALES:** La inclusión de traducciones a nivel de morfema mejora el rendimiento de los modelos más pequeños. Sin embargo, en modelos más avanzados (GPT-4o), añadir contexto gramatical o de corpus reduce los puntajes BLEURT y aumenta la divergencia gramatical.
 6. **CONCLUSIONES DEL AUTOR:** Incluso explicaciones gramaticales relevantes ayudan poco a las generaciones más recientes de LLMs en tareas de bajos recursos. Las traducciones infieles suelen ser engañosamente fluidas en español, y en ocasiones introducen estereotipos culturales no presentes en la frase original.
 7. **RELEVANCIA PARA MI TESIS:** Demuestra que no basta con usar la técnica RAG para inyectar reglas gramaticales en un modelo genérico. Justifica la necesidad de afinar o cuantizar un Small Language Model especializado en lugar de depender únicamente del aprendizaje en contexto de un modelo en la nube.
 8. **CITAS TEXTUALES ÚTILES:** “providing additional information in the prompt’s context actually degrades GPT-4o’s ability to translate from S. Quechua to Spanish in all experimental conditions” (p. 7).
 9. **PALABRAS CLAVE ASIGNADAS:** LLMs, Quechua sureño, RAG, traducción automática, aprendizaje en contexto.
-

Ficha 3: Walusimbi et al. (2026)

1. **REFERENCIA COMPLETA (APA 7):** Walusimbi, J., Oguti, A. M., Ssentongo, J. B., & Ainebyona, K. (2026). Arapai: An Offline-First AI Chatbot Architecture for Low-Connectivity Educational Environments. *arXiv preprint arXiv:2603.03339*.
2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Diseñar y evaluar una arquitectura de LLM orientada a operar sin conexión a internet (offline-first) para asistencia educativa en entornos con baja conectividad.

4. **METODOLOGÍA:** Investigación aplicada. Se implementaron modelos cuantizados (TinyLlama, Qwen2.5-3B, Mistral-7B) ejecutados localmente en CPU. El sistema adaptativo fue evaluado cualitativa y cuantitativamente con 120 estudiantes y 9 docentes en condiciones reales.
 5. **RESULTADOS PRINCIPALES:** El sistema operó de forma estable en hardware heredado (CPU). Las consultas instructivas típicas mostraron latencias de respuesta de 1 a 3 segundos. Los usuarios reportaron una alta utilidad para el aprendizaje autodirigido a diferentes niveles de complejidad.
 6. **CONCLUSIONES DEL AUTOR:** Es viable desplegar asistentes educativos basados en IA en contextos con limitaciones de infraestructura utilizando LLMs cuantizados que se ejecutan localmente, ofreciendo una alternativa confiable a los sistemas que dependen de la nube.
 7. **RELEVANCIA PARA MI TESIS:** Es el principal antecedente arquitectónico. Valida la hipótesis de que los modelos cuantizados ejecutados en CPU son suficientemente rápidos y útiles para aplicaciones educativas offline en zonas rurales.
 8. **CITAS TEXTUALES ÚTILES:** “The system performs all inference locally using quantized language models and incorporates hardware-aware model selection to enable deployment on low-specification, CPU-only devices” (p. 1).
 9. **PALABRAS CLAVE ASIGNADAS:** Arquitectura offline-first, IA educativa, modelos cuantizados, edge AI.
-

Ficha 4: Xu et al. (2024)

1. **REFERENCIA COMPLETA (APA 7):** Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., & Ling, Z. (2024). On-Device Language Models: A Comprehensive Review. *arXiv preprint arXiv:2409.00088*.
2. **TIPO DE DOCUMENTO:** Artículo de revisión (Survey)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Examinar los desafíos de desplegar LLMs computacionalmente costosos en dispositivos con recursos limitados y explorar las soluciones innovadoras en múltiples dominios.
4. **METODOLOGÍA:** Revisión sistemática de literatura sobre arquitecturas eficientes de modelos de lenguaje en dispositivos (on-device), analizando técnicas de compresión de modelos, aceleración de hardware y despliegue colaborativo borde-nube.
5. **RESULTADOS PRINCIPALES:** Se identifican tres estrategias clave para habilitar modelos en dispositivos: compartición de parámetros, cuantización (PTQ y QAT) para reducir bits de peso/activación, y destilación de conocimiento. La cuantización int4/int8 resulta esencial para procesadores móviles.
6. **CONCLUSIONES DEL AUTOR:** La transición de la nube al borde (edge) reduce latencia y aumenta privacidad, pero requiere un equilibrio delicado entre el rendimiento del modelo (precisión) y la utilización de recursos (memoria y energía) que solo se logra combinando múltiples técnicas de compresión.

7. **RELEVANCIA PARA MI TESIS:** Proporciona el marco teórico tecnológico sobre Small Language Models y cuantización que fundamenta el diseño del asistente educativo para hardware de bajo costo.
 8. **CITAS TEXTUALES ÚTILES:** “deploying computationally expensive LLMs on resource-constrained devices poses significant challenges. The primary obstacles include limited computational power, reduced memory capacity, and energy constraints” (p. 2).
 9. **PALABRAS CLAVE ASIGNADAS:** On-Device AI, cuantización, compresión de modelos, Small Language Models.
-

Ficha 5: Hevia et al. (2025)

1. **REFERENCIA COMPLETA (APA 7):** Hevia, J. S., Arredondo, F., & Kumar, V. (2025). Towards an Efficient, Customizable, and Accessible AI Tutor. *arXiv preprint arXiv:2510.06255*.
 2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)
 3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Proponer un sistema tutorial de IA fuera de línea (offline) basado en Generación Aumentada por Recuperación (RAG) emparejado con un Small Language Model (SLM) para entornos de bajos recursos.
 4. **METODOLOGÍA:** Experimental cuantitativa. Evaluación de modelos de la familia SmolLM (135M y 1.7B) y RAG con libros de texto de biología de OpenStax usando métricas del benchmark MMLU para evaluar el impacto del contexto en la precisión de respuesta.
 5. **RESULTADOS PRINCIPALES:** Contrario a lo esperado, la inclusión de recuperación RAG en SLMs disminuyó su precisión en el MMLU (de 21.59 % a 21.81 % con RAG en SmolLM2-135M, y una caída drástica en el modelo 1.7B), debido a la incapacidad de estos modelos pequeños para manejar ventanas de contexto extendidas y ruidosas.
 6. **CONCLUSIONES DEL AUTOR:** Los Small Language Models luchan por aprovechar efectivamente el contexto extendido provisto por RAG, especialmente si los fragmentos contienen información irrelevante. Es crítico usar técnicas avanzadas de “*chunking*” (fragmentación semántica) y métricas de evaluación holísticas más allá de opciones múltiples.
 7. **RELEVANCIA PARA MI TESIS:** Alerta sobre los riesgos de usar arquitectura RAG simple con SLMs en el diseño del asistente EIB. Justifica la necesidad de un preprocesamiento cuidadoso de los contenidos curriculares y glosarios locales para evitar introducir ruido en la consulta.
 8. **CITAS TEXTUALES ÚTILES:** “smaller models, such as SmolLM, struggle to effectively leverage extended contexts provided by the RAG pipeline, particularly when noisy or irrelevant chunks are included” (p. 1).
 9. **PALABRAS CLAVE ASIGNADAS:** RAG, AI Tutor, Small Language Model, educación fuera de línea.
-

Ficha 6: Chen et al. (2024)

- 1. REFERENCIA COMPLETA (APA 7):** Chen, Z., Liu, J., Dong, R., & Mao, H. (2024). QueEn: Leveraging RAG and LLM-Based Agents for Quechua-English Translation. *Proceedings of the Conference on Machine Translation*. <https://aclanthology.org/2024.wmt-1.126/>
 - 2. TIPO DE DOCUMENTO:** Artículo de conferencia científica
 - 3. OBJETIVO O PREGUNTA DEL ESTUDIO:** Mejorar la traducción automática quechua-inglés mediante un sistema multi-agente que combina RAG sobre recursos lingüísticos con adaptación paramétrica ligera (LoRA).
 - 4. METODOLOGÍA:** Experimental cuantitativa. Implementación de un pipeline multi-agente que integra recuperación de diccionarios y reglas gramaticales con ajuste LoRA sobre un modelo base. Evaluación con BLEU y chrF++ sobre conjuntos de prueba estándar de WMT.
 - 5. RESULTADOS PRINCIPALES:** La hibridación de RAG con LoRA elevó el puntaje BLEU de 1,5 (línea base sin contexto) a 17,6, demostrando que la combinación de RAG con adaptación paramétrica ligera produce mejoras significativas para lenguas de bajos recursos.
 - 6. CONCLUSIONES DEL AUTOR:** La combinación de agentes RAG especializados con ajuste paramétrico ligero supera significativamente tanto al prompting directo como al RAG puro para traducción de lenguas de bajos recursos como el quechua.
 - 7. RELEVANCIA PARA MI TESIS:** Es el antecedente más directo del enfoque híbrido propuesto. Valida empíricamente que la arquitectura RAG + LoRA es la vía más prometedora para el quechua, fundamentando la decisión de combinar RAG disciplinado con QLoRA en el asistente EIB.
 - 8. CITAS TEXTUALES ÚTILES:** “Our system integrates dictionary-based retrieval, grammar rule application, and fine-tuned translation models to handle the morphological complexity of Quechua” (p. 1).
 - 9. PALABRAS CLAVE ASIGNADAS:** RAG, LoRA, quechua, traducción automática, sistema multi-agente.
-

Ficha 7: Zhang et al. (2024)

- 1. REFERENCIA COMPLETA (APA 7):** Zhang, T., Patil, S. G., Jain, N., Shen, S., Zaharia, M., Stoica, I., & Gonzalez, J. E. (2024). RAFT: Adapting Language Model to Domain Specific RAG. *arXiv preprint arXiv:2403.10131*.
- 2. TIPO DE DOCUMENTO:** Artículo científico (Preprint)
- 3. OBJETIVO O PREGUNTA DEL ESTUDIO:** Proponer un método de ajuste fino que enseñe a los modelos de lenguaje a usar el contexto RAG de forma resiliente, distinguiendo fragmentos relevantes de distractores.

4. **METODOLOGÍA:** Experimental cuantitativa. Entrenamiento de modelos con datasets que incluyen documentos relevantes mezclados con distractores, evaluando la capacidad del modelo para generar respuestas ancladas únicamente en la evidencia pertinente.
5. **RESULTADOS PRINCIPALES:** RAFT mejoró consistentemente el rendimiento en benchmarks de dominio específico frente a tanto RAG puro como fine-tuning sin contexto, demostrando que entrenar al modelo a “ignorar distractores” es tan importante como entrenarlo a “usar contexto”.
6. **CONCLUSIONES DEL AUTOR:** La combinación de fine-tuning con entrenamiento en presencia de distractores produce modelos más robustos para aplicaciones RAG de dominio específico.
7. **RELEVANCIA PARA MI TESIS:** Fundamenta teóricamente la capa de adaptación ligera del enfoque híbrido: el QLoRA del asistente EIB debe enseñar al modelo no solo a responder pedagógicamente, sino a distinguir fragmentos dialectalmente correctos (Collao) de distractores (Cusqueño, Chanka).
8. **CITAS TEXTUALES ÚTILES:** “RAFT learns to ignore distractor documents and cite the relevant sequence from the oracle document to generate the answer” (p. 3).
9. **PALABRAS CLAVE ASIGNADAS:** RAFT, RAG, fine-tuning, distractores, adaptación de dominio.