

UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO
FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y
MECÁNICA
ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

Small Language Model bilingüe español-Quechua Collao para asistencia educativa
offline en entornos rurales de Educación Intercultural Bilingüe del sur andino
peruano

Curso:

Seminario de Investigación I

Para optar al Título Profesional de:

Ingeniero Informático y de Sistemas

Presentado por:

Br. Edmil Jampier Saire Bustamante

Br. Haider Alex Carpio Hermoza

Asesora:

Dra. Gabriela Zuñiga Rojas

Cusco – Perú
2026

Resumen

La presente propuesta de plan de tesis aborda el diseño, implementación y evaluación de un Small Language Model bilingüe español-Quechua Collao para asistencia educativa offline en contextos rurales de Educación Intercultural Bilingüe del sur andino peruano. El problema se ubica en la convergencia de tres factores: la brecha de conectividad que afecta a más del 79 % de los hogares rurales sin acceso a internet, la limitada disponibilidad de recursos tecnológicos adaptados a lenguas indígenas de bajos recursos y la necesidad de apoyo pedagógico contextualizado para estudiantes que interactúan en español, Quechua Collao o formas mixtas de comunicación. La investigación plantea un asistente educativo que no funcione como traductor aislado, sino como un sistema capaz de detectar el idioma predominante de la consulta, recuperar contenidos curriculares y glosarios locales mediante generación aumentada por recuperación, y producir respuestas pedagógicas pertinentes en el idioma requerido. El estudio se delimita exclusivamente a la variedad Quechua Collao, de acuerdo con la ubicación geográfica del estudio, la disponibilidad de corpus paralelos validados y la presencia de rasgos fonológicos diferenciadores como consonantes oclusivas glotizadas y aspiradas. Se espera que la propuesta contribuya teórica, práctica y metodológicamente al integrar procesamiento de lenguaje natural para lenguas indígenas, modelos compactos desplegados en dispositivos locales mediante técnicas de cuantización y criterios pedagógicos propios de la Educación Intercultural Bilingüe.

Palabras clave: Small Language Model, Quechua Collao, Educación Intercultural Bilingüe, asistencia educativa, inferencia offline, RAG.

Índice general

Resumen	II
Índice general	III
Índice de figuras	V
Índice de Tablas	VI
1. Problema de Investigación	1
1.1. Descripción del problema	1
1.2. Identificación del problema	2
1.3. Formulación del problema	2
2. Justificación	3
3. Alcances y limitaciones	4
3.1. Alcances	4
3.2. Limitaciones	4
4. Objetivos	5
4.1. Objetivo General	5
4.2. Objetivos Específicos	5
4.3. Alineación con los Objetivos de Desarrollo Sostenible	6
Estado del Arte	7
5. Estado del Arte	7
5.1. Procesamiento de Lenguaje Natural y Traducción Automática para Quechua Collao	7
5.2. Small Language Models y Despliegue Offline	7
5.3. Generación Aumentada por Recuperación (RAG) y Tecnología Edu- cativa con IA	8
5.4. Política Educativa y Educación Intercultural Bilingüe en el Perú . . .	8
5.5. Síntesis crítica y vacíos de investigación	8
6. Antecedentes	9
7. Marco Teórico	10
7.1. Educación Intercultural Bilingüe (EIB)	10
7.2. Quechua Collao: caracterización y justificación dialectal	11
7.3. Translenguaje y alternancia de códigos en aulas EIB	12
7.4. Procesamiento de Lenguaje Natural	12
7.5. Modelos de lenguaje y arquitectura Transformer	13
7.6. Small Language Models y cuantización	14
7.7. Asistentes educativos inteligentes	15
7.8. Generación Aumentada por Recuperación (RAG)	15
7.9. Detección automática de idioma	16
7.10. Evaluación de sistemas educativos con IA	16
8. Metodología	16
8.1. Enfoque	16
8.2. Alcance	16
8.3. Diseño	17

8.4.	Metodología de desarrollo	17
8.5.	Población y muestra	17
9.	Estudio de Factibilidad	18
9.1.	Factibilidad técnica y de datos	18
9.2.	Factibilidad económica e infraestructura	20
9.3.	Factibilidad operativa y gestión del alcance	21
9.4.	Semáforo de riesgo tecnológico	22
9.5.	Conclusiones y recomendaciones	23
10.	Importancia del estudio	23
10.1.	Resultados esperados	23
10.2.	Contribuciones	24
10.3.	Impacto social	24
11.	Cronograma de actividades	24
12.	Presupuesto	25
	Bibliografía	27
	Anexos	28

Índice de figuras

Índice de Tablas

1.	Modelos candidatos evaluados y de referencia para el asistente <i>offline</i>	14
2.	Matriz de viabilidad técnica aplicada al proyecto	19
3.	Comparación del presupuesto original vs. valores de mercado corregidos (junio 2026)	21
4.	Factores de riesgo operativo y estrategias de mitigación	22
5.	Semáforo de riesgo por dimensión	22
6.	Cronograma de actividades por fases y meses	25
7.	Presupuesto estimado del proyecto	26

1. Problema de Investigación

1.1. Descripción del problema

A nivel global, la educación en lenguas indígenas y minoritarias enfrenta una brecha tecnológica persistente. Más de la mitad de los niños en edad escolar no aprende en su lengua materna durante los primeros años de escolaridad, lo que afecta negativamente su comprensión lectora, su identidad cultural y sus trayectorias educativas a largo plazo (UNESCO, 2022). El acceso a recursos pedagógicos culturalmente pertinentes —adaptados a la lengua y al contexto del estudiante— representa una necesidad urgente y aún no resuelta, especialmente en regiones rurales con limitaciones de infraestructura digital.

En América Latina, esta problemática adquiere una dimensión étnica y lingüística particular. Más de 45 millones de personas pertenecen a pueblos indígenas distribuidos en 23 países, con lenguas que en su mayoría carecen de recursos digitales estructurados para la enseñanza formal. Los estados de la región han avanzado normativamente hacia la Educación Intercultural Bilingüe (EIB) —el modelo pedagógico que busca garantizar el derecho de los estudiantes de pueblos originarios a aprender en su lengua materna junto al español, en diálogo con su cultura y con otras culturas—, pero la brecha entre el mandato normativo y la disponibilidad real de herramientas tecnológicas pertinentes permanece amplia.

En el Perú, esta tensión se manifiesta de manera crítica. El sistema EIB atiende a más de 1,2 millones de estudiantes en aproximadamente 26 400 instituciones educativas (Ministerio de Educación del Perú, 2018), concentradas principalmente en el sur andino y la Amazonía. Según datos del INEI, al primer trimestre de 2025 solo el 20,5 % de los hogares del área rural cuenta con acceso a internet, frente al promedio nacional que supera el 58 %. Esta brecha digital se profundiza especialmente en los departamentos del sur andino —Cusco, Apurímac, Ayacucho, Puno y Huancavelica—, precisamente donde se concentra la mayor parte del alumnado EIB, que carece casi por completo de herramientas tecnológicas adaptadas a su realidad lingüística y territorial.

Dentro del sur andino peruano, la lengua indígena predominante es el Quechua Collao, variedad hablada principalmente en Cusco, Puno, Arequipa y Moquegua. Esta variedad posee particularidades lingüísticas de alta relevancia para el diseño de recursos tecnológicos: su morfología aglutinante permite construir palabras de gran complejidad semántica mediante sufijación encadenada, y su fonología incluye tres series de consonantes oclusivas —simples, aspiradas y glotizadas— que no tienen equivalente en el español. Estas características la convierten en una lengua especialmente compleja para los sistemas de procesamiento automático del lenguaje. Adicionalmente, los estudiantes de estas comunidades frecuentemente alternan entre el quechua y el español en una misma interacción —fenómeno denominado translenguaje o alternancia de códigos—, lo que exige que cualquier herramienta de apoyo educativo sea capaz de operar en ambas lenguas y de identificar el idioma predominante de cada consulta.

Frente a este escenario, los avances recientes en inteligencia artificial generativa han abierto posibilidades para el desarrollo de asistentes educativos capaces de responder preguntas, explicar contenidos y apoyar procesos de aprendizaje. Sin embargo, la gran mayoría de estas soluciones presentan tres limitaciones estructurales que las hacen inaplicables en el contexto EIB rural del sur andino: primero, dependen de conectividad estable a internet para acceder a modelos alojados en servidores remotos; segundo, están diseñadas con datos de lenguas de alta disponibilidad, con escasa o nula representación del Quechua Collao; tercero, no están adaptadas a contenidos curriculares ni a la realidad pedagógica de las aulas EIB.

La literatura técnica muestra avances específicos pero fragmentados en este campo. Sullá Torres et al. (2024) desarrollaron un modelo de traducción automática neuronal optimizado con BERT para la dirección quechua-español, reportando un BLEU de 20,13 y destacando

las dificultades de la morfología aglutinante del quechua para los modelos estándar. Orcotoma Mormontoy et al. (2025) contribuyeron con la creación de un corpus paralelo Quechua Collao-español de 44 263 palabras usando reconocimiento óptico de caracteres sobre diccionarios de la Academia Mayor de la Lengua Quechua, sentando precedentes para la recopilación de datos en esta variedad específica. Duran and Silberztein (2026) propusieron un método semi-automático de construcción de diccionarios quechua-español utilizando formalismos lingüísticos y transductores de estados finitos, ampliando los recursos léxicos disponibles. Sin embargo, estos trabajos se concentran principalmente en subtarefas lingüísticas y no en la construcción de un asistente educativo offline alineado con materiales curriculares y necesidades docentes.

Del mismo modo, los estudios sobre despliegue offline de modelos pequeños demuestran viabilidad técnica. Walusimbi et al. (2026) proponen Arapai, una arquitectura de chatbot educativo offline-first que valida que modelos cuantizados a 4 bits pueden funcionar en dispositivos locales con latencia de 1 a 3 segundos. Hevia et al. (2025) evaluaron un sistema de recuperación aumentada por generación combinado con un modelo pequeño para educación offline, encontrando que la calidad del fragmentado de documentos es crítica para el rendimiento del sistema. No obstante, estos estudios se centran en inglés y no abordan los retos de lenguas aglutinantes de bajos recursos.

El problema se agrava cuando los estudiantes formulan consultas en español, Quechua Collao o mezclas bilingües —fenómeno documentado en aulas EIB del sur andino como alternancia de códigos o translenguaje—. En estos casos, un sistema educativo debe identificar el idioma predominante, reconocer posibles segmentos alternados y recuperar materiales adecuados al contexto. Si el sistema falla en esta etapa, puede responder en una lengua no pertinente, perder información cultural o generar explicaciones desconectadas del currículo local. El reto no es únicamente técnico, sino también pedagógico y lingüístico.

En consecuencia, existe una brecha de investigación y desarrollo: no se identifica una solución integrada de asistente educativo bilingüe español-Quechua Collao que funcione offline, use modelos pequeños de lenguaje, incorpore detección automática del idioma y recupere contenido curricular local para apoyar procesos de aprendizaje en zonas rurales de EIB. Esta brecha justifica el diseño de una propuesta que articule las capas lingüística, pedagógica y tecnológica en un único artefacto evaluable.

1.2. Identificación del problema

El problema central de la investigación es la ausencia de un asistente educativo bilingüe español-Quechua Collao, ejecutable sin conexión a internet, que integre detección automática del idioma, recuperación local de contenidos curriculares y generación de respuestas pedagógicas pertinentes para estudiantes y docentes de contextos rurales de Educación Intercultural Bilingüe del sur andino peruano.

1.3. Formulación del problema

Problema general.

¿Cómo diseñar e implementar un asistente educativo bilingüe español-Quechua Collao basado en un Small Language Model que funcione offline en dispositivos de bajo o mediano costo para apoyar procesos de aprendizaje en contextos rurales de Educación Intercultural Bilingüe del sur andino peruano?

Sub problemas.

- ¿Cuáles son los requerimientos lingüísticos, pedagógicos y tecnológicos que debe satisfacer un asistente educativo bilingüe offline para contextos rurales de EIB del sur andino peruano?
- ¿Cómo diseñar una arquitectura de software que integre detección automática del idioma, recuperación local de contenidos curriculares y generación de respuestas pedagógicas en español y Quechua Collao?
- ¿Cómo implementar y configurar un Small Language Model cuantizado para operar sin conexión a internet en dispositivos de bajo o mediano costo con pertinencia lingüística para el Quechua Collao?
- ¿Cómo evaluar la calidad lingüística, la utilidad educativa, la adecuación intercultural y el rendimiento técnico offline del asistente propuesto?

2. Justificación

La investigación se justifica porque las condiciones descritas en el problema —escasa conectividad rural, ausencia de herramientas tecnológicas en Quechua Collao y más de 1,2 millones de estudiantes EIB desatendidos tecnológicamente (Ministerio de Educación del Perú, 2018)— no encontrarán solución con las herramientas de IA generativa existentes, que dependen de internet y de lenguas de alta disponibilidad. El proyecto propone una respuesta específica a esa brecha desde tres perspectivas complementarias:

- **Justificación Teórica:** El estudio aporta a un campo todavía fragmentado. Mientras existen investigaciones sobre traducción automática neural para quechua (Sulla Torres et al., 2024; Orcotoma Mormontoy et al., 2025) y se sabe que los Grandes Modelos de Lenguaje presentan deficiencias sistemáticas en lenguas de bajos recursos (Court and Elsnér, 2024), estas líneas no se han integrado con un enfoque educativo bilingüe. La investigación propone articular avances en inferencia local de modelos pequeños (Xu et al., 2024) con detección de idioma y generación aumentada por recuperación (RAG).
- **Justificación Práctica:** El proyecto propone una alternativa directa para apoyar a docentes y estudiantes en entornos de baja conectividad sin necesidad de reemplazar al docente. Su propósito es ofrecer apoyo localizado para responder consultas, explicar conceptos y recuperar información curricular manteniendo el Quechua Collao como lengua válida de aprendizaje. Estudios recientes, como la arquitectura Arapai (Walusimbi et al., 2026), confirman que el despliegue de chatbots offline con modelos pequeños es viable para entornos con limitaciones de infraestructura similares al sur andino peruano.
- **Justificación Metodológica:** La propuesta permite organizar un proceso de diseño y evaluación que combina herramientas de procesamiento de lenguaje natural con criterios pedagógicos. La integración de sistemas RAG (Li et al., 2025) y criterios de tutoría inteligente (Levonian et al., 2025) permite evaluar el sistema no solo por métricas lingüísticas algorítmicas (como BLEU o chrF++), sino también por criterios de utilidad educativa, pertinencia cultural, y estabilidad *offline* en hardware de bajo costo.

La viabilidad del estudio se sostiene en la disponibilidad creciente de modelos compactos y herramientas de inferencia local que pueden ejecutarse mediante técnicas de cuantización (Xu et al., 2024).

3. Alcances y limitaciones

3.1. Alcances

El presente estudio abarca el diseño, implementación y evaluación de un asistente educativo bilingüe español-Quechua Collao basado en un Small Language Model. El artefacto principal es un prototipo de sistema informático que no desarrolla un modelo de lenguaje desde cero ni realiza entrenamiento del modelo base, sino que selecciona, cuantiza y configura un SLM pre-entrenado e integra un pipeline de recuperación aumentada por generación con contenidos curriculares EIB locales. La investigación se centra en la asistencia textual para estudiantes y docentes de contextos rurales de EIB, considerando entradas en español, Quechua Collao o mezcla bilingüe. Se definen los siguientes alcances específicos:

- **Alcance lingüístico:** Se delimita de forma exclusiva al Quechua Collao, de acuerdo con la ubicación geográfica del estudio y la disponibilidad de corpus paralelos como los construidos por Orcotoma Mormontoy et al. (2025). Esta variedad presenta rasgos fonológicos diferenciadores (consonantes oclusivas glotizadas y aspiradas) que deben reflejarse cuidadosamente en los recursos del sistema. Esta delimitación evita prometer cobertura de otras variedades dialectales, permitiendo construir un prototipo culturalmente pertinente.
- **Alcance pedagógico:** El asistente está diseñado para apoyar consultas de nivel primaria (3.° a 6.° grado) y secundaria básica, en las áreas curriculares de Comunicación y Ciencia y Tecnología, conforme al Currículo Nacional (CN-2016) y los materiales EIB del MINEDU. Las respuestas seguirán el principio de andamiaje cognitivo, priorizando explicaciones graduales sobre respuestas directas, y el corpus pedagógico se construirá con libros de texto EIB, el Currículo Nacional y glosarios terminológicos del MINEDU para Quechua Collao.
- **Alcance tecnológico:** Comprende una arquitectura offline compuesta por detección automática del idioma, enrutamiento lingüístico, recuperación aumentada por generación con recursos locales y un Small Language Model pre-entrenado con técnicas de cuantización a 4 bits. El aporte tecnológico radica en la integración, configuración y evaluación del *pipeline* completo.
- **Alcance disciplinar:** Se ubica en la convergencia de la ingeniería informática, el procesamiento de lenguaje natural, la tecnología educativa y la Educación Intercultural Bilingüe. Se orienta como una investigación aplicada de alcance tecnológico-experimental, que implementa y evalúa un prototipo funcional bajo condiciones controladas.

3.2. Limitaciones

Se reconocen las siguientes limitaciones que condicionan la ejecución del proyecto:

- **Disponibilidad de corpus (Limitación de datos):** Al tratarse de una lengua de bajos recursos digitales, los datos existentes pueden ser reducidos o heterogéneos, lo cual afecta la recuperación y comprensión de los modelos (Court and Elsner, 2024). Para mitigar esto, se complementará el corpus con glosarios, materiales EIB y datos sintéticos validados por hablantes nativos.
- **Restricción dialectal:** El prototipo construido está estrictamente orientado a los rasgos fonológicos y léxicos del Quechua Collao. El sistema no está diseñado para generalizarse o atender consultas en otras variedades quechuas.

- **Restricciones de hardware (Tecnológicas):** La ejecución offline de un SLM depende estrictamente de la memoria disponible (RAM), el *runtime* y el consumo energético del dispositivo local (Xu et al., 2024). Esto restringe el tamaño del modelo utilizable y la complejidad de las consultas que puede atender con una latencia aceptable.
- **Evaluación pedagógica multidimensional:** La utilidad educativa no puede medirse únicamente con métricas automáticas. Las interacciones generativas requieren evaluación de relevancia y pertinencia pedagógica (Levonian et al., 2025), lo que demanda la revisión obligatoria por parte de docentes o especialistas EIB.
- **Acceso territorial para validación:** La evaluación con usuarios reales requiere coordinación institucional con Direcciones Regionales (DRE) y Unidades de Gestión Educativa Local (UGEL), lo cual está condicionado por factores logísticos, distancias geográficas y autorizaciones escolares.
- **Alcance exclusivamente textual:** El prototipo no incorpora reconocimiento ni síntesis de voz. Los desafíos del habla bilingüe se consideran fuera del alcance actual y como posibles líneas de ampliación futura.
- **Dependencia de especialistas institucionales:** La validación final del asistente depende de la disponibilidad y experiencia de especialistas en Quechua Collao vinculados al ámbito institucional. Sin esta validación, el prototipo carecería de la fundamentación cultural necesaria.

4. Objetivos

4.1. Objetivo General

Diseñar, implementar y evaluar un asistente educativo bilingüe español-Quechua Collao basado en un Small Language Model, con funcionamiento offline, detección automática del idioma y recuperación local de contenidos curriculares, para apoyar procesos de aprendizaje en contextos rurales de Educación Intercultural Bilingüe del sur andino peruano.

4.2. Objetivos Específicos

- Determinar los requerimientos funcionales lingüísticos, pedagógicos y tecnológicos que debe satisfacer un asistente educativo bilingüe offline para contextos rurales de EIB del sur andino peruano, mediante revisión de literatura especializada, análisis de documentos normativos del MINEDU y consulta con especialistas en Quechua Collao.
- Diseñar una arquitectura de software offline que integre detección automática del idioma de entrada, enrutamiento lingüístico, recuperación aumentada por generación con base local de contenidos EIB, y generación de respuestas pedagógicas contextualizadas mediante un Small Language Model cuantizado.
- Implementar un prototipo funcional del asistente educativo bilingüe, seleccionando, cuantizando y configurando el Small Language Model base e integrando la base local de contenidos curriculares en español y Quechua Collao.
- Evaluar el desempeño técnico del prototipo considerando latencia, consumo de memoria, tokens por segundo, estabilidad offline y capacidad de respuesta en dispositivos de bajo o mediano costo.

- Evaluar la pertinencia lingüística, utilidad educativa y adecuación intercultural de las respuestas generadas por el asistente, con participación de docentes y especialistas EIB, mediante métricas automáticas de calidad lingüística y rúbricas de valoración pedagógica.

4.3. Alineación con los Objetivos de Desarrollo Sostenible

La investigación se alinea con los siguientes Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030 de las Naciones Unidas:

- **ODS 4 — Educación de calidad.** El estudio contribuye a garantizar una educación inclusiva, equitativa y de calidad al proponer una herramienta de apoyo pedagógico en lengua materna para estudiantes de pueblos originarios en zonas rurales. El asistente educativo bilingüe busca reducir las barreras lingüísticas y tecnológicas que limitan el acceso a recursos de aprendizaje en contextos de Educación Intercultural Bilingüe.
- **ODS 9 — Industria, innovación e infraestructura.** La propuesta promueve la innovación tecnológica al diseñar una solución basada en modelos pequeños de lenguaje con funcionamiento offline, adaptada a condiciones de infraestructura limitada. El despliegue de un SLM cuantizado en dispositivos de bajo costo representa una contribución a la infraestructura tecnológica educativa de las comunidades rurales del sur andino.
- **ODS 10 — Reducción de las desigualdades.** El proyecto aborda directamente la brecha digital y lingüística que afecta a las comunidades quechuahablantes. Al ofrecer un asistente que funciona sin conexión a internet y que opera en Quechua Collao, se busca reducir la desigualdad en el acceso a herramientas educativas tecnológicas entre zonas urbanas y rurales.

5. Estado del Arte

El desarrollo de un asistente educativo bilingüe español-Quechua Collao requiere la integración de avances en múltiples dominios disciplinares. A continuación, se presenta una síntesis analítica y crítica de las investigaciones previas más relevantes, organizadas temáticamente.

5.1. Procesamiento de Lenguaje Natural y Traducción Automática para Quechua Collao

El procesamiento de lenguaje natural (PLN) para lenguas aglutinantes de bajos recursos como el quechua ha presentado desafíos históricos debido a su complejidad morfológica. Investigaciones recientes han abordado estas brechas mediante la construcción de corpus y el ajuste de modelos neuronales. Orcotoma Mormontoy et al. (2025) aportaron significativamente al construir un corpus paralelo Quechua Collao-español de 44 263 palabras mediante el uso de reconocimiento óptico de caracteres (OCR) sobre textos académicos de la Academia Mayor de la Lengua Quechua, logrando tasas de error de palabra (WER) de 6.59 %. Por su parte, Duran and Silberztein (2026) propusieron métodos semi-automáticos para la construcción de diccionarios quechua-español utilizando formalismos lingüísticos, lo que amplía la disponibilidad de recursos léxicos estructurados.

En cuanto a la traducción, Sulla Torres et al. (2024) demostraron que los modelos de traducción automática neuronal (NMT) optimizados con BERT pueden alcanzar puntajes aceptables (BLEU de 20.13) en la dirección quechua-español, aunque subrayaron las limitaciones impuestas por la escasez de datos. No obstante, el paradigma de traducción y PLN ha cambiado con la llegada de los Grandes Modelos de Lenguaje (LLM). En este contexto, Court and Elsner (2024) evaluaron las habilidades de aprendizaje en contexto de LLMs comerciales (GPT-4, Gemini) para traducir del quechua al español. Sus hallazgos indican que, si bien la inclusión de traducciones a nivel de morfema mejora el rendimiento, la inyección de largas reglas gramaticales o ejemplos de corpus mediante técnicas de recuperación puede, paradójicamente, degradar el rendimiento de los modelos más avanzados, generando traducciones fluidas pero infieles o estereotipadas. Esto evidencia que depender exclusivamente de LLMs en la nube mediante *prompting* no resuelve el problema de comprensión estructural en lenguas de bajos recursos.

5.2. Small Language Models y Despliegue Offline

Frente a la dependencia de conectividad y alto consumo computacional de los LLMs, el desarrollo de Small Language Models (SLM) y técnicas de optimización para hardware restringido (on-device AI) ha cobrado relevancia. La exhaustiva revisión de Xu et al. (2024) sistematiza cómo técnicas como la compartición de parámetros, la destilación de conocimiento y, fundamentalmente, la cuantización (PTQ y QAT), permiten que modelos con menos de 10 mil millones de parámetros se ejecuten eficientemente en dispositivos móviles y procesadores de bajo consumo.

La aplicación de estas tecnologías en contextos de baja conectividad fue validada empíricamente por Walusimbi et al. (2026), quienes diseñaron *Arapai*, una arquitectura de chatbot educativo offline-first. Al desplegar modelos cuantizados (como TinyLlama o Qwen) en hardware heredado (solo CPU), lograron latencias de respuesta de 1 a 3 segundos, demostrando que la inferencia local es técnicamente factible y pedagógicamente útil para el aprendizaje autodirigido en entornos con infraestructura precaria. Sin embargo, su estudio se centró en inglés y no abordó los retos de lenguas aglutinantes.

5.3. Generación Aumentada por Recuperación (RAG) y Tecnología Educativa con IA

La Generación Aumentada por Recuperación (RAG) se ha convertido en el estándar para mitigar las alucinaciones en modelos generativos, vinculando sus respuestas a corpus documentales específicos. La revisión sistemática de Li et al. (2025) confirma que los sistemas RAG mejoran significativamente la precisión factual y la personalización en aplicaciones educativas, permitiendo que la IA asuma roles de tutoría basados en el currículo local.

Sin embargo, el despliegue de RAG con modelos pequeños presenta desafíos particulares. Hevia et al. (2025) evaluaron un tutor de IA offline combinando RAG con SLMs (SmolLM), encontrando que los modelos pequeños tienen dificultades para procesar contextos recuperados extensos o ruidosos, lo que irónicamente redujo su precisión en evaluaciones de respuestas múltiples. Esto sugiere la necesidad de estrategias de recuperación y segmentación (chunking) altamente optimizadas. Adicionalmente, el despliegue de estas herramientas con estudiantes requiere garantías pedagógicas. Levonian et al. (2025) establecen que los sistemas de tutoría inteligente deben ser diseñados para generar interacciones seguras y relevantes, priorizando el andamiaje cognitivo sobre la simple provisión de respuestas directas.

5.4. Política Educativa y Educación Intercultural Bilingüe en el Perú

El desarrollo tecnológico debe alinearse con los marcos normativos y pedagógicos vigentes. El Modelo de Servicio Educativo Intercultural Bilingüe (MSEIB) del Ministerio de Educación del Perú (Ministerio de Educación del Perú, 2018) establece lineamientos para garantizar una educación pertinente a estudiantes de pueblos originarios. El MSEIB distingue escenarios de fortalecimiento lingüístico (donde el quechua es lengua materna y el español segunda lengua) y revitalización (donde el español es lengua materna). Esto exige que cualquier herramienta de asistencia educativa no sea un simple traductor bidireccional, sino un sistema capaz de alternar códigos, detectar el idioma predominante del estudiante y recuperar contenidos con pertinencia cultural e intercultural, apoyando directamente la labor del docente bilingüe.

5.5. Síntesis crítica y vacíos de investigación

La revisión de literatura demuestra que existen avances maduros, pero aislados, en los componentes necesarios para el sistema propuesto. Por un lado, se han construido corpus y evaluado LLMs para quechua (Orcotoma Mormontoy et al. 2025; Court and Elsner 2024), pero su aplicación práctica en tecnología educativa es casi nula. Por otro lado, la viabilidad de SLMs offline y sistemas RAG ha sido probada (Walusimbi et al. 2026; Hevia et al. 2025; Xu et al. 2024), pero principalmente para inglés y lenguas mayoritarias. Finalmente, la política EIB (Ministerio de Educación del Perú 2018) exige recursos pertinentes que la actual oferta de LLMs comerciales en la nube no puede satisfacer, ya sea por barreras de conectividad o por la degradación del rendimiento al inyectarles reglas complejas (Court and Elsner, 2024).

En consecuencia, el principal vacío de investigación radica en la falta de integración de estas tecnologías en un artefacto cohesionado: **no existe un asistente educativo offline basado en SLMs, optimizado mediante RAG local y afinado específicamente para la variedad Quechua Collao, que responda a los requerimientos pedagógicos del MSEIB en el sur andino peruano.** Esta brecha justifica el presente plan de tesis, cuyo propósito es articular el procesamiento de lenguaje natural de bajos recursos con la inferencia local eficiente, ofreciendo una solución tecnológica y socialmente pertinente.

6. Antecedentes

Orcotoma Mormontoy G. C. et al., (2025), *Towards the Creation of a Collao Quechua-Spanish Parallel Corpus Using Optical Character Recognition*, Universidad Andina del Cusco, Perú.

- **Objetivo:** Construir un corpus paralelo Quechua Collao-español utilizando reconocimiento óptico de caracteres (OCR) para superar la escasez de recursos digitales en esta variante.
- **Metodología:** Escaneo y procesamiento de libros de la Academia Mayor de la Lengua Quechua (AMLQ), seguido de extracción de texto con Tesseract OCR y corrección manual para establecer una verdad base.
- **Resultados:** Se generó un corpus de 44 263 palabras con tasas de error de carácter (CER) de 1.82 % y de palabra (WER) de 6.59 %, demostrando la eficacia de la técnica para digitalizar materiales en lenguas de bajos recursos.
- **Comentario:** Esta investigación proporciona tanto la metodología como la fuente de datos (libros de la AMLQ) que servirán como base para recolectar el corpus paralelo necesario para el banco de conocimiento RAG del asistente propuesto. Es el antecedente más directamente aprovechable del proyecto, ya que trabaja con la misma variedad lingüística y los mismos materiales de referencia.

Sulla Torres J. A., Cueva Medina B., y Tuco Casquino G. F., (2024), *Development of a Neural Machine Translation Model Optimized with BERT for Translation from Quechua to Spanish*, Universidad Católica de Santa María, Perú.

- **Objetivo:** Desarrollar y evaluar un modelo de traducción automática neuronal (NMT) optimizado con BERT para la dirección quechua-español.
- **Metodología:** Pre-entrenamiento y afinamiento de un modelo transformador utilizando un corpus bilingüe quechua-español, con evaluación mediante la métrica BLEU.
- **Resultados:** El modelo propuesto alcanzó un puntaje BLEU de 20.13, superando a líneas base previas pero evidenciando dificultades con la morfología aglutinante del quechua.
- **Comentario:** Define el estado del arte y establece un umbral base (baseline) métrico para la evaluación de la capacidad del asistente al momento de procesar y generar texto en Quechua Collao. Justifica la necesidad de estrategias especializadas frente a la morfología de la lengua.

Walusimbi J. et al., (2026), *Arapai: An Offline-First AI Chatbot Architecture for Low-Connectivity Educational Environments*, Soroti University, Uganda.

- **Objetivo:** Presentar una arquitectura de chatbot educativo basada en modelos de lenguaje que funcione completamente sin conexión (offline-first) para entornos con conectividad limitada.
- **Metodología:** Implementación de modelos de lenguaje cuantizados (Qwen y Mistral) en hardware heredado (solo CPU) y evaluación piloto con 120 estudiantes midiendo rendimiento técnico y usabilidad.

- **Resultados:** El sistema demostró una latencia de 1 a 3 segundos en CPUs estándar, proveyendo respuestas instructivas adaptables a diferentes niveles educativos con alta aceptación de usuarios.
- **Comentario:** Constituye el antecedente metodológico más cercano al proyecto: mismo tipo de sistema (asistente educativo offline), mismo enfoque tecnológico (modelos cuantizados en CPU) y mismo contexto de aplicación (entornos educativos de baja infraestructura). Aporta validación empírica directa de la viabilidad técnica del enfoque propuesto.

Hevia J. S., Arredondo F., y Kumar V., (2025), *Towards an Efficient, Customizable, and Accessible AI Tutor*, Rice University, Estados Unidos.

- **Objetivo:** Proponer un flujo de Generación Aumentada por Recuperación (RAG) offline emparejado con un Small Language Model (SLM) para entornos educativos de bajos recursos.
- **Metodología:** Implementación de SmolLM con un sistema RAG sobre libros de texto de biología y evaluación de su precisión en respuestas de opción múltiple (MMLU).
- **Resultados:** La inclusión del RAG redujo la precisión del SLM al introducir contextos extensos que el modelo pequeño luchaba por procesar de forma efectiva, evidenciando la importancia del fragmentado semántico.
- **Comentario:** Antecedente metodológicamente muy cercano: combina RAG y SLM para uso educativo offline. Su hallazgo crítico —que el fragmentado de documentos es determinante para el rendimiento— orienta directamente el diseño del módulo RAG del asistente propuesto y advierte contra inyecciones de contexto extensas sin optimización.

Duran M. y Silberztein M., (2026), *Semi-automatic Construction of a Quechua-Spanish Dictionary*, Université de Franche-Comté, Francia.

- **Objetivo:** Proponer un enfoque semi-automático para construir diccionarios electrónicos quechua-español a partir de textos digitalizados y corpus.
- **Metodología:** Uso de transductores de estados finitos y herramientas NooJ para alinear lemas y afijos entre ambos idiomas, capturando la polisemia y la morfología aglutinante.
- **Resultados:** Se generó un recurso léxico estructurado que captura adecuadamente las correspondencias morfológicas y semánticas entre quechua y español.
- **Comentario:** Ilustra métodos viables para estructurar diccionarios locales que pueden ser indexados en el banco de datos RAG del asistente. Su metodología de alineación léxica es directamente aplicable a la construcción de los recursos lingüísticos de Quechua Collao del proyecto.

7. Marco Teórico

7.1. Educación Intercultural Bilingüe (EIB)

La Educación Intercultural Bilingüe es el modelo pedagógico promovido por el Ministerio de Educación del Perú (MINEDU) para garantizar el derecho a una educación pertinente a

los estudiantes de pueblos originarios. Según el Modelo de Servicio Educativo Intercultural Bilingüe (Ministerio de Educación del Perú, 2018), el enfoque busca desarrollar competencias en los estudiantes a partir de su matriz cultural, en un diálogo de saberes con otras culturas, y promover el uso comunicativo de su lengua originaria y el castellano. El modelo establece dos formas de atención principales:

- **EIB de Fortalecimiento Cultural y Lingüístico:** Orientada a estudiantes que tienen la lengua originaria (como el Quechua Collao) como lengua materna y el castellano como segunda lengua. El asistente propuesto debe apoyar el desarrollo de aprendizajes principalmente en quechua.
- **EIB de Revitalización Cultural y Lingüística:** Dirigida a estudiantes cuya lengua materna es el castellano, pero pertenecen a comunidades con herencia cultural originaria. Aquí, el asistente puede funcionar como apoyo para la enseñanza progresiva del quechua como segunda lengua.

Cualquier tecnología educativa insertada en este contexto debe respetar el enfoque de bilingüismo aditivo, en el que ninguna lengua desplaza a la otra.

7.2. Quechua Collao: caracterización y justificación dialectal

El Quechua Collao (qheswa sureño) pertenece a la rama Quechua II-C de la clasificación de Torero. Dentro de esta rama coexisten dos variedades principales con raíz compartida pero diferencias relevantes: el Quechua Cusqueño (qheswa Qusqu) y el Quechua Collao (qheswa Qulla). Ambas comparten las tres series consonánticas —simple, aspirada y glotizada—, pero difieren en aspectos léxicos, morfológicos y en la disponibilidad de recursos digitales.

El Quechua Collao es la variedad predominante en Puno, Moquegua y el sur de Arequipa, con presencia también en partes de Cusco. El Quechua Cusqueño, en cambio, es predominante en la ciudad del Cusco y zonas aledañas. Si bien son mutuamente inteligibles en gran medida, presentan diferencias de vocabulario, preferencias morfológicas y convenciones ortográficas que hacen inviable tratarlas como una sola variedad para propósitos tecnológicos.

La presente investigación delimita su alcance exclusivamente al Quechua Collao por tres razones académicamente justificadas: primero, el único corpus paralelo validado y disponible para tareas de PLN fue construido específicamente con materiales de la Academia Mayor de la Lengua Quechua orientados a esta variedad (Orcotoma Mormontoy et al., 2025); segundo, la zona geográfica de intervención del estudio corresponde predominantemente al área de habla Collao (Puno, Moquegua, sur de Arequipa); tercero, los materiales curriculares EIB del MINEDU disponibles para estas regiones están adaptados a esta variedad. Utilizar recursos del Quechua Cusqueño introduciría variación dialectal no controlada que afectaría negativamente la pertinencia lingüística del asistente.

A nivel morfosintáctico, el Quechua Collao es una lengua aglutinante y sufijadora: una sola raíz puede recibir múltiples sufijos derivativos y flexivos para expresar significados que en español requerirían varias palabras. A nivel fonológico, la variedad Collao se caracteriza por la presencia de consonantes oclusivas glotizadas y aspiradas, rasgos fonológicos diferenciadores que deben considerarse al diseñar la tokenización y el procesamiento de texto del sistema. Adicionalmente, la digitalización de esta variante enfrenta el problema de escasez de recursos estructurados (Orcotoma Mormontoy et al., 2025) y alta variabilidad ortográfica, debido a las tensiones entre alfabetos pentavocálicos y trivocálicos en el entorno académico (Court and Elsner, 2024).

7.3. Translengüaje y alternancia de códigos en aulas EIB

El translengüaje (*translanguaging*) es el proceso por el cual los hablantes bilingües o multilingües utilizan su repertorio lingüístico completo de manera dinámica y estratégica, sin respetar los límites estrictos entre lenguas. Lejos de ser un déficit, el translengüaje es reconocido actualmente como una práctica comunicativa legítima que refleja la competencia lingüística integrada del hablante. En las aulas EIB del sur andino, este fenómeno es habitual: un estudiante puede iniciar una pregunta en quechua, continuar en español para un término técnico y retomar el quechua para concluir.

La alternancia de códigos (*code-switching*) es una manifestación del translengüaje que implica el cambio sistemático entre dos lenguas dentro de un mismo enunciado o entre enunciados sucesivos. Para el asistente educativo propuesto, esta realidad representa un requerimiento funcional crítico: el sistema debe ser capaz de identificar el idioma predominante en entradas mixtas, reconocer posibles segmentos alternados y responder en el idioma más pertinente para el contexto pedagógico, sin penalizar al estudiante por usar ambas lenguas en una misma consulta.

7.4. Procesamiento de Lenguaje Natural

El Procesamiento de Lenguaje Natural (PLN), también conocido por sus siglas en inglés NLP (*Natural Language Processing*), es el campo de la inteligencia artificial que estudia la interacción computacional entre las lenguas humanas y las máquinas. Sus tareas incluyen la tokenización, el análisis morfológico y sintáctico, el reconocimiento de entidades nombradas, la clasificación de texto, la traducción automática, la generación de texto y la comprensión del lenguaje.

En el caso de lenguas morfológicamente complejas como el Quechua Collao, las tareas de PLN enfrentan desafíos adicionales. Su naturaleza aglutinante implica que un solo token puede contener información semántica equivalente a una oración completa en español, lo que afecta directamente a la tokenización, al modelado de representaciones vectoriales (*embeddings*) y a la capacidad de comprensión de los modelos estándar entrenados principalmente en lenguas analíticas como el inglés.

Entendimiento del Lenguaje Natural (NLU)

El Entendimiento del Lenguaje Natural (NLU, *Natural Language Understanding*) es el subcampo del PLN orientado a que los sistemas informáticos comprendan el significado, la intención y el contexto de los enunciados, más allá del reconocimiento superficial de patrones. En el contexto de un asistente educativo, la capacidad de NLU determina si el sistema puede diferenciar entre una consulta de vocabulario («¿qué significa...?»), una solicitud de explicación («¿cómo funciona...?») o una pregunta de aplicación práctica («¿cómo se resuelve...?»), y responder de manera pedagógicamente apropiada a cada tipo de intención.

Sin capacidad de NLU, el asistente se limita a generar texto estadísticamente probable sin comprender el propósito educativo de la consulta. En la arquitectura propuesta, el pipeline RAG actúa como mecanismo de NLU implícito al recuperar documentos semánticamente relevantes para la intención detectada en la consulta, mientras que el SLM genera una respuesta coherente con ese contexto recuperado.

PLN para lenguas de bajos recursos

Una lengua de bajos recursos digitales (*low-resource language*) es aquella para la cual los datos de entrenamiento disponibles son insuficientes para construir modelos de lenguaje de

alta calidad mediante métodos estándar. El Quechua Collao se inscribe en esta categoría: los corpus paralelos digitalizados son escasos y heterogéneos, los recursos léxicos estructurados son limitados y los modelos de lenguaje preentrenados disponibles no han sido entrenados con datos representativos de esta variedad.

Las estrategias adoptadas en el campo para abordar este problema incluyen: la construcción de corpus mediante técnicas de OCR sobre materiales impresos (Orcotoma Mormontoy et al., 2025), el uso de transferencia de aprendizaje desde modelos multilingües, la generación de datos sintéticos validados por hablantes nativos, y el diseño de arquitecturas RAG que no dependen del conocimiento paramétrico del modelo sino de fuentes externas validadas. Esta última estrategia es especialmente relevante para el presente proyecto.

Traducción automática neuronal

La Traducción Automática Neuronal (NMT, *Neural Machine Translation*) es el paradigma actual en traducción automática, basado en redes neuronales profundas de arquitectura encoder-decoder con mecanismos de atención. A diferencia de los enfoques estadísticos anteriores, los modelos NMT aprenden representaciones contextuales de las lenguas fuente y objetivo, produciendo traducciones más fluidas y coherentes. Sin embargo, su eficacia depende de la disponibilidad de corpus paralelos de gran tamaño.

En el par español-Quechua Collao, la escasez de datos limita el rendimiento de los modelos NMT: Sulla Torres et al. (2024) reportaron un BLEU de 20.13, considerado bajo según los estándares para lenguas con recursos abundantes. Adicionalmente, Court and Elsner (2024) evaluaron la capacidad de los Grandes Modelos de Lenguaje comerciales (GPT-4, Gemini) para traducir quechua sureño mediante técnicas de recuperación en contexto, encontrando que la inyección de reglas gramaticales complejas puede paradójicamente degradar el rendimiento de los modelos más avanzados, generando traducciones fluidas pero semánticamente infieles. Este hallazgo refuerza la decisión de no depender de LLMs comerciales en la nube para la lengua objetivo y justifica el diseño de un sistema con recursos locales especializados.

En el presente proyecto, la generación en Quechua Collao no es una tarea de traducción aislada, sino parte de la capacidad general del asistente de responder en el idioma del usuario. La métrica chrF++ se empleará para evaluar la coherencia lingüística de las respuestas generadas en Quechua Collao respecto a referencias validadas por especialistas.

7.5. Modelos de lenguaje y arquitectura Transformer

Un modelo de lenguaje es un sistema estadístico entrenado para modelar la distribución de probabilidad de secuencias de tokens en una lengua. Los modelos de lenguaje modernos se basan en la arquitectura Transformer (Vaswani et al., 2017), que introduce mecanismos de autoatención multi-cabeza para capturar dependencias de largo alcance en el texto sin recurrir a estructuras recurrentes. Esta arquitectura permitió escalar el entrenamiento a corpus de cientos de miles de millones de tokens, dando origen a los Grandes Modelos de Lenguaje (LLM, *Large Language Models*), como GPT-4, Llama y Gemini.

Los LLM poseen capacidades notables de generación, razonamiento y comprensión, pero su tamaño —que puede superar los 70 mil millones de parámetros— los hace inaccesibles para el despliegue en hardware de bajo costo sin conectividad permanente a la nube. Esta limitación es determinante para el contexto rural del sur andino peruano, donde la conectividad es escasa y los dispositivos disponibles son de gama baja o media.

7.6. Small Language Models y cuantización

Los Small Language Models (SLM) son modelos de lenguaje fundamentados en la arquitectura Transformer que típicamente poseen menos de 10 mil millones (10B) de parámetros. A diferencia de los LLM masivos, los SLM (como Llama 3 8B, Phi-3-mini, Gemma-2 9B, Qwen2.5) están diseñados para operar con menores requerimientos de cómputo y memoria, siendo idóneos para despliegues locales (*on-device*) o en dispositivos de borde (*edge computing*) (Xu et al., 2024).

Para hacer factible su ejecución en dispositivos con limitaciones estrictas de hardware (como CPU sin GPU dedicada), se emplean técnicas de compresión. La más extendida es la **Cuantización Post-Entrenamiento (PTQ, *Post-Training Quantization*)**, la cual reduce la precisión en bits de los pesos del modelo (por ejemplo, de Float16 a Int4 o Int8), minimizando el espacio en memoria RAM requerido y acelerando la inferencia de *tokens* con una pérdida mínima de calidad (Xu et al., 2024).

Para el presente proyecto, el modelo base candidato principal es **Qwen2.5-7B** (o su variante de 3B), por cuatro razones: (1) soporte multilingüe nativo para más de 29 idiomas, incluido el español, con mejor manejo de morfemas no latinos que modelos entrenados mayoritariamente en inglés; (2) rendimiento competitivo en *benchmarks* de comprensión en configuraciones cuantizadas a 4 bits; (3) validación empírica de ejecución *offline* en hardware CPU-only en contextos educativos de baja conectividad (Walusimbi et al., 2026); (4) requerimientos de RAM en cuantización Q4_K_M de aproximadamente 4,5 GB, compatibles con equipos de gama media. La selección definitiva se realizará en la Fase 2 del Design Science Research mediante evaluación comparativa de latencia, consumo de memoria y calidad de respuesta.

Tabla 1

Modelos candidatos evaluados y de referencia para el asistente offline

Modelo	Params.	RAM (Q4_K_M)	ES / CPU	Rol en el proyecto
Qwen2.5-7B-Instruct	7,6B	~4,7 GB	Sí / Sí	Candidato principal — equipos 16 GB
Qwen2.5-3B-Instruct	3,1B	~2,1 GB	Sí / Sí	Candidato base — equipos 8 GB
Llama 3.2 3B-Instruct	3,2B	~2,0 GB	Sí / Sí	Alternativa viable; buena instrucción
Phi-3.5-mini-Instruct	3,8B	~2,5 GB	Parcial / Sí	Razonamiento fuerte; menos multilingüe
Gemma 3 4B-IT	4,0B	~2,7 GB	Sí / Sí	Alternativa futura (Google, 2025)
SmolLM2-1.7B-Instruct	1,7B	~1,1 GB	Parcial / Sí	Hardware muy restringido (<4 GB RAM)
Llama 3.2 1B-Instruct	1,2B	~0,7 GB	Limitado / Sí	Dispositivos ultra-restringidos
TinyLlama-1.1B	1,1B	~0,8 GB	No / Sí	Descartado — sin soporte multilingüe

Nota: los modelos marcados como «candidato» serán evaluados empíricamente en la Fase 2 del DSR. Los modelos de generación siguiente (Gemma 3, Qwen3) representan opciones a

considerar en trabajos derivados o en una segunda iteración del prototipo si el cronograma lo permite.

7.7. Asistentes educativos inteligentes

Los Sistemas de Tutoría Inteligente (ITS, *Intelligent Tutoring Systems*) son sistemas informáticos diseñados para proporcionar instrucción personalizada adaptada al nivel de comprensión del estudiante, sin intervención humana directa en tiempo real. Los ITS modernos basados en modelos de lenguaje incorporan principios pedagógicos como el andamiaje cognitivo (*scaffolding*), que consiste en ofrecer apoyos estructurados que el aprendiz retira progresivamente a medida que adquiere competencia; la Zona de Desarrollo Próximo (ZDP) de Vygotsky, que delimita el rango de tareas que el estudiante puede realizar con guía pero no de forma autónoma; y el *feedback* formativo, que orienta al estudiante hacia la comprensión correcta en lugar de limitarse a confirmar o refutar respuestas.

El asistente educativo propuesto se inscribe en este marco conceptual. Su propósito no es reemplazar al docente bilingüe sino proveer un apoyo adicional disponible fuera del horario de clase y en entornos sin conectividad, respondiendo consultas curriculares con un tono pedagógico adecuado a la edad y al nivel educativo del usuario. Levonian et al. (2025) establecen que los sistemas de tutoría generativa deben diseñarse para generar interacciones seguras y relevantes, priorizando el andamiaje cognitivo sobre la simple provisión de respuestas directas, criterio que guía el diseño del pipeline de generación del presente proyecto.

7.8. Generación Aumentada por Recuperación (RAG)

La Generación Aumentada por Recuperación (*Retrieval-Augmented Generation*, RAG) es una arquitectura que acopla un modelo generativo con un mecanismo de recuperación de información (Li et al., 2025). El proceso típico involucra tres etapas:

1. **Indexación:** Los documentos base (currículo, glosarios, materiales EIB) se dividen en fragmentos (*chunks*) y se convierten en vectores mediante un modelo de incrustación (*embedding*), almacenándose en una base de datos vectorial local.
2. **Recuperación (*Retrieval*):** Cuando el usuario realiza una consulta, esta se vectoriza para buscar los fragmentos más similares semánticamente, utilizando métricas de similitud de coseno.
3. **Generación:** Los fragmentos recuperados se inyectan en el contexto del *prompt* junto a la consulta original, permitiendo que el SLM genere una respuesta anclada a esa información específica.

La revisión sistemática de Li et al. (2025) confirma que los sistemas RAG mejoran significativamente la precisión factual y la personalización en aplicaciones educativas, permitiendo que la IA asuma roles de tutoría basados en el currículo local en lugar de depender del conocimiento paramétrico genérico del modelo.

En contextos de SLM, el tamaño y la relevancia (ausencia de ruido) de los fragmentos recuperados es crítico, ya que ventanas de contexto muy largas o ruidosas pueden degradar severamente la precisión del modelo pequeño (Hevia et al., 2025). Por ello, la estrategia de fragmentado semántico y la selección del número óptimo de fragmentos recuperados por consulta constituyen decisiones de diseño determinantes para el rendimiento del asistente propuesto.

7.9. Detección automática de idioma

En entornos bilingües en los que ocurre el translenguaje o la alternancia de códigos, es necesario identificar si la consulta del usuario se formula predominantemente en español, en Quechua Collao o tiene naturaleza mixta. Para lenguas de bajos recursos, la detección basada en reglas combinada con modelos ligeros de clasificación de texto permite enrutar internamente la consulta al *prompt* específico o al índice documental correcto (español o quechua) antes de activar la generación computacionalmente más costosa del SLM (Walusimbi et al., 2026). La precisión de este módulo tiene impacto directo en la pertinencia de la respuesta final: un error de detección produce respuestas en el idioma equivocado, lo que rompe la experiencia pedagógica del usuario.

7.10. Evaluación de sistemas educativos con IA

La evaluación de sistemas generativos en entornos educativos abarca tres dimensiones complementarias. En la **dimensión técnica**, se miden variables como latencia (*Time-To-First-Token*), consumo de memoria RAM y velocidad de generación (tokens por segundo) en el hardware objetivo (Walusimbi et al., 2026). En la **dimensión lingüística**, se utilizan métricas de correspondencia léxica como chrF++ para evaluar la coherencia de las respuestas generadas en Quechua Collao frente a referencias validadas por especialistas (Sulla Torres et al., 2024). En la **dimensión pedagógica**, se requiere la intervención de docentes y especialistas EIB para validar la exactitud factual, la adecuación al tono educativo, la seguridad del contenido y la pertinencia intercultural de las respuestas generadas. Levonian et al. (2025) proponen marcos multidimensionales que incorporan criterios de relevancia curricular, tono apropiado al nivel educativo y ausencia de contenidos dañinos o culturalmente inadecuados, superando así la evaluación basada exclusivamente en métricas automáticas.

8. Metodología

8.1. Enfoque

La presente investigación tendrá un enfoque metodológico predominantemente **cuantitativo**. Esto se debe a que la validación y evaluación de la solución se sustentará en la recolección y análisis de datos medibles para comprobar el cumplimiento de los objetivos. Se cuantificarán variables de rendimiento técnico del software (latencia, uso de memoria, tokens por segundo) y se emplearán métricas lingüísticas algorítmicas estandarizadas (chrF++) para medir el desempeño del sistema. La evaluación pedagógica también se apoyará en escalas numéricas estandarizadas aplicadas a instrumentos de juicio de expertos.

8.2. Alcance

El alcance de la investigación será **descriptivo** con una naturaleza de investigación tecnológica-aplicada. Se implementará una arquitectura de *software* con parámetros específicos y se describirá y medirá su comportamiento individual frente a métricas predefinidas, sin la intención de buscar causalidad estadística pura ni la generalización a toda otra variante de la lengua. Su propósito es resolver un problema práctico en un escenario particular mediante ingeniería y medir sus indicadores de éxito.

8.3. Diseño

El diseño de investigación adoptará el modelo **No Experimental Transversal**. No se manipularán variables independientes ni se crearán grupos de control de usuarios. En cambio, se recolectarán datos en un único momento temporal una vez que el prototipo esté completamente funcional y expuesto a las consultas del corpus de prueba o a las sesiones de validación por parte de los especialistas, describiendo los resultados de estas interacciones directas.

8.4. Metodología de desarrollo

Para la construcción del sistema basado en inteligencia artificial y arquitecturas SLM, se empleará el paradigma **Design Science Research (DSR)**. Esta metodología iterativa es idónea para investigaciones en sistemas de información que buscan crear un artefacto innovador para resolver problemas reales. El proceso contemplará las siguientes fases:

1. **Identificación del problema y motivación:** Caracterización de las limitaciones de conectividad y la carencia de herramientas educativas en Quechua Collao.
2. **Definición de los objetivos de la solución:** Establecimiento de requisitos técnicos (inferencia offline, uso en CPU) y pedagógicos (pertinencia curricular EIB).
3. **Diseño y desarrollo:** Selección y cuantización del Small Language Model óptimo, diseño de la arquitectura RAG local y construcción del pipeline de detección de idioma y generación de respuestas.
4. **Demostración:** Integración del prototipo funcional y curación del banco de conocimiento con el corpus de la Academia Mayor de la Lengua Quechua y textos del MINEDU.
5. **Evaluación:** Sometimiento del artefacto a pruebas de rendimiento en hardware de bajo costo, medición de calidad lingüística (chrF++) y evaluación de pertinencia por parte de especialistas EIB.
6. **Comunicación:** Documentación de resultados, arquitectura y recomendaciones de uso en la tesis final.

8.5. Población y muestra

La evaluación del artefacto requerirá poblaciones de distinta naturaleza. Por el lado de los datos de *software*, la población estará conformada por el corpus digitalizado disponible en Quechua Collao-español. La muestra de datos para el bloque RAG consistirá en manuales y currículos oficiales EIB para primaria (3.º a 6.º grado) y secundaria básica, y los textos paralelos validados por Orcotoma Mormontoy et al. (2025). La muestra de interacción incluirá un banco de pruebas mínimo de 100 consultas estructuradas extraídas de contextos académicos reales, organizadas por nivel educativo y área curricular.

Para la validación pedagógica, la población objetivo estará constituida por la comunidad educativa EIB del sur andino. La muestra será de tipo no probabilística intencional, seleccionando de 3 a 5 especialistas o docentes activos en Instituciones Educativas EIB con dominio acreditado de la variante Quechua Collao. Ellos evaluarán muestras de respuestas generadas por el sistema mediante rúbricas estandarizadas, garantizando que el diseño experimental cuente con rigor cualitativo en la comprobación final de viabilidad pedagógica.

9. Estudio de Factibilidad

El estudio de factibilidad determina si el proyecto puede ejecutarse con éxito dentro de las restricciones reales de tiempo, hardware, presupuesto, datos y acceso institucional. Se estructura en tres dimensiones: viabilidad técnica, viabilidad económica y viabilidad operativa.

La conclusión anticipada es que el proyecto **sí es factible como prototipo académico** (*Minimum Viable Product*), pero **no** como sistema de producción ni como modelo entrenado desde cero. La razón es que el plan reduce correctamente el riesgo al proponer **seleccionar, cuantizar y desplegar** un SLM preentrenado con RAG local y detección de idioma, en lugar de entrenar un LLM desde cero. Esta estrategia es coherente con la literatura reciente sobre despliegue *on-device* (Xu et al., 2024) y educación *offline* en entornos de baja conectividad (Walusimbi et al., 2026). La calificación global del proyecto, con la información disponible, es **AMARILLO favorable**: el mayor riesgo no es el modelo base, sino la curación de datos, la pertinencia lingüística y la validación pedagógica intercultural.

9.1. Factibilidad técnica y de datos

La viabilidad técnica es **realista dentro de un perímetro bien acotado**. El plan propone un asistente textual *offline* con detección de idioma, enrutamiento lingüístico, RAG local y un SLM cuantizado; excluye voz y sitúa la contribución en la integración y evaluación del *pipeline* completo, no en el entrenamiento de un modelo nuevo. Esa acotación reduce el riesgo de sobreingeniería y hace el proyecto ejecutable dentro del plazo de una tesis.

Hardware e inferencia local

El archivo GGUF de **Qwen2.5-7B-Instruct en cuantización Q4_K_M pesa 4,68 GB**; el de **Qwen2.5-3B-Instruct pesa 2,1 GB**. El consumo real de RAM en ejecución es mayor que el tamaño del archivo, porque incluye los pesos, la caché KV y el *overhead* del *runtime*: aproximadamente **6–7 GB** para el modelo de 7B y **3 GB** para el de 3B. Esto implica que en una laptop con **16 GB de RAM**, el 7B corre con holgura; en una con **8 GB**, el 7B es marginal y el **3B es la opción segura**. A efectos de este proyecto, se adopta el **Qwen2.5-3B como configuración base** (equipos de 8 GB) y el **Qwen2.5-7B como variante de calidad** (equipos de 16 GB).

La inferencia en CPU está limitada por el ancho de banda de memoria, no por la frecuencia del procesador. En una laptop de gama media (Intel Core i5 de 10.^a a 13.^a generación o AMD Ryzen 5, con memoria DDR4/DDR5), un 7B Q4_K_M genera aproximadamente **8–12 tokens por segundo** y un 3B genera **10–25 tokens por segundo**. Estas velocidades son aceptables para un asistente educativo de turnos cortos. La cuantización no exige GPU; se realiza con utilidades de `llama.cpp` en CPU o, para acelerar la conversión, en el nivel gratuito de Google Colab (GPU T4) o Kaggle, sin costo adicional.

Datos y corpus disponible

El corpus paralelo Quechua Collao–español de Orcotoma Mormontoy et al. (2025) está confirmado: **44 263 palabras** digitalizadas por OCR a partir de cinco libros de la Academia Mayor de la Lengua Quechua (AMLQ). Es un conteo de palabras, no de pares de oraciones; el propio artículo advierte que no se aplicó limpieza *post-OCR*. Como recursos complementarios de dominio público se identifican: el corpus monolingüe `Llamacha/monolingual-quechua-iic` (base del modelo QuBERT para quechua sureño), datos de AmericasNLP 2023 —que com-

prenden aproximadamente 154 000 pares quechua–español de entrenamiento— y materiales curriculares EIB abiertos del MINEDU.

Advertencia dialectal crítica: la variante *quy* utilizada en AmericasNLP corresponde al Quechua Chanka (Ayacucho), no al Quechua Collao (Cusco–Puno). Su uso en el RAG exige validación y normalización ortográfica previa por un especialista. Construir la base RAG en doce meses es **realista** porque el RAG no entrena el modelo; solo requiere curar, segmentar (*chunking*) y vectorizar documentos. El *tokenization premium* del quechua —lengua aglutinante con alta fertilidad de tokens— debe monitorearse como métrica de control del sistema.

El carácter multilingüe de Qwen2.5 no debe confundirse con competencia real en Quechua Collao: el modelo card declara soporte para español y más de 29 idiomas, pero **no garantiza soporte específico de Quechua Collao** (Court and Elsner, 2024). La pertinencia en esta variedad dependerá del corpus recuperado, los glosarios curados y los *prompts* diseñados con revisión de hablantes nativos, no del conocimiento paramétrico del modelo.

Stack tecnológico

Todo el *stack* propuesto es abierto, local y gratuito: `llama.cpp` / **Ollama** (inferencia *offline*), **LangChain** o **LlamaIndex** (orquestación RAG), **sentence-transformers** (*embeddings* locales) y **FAISS** o **ChromaDB** (base vectorial local). La curva de aprendizaje es moderada y los ecosistemas están ampliamente documentados. El costo recurrente de inferencia es **S/ 0**.

Matriz técnica de factibilidad

Tabla 2
Matriz de viabilidad técnica aplicada al proyecto

Componente crítico	Estado actual	Justificación	Contingencia
Cómputo para inferencia (CPU-only)	Por gestionar	Inferencia local validada en literatura (Walusimbi et al., 2026); 8–25 tok/s en laptop gama media según tamaño de modelo	Iniciar con 3B; escalar a 7B solo si el equipo lo soporta
Dataset y corpus para RAG	Por gestionar	Corpus base disponible (Orcotoma Mormontoy et al., 2025); pequeño, requiere limpieza y complemento curricular	Acotar dominio a un área y grado; curación manual validada por especialista AMLQ
Stack tecnológico	Parcialmente cubierto	<i>Stack</i> abierto y documentado; soporte Qwen en ecosistemas estándar (Xu et al., 2024)	Congelar versiones con <code>requirements.txt</code> ; evitar dependencias de pago
Riesgo de sobreingeniería	Alto si no se contiene	Viable como prototipo textual; riesgo si se agrega voz, app móvil o despliegue institucional masivo (Hevia et al., 2025)	Interfaz mínima (CLI/web local); priorizar evaluación del <i>pipeline</i>

9.2. Factibilidad económica e infraestructura

Económicamente, el proyecto es **más viable de lo que podría estimarse inicialmente**, siempre que se mantenga la estrategia *offline*. El presupuesto original del plan asciende a S/ 7 205,00. Sin embargo, el análisis de mercado identifica **dos partidas mal calibradas**: el cómputo en la nube está sobreestimado (puede reducirse a casi cero con niveles gratuitos) y el almacenamiento externo está subestimado frente al precio real de un SSD en el mercado peruano.

Fuentes de financiamiento y niveles gratuitos

Los pasos de cuantización y vectorización son tareas **puntuales** (*one-off*), no servicios persistentes. Se cubren íntegramente con niveles gratuitos:

- **Kaggle**: hasta 30 horas semanales de GPU con sesiones de hasta 9 horas; suficiente para cuantización y vectorización.
- **Google Colab (nivel gratuito, GPU T4)**: adecuado para las mismas tareas; no imprescindible contratar Colab Pro.
- **GitHub Student Developer Pack**: incluye créditos de DigitalOcean, Azure y acceso a Copilot y Codespaces. **Advertencia**: desde junio de 2026, los créditos de DigitalOcean *no pueden usarse en GPU Droplets*; son útiles para hosting en CPU, no para cómputo GPU. Kaggle/Colab son la vía recomendada.
- **AWS Educate**: formación autoguiada y laboratorios sin costo; no garantiza GPU sostenida para el proyecto.

Las APIs de terceros (OpenAI, Google Cloud) deben evitarse por dos razones: aumentan el costo y, al requerir internet, **contradicen el propio supuesto de la investigación** (asistente *offline*).

Presupuesto corregido

Tabla 3

Comparación del presupuesto original vs. valores de mercado corregidos (junio 2026)

Rubro	Plan original (S/)	Valor real (S/)	Veredicto
Dispositivo de prueba (lap-top/tablet 16 GB)	2 500,00	2 299–2 599	Confirmado
Almacenamiento externo 1 TB	250,00	480–570 (SSD) / 280 (HDD)	Subestimado
Cómputo en la nube	900,00	0–200 (niveles gratuitos)	Sobreestimado
Bibliografía y bases de datos	300,00	—	Razonable
Impresiones y empastados	200,00	—	Razonable
Transporte a zonas rurales (5 visitas)	750,00	—	Razonable
Viáticos para trabajo de campo (5 días)	500,00	—	Razonable
Material para talleres EIB	200,00	—	Razonable
Consulta con especialistas Quechua Collao	450,00	—	Razonable
Validación lingüística por hablantes nativos	500,00	—	Razonable
Subtotal	6 550,00	6 179,00	
Contingencia (10 %)	655,00	618,00	
TOTAL	7 205,00	≈ 6 800,00	

Nota: los precios corresponden a cotizaciones en retailers peruanos (Hiraoka, Falabella, Promart) a junio de 2026, con tipo de cambio BCRP/SBS de $\approx$ S/ 3,40 por USD. Se recomienda **reasignar el excedente de la partida de nube** ($\approx$ S/ 700) a la corrección del almacenamiento y al refuerzo de las sesiones de validación lingüística.

9.3. Factibilidad operativa y gestión del alcance

Operativamente, el proyecto es más viable que una tesis dependiente de sistemas empresariales, porque el artefacto propuesto es un **prototipo autónomo** que no requiere acceso a código fuente, APIs internas o bases de datos corporativas. Sin embargo, mantiene dos dependencias operativas serias: la coordinación con docentes o especialistas EIB para la validación pedagógica, y el acceso a materiales curriculares en escenarios de prueba con pertinencia lingüística responsable.

Tabla 4

Factores de riesgo operativo y estrategias de mitigación

Factor de riesgo	Estrategia de mitigación / delimitación
Acceso a validadores EIB (DRE/UGEL/AMLQ)	Iniciar gestiones institucionales desde el arranque del proyecto; tener plan B de validación remota con panel reducido de especialistas.
«Agujero negro» del desarrollo UI/UX	Limitar la interfaz a un mínimo funcional (CLI o web local tipo Streamlit); concentrar el esfuerzo en el <i>pipeline</i> SLM+RAG y su evaluación. El valor académico no está en la interfaz, sino en el <i>pipeline</i> (Hevia et al., 2025).
Indefinición del criterio de parada	Fijar umbrales de éxito <i>ex ante</i> : (i) técnicos — latencia, $RAM \leq$ capacidad del equipo objetivo, tok/s, estabilidad <i>offline</i> ; (ii) lingüísticos — chrF++ sobre corpus de prueba Collao–español; (iii) pedagógicos — rúbricas de docentes EIB.
Sobreextensión del corpus y alcance	Acotar el dominio curricular a áreas de Comunicación y Ciencia y Tecnología para el primer ciclo de validación; no intentar cubrir toda la EIB en una sola iteración.

9.4. Semáforo de riesgo tecnológico

Tabla 5

Semáforo de riesgo por dimensión

Dimensión	Nivel	Justificación
Técnica (hardware / inferencia / cuantización)	VERDE	Modelos y herramientas probados; inferencia en CPU validada; cuantización en nivel gratuito.
Stack / tooling	VERDE	Maduro, abierto, documentado; alerta menor en tokenización del quechua.
Económica / nube	VERDE	Costos cubribles; nube gratuita (Kaggle/Colab) cubre tareas <i>one-off</i> ; presupuesto corregido holgado.
Datos (corpus Collao)	AMARILLO	Corpus base disponible (Orcotoma Mormontoy et al., 2025) pero pequeño, sin limpieza <i>post-OCR</i> ; variantes dialectales (Chanka vs. Collao) exigen validación.
Operativo (acceso EIB / alcance)	AMARILLO	Depende de trámites con DRE/UGEL/AMLQ y de disciplina de alcance para evitar <i>scope creep</i> .
GLOBAL	AMARILLO	Factible con gestión activa de los riesgos de datos y operativos.

El proyecto pasa a **VERDE** si se consolidan estas condiciones: usar un modelo entre 3B y 7B cuantizado; mantener el sistema estrictamente textual y *offline*; limitar la base de conocimiento a áreas curriculares concretas; fijar desde el inicio un corpus validado y un

comité de revisión lingüística; y usar la nube solo como apoyo puntual, no como dependencia estructural (Walusimbi et al., 2026; Xu et al., 2024).

El proyecto pasa a **ROJO** si deriva hacia: entrenar o afinar intensivamente el modelo base como parte central de la tesis; incorporar voz, app móvil completa y despliegue institucional simultáneamente; o depender de una API externa para la generación principal.

9.5. Conclusiones y recomendaciones

La factibilidad es un espectro, no una decisión binaria, y este proyecto se ubica en el **lado factible**. La decisión de no entrenar desde cero, sino cuantizar y orquestar un SLM preexistente con RAG local, reduce drásticamente las exigencias de cómputo y costo, haciéndolo viable bajo cualquier escenario de hardware disponible para el equipo de tesis. Las recomendaciones concretas son las siguientes:

1. **Modelo base:** adoptar **Qwen2.5-3B** como configuración por defecto (equipos de 8 GB) y promover el 7B si el equipo objetivo sostiene ≥ 8 tok/s con ≤ 7 GB de RAM durante pruebas reales.
2. **Presupuesto:** subir el almacenamiento a S/ 500 (SSD) o S/ 300 (HDD) y reducir la nube a S/ 100–200, reasignando el excedente a validación lingüística.
3. **Corpus:** acotar a un dominio curricular y grado específicos para el primer ciclo de validación, priorizando curación manual sobre cantidad.
4. **Criterio de parada:** fijar antes del inicio del desarrollo los umbrales de latencia, RAM, chrF++ y rúbrica pedagógica como condiciones de suficiencia del prototipo.
5. **Gestión institucional:** iniciar de inmediato las gestiones con la DRE/UGEL de Cusco (y eventualmente Puno) y la AMLQ para asegurar acceso a validadores.
6. **Interfaz:** limitar el desarrollo a lo mínimo funcional; el valor académico reside en el *pipeline* y su evaluación, no en la experiencia de usuario.

10. Importancia del estudio

10.1. Resultados esperados

El artefacto principal de esta investigación es un **prototipo de sistema informático**: un asistente educativo bilingüe español-Quechua Collao ejecutable sin conexión a internet en dispositivos de bajo o mediano costo. Este prototipo no constituye un modelo de lenguaje nuevo ni realiza entrenamiento del modelo base, sino que integra un Small Language Model pre-entrenado y cuantizado con un pipeline RAG local y un módulo de detección de idioma, adaptado específicamente para responder consultas pedagógicas en contextos EIB del sur andino peruano. Los productos derivados de su construcción y evaluación son:

- Un prototipo funcional de asistente educativo bilingüe español-Quechua Collao, ejecutable sin conexión a internet en dispositivos de bajo o mediano costo, basado en un SLM cuantizado con pipeline RAG local.
- Una base local de contenidos curriculares, glosarios y materiales EIB en español y Quechua Collao, organizados para su recuperación mediante RAG y orientados a los niveles primaria (3.º a 6.º grado) y secundaria básica.

- Un corpus curado de recursos lingüísticos español-Quechua Collao, complementado con datos sintéticos y validado por especialistas hablantes nativos.
- Un reporte de evaluación técnica que documente métricas de latencia, consumo de memoria, tokens por segundo y estabilidad offline del prototipo en hardware de bajo o mediano costo.
- Un reporte de evaluación lingüística y pedagógica con resultados de métricas automáticas (chrF++) y valoraciones de docentes y especialistas EIB sobre la utilidad educativa, pertinencia intercultural y adecuación pedagógica de las respuestas generadas.

10.2. Contribuciones

- **Contribución tecnológica:** Arquitectura funcional de un asistente educativo offline que integra detección de idioma, enrutamiento lingüístico, RAG local y generación de respuestas mediante un SLM cuantizado a 4 bits, ejecutable en dispositivos de bajo o mediano costo sin conexión a internet.
- **Contribución educativa:** Base de conocimiento local organizada con materiales curriculares EIB en español y Quechua Collao, orientada a apoyar consultas pedagógicas de estudiantes y docentes en zonas rurales, junto con un corpus curado de recursos lingüísticos para la variedad Quechua Collao aplicados a tareas de educación intercultural bilingüe.
- **Contribución metodológica:** Marco de evaluación multidimensional que combina métricas automáticas de calidad lingüística con criterios pedagógicos e interculturales validados por especialistas EIB, aplicable a otros proyectos de tecnología educativa en lenguas indígenas de bajos recursos del sur andino.

10.3. Impacto social

El desarrollo de un asistente educativo bilingüe offline tiene el potencial de beneficiar a docentes y estudiantes de comunidades quechuahablantes del sur andino peruano que actualmente carecen de herramientas tecnológicas adaptadas a su realidad lingüística y territorial. Al operar sin conexión a internet y en Quechua Collao, el prototipo podría contribuir a reducir la brecha digital educativa en zonas rurales, fortalecer el uso de la lengua materna en contextos de aprendizaje formal y apoyar los objetivos del modelo de servicio educativo intercultural bilingüe del Ministerio de Educación.

11. Cronograma de actividades

El desarrollo de la tesis se planifica en un horizonte de doce meses a partir de la aprobación del plan. Las actividades se organizan en seis fases según la metodología Design Science Research.

Tabla 6

Cronograma de actividades por fases y meses

Actividad	1	2	3	4	5	6	7	8	9	10	11	12
Fase 1: Identificación del problema												
Revisión de literatura y estado del arte	•	•										
Caracterización de requerimientos EIB	•	•										
Fase 2: Diseño de la solución												
Diseño de la arquitectura offline		•	•									
Selección del SLM base y técnica de cuantización			•	•								
Fase 3: Recopilación de recursos												
Curación de corpus Quechua Collao-español			•	•	•							
Organización de materiales EIB y glosarios				•	•							
Fase 4: Implementación												
Selección, cuantización y configuración del SLM base					•	•	•					
Módulo de detección de idioma						•	•					
Módulo RAG local con contenidos EIB							•	•				
Integración y prototipo funcional								•	•			
Fase 5: Evaluación												
Evaluación técnica (latencia, memoria, TPS)									•	•		
Evaluación lingüística (BLEU, chrF++)									•	•		
Evaluación pedagógica con especialistas EIB										•	•	
Fase 6: Documentación												
Redacción del informe final de tesis										•	•	•
Preparación de sustentación												•

12. Presupuesto

El presupuesto estimado para el desarrollo de la tesis se detalla a continuación. Se consideran los recursos necesarios para la implementación del prototipo, la evaluación y la documentación.

Tabla 7*Presupuesto estimado del proyecto*

Rubro	Cantidad	Costo (S/.)
Recursos tecnológicos		
Dispositivo de prueba (laptop/tablet gama media)	1	2 500.00
Almacenamiento externo (SSD 1 TB)	1	500.00
Servicio de cómputo en la nube (cuantización y vectorización)	Puntual	200.00
Recursos académicos		
Material bibliográfico y acceso a bases de datos	Global	300.00
Impresiones y empastados	Global	200.00
Trabajo de campo		
Transporte a zonas rurales (validación)	5 visitas	750.00
Viáticos para trabajo de campo	5 días	500.00
Material para talleres con docentes EIB	Global	200.00
Servicios profesionales		
Consulta con especialistas en Quechua Collao	3 sesiones	450.00
Validación lingüística por hablantes nativos	5 sesiones	500.00
Otros		
Imprevistos (10 %)	Global	618.00
TOTAL		6 796.00

Bibliografía

- Court, S. and Elsner, M. (2024). Shortcomings of llms for low-resource translation: Retrieval and understanding are both the problem. In *Proceedings of the Conference on Machine Translation*. Disponible en: <https://aclanthology.org/2024.wmt-1.125/>.
- Duran, M. and Silberztein, M. (2026). Semi-automatic construction of a quechua-spanish dictionary. In *Proceedings for the Ninth Workshop on Technologies for Machine Translation of Low Resource Languages*, pages 111–118. DOI: <https://doi.org/10.18653/v1/2026.loresmt-1.9>.
- Hevia, J. S., Arredondo, F., and Kumar, V. (2025). Towards an efficient, customizable, and accessible ai tutor. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2510.06255>.
- Levonian, Z., Henkel, O., Li, C., and Postle, M.-E. (2025). Designing safe and relevant generative chats for math learning in intelligent tutoring systems. *Journal of Educational Data Mining*, 17(1):66–97. DOI: <https://doi.org/10.5281/zenodo.14751365>.
- Li, Z., Wang, Z., Wang, W., Hung, K., Xie, H., and Wang, F. L. (2025). Retrieval-augmented generation for educational application: A systematic survey. *Computers and Education: Artificial Intelligence*. DOI: <https://doi.org/10.1016/j.caeai.2025.100417>.
- Ministerio de Educación del Perú (2018). Modelo de servicio educativo intercultural bilingüe. Disponible en: <https://repositorio.minedu.gob.pe/handle/20.500.12799/5971>.
- Orcotoma Mormontoy, G. C., Leon Nuñez, L., and Espetia Huamanga, H. (2025). Towards the creation of a collao quechua-spanish parallel corpus using optical character recognition. In *Proceedings of the Workshop on Beyond English*. Disponible en: <https://aclanthology.org/2025.globalnlp-1.1/>.
- Sulla Torres, J. A., Cueva Medina, B., and Tuco Casquino, G. F. (2024). Development of a neural machine translation model optimized with bert for translation from quechua to spanish. In *LACCEI*. DOI: <https://doi.org/10.18687/LACCEI2024.1.1.1636>.
- Walusimbi, J., Oguti, A. M., Ssentongo, J. B., and Ainebyona, K. (2026). Arapai: An offline-first ai chatbot architecture for low-connectivity educational environments. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2603.03339>.
- Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., and Ling, Z. (2024). On-device language models: A comprehensive review. *arXiv preprint*. Disponible en: <https://arxiv.org/abs/2409.00088>.

Anexo: Fichas de Análisis

A continuación, se presentan las fichas de análisis de las cinco fuentes más relevantes para la investigación, elaboradas conforme a las exigencias de la guía metodológica del seminario.

Ficha 1: Orcotoma Mormontoy et al. (2025)

1. **REFERENCIA COMPLETA (APA 7):** Orcotoma Mormontoy, G. C., Leon Nuñez, L., & Espetia Huamanga, H. (2025). Towards the Creation of a Collao Quechua-Spanish Parallel Corpus Using Optical Character Recognition. *Proceedings of the Workshop on Beyond English*, 1-6. <https://doi.org/10.26615/978-954-452-105-9-001>
 2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica
 3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Construir un corpus paralelo Quechua Collao-español utilizando reconocimiento óptico de caracteres (OCR) para superar la escasez de recursos digitales en esta lengua de bajos recursos.
 4. **METODOLOGÍA:** Enfoque tecnológico. Digitación y procesamiento (filtros de mediana y binarización) de libros de grado de la Academia Mayor de la Lengua Quechua, seguido de extracción de texto con Tesseract OCR y evaluación mediante Character Error Rate (CER) y Word Error Rate (WER) frente a un texto validado manualmente (ground truth).
 5. **RESULTADOS PRINCIPALES:** Se construyó un corpus de 44 263 palabras (18 179 en quechua y 26 084 en español). La evaluación del OCR mostró un CER de 1.82 % y un WER de 6.59 %, demostrando la viabilidad de la extracción automática con posprocesamiento.
 6. **CONCLUSIONES DEL AUTOR:** El uso de OCR es viable para crear corpus paralelos en Quechua Collao si se aplican métodos adecuados de preprocesamiento, lo que proporciona una metodología valiosa para preservar la lengua y entrenar futuras tecnologías NLP.
 7. **RELEVANCIA PARA MI TESIS:** Es un antecedente directo para la obtención de datos de entrenamiento y evaluación. Justifica la delimitación del proyecto al Quechua Collao al confirmar la existencia de recursos paralelos validados procedentes de la Academia Mayor de la Lengua Quechua.
 8. **CITAS TEXTUALES ÚTILES:** “The importance of the result of this study lies in providing a methodology for the development of new technologies that require Collao Quechua-Spanish parallel corpora, such as automatic translators and sentence auto-completion systems” (p. 1).
 9. **PALABRAS CLAVE ASIGNADAS:** Corpus paralelo, OCR, Quechua Collao, NLP de bajos recursos.
-

Ficha 2: Court & Elsner (2024)

1. **REFERENCIA COMPLETA (APA 7):** Court, S., & Elsner, M. (2024). Shortcomings of LLMs for Low-Resource Translation: Retrieval and Understanding Are Both the Problem. *Proceedings of the Ninth Conference on Machine Translation*, 1332-1354.
 2. **TIPO DE DOCUMENTO:** Artículo de conferencia científica
 3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Investigar las habilidades de aprendizaje en contexto de Grandes Modelos de Lenguaje (LLMs) al traducir desde una lengua de bajos recursos (quechua sureño) hacia el español, utilizando información recuperada de diccionarios, gramáticas y corpus.
 4. **METODOLOGÍA:** Experimental cuantitativa. Se evaluó la salida de cuatro LLMs (GPT-3.5, GPT-4o, Gemini 1.5, Llama 3) bajo ocho condiciones de prompt que combinaban información de morfemas, gramática y ejemplos de corpus, usando métricas automáticas (BLEURT, BLEU) y anotación humana de errores.
 5. **RESULTADOS PRINCIPALES:** La inclusión de traducciones a nivel de morfema mejora el rendimiento de los modelos más pequeños. Sin embargo, en modelos más avanzados (GPT-4o), añadir contexto gramatical o de corpus reduce los puntajes BLEURT y aumenta la divergencia gramatical.
 6. **CONCLUSIONES DEL AUTOR:** Incluso explicaciones gramaticales relevantes ayudan poco a las generaciones más recientes de LLMs en tareas de bajos recursos. Las traducciones infieles suelen ser engañosamente fluidas en español, y en ocasiones introducen estereotipos culturales no presentes en la frase original.
 7. **RELEVANCIA PARA MI TESIS:** Demuestra que no basta con usar la técnica RAG para inyectar reglas gramaticales en un modelo genérico. Justifica la necesidad de afinar o cuantizar un Small Language Model especializado en lugar de depender únicamente del aprendizaje en contexto de un modelo en la nube.
 8. **CITAS TEXTUALES ÚTILES:** “providing additional information in the prompt’s context actually degrades GPT-4o’s ability to translate from S. Quechua to Spanish in all experimental conditions” (p. 7).
 9. **PALABRAS CLAVE ASIGNADAS:** LLMs, Quechua sureño, RAG, traducción automática, aprendizaje en contexto.
-

Ficha 3: Walusimbi et al. (2026)

1. **REFERENCIA COMPLETA (APA 7):** Walusimbi, J., Oguti, A. M., Ssentongo, J. B., & Ainebyona, K. (2026). Arapai: An Offline-First AI Chatbot Architecture for Low-Connectivity Educational Environments. *arXiv preprint arXiv:2603.03339*.
2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Diseñar y evaluar una arquitectura de LLM orientada a operar sin conexión a internet (offline-first) para asistencia educativa en entornos con baja conectividad.

4. **METODOLOGÍA:** Investigación aplicada. Se implementaron modelos cuantizados (TinyLlama, Qwen2.5-3B, Mistral-7B) ejecutados localmente en CPU. El sistema adaptativo fue evaluado cualitativa y cuantitativamente con 120 estudiantes y 9 docentes en condiciones reales.
 5. **RESULTADOS PRINCIPALES:** El sistema operó de forma estable en hardware heredado (CPU). Las consultas instructivas típicas mostraron latencias de respuesta de 1 a 3 segundos. Los usuarios reportaron una alta utilidad para el aprendizaje autodirigido a diferentes niveles de complejidad.
 6. **CONCLUSIONES DEL AUTOR:** Es viable desplegar asistentes educativos basados en IA en contextos con limitaciones de infraestructura utilizando LLMs cuantizados que se ejecutan localmente, ofreciendo una alternativa confiable a los sistemas que dependen de la nube.
 7. **RELEVANCIA PARA MI TESIS:** Es el principal antecedente arquitectónico. Valida la hipótesis de que los modelos cuantizados ejecutados en CPU son suficientemente rápidos y útiles para aplicaciones educativas offline en zonas rurales.
 8. **CITAS TEXTUALES ÚTILES:** “The system performs all inference locally using quantized language models and incorporates hardware-aware model selection to enable deployment on low-specification, CPU-only devices” (p. 1).
 9. **PALABRAS CLAVE ASIGNADAS:** Arquitectura offline-first, IA educativa, modelos cuantizados, edge AI.
-

Ficha 4: Xu et al. (2024)

1. **REFERENCIA COMPLETA (APA 7):** Xu, J., Li, Z., Chen, W., Wang, Q., Gao, X., Cai, Q., & Ling, Z. (2024). On-Device Language Models: A Comprehensive Review. *arXiv preprint arXiv:2409.00088*.
2. **TIPO DE DOCUMENTO:** Artículo de revisión (Survey)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Examinar los desafíos de desplegar LLMs computacionalmente costosos en dispositivos con recursos limitados y explorar las soluciones innovadoras en múltiples dominios.
4. **METODOLOGÍA:** Revisión sistemática de literatura sobre arquitecturas eficientes de modelos de lenguaje en dispositivos (on-device), analizando técnicas de compresión de modelos, aceleración de hardware y despliegue colaborativo borde-nube.
5. **RESULTADOS PRINCIPALES:** Se identifican tres estrategias clave para habilitar modelos en dispositivos: compartición de parámetros, cuantización (PTQ y QAT) para reducir bits de peso/activación, y destilación de conocimiento. La cuantización int4/int8 resulta esencial para procesadores móviles.
6. **CONCLUSIONES DEL AUTOR:** La transición de la nube al borde (edge) reduce latencia y aumenta privacidad, pero requiere un equilibrio delicado entre el rendimiento del modelo (precisión) y la utilización de recursos (memoria y energía) que solo se logra combinando múltiples técnicas de compresión.

7. **RELEVANCIA PARA MI TESIS:** Proporciona el marco teórico tecnológico sobre Small Language Models y cuantización que fundamenta el diseño del asistente educativo para hardware de bajo costo.
 8. **CITAS TEXTUALES ÚTILES:** “deploying computationally expensive LLMs on resource-constrained devices poses significant challenges. The primary obstacles include limited computational power, reduced memory capacity, and energy constraints” (p. 2).
 9. **PALABRAS CLAVE ASIGNADAS:** On-Device AI, cuantización, compresión de modelos, Small Language Models.
-

Ficha 5: Hevia et al. (2025)

1. **REFERENCIA COMPLETA (APA 7):** Hevia, J. S., Arredondo, F., & Kumar, V. (2025). Towards an Efficient, Customizable, and Accessible AI Tutor. *arXiv preprint arXiv:2510.06255*.
2. **TIPO DE DOCUMENTO:** Artículo científico (Preprint)
3. **OBJETIVO O PREGUNTA DEL ESTUDIO:** Proponer un sistema tutorial de IA fuera de línea (offline) basado en Generación Aumentada por Recuperación (RAG) emparejado con un Small Language Model (SLM) para entornos de bajos recursos.
4. **METODOLOGÍA:** Experimental cuantitativa. Evaluación de modelos de la familia SmolLM (135M y 1.7B) y RAG con libros de texto de biología de OpenStax usando métricas del benchmark MMLU para evaluar el impacto del contexto en la precisión de respuesta.
5. **RESULTADOS PRINCIPALES:** Contrario a lo esperado, la inclusión de recuperación RAG en SLMs disminuyó su precisión en el MMLU (de 21.59 % a 21.81 % con RAG en SmolLM2-135M, y una caída drástica en el modelo 1.7B), debido a la incapacidad de estos modelos pequeños para manejar ventanas de contexto extendidas y ruidosas.
6. **CONCLUSIONES DEL AUTOR:** Los Small Language Models luchan por aprovechar efectivamente el contexto extendido provisto por RAG, especialmente si los fragmentos contienen información irrelevante. Es crítico usar técnicas avanzadas de chunking” (fragmentación semántica) y métricas de evaluación holísticas más allá de opciones múltiples.
7. **RELEVANCIA PARA MI TESIS:** Alerta sobre los riesgos de usar arquitectura RAG simple con SLMs en el diseño del asistente EIB. Justifica la necesidad de un preprocesamiento cuidadoso de los contenidos curriculares y glosarios locales para evitar introducir ruido en la consulta.
8. **CITAS TEXTUALES ÚTILES:** “smaller models, such as SmolLM, struggle to effectively leverage extended contexts provided by the RAG pipeline, particularly when noisy or irrelevant chunks are included” (p. 1).
9. **PALABRAS CLAVE ASIGNADAS:** RAG, AI Tutor, Small Language Model, educación fuera de línea.