EL PLANO ARQUITECTÓNICO DE LA MATRIZ DE CONSISTENCIA

Arquitectura y Alineación Rigurosa de la Investigación

iseño e implementación de una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechu

El ADN Inmutable: [PROCESO: P] + [TECNOLOGÍA: T] + [CONTEXTO: C]
Guía metodológica basada en las tres leyes de la investigación científica aplicada a la tesis

Tesista: Br. Edmil Jampier Saire Bustamante | **Cátedra:** Msc. Raúl Huillca Huallparimachi (Seminario de Investigación II)
UNSAAC – Facultad de Ingeniería Eléctrica, Electrónica, Informática y Mecánica | Cusco, 2026

Las Tres Variables Inmutables de la Tesis

Todo proyecto de investigación se reduce a tres variables inmutables:

[P] PROCESO

La acción metodológica

Definición en el Plan:

Diseño e implementación de una arquitectura de software **SLM–RAG offline** (sistema de procesamiento local autónomo sin conexión).

+

[T] TECNOLOGÍA

El núcleo técnico

Definición en el Plan:

Modelo compacto cuantizado a 4 bits con **adaptadores QLoRA** y recuperación local indexada.

+

[C] CONTEXTO

El ámbito / problema

Definición en el Plan:

Generación y anclaje factual de respuestas en **Quechua Collao** en entornos sin conectividad digital.

Ley 1 (El Título es la Ley): El título actúa como el genoma del proyecto. Los problemas, objetivos e hipótesis son solo **mutaciones gramaticales** de [*P*], [*T*] y [*C*], sin agregar variables huérfanas.

Derivación Macro: Transformación Sintáctica del ADN

Elemento	Estructura Gramatical	Expresión en la Tesis
Título Base	**[P]** + **[T]** + **[C]**	Diseño e implementación de una arquitectura SLM–RAG **[P]** con QLoRA **[T]** para la generación contextualizada en Quechua Collao **[C]**.
Problema General	¿Cómo **[P]** mediante **[T]** influye en **[C]**?	¿De qué manera el diseño e implementación de una arquitectura SLM–RAG **[P]** con QLoRA **[T]** influye en la generación contextualizada en Quechua Collao **[C]**?
Objetivo General	**[Verbo P]** + **[T]** + **[C]**	Diseñar e implementar una arquitectura SLM–RAG **[P]** con QLoRA **[T]** para la generación contextualizada en Quechua Collao **[C]**.
Hipótesis General	La aplicación de **[P]** mediante **[T]** optimiza/garantiza **[C]**	La implementación de la arquitectura SLM–RAG **[P]** con QLoRA **[T]** optimiza la asimilación del contexto e incrementa la fidelidad factual en Quechua Collao **[C]**.

Alineación Confirmada (100 % Consistente): Sustantivo → Interrogación → Verbo Infinitivo → Afirmación Resolutiva. Ningún elemento conceptual nuevo ha sido inventado.

Desglose Específico: Secuencia Cronológica de Fases

Los Objetivos Específicos cronometran el proceso metodológico en 3 fases de ingeniería:

FASE 1: Preparación

Node 1: Datos y Recuperación

Acción Metodológica:

Curar, estructurar e indexar semánticamente la base de conocimiento documental bilingüe para el motor de recuperación local en Quechua Collao.

→

FASE 2: Núcleo Técnico

Node 2: Adaptadores QLoRA

Acción Metodológica:

Implementar y acoplar adaptadores QLoRA en el SLM cuantizado a 4 bits para maximizar la asimilación del contexto RAG.

→

FASE 3: Validación

Node 3: Benchmarking Computacional

Acción Metodológica:

Evaluar empíricamente el rendimiento (latencia/RAM), fidelidad léxica (chrF++, BLEU) y anclaje factual RAG (framework Ragas).

Ley 3 (Secuencia Lógica): Los objetivos específicos constituyen los hitos técnicos cronológicos que resuelven secuencialmente la arquitectura propuesta de principio a fin.

Correspondencia Específica: Problemas vs. Objetivos

Nodo 1: Datos y Recuperación

Problema Específico 1:
¿Cómo estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación local en Quechua Collao?

Objetivo Específico 1:
Curar, estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación local en Quechua Collao.

Nodo 2: Núcleo Técnico

Problema Específico 2:
¿De qué manera los adaptadores QLoRA del SLM cuantizado optimizan la utilización de contexto bajo restricciones offline?

Objetivo Específico 2:
Implementar y acoplar adaptadores QLoRA en el SLM cuantizado para maximizar la asimilación del contexto RAG en inferencia offline.

Nodo 3: Validación Computacional

Problema Específico 3:
¿Qué nivel de fidelidad léxica, consistencia factual y eficiencia alcanza la arquitectura frente al modelo base y RAG estándar?

Objetivo Específico 3:
Evaluar computacionalmente el rendimiento, fidelidad lingüística y anclaje factual frente al SLM base y RAG estándar.

Alineación 1 a 1: Cada fase responde a una pregunta de ingeniería con su respectivo objetivo operativo verificable.

La Matriz de Consistencia Completa del Proyecto

TÍTULO: Diseño e implementación de una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao			
Problemas de Investigación	**Objetivos de la Tesis**	**Hipótesis de Trabajo**	**Variables e Instrumentos**
NIVEL GENERAL			
¿De qué manera el diseño e implementación de una arquitectura SLM–RAG con QLoRA influye en la generación contextualizada en Quechua Collao?	Diseñar e implementar una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao.	La arquitectura SLM–RAG con QLoRA optimiza la asimilación del contexto e incrementa la fidelidad factual en Quechua Collao en inferencia offline.	**VI:** Arquitectura SLM–RAG con QLoRA. **VDs:** Rendimiento, calidad PLN y fidelidad RAG. **Inst:** `llama.cpp`, Ragas, SacreBLEU.
NIVEL ESPECÍFICO (Fases Metodológicas de Ingeniería)			
PE1 (Datos): ¿Cómo estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación en Quechua Collao?	**OE1:** Curar, estructurar e indexar semánticamente una base documental bilingüe para optimizar la recuperación local.	**HE1:** La segmentación morfo-léxica e indexación semántica local maximizan la precisión de recuperación documental.	**Var:** Precisión de indexación. **Inst:** `sqlite-vec`, FAISS, `multilingual-e5-small`.
PE2 (Núcleo): ¿De qué manera los adaptadores QLoRA del SLM optimizan la utilización de contexto bajo restricciones offline?	**OE2:** Implementar y acoplar adaptadores QLoRA en el SLM cuantizado para maximizar la asimilación del contexto RAG offline.	**HE2:** La adaptación de bajo rango con QLoRA incrementa la fidelidad factual sin penalizar hardware modesto.	**Var:** Latencia (ms), TPS, RAM (GB). **Inst:** `llama.cpp`, `peft`, `psutil`.
PE3 (Validación): ¿Qué nivel de fidelidad léxica, consistencia factual y eficiencia alcanza la arquitectura frente al modelo base y RAG estándar?	**OE3:** Evaluar computacionalmente el rendimiento, fidelidad lingüística y anclaje factual frente al SLM base y RAG estándar.	**HE3:** La arquitectura con QLoRA supera significativamente al SLM base y RAG estándar en chrF++ y fidelidad Ragas.	**Var:** chrF++, BLEU, Faithfulness. **Inst:** Scripts Python, framework Ragas, Friedman/Wilcoxon.

Las Tres Leyes del Diseño y Panel de Control Final

1. El Título es la Ley

Consistencia de Variables

Cero variables huérfanas: problemas, objetivos e hipótesis derivan estrictamente de [*P*], [*T*] y [*C*] sin variables pedagógicas extrañas.

2. Transformación

Mutación Gramatical

Los componentes generales son transformaciones sintácticas exactas (pregunta $\leftrightarrow$ verbo $\leftrightarrow$ afirmación), no ideas conceptuales distintas.

3. Secuencia Lógica

Cronología Ingenieril

Los objetivos específicos dividen el proceso en fases operativas de ingeniería DSR: **Datos** $\rightarrow$ **Adaptación con QLoRA** $\rightarrow$ **Evaluación**.

Panel de Control de Calidad y Auditoría Académica (100 % Aprobado)

[✓]	**Trazabilidad Total:**	Correspondencia matemática entre Título, PG, OG, HG y Fases Específicas.
[✓]	**Cero Variables Huérfanas:**	Todas las variables específicas provienen del desglose de [*P*] y [*T*].
[✓]	**Viabilidad Experimental:**	Cada objetivo específico cuenta con variables e instrumentos computacionales reproducibles.
[✓]	**Rigor de Ingeniería:**	Enfoque DSR estructurado, autónomo y defendible ante el jurado de sistemas.