DEL CONTEXTO A LA EVALUACIÓN
EL PROCESO COMPLETO DEL PLAN DE TESIS

Diseño e implementación de una arquitectura SLM–RAG con QLoRA

para la generación contextualizada en Quechua Collao

Ruta de investigación aplicada: contexto → evidencia → problema → objetivos → método → evaluación

Tesista: Br. Edmil Jampier Saire Bustamante | **Cátedra:** Seminario de Investigación II
UNSAAC – Cusco, 2026

La ruta completa aplicada al tema

1. Contexto

Quechua Collao, recursos limitados y meta de uso offline.

2. Evidencia

Corpus, diccionarios y estudios sobre recuperación y SLM.

3. Problema

¿El SLM aprovecha el contexto recuperado para generar en Collao?

4. Objetivos

Curar datos, adaptar el modelo y comparar configuraciones.

5. Justificación

Aporte lingüístico, técnico y práctico para ejecución local.

6. Método

DSR, experimento E1/E2/E3 y métricas de calidad y recursos.

Cada etapa debe dejar una decisión rastreable en el plan.

Situación de investigación

- El plan se enfoca en Quechua Collao, una variedad que requiere recursos identificados y validados.
- El acceso a conocimiento confiable depende de corpus, diccionarios y documentos digitalizados.
- Un servicio exclusivamente en la nube no satisface el objetivo de inferencia offline.
- Un SLM compacto reduce requisitos de despliegue, pero su calidad en la variedad debe medirse.

Necesidad

acceso local a respuestas contextualizadas

⇓

evidencia documental + generación lingüística

Base documental: Plan de tesis, introducción, problema y factibilidad.

El tema expresado como proceso + tecnología + contexto

Proceso

P

Diseñar e implementar una arquitectura y evaluar su generación contextualizada.

Tecnología

T

SLM cuantizado + recuperación local (RAG) + adaptación eficiente (QLoRA).

Contexto

C

Quechua Collao y ejecución en un entorno computacional offline.

FORMULACIÓN DEL PLAN

Diseñar SLM–RAG con QLoRA para generar en Quechua Collao offline.

2 | Marco conceptual: qué hace cada componente

Componente	Función prevista en la tesis	Pregunta de control
SLM	Modelo compacto Qwen2.5-3B-Instruct cuantizado; genera la respuesta.	¿Puede ejecutarse localmente con los recursos disponibles?
RAG local	Busca fragmentos documentales y los incorpora al prompt.	¿El contexto recuperado es pertinente y trazable?
QLoRA	Ajusta adaptadores ligeros manteniendo congelado el modelo base cuantizado.	¿Mejora el uso del contexto frente a RAG estándar?
Corpus bilingüe	Aporta evidencia textual en español y Quechua Collao.	¿Se controla calidad, fuente y variedad dialectal?

Distinción clave: RAG aporta conocimiento recuperable; QLoRA busca adaptar el comportamiento del modelo para utilizar el contexto.

2 | Evidencia documentada: recursos para Quechua

Corpus paralelo

Orcotoma Mormontoy et al. (2025) presentan un corpus paralelo Quechua–español construido a partir de publicaciones digitalizadas y OCR.

Aporte al plan: semillas documentales y material para validar/curar.
Cuidado: OCR exige limpieza; no equivale a un corpus de entrenamiento listo.

Recursos léxicos

Durán y Silberztein (2026) describen recursos léxicos y gramaticales para Quechua Sureño, incluidos verbos y formalización para procesamiento.

Aporte al plan: apoyo para normalización y verificación léxica.
Cuidado: comprobar variedad, licencia y compatibilidad antes de integrar.

Base documental: Orcotoma Mormontoy et al. (2025); Durán y Silberztein (2026).

2 | Evidencia documentada: recuperación y modelos compactos

Court y Elsner (2024)	Hevia et al. (2025)	Walusimbi et al. (2026)
Estudian traducción de Quechua Sureño al español con contexto. El efecto de proporcionar ejemplos depende del modelo, recuperación y contexto.	Describen un tutor de IA con RAG y un modelo ligero para operar offline con pocos recursos; exploran estrategias de recuperación sobre libros universitarios.	Proponen una arquitectura offline-first para entornos de conectividad limitada, con modelos locales cuantizados.

Lectura para esta tesis: la recuperación de contexto y la inferencia offline son enfoques plausibles; su combinación no garantiza por sí sola fidelidad lingüística ni buen uso del contexto.

Base documental: Estudios publicados; ver referencias al final.

Qué aporta

Chen et al. (2024) presentan QueEn, un modelo de traducción Quechua–inglés que combina recuperación de información y ajuste eficiente de parámetros.

- Antecedente de RAG + PEFT en una tarea que involucra Quechua.
- Da un punto de comparación conceptual para el enfoque híbrido.
- Su tarea y dirección de traducción no son idénticas a la generación contextualizada Collao planteada aquí.

Verificación bibliográfica

En la bibliografía local, la clave `Chen2024` apunta a un registro ACL distinto (NewsPaLM).

El trabajo QueEn corresponde a arXiv:2412.05184.

Acción pendiente: corregir la entrada BibTeX antes de la entrega formal del plan.

Base documental: Chen et al., *QueEn: A Large Language Model for Quechua-English Translation* (2024), arXiv:2412.05184.

De los antecedentes a la brecha investigable

Lo que existe

Corpus y recursos léxicos; traducción con contexto; sistemas offline con SLM y RAG.

Lo que falta comprobar

Cómo se comporta una integración concreta SLM–RAG–QLoRA para Quechua Collao, con evidencia local y restricciones de cómputo.

Foco evaluable

Comparar el uso de contexto recuperado entre modelo base, RAG estándar y RAG con QLoRA.

Alcance de la afirmación: es una brecha delimitada por este plan; no se afirma que nadie haya investigado previamente todos sus componentes.

Problema general del plan

Capacidad limitada de modelos compactos cuantizados para asimilar contextos recuperados en una arquitectura RAG offline orientada a generación en Quechua Collao.

Datos y recuperación

Corpus heterogéneo; ruido OCR; necesidad de etiquetar fuentes y variedad lingüística.

Uso del contexto

El SLM puede recibir fragmentos pertinentes, pero no utilizarlos de forma completa o fiel.

Restricción de cómputo

La solución debe operar localmente; adaptación y evaluación quedan sujetas a recursos acotados.

El problema se traduce en una comparación experimental, no en una promesa de mejora.

Base documental: Plan de tesis, planteamiento del problema.

Pregunta general
¿De qué manera el diseño e implementación de una arquitectura SLM–RAG con QLoRA influye en la generación contextualizada en Quechua Collao dentro de un entorno computacional offline?

PE1	¿Cómo curar, estructurar e indexar una base documental bilingüe para recuperación local en Quechua Collao?
PE2	¿Cómo adaptar con QLoRA un SLM cuantizado para mejorar el uso del contexto recuperado dentro de las restricciones de hardware?
PE3	¿Cómo comparar fidelidad, calidad lingüística y eficiencia computacional frente al SLM base y al RAG estándar?

Base documental: Plan de tesis, preguntas general y específicas.

4 | Objetivo general y objetivos específicos

Objetivo general
Diseñar e implementar una arquitectura SLM–RAG con QLoRA para la generación contextualizada en Quechua Collao dentro de un entorno computacional offline.

OE1 | Base documental	OE2 | Adaptación	OE3 | Evaluación
Curar, estructurar e indexar una base de conocimiento bilingüe para recuperación local.	Implementar adaptadores QLoRA sobre un SLM cuantizado para asimilar contexto recuperado.	Comparar fidelidad, calidad lingüística y eficiencia frente a las configuraciones de referencia.

Los objetivos describen productos verificables: índice, adaptador y resultados comparativos.

Hipótesis del plan

La arquitectura híbrida SLM–RAG con QLoRA mejorará la generación contextualizada respecto al SLM base y al RAG estándar, dentro de límites de cómputo offline.

Estado

Predicción por contrastar. No es un resultado ni puede presentarse como hallazgo antes del experimento.

Variable independiente

Configuración del sistema:

- E1: SLM cuantizado, sin RAG.
- E2: SLM cuantizado + RAG local.
- E3: SLM cuantizado + RAG + QLoRA.

Variables dependientes

Fidelidad al contexto; calidad lingüística; eficiencia computacional.

Base documental: Plan de tesis, hipótesis y diseño experimental.

La matriz de consistencia en una sola vista

Problema específico	Objetivo asociado	Componente / producto	Evidencia de evaluación
PE1: evidencia documental para RAG	OE1: curar e indexar recursos bilingües	Corpus depurado, metadatos e índice local	Trazabilidad de fuentes; recuperación y precisión de contexto
PE2: uso limitado del contexto	OE2: adaptar SLM con QLoRA	Adaptador entrenado y configuración E3	Comparación E2 vs. E3 bajo el mismo banco de consultas
PE3: impacto sin medir	OE3: comparar las tres configuraciones	Banco de evaluación y ejecución reproducible	Métricas lingüísticas, de fidelidad y de recursos

Regla de consistencia: cada pregunta tiene un objetivo; cada objetivo produce un artefacto o evidencia observable.

5 | Justificación: por qué merece hacerse

Lingüística y social

Contribuye a explorar herramientas locales para una variedad que requiere recursos lingüísticos identificados y respetados.

Técnica

Evalúa si QLoRA puede mejorar el uso de contexto recuperado, además de medir el aporte propio de RAG.

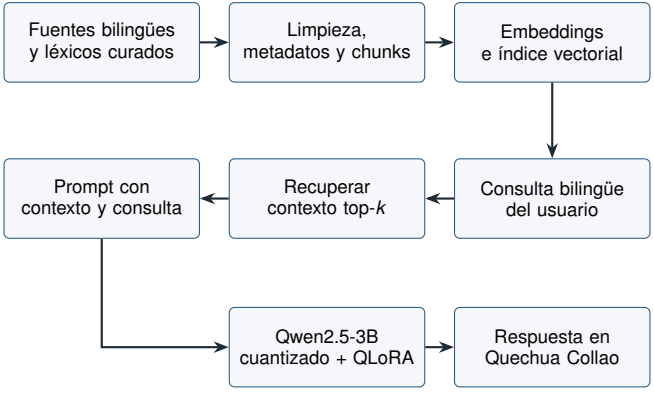
Práctica y académica

Deja un prototipo y un protocolo experimental comparativo que pueden reproducirse y ampliarse.

Delimitación ética: fuentes públicas con atribución; control explícito de variante; resultados reportados sin prometer utilidad comunitaria no evaluada.

Base documental: Plan de tesis, justificación y factibilidad.

6 | Propuesta: flujo SLM–RAG con QLoRA



Índice documental local; generación offline.

Base documental: Plan de tesis, arquitectura propuesta y factibilidad técnica.

Enfoque metodológico

- Investigación aplicada, cuantitativa y experimental.
- Design Science Research (DSR): problema, objetivos, diseño, demostración, evaluación y comunicación.
- Artefacto: pipeline local de recuperación y generación con adaptador.
- Comparación controlada usando consultas y datos separados por partición.

Configuraciones

E1 SLM base cuantizado

E2 SLM base + RAG local

E3 SLM + RAG local + QLoRA

Cada ejecución debe compartir el banco de consultas, parámetros comparables y registro de hardware.

E1 establece línea base; E2 aísla el aporte de RAG; E3 permite estimar el aporte adicional de QLoRA.

Base documental: Plan de tesis, metodología y diseño experimental.

6 | Evaluación: qué se medirá

Dimensión	Indicadores propuestos	Lectura
Calidad lingüística	chrF++, SacreBLEU y revisión de fluidez/variedad	¿La respuesta es comprensible y compatible con Quechua Collao?
Fidelidad / RAG	Faithfulness, context precision y answer relevancy (RAGAS)	¿La respuesta sigue la evidencia y el contexto recuperado?
Eficiencia	Latencia, tokens/s, RAM y VRAM	¿Puede operar bajo las restricciones offline?

Protocolo necesario: fijar el banco de consultas, documentar versiones y parámetros, repetir mediciones y reportar limitaciones de las métricas automáticas.

Base documental: Plan de tesis, métricas e instrumentos.

Decisión técnica

- Evitar entrenamiento desde cero; partir de Qwen2.5-3B-Instruct.
- Inferencia local cuantizada y recuperación con índice embebido.
- Entrenar QLoRA en sesiones puntuales con GPU disponible si la máquina local no alcanza.
- Mantener chunks y top-k acotados para controlar memoria.

Riesgos y respuesta

OCR ruidoso $\rightarrow$ limpieza y trazabilidad.

Mezcla de variedades $\rightarrow$ etiquetar y filtrar dialecto.

Datos sintéticos débiles $\rightarrow$ validar contra recursos documentales.

Memoria limitada $\rightarrow$ cuantización, inferencia CPU y adaptación acotada.

La factibilidad respalda un prototipo experimental; no demuestra de antemano su rendimiento.

Base documental: Plan de tesis, estudio de factibilidad y gestión de riesgos.

Cómo se convierte en una tesis

1. **Introducción**: contexto, problema, objetivos y justificación.
2. **Marco teórico y estado del arte**: conceptos, recursos y antecedentes.
3. **Metodología y arquitectura**: diseño del artefacto y protocolo.
4. **Implementación**: corpus, índice, SLM y adaptadores.
5. **Resultados y evaluación**: E1/E2/E3, métricas y análisis.
6. **Conclusiones y trabajo futuro**: respuesta a objetivos, límites y siguientes pasos.

Nota: la organización de seis capítulos es tentativa y se ajustará al reglamento y a la evolución del proyecto.

Base documental: Plan de tesis, estructura tentativa.

Control de calidad: decisiones que faltan cerrar

1. **Corregir bibliografía de QueEn:** clave `Chen2024` actualmente remite a otro trabajo; confirmar autores y metadatos de arXiv:2412.05184.
2. **Alinear objetivo general e indicadores:** explicitar en el objetivo o en los específicos cómo se observarán calidad lingüística y eficiencia.
3. **Precisar evaluación lingüística:** quién revisa la variante Collao, con qué rúbrica y cómo se resolverán desacuerdos.
4. **Fijar protocolo de datos:** fuentes permitidas, particiones sin fuga, criterios de limpieza y registro de versiones.
5. **Separar plan y resultados:** hipótesis, métricas y mejoras se presentan como propuestas hasta completar experimentos.

Estas observaciones sirven para fortalecer el plan; no modifican el documento fuente de la tesis.

Referencias principales verificadas

Orcotoma Mormontoy, G. C., Leon Nuñez, L. y Espetia Huamanga, H. (2025). *Towards the Creation of a Collao Quechua–Spanish Parallel Corpus Using Optical Character Recognition*. GlobalNLP. https://aclanthology.org/2025.globalnlp-1.1/

Court, S. y Elsner, M. (2024). *Shortcomings of LLMs for Low-Resource Translation: Retrieval and Understanding Are Both the Problem*. WMT. https://aclanthology.org/2024.wmt-1.125/

Chen, J. et al. (2024). *QueEn: A Large Language Model for Quechua-English Translation*. arXiv:2412.05184. https://arxiv.org/abs/2412.05184

Hevia, J. S., Arredondo, F. y Kumar, V. (2025). *Towards an Efficient, Customizable, and Accessible AI Tutor*. PMLR 273:250–254. https://proceedings.mlr.press/v273/hevia25a.html

Duran, M. y Silberztein, M. (2026). *Semi-Automatic Construction of a Quechua-Spanish Dictionary*. LoResMT. https://aclanthology.org/2026.loresmt-1.9/

Walusimbi, A. et al. (2026). *Arapai: An Offline-First LLM Architecture for Adaptive Learning in Low-Connectivity Environments*. arXiv:2603.03339. https://arxiv.org/abs/2603.03339

[1] Fuente de estructura y planteamiento: Plan de Tesis; proceso de referencia: presentación Seminario II adjunta.