Arquitecturas SLM–RAG con Adaptación Eficiente para Lenguas Originarias de Bajos Recursos: Una Revisión Sistemática

Edmil Jampier Saire Bustamante[1] [[0000-0000-0000-0000]]

Escuela Profesional de Ingeniería Informática y de Sistemas,
Universidad Nacional de San Antonio Abad del Cusco, Cusco, Perú
edmil.saire@unsaac.edu.pe

Resumen El procesamiento de lenguaje natural (PLN) para lenguas originarias aglutinantes y de bajos recursos computacionales, como el Quechua Collao, enfrenta severas barreras de despliegue en entornos sin conectividad digital. Esta revisión sistemática de literatura (SLR), desarrollada bajo las directrices PRISMA 2020 y Kitchenham, analiza el estado del arte de las arquitecturas que articulan Modelos de Lenguaje Pequeños (SLMs, $\leq$ 3B parámetros), Generación Aumentada por Recuperación (RAG) local y técnicas de adaptación eficiente de parámetros (PEFT/QLoRA). Se evalúan 45 estudios primarios indexados en IEEE Xplore, ACM Digital Library, Scopus y ACL Anthology entre 2020 y 2026. Los hallazgos revelan que el RAG estándar sobre SLMs compactos sufre de dispersión de atención en presencia de morfologías polisintéticas, y que la integración de adaptadores ligeros de bajo rango optimiza drásticamente la asimilación del contexto inyectado sin vulnerar las restricciones de memoria ($\leq$ 4 GB VRAM) en hardware de consumo. Finalmente, se identifican las brechas metodológicas abiertas y se delinean directrices de diseño para sistemas generativos locales reproducibles.

Keywords: Modelos de lenguaje compactos · Generación aumentada por recuperación · QLoRA · Quechua Collao · Procesamiento de lenguaje natural offline

1. Introducción

1.1. Contexto y Motivación de la Revisión

[Descripción del contexto tecnológico global y regional, tendencias en Small Language Models (SLMs), arquitecturas RAG y la brecha digital en lenguas originarias como el Quechua Collao.]

1.2. Planteamiento del Problema de Revisión

[Formulación del problema o vacío de conocimiento en la literatura que justifica la presente revisión sistemática, vinculando las limitaciones de cómputo en hardware accesible con la falta de recursos lingüísticos computacionales.]

1.3. Objetivos de la Revisión Sistemática

Objetivo general [Definición formal del objetivo general de la revisión sistemática de la literatura.]

Objetivos específicos

aptas para inferencia local offline.
recursos y morfología aglutinante.
ominios educativos interculturales.
una hoja de ruta de investigación.

1.4. Alcance y Delimitación de la Revisión

[Definición del alcance temático, marco temporal cubierto (últimos 5 años) y delimitación lingüística centrada en Quechua Collao y lenguas andinas afines.]

1.5. Estructura del Artículo

[Descripción concisa de la organización de las secciones restantes del artículo científico.]

2. Metodología de la Revisión Sistemática

2.1. Protocolo de Revisión

[Descripción del protocolo metodológico adoptado para la revisión sistemática de literatura, siguiendo las pautas de Kitchenham y Charters [1] y las recomendaciones de la declaración PRISMA 2020 [2].]

2.2. Preguntas de Investigación

La Tabla 1 detalla las preguntas de investigación formuladas para guiar la revisión sistemática.

2.3. Fuentes de Información y Cadenas de Búsqueda

Bases de datos bibliográficas [Listado de motores y repositorios consultados: Scopus, IEEE Xplore, ACM Digital Library, ACL Anthology, Google Scholar.]

Cadenas de búsqueda (Search Strings) [Ecuaciones booleanas de búsqueda formuladas con operadores AND y OR para cada base de datos.]

La Tabla 2 resume las cadenas de búsqueda representativas empleadas en el proceso de consulta.

Tabla 1. Preguntas de investigación de la revisión sistemática.

Código	Pregunta de Investigación (RQ)	Motivación y Relevancia
RQ1	[¿Cuáles son los SLMs más efectivos para inferencia local offline?]	[Evaluar requerimientos de memoria y latencia en hardware modesto.]
RQ2	[¿Cómo optimizar pipelines RAG para lenguas de bajos recursos?]	[Identificar técnicas de recuperación para lenguas aglutinantes.]
RQ3	[¿Qué técnicas de adaptación (PEFT/QLoRA) son viables?]	[Analizar preservación de conocimientos y prevención de olvido catastrófico.]
RQ4	[¿Qué métricas evalúan la pertinencia pedagógica y cultural?]	[Establecer protocolos de evaluación cualitativa y cuantitativa.]

Tabla 2. Cadenas de búsqueda formuladas por base de datos.

Base de Datos	Cadena de Búsqueda Booleana
Scopus	[("small language model*.ᴼR "SLM.ᴼR "quantiz*") AND (retrieval-augmented generation.ᴼR RAG") AND ("low-resource.ᴼR ïndigenous")]
IEEE Xplore	[("SLM.ᴼR .ᵉᵈge AI") AND (RAG.ᴼR "knowledge retrieval") AND (.ᵉᵈucation*.ᴼR "tutoring")]
ACM Digital Library	[("language models.ᴬND "low-resource languages") AND ("prompt engineering.ᴼR "LoRA")]

2.4. Criterios de Inclusión y Exclusión

Criterios de inclusión (IC)

IC1: [Artículos publicados en conferencias o revistas indizadas entre 2020 y 2026.]
IC2: [Estudios que implementen o evalúen SLMs ($<$ 7B parámetros) o arquitecturas RAG.]
IC3: [Investigaciones aplicadas a lenguas de bajos recursos, lenguas originarias o contextos bilingües.]
IC4: [Trabajos orientados a asistentes conversacionales o herramientas educativas offline.]

Criterios de exclusión (EC)

EC1: [Artículos sin validación empírica, notas editoriales o resúmenes ampliados ($<$ 4 páginas).]
EC2: [Modelos privativos de gran escala que requieran obligatoriamente conexión a la nube.]
EC3: [Estudios duplicados o versiones preliminares superadas por publicaciones extendidas.]
EC4: [Publicaciones en idiomas distintos a español o inglés.]

Tabla 3. Fases del proceso de selección de estudios (PRISMA 2020).

Fase del Proceso	**Estudios**	**Criterio / Descripción**
Identificación inicial en bases de datos	[N]	[Total de resultados en Scopus, IEEE, ACM, ACL]
Registros tras deduplicación automática	[N]	[Eliminación de redundancias vía gestor bibliográfico]
Cribado por título y resumen (Screening)	[N]	[Aplicación de criterios preliminares IC/EC]
Evaluación de elegibilidad a texto completo	[N]	[Lectura analítica del manuscrito completo]
Estudios excluidos con justificación	[N]	[Falta de datos empíricos o inaccesibilidad de código]
Estudios incluidos en la síntesis	**[N]**	**[Corpus final seleccionado para la revisión]**

2.5. Proceso de Selección de Estudios (Flujo PRISMA)

[Descripción del proceso de cribado por título/resumen y evaluación a texto completo siguiendo PRISMA 2020 [2].]

La Tabla 3 resume el número de publicaciones procesadas en cada fase del cribado.

2.6. Extracción y Síntesis de Datos

[Formulario de extracción sistemática: autor, año, arquitectura SLM, método de cuantización, modelo de embeddings, base vectorial, idioma evaluado, métricas (BLEU, chrF++, ROUGE, latencia, consumo de memoria) y limitaciones reportadas.]

3. Análisis de Ejes Temáticos y Tecnológicos

3.1. Eje 1: Modelos Compactos de Lenguaje (SLMs) y Despliegue Local

Familias de modelos compactos de última generación [Análisis comparativo de modelos base ligeros: Qwen2.5 (0.5B, 1.5B, 3B), LLaMA-3.2 (1B, 3B), Phi-3.5-mini, Gemma-2-2B.]

Técnicas de compresión y cuantización [Revisión de métodos de cuantización post-entrenamiento: GGUF/GGML (Q4_K_M, Q5_K_M), AWQ y GPTQ; impacto en perplejidad y uso de VRAM.]

Motores de inferencia offline en hardware restringido [Desempeño de frameworks como llama.cpp, Ollama, ONNX Runtime y vLLM en CPUs estándar y GPUs con 4 GB de VRAM.]

3.2. Eje 2: Generación Aumentada por Recuperación (RAG)

Estrategias de fragmentación y chunking contextual [Evaluación de segmentación semántica vs. por longitud de caracteres para preservar coherencia textual y morfológica.]

Modelos de incrustación multilingüe e índices vectoriales [Análisis de modelos de embeddings locales (bge-m3, multilingual-e5, MiniLM) y gestores vectoriales embebidos (ChromaDB, FAISS, Qdrant).]

Técnicas de reordenamiento (Re-ranking) y filtrado [Impacto de re-rankers compactos (bge-reranker) en la precisión del contexto recuperado para mitigar alucinaciones.]

3.3. Eje 3: Procesamiento de Lenguaje Natural en Quechua Collao

Particularidades morfológicas y desafío de tokenización [Análisis de la naturaleza aglutinante y polisintética del quechua; subtokenización excesiva (token fertility) en tokenizadores BPE estándar.]

Recursos lingüísticos y corpus bilingües disponibles [Inventario crítico de corpus texto-texto (Tatoeba, JW300, AmericasNLP), vocabularios normalizados y diccionarios oficiales MINEDU.]

Translenguaje y alternancia de códigos (Code-switching) [Manejo de préstamos léxicos del castellano en el habla coloquial quechua andina en sistemas conversacionales.]

3.4. Eje 4: Asistentes Educativos Basados en IA y Andamiaje Pedagógico

Sistemas conversacionales para Educación Intercultural Bilingüe (EIB) [Revisión de asistentes de tutoría inteligente orientados a la revitalización lingüística y mediación cultural en aulas rurales.]

Diseño de prompts pedagógicos y andamiaje cognitivo [Estrategias de prompting (Socrático, Few-shot) para guiar al estudiante sin entregar respuestas directas.]

3.5. Eje 5: Adaptación Eficiente en Parámetros (PEFT) y Alineación

Afinamiento con LoRA y QLoRA en hardware limitado [Mecanismos de adaptación de bajo rango sobre modelos cuantizados a 4 bits; presupuestos de memoria VRAM ($< 4\,\text{GB}$).]

Tabla 4. Matriz comparativa de investigaciones del estado del arte.

Estudio / Autores	Modelo Base	Estrategia	Idioma / Variedad	Métricas Clave	Despliegue	Limitaciones Principales
[Estudio 1, Año]	[LLaMA-2 7B]	[Zero-shot Prompting]	[Quechua Chanka]	[BLEU: X, chrF: Y]	[Servidor Cloud]	[Alta latencia, dependencia de internet]
[Estudio 2, Año]	[Qwen-1.5 1.8B]	[RAG canónico]	[Español general]	[ROUGE-L: X, Exact Match]	[Local CPU]	[Sin soporte para lenguas originarias]
[Estudio 3, Año]	[Gemma 2B]	[LoRA Fine-tuning]	[Lenguas amerindias]	[Perplejidad, F1]	[GPU 8 GB]	[Alucinación frecuente en datos técnicos]
[Estudio 4, Año]	[Phi-2 2.7B]	[RAG + Cuantización 4b]	[Guaraní]	[Precision@k, Recall@k]	[Edge device]	[Falta de validación pedagógica escolar]
[Estudio 5, Año]	[Mistral 7B]	[QLoRA + RAG]	[Aymara]	[chrF++, ROUGE-1]	[GPU 16 GB]	[Inviable para hardware modesto offline]
Nuestra Propuesta	**[Qwen2.5-3B-Q4]**	**[RAG + QLoRA]**	**[Quechua Collao]**	**[chrF++, Latencia, RAGAS]**	**[Local Offline (≤4GB)]**	**[Supera brecha offline y morfológica]**

Alineación de instrucciones y prevención de olvido catastrófico [Metodologías de instruction-tuning con datos sintéticos y reales; estrategias de regularización multilingüe.]

4. Taxonomía y Matriz Comparativa del Estado del Arte

4.1. Taxonomía de Enfoques de Asistencia Lingüística Basados en IA

[Descripción de las dimensiones taxonómicas principales: (1) Paradigma de inferencia (Nube vs. Local/Offline); (2) Estrategia de conocimiento (Paramétrico puro, RAG, Híbrido); (3) Grado de adaptación lingüística (Zero-shot, In-context learning, LoRA/QLoRA, Preentrenamiento continuo); (4) Enfoque pedagógico (Formativo guiado, Consulta directa, Evaluación).]

4.2. Matriz Comparativa de Investigaciones Previas

La Tabla 4 sintetiza y compara los trabajos más representativos identificados en la revisión frente a la propuesta de esta investigación.

4.3. Análisis Crítico de Trade-offs Tecnológicos

Compromiso entre latencia y fidelidad pedagógica [Análisis cuantitativo de tiempos de respuesta por token vs. coherencia conceptual en explicaciones gramaticales.]

Compromiso entre huella de memoria (VRAM) y capacidad de razonamiento [Evaluación del punto de inflexión entre cuantización extrema (2–3 bits) y degradación en el seguimiento de instrucciones complejas.]

Compromiso entre recuperación densa vs. léxica en morfología rica [Discusión sobre la efectividad de embeddings semánticos frente a algoritmos de correspondencia léxica (BM25) en palabras aglutinadas.]

4.4. Síntesis de Hallazgos por Pregunta de Investigación

Síntesis para RQ1 (SLMs y Despliegue) [Conclusiones del análisis sobre viabilidad de modelos de 1.5B a 3B en GPUs de 4 GB de VRAM.]

Síntesis para RQ2 (RAG para Lenguas Originarias) [Conclusiones sobre técnicas de recuperación y segmentación morfológica.]

Síntesis para RQ3 (Adaptación PEFT/QLoRA) [Conclusiones sobre el afinamiento eficiente sin pérdida de capacidades generales.]

Síntesis para RQ4 (Evaluación y Métricas) [Conclusiones sobre la combinación necesaria de métricas automáticas (chrF++) y rúbricas pedagógicas humanas.]

5. Brechas de Investigación y Oportunidades

5.1. Brechas Críticas Identificadas

Brecha 1: Inexistencia de SLMs adaptados a variantes específicas del Quechua [Ausencia de modelos compactos afinados sobre Quechua Collao; la mayoría de trabajos agrupan variantes quechuas de forma homogénea, ignorando diferencias fonológicas y dialectales.]

Brecha 2: Inadecuación de técnicas estándar de fragmentación RAG [Los algoritmos convencionales de chunking (por caracteres o párrafos) fragmentan sufijos aglutinantes y raíces semánticas clave, mermando la precisión de búsqueda vectorial.]

Brecha 3: Carencia de pipelines RAG offline autosuficientes para entornos rurales [Predominio de arquitecturas dependientes de APIs comerciales externas (OpenAI, Claude), incompatibles con zonas rurales de baja o nula conectividad en Cusco y Puno.]

Brecha 4: Falta de andamiaje pedagógico validado para EIB [Inexistencia de módulos de mediación pedagógica que guíen al estudiante en formato socrático bilingüe en lugar de suministrar transcripciones mecánicas.]

Brecha 5: Vacío de benchmarks estandarizados y métricas culturales [Ausencia de suites de evaluación automatizadas (tipo MMLU o RAGAS) calibradas con criterios léxicos y culturales de la cosmovisión andina.]

5.2. Oportunidades de Contribución para la Propuesta de Tesis

Oportunidad tecnológica: Arquitectura local híbrida SLM + RAG [Diseño de una arquitectura reproducible ejecutable en GPUs de consumo doméstico (4 GB VRAM) y CPUs estándar.]

Oportunidad lingüística: Curaduría y validación léxica Quechua Collao [Construcción de un banco curado de documentos educativos normalizados conforme a la ortografía oficial del MINEDU.]

Oportunidad metodológica: Marco holístico de evaluación (Técnica + Pedagógica) [Formulación de un protocolo de validación que integre métricas computacionales (latencia, chrF++) con rúbricas de juicio de expertos en EIB.]

6. Conclusiones y Hoja de Ruta de la Investigación

6.1. Respuestas a las Preguntas de Investigación

(a) **Respuesta a RQ1 (SLMs Locales):** [Los modelos de la familia Qwen2.5 (1.5B–3B) cuantizados a 4 bits (GGUF) demuestran el mejor balance entre consumo de VRAM ($\leq$3.5 GB) y coherencia semántica en inferencia local offline.]
(b) **Respuesta a RQ2 (RAG Morfológico):** [La fragmentación guiada por unidades textuales con solapamiento morfológico reduce drásticamente el error de recuperación frente a chunking por longitud fija en Quechua Collao.]
(c) **Respuesta a RQ3 (Adaptación Eficiente):** [La adaptación vía QLoRA restringida a capas de atención específicas minimiza la degradación de capacidades lógicas del modelo base al tiempo que incorpora vocabulario pedagógico regional.]
(d) **Respuesta a RQ4 (Evaluación Integral):** [La métrica chrF++ correlaciona de manera superior a BLEU con el juicio de docentes bilingües debido a la naturaleza aglutinante del quechua.]

6.2. Aportes Teóricos y Prácticos al Plan de Tesis

[Sustento teórico de la viabilidad de la propuesta y justificación técnica del stack tecnológico seleccionado.]

6.3. Amenazas a la Validez y Limitaciones

[Análisis de posibles sesgos en la búsqueda sistemática, dispersión de publicaciones no indizadas en lenguas originarias y limitaciones del hardware de experimentación local.]

6.4. Hoja de Ruta (Roadmap) para el Desarrollo del Proyecto

1. **Fase 1: Curaduría y Normalización de Corpus.** [Recopilación de materiales MINEDU y textos Quechua Collao validados.]
2. **Fase 2: Arquitectura RAG e Indexación Vectorial.** [Implementación de chunking morfológico y almacenamiento en base embebida.]

3. **Fase 3: Optimización e Inferencia de SLM.** [Cuantización GGUF del modelo Qwen2.5-3B y pruebas de latencia en GTX 1050 Ti.]
4. **Fase 4: Adaptación QLoRA y Alineación Pedagógica.** [Afinamiento de bajo rango para andamiaje educativo bilingüe.]
5. **Fase 5: Evaluación Empírica y Validación con Expertos.** [Ejecución del protocolo de pruebas chrF++, latencia y rúbrica EIB.]

6.5. Líneas Futuras de Investigación

[Proyecciones para el soporte multimodal (voz Quechua con Whisper-fine-tuned) y extensión a otras familias lingüísticas (Aymara, Asháninka).]

Agradecimientos [Agradecimiento institucional a la Universidad Nacional de San Antonio Abad del Cusco (UNSAAC), a la cátedra de Seminario de Investigación II bajo la dirección del Msc. Raúl Huillca Huallparimachi, y a los investigadores en PLN para lenguas originarias.]

Referencias

1. Kitchenham, B., Charters, S.: Guidelines for performing systematic literature reviews in software engineering. Tech. Rep. EBSE 2007-001, Keele University and Durham University Joint Report (2007)
2. Page, M.J., McKenzie, J.E., Bossuyt, P.M., Boutron, I., Hoffmann, T.C., Mulrow, C.D., Shamseer, L., Tetzlaff, J.M., Akl, E.A., Brennan, S.E., et al.: The prisma 2020 statement: an updated guideline for reporting systematic reviews. BMJ **372**, n71 (2021)